

AGM: 面向冻结 VLA 策略的闭环智能体的成就锚定记忆

Hongbo Gao^{1*} Zeyu Ni^{2*} Xin Wen¹ Siyu Xu³ Ruifeng Li^{1†}

¹Harbin Institute of Technology ²The University of Sydney ³StellarEdge AI

摘要

冻结的视觉-语言-动作（VLA）策略提供了广泛的操控技能，但执行开环动作块时无法跟踪任务进度，因此智能体无法可靠地决定是继续、重试还是终止。外部记忆是一种自然的补救措施，然而当尝试的动作被视为已完成的进度时，它可能有害，将局部执行错误转化为持续的任务状态错误。我们提出成就锚定记忆（AGM），这是一种面向冻结 VLA 策略的轻量级闭环框架，将任务表示为带有进度指针的子目标序列，并且仅当当前子目标通过物理证据验证后才推进该记忆。本体感觉交互线索决定何时验证，而连贯点跟踪和语言条件跨视角比较（源自冻结基础模型，通过一个仅含 243 万参数的验证头）决定实现了什么。AGM 因此将开环执行转化为执行、验证和进度的闭环，保持策略冻结且无需测试时大模型推理。在 RoboMME 计数基准上，AGM 在 PickXTimes 上达到 100.0%，在 BinFill 上达到 84.0%，平均超越最强记忆增强基线 7.1 分，并且该框架在物理机器人上产生了同样决定性的增益。因此，可靠的具身记忆更多地依赖于有纪律的状态更新，而非记忆容量。

引言

视觉-语言-动作（VLA）模型将视觉观察和语言指令直接映射为连续动作（Brohan 等人，2023；Kim 等人，2024；Team 等人，2024；Intelligence 等人，2025）。由于将此类模型适配到每个下游任务成本高昂，一种实用的替代方案是保持策略冻结，并通过语言条件子目标组合其技能（Ahn 等人，2022；Huang 等人，2022）。该策略暴露了一个根本性局限。任务进度是一个隐藏状态，冻结策略既无法表示，也无法从当前观察中恢复。在重复性和基于计数的操控中（Dai 等人，2026），任务阶段在感知上是混淆的。将物体放入容器后，仅凭当前图像无法揭示正在进行的是哪一次重复。即使每次抓取和放置都在冻结策略的能力范围内，可靠的完-

完成仍然需要一个持久的任务状态来决定何时继续、重试、回滚或终止。外部记忆似乎是一个直接的解决方案（Sridhar 等人，2025），然而我们发现，在相同的冻结策略和子目标接口下，一个在每次操作尝试后推进的进度记忆可能比完全不使用进度记忆表现更差。尝试的动作并不等于已实现的结果。抓取可能失败，物体可能在提升过程中滑落，释放可能无法建立所指示的物体-目标关系。一旦这样的尝试被写入记忆作为进度，一个暂时的失败就变成了持久的任务状态错误。因此，核心问题从存储什么转变为何时写入。一个带有进度指针的有序子目标序列通常是足够的记忆，前提是每次更新都由可观察的执行证据支持，而不是仅仅由尝试的发生支持。我们在成就基础记忆中实例化这一原则

记忆（成就基础记忆（AGM）），一个用于冻结视觉语言动作策略的轻量级闭环框架。夹爪负载状态机定位进展可能发生变化的时刻，视觉验证判断预期的物理转移是否发生（Du 等，2023；Liu、Bahety 和 Song，2023）。支撑重复操作的两类成就类型具有不同的可观测特征，自动抓取监控从最适合的冻结基础模型中分别获取这些特征。抓取成功是一个运动学问题，即物体是否与夹爪一致地上升，冻结的点跟踪器（Co-Tracker3（Karaev 等，2024））无需任何训练即可回答（Vecerik 等，2023）。放置成功是一个语义问题，即指令中的物体-目标关系是否成立，自动抓取监控通过在冻结的 SigLIP 嵌入（Zhai 等，2023）条件下，对比事件相对的前置和腕部观测来回答，并以子目标语言为条件。验证结果驱动一个可恢复性感知的指针转移。指针在成功时前进，在抓取失败后保持，在可恢复的放置失败后回退。视觉语言动作策略、点跟踪器和编码器均保持冻结。仅训练一个 2.43M 参数的验证头，部署时无需辅助的自回归视觉语言模型。在 RoboMME 计数基准（Dai 等，2026）上，自动抓取监控达到了最佳平均成功率（55.96%），超越了最强的记忆增强基线（Sridhar et al. 2025）by 7.1 个百分点，并几乎使冻结基础模型翻倍

*These 作者贡献相同。†通讯作者。

策略 (Intelligence 等, 2025)。在锚定于夹爪交互的子目标上, 它在 PickXTimes 上达到 100.00%, 在 BinFill 上达到 84.00%, 建立了新的最先进结果, 同时仅引入 231M 冻结的外部参数, 而非微调一个 4B 的视觉语言模型。在其他子目标上, AGM 在不降低冻结策略性能的前提下进行延迟处理, 受控比较证实增益源于经过验证的记忆写入, 而非记忆容量或模型规模。在物理机器人上, 策略和验证头针对真实平台重新训练, 而框架本身保持不变, AGM 在两个任务上分别取得 100.0% 和 82.0%, 表明基于成就的写入的益处并非仿真的工件。我们的贡献总结如下: • 我们识别出记忆增强的冻结 VLA 智能体的一种失败模式, 其中基于尝试的进度更新将瞬态操作失败转化为持久的任务状态错误, 并且可能比不使用进度记忆表现更差。

- 我们提出 AGM, 一个基于成就的记忆框架, 将紧凑进度指针的每次更新都建立在来自冻结基础模型的可观察执行证据之上, 支持前进、保持和恢复感知的回滚。
- 我们在 RoboMME Counting 的 PickXTimes 和 BinFill 上建立了新的最先进结果, 取得了最佳平均成功率, 同时仅训练一个 2.43M 参数的验证头, 并在物理机器人上验证了该框架。

相关工作

视觉-语言-动作模型与技能组合。大规模 VLA 模型将视觉观察和语言指令直接映射为低级动作 (Brohan 等, 2022, 2023; Team 等, 2024; Kim 等, 2024; Black 等, 2024; Intelligence 等, 2025), 越来越多地在大型跨具身语料库上进行训练 (O’Neill 等, 2024)。由于逐任务微调成本高昂, 一条互补的研究路线通过语言组合预训练技能, 包括基于可供性的规划 (Ahn 等, 2022)、具身多模态规划 (Driess 等, 2023)、策略-代码生成 (Liang 等, 2023) 以及反馈增强规划 (Huang 等, 2022)。这些系统选择下一个技能, 并假设其完成是可观察的或通过重新规划来处理。在重复操作中, 任务阶段在感知上存在混淆, 子目标完成情况无法从当前观察中恢复。AGM 保持冻结策略和子目标接口不变, 并提供缺失的任务进度状态。

面向长时程具身智能体的记忆机制。在部分可观测条件下维持任务状态是一个经典问题 (Kaelbling, Littman, and Cassandra 1998)。基于大语言模型的智能体通过记忆流 (Park et al. 2023)、情景反思 (Shinn et al. 2023) 以及不断增长的技能库 (Wang et al. 2023) 来解决该问题。在机器人学习领域, SAM2Act

为操作策略配备了空间记忆架构 (Fang et al. 2025), RoboMME 表明通用策略在缺乏外部记忆的情况下无法处理非马尔可夫操作任务 (Dai et al. 2026), 而 MemER 利用微调后的视觉语言模型从过往经验中检索与任务相关的关键帧 (Sridhar et al. 2025)。这些方法扩展了存储或检索的规模, 而 AGM 则关注何时进行写入是合理的。对于重复性操作, 一个紧凑的子目标指针足以作为任务状态, 未经验证的写入而非有限的容量才是主要的失败来源。

验证操作结果。执行结果已通过微调的视觉语言成功检测器 (Du et al. 2023)、基于多模态推理的失败解释 (Liu, Bahety, and Song 2023; Duan, Pumacay et al. 2024)、计划-执行不一致检测与运行时监控器 (Guo, Wang et al. 2023; Zhou et al. 2025) 以及注入规划循环的环境反馈 (Huang et al. 2022) 进行验证, 通常采用固定间隔查询大型模型或事后分析失败的方式。AGM 则仅在本体感觉的夹爪负载转变时触发验证, 并将决策建立在冻结的感知之上。点跟踪技术已从专用基准 (Doersch et al. 2022) 发展到稳健的通用跟踪器 (Doersch et al. 2023; Karaev et al. 2024), 并已作为模仿学习和策略学习的表征 (Vecerik et al. 2023; Wen et al. 2023), 在此被重新用作零训练的抓取成功运动学证据, 而冻结的视觉语言编码器 (Zhai et al. 2023) 提供语言条件下的放置证据; 由此产生的判定直接驱动任务状态的推进、保留或回滚。

Method

问题表述与概述 我们考虑一个冻结的、以子目标为条件的视觉-语言-动作策略

$$\pi_{\theta}(A_t | o_t, g_t), \quad (1)$$

其中 θ 在训练和评估过程中保持不变。观测 o_t 包含前视图和腕视图图像、夹爪开合宽度以及末端执行器位姿;

g_t is a 为语言子目标; A_t 表示动作块。图 1 总结了该框架。对于重复性操作, 任务指令被确定性地展开为有序序列

$$\mathcal{G} = \{(g_k, c_k)\}_{k=1}^T, \quad (2)$$

其中 g_k 提供给冻结的视觉语言动作模型和放置可

$$c_k \in \mathcal{C} = \{\text{grasp}, \text{逆放置不可}, \text{逆}, \text{other}\} \quad (3)$$

表示子目标类型。平面放置被视为可通过重新抓取恢复, 而容器放置被视为释放后不可恢复。类型标签决定了兼容的验证事件和恢复行为; 它们不是额外的策略输出。在机器人多模态环境计数中, 我们使用基准提供的分解




图 1：自适应目标记忆概述。顶部：指令被展开为带类型的子目标序列 $\mathcal{G}$ ，与进度指针一起构成任务记忆 $\mathcal{M}_t = (\mathcal{G}, p_t)$ 。冻结的视觉语言动作模型作用于 g_{p_t} ，夹爪负载状态机检测交互事件；只有与当前子目标类型兼容的事件才会触发验证，因为仅凭交互并不能证明目标达成。判定结果通过公式 (21) 更新指针；彩色箭头描述了该规则，而非单个子目标可达的三种结果。底部：抓取达成通过冻结跟踪器下连贯的向上点运动进行验证，放置达成通过冻结编码器下语言条件的释放前后跨视角度证据进行验证。雪花标记表示冻结模块；仅训练 243 万参数的验证头（火焰标记）。

并将其与仅使用指令的解析器进行交叉检查，该解析器既不访问环境状态也不访问任务真值。自适应目标记忆维护紧凑的任务记忆

$$\mathcal{M}_t = (\mathcal{G}, p_t), \quad p_t \in \{1, \dots, T\}, \quad (4)$$

其中 $\mathcal{G}$ 在一个回合内保持不变， p_t 是唯一在线更新的持久任务进度状态。冻结策略以索引子目标为条件：

$$A_t \sim \pi_\theta(\cdot \mid o_t, g_{p_t}). \quad (5)$$

指针保留了无法仅从当前观测推断的任务阶段信息，从而在不存储完整交互历史的情况下消除视觉相似重复的歧义。自适应目标记忆仅在兼容的交互事件后更新指针。设

$$\mathcal{E}_{\text{ver}} = \{t \mid \chi(e_t, c_{p_t}) = 1\} = \{\tau_1, \tau_2, \dots\}, \quad (6)$$

其中 e_t 为检测到的事件， χ 仅保留由 AGM 支持的事件-子目标对。事件 τ_n 发生后，AGM 收集一个事件相关的观测窗口，并在 $\bar{\tau}_n$ 处执行验证。对于抓取，该窗口覆盖随后的提升运动；对于放置，则包括

释放后的稳定期。由此产生的达成判定 $\hat{v}_n^{\text{cp}} \in \{0, 1\}$ 决定进度指针是前进、保持不变还是回退。在标称执行下，指针仅在获得此类判定时才发生变化；终端一致性检查和有界死锁保护机制将在后续章节中描述。因此，AGM 通过将每个任务状态更新建立在可观测的执行结果上，闭合了冻结 VLA 的回路。VLA 策略、点跟踪器和视觉-语言编码器保持冻结，仅训练一个轻量级验证头。

事件触发的达成验证 AGM 将交互发生与任务达成分离。本体感觉信号决定何时应检查结果，而视觉证据决定预期的物理转移是否已发生。

Interaction Event Localization Let w_t denote the gripper opening width. A hysteretic finite-state machine produces

$$(\xi_t, e_t) = F_{\text{fsm}}(\xi_{t-1}, w_t), \quad (7)$$

where ξ_t is the internal load state and

$$e_t \in \{\emptyset, G^+, R^+, R^0\}. \quad (8)$$

此处， G^+ 表示稳定的负载抓取， R^+ 表示从负载状态释放， R^0 表示从空载状态释放。式 (6) 中的兼容性函数仅对抓取子目标满足 $\chi(G^+, c) = 1$ ，仅对放置子目标满足 $\chi(R^+, c) = 1$ 。空载释放和不兼容的事件-子目标对被忽略。这些事件定位潜在的状态转移，但其本身不被视为成功的证据。

相干运动抓取验证 成功的抓取会使被操作物体在提升过程中随夹爪向上移动。当 $e_{\tau_n} = G^+$ 时，AGM 记录末端执行器位置 $\mathbf{x}_{\tau_n}^{ee}$ 并缓存随后的前视提升片段。记录的位置通过相机外参 E 和内参 K 投影到图像中：

$$\mathbf{x}_c = E \begin{bmatrix} \mathbf{x}_{\tau_n}^{ee} \\ 1 \end{bmatrix}, \quad \tilde{\mathbf{u}} = K \mathbf{x}_c, \quad \mathbf{u}_n = \begin{pmatrix} \tilde{u}_1, \tilde{u}_2 \\ \tilde{u}_3, \tilde{u}_3 \end{pmatrix}. \quad (9)$$

末端执行器位姿仅用于定位查询区域并确定何时已观测到足够的提升运动。设

$$\mathcal{P}_n^0 = \{\mathbf{u}_{n,i}^0\}_{i=1}^{N_q} \quad (10)$$

在 $\mathbf{u}_n$ 周围采样规则网格，并令 $\mathbf{I}_n^f = \{I_{n,\ell}^f\}_{\ell=1}^L$ 表示对应的 L 帧提升片段。冻结的点跟踪函数生成点轨迹和可见性分数：

$$(\mathbf{U}_n, \mathbf{V}_n) = \mathcal{F}_\phi(\mathbf{I}_n^f, \mathcal{P}_n^0), \quad \phi \text{ fixed}, \quad (11)$$

其中 $\mathbf{U}_{n,i,\ell} \in \mathbb{R}^2$ 是查询点 i 在第 $\ell \in \{1, \dots, L\}$ 帧的图像位置， $V_{n,i,\ell} \in [0, 1]$ 是其可见性分数。我们使用 CoTracker3 (Karaev 等人, 2024 年) 实例化 $\mathcal{F}_\phi$ 。有效轨迹索引为

$$\mathcal{I}_n^{\text{vis}} = \{i \mid V_{n,i,L} \geq \eta_{\text{vis}}\}, \quad (12)$$

其垂直位移为

$$d_{n,i} = U_{n,i,1}^{(y)} - U_{n,i,L}^{(y)}, \quad i \in \mathcal{I}_n^{\text{vis}}. \quad (13)$$

由于图像 y 轴向下， $d_{n,i} > 0$ 表示向上运动。查询区域可能同时包含物体和背景点。因此，AGM 保留有效轨迹中向上位移最大的 ρ 比例，并计算

$$r_n^G = \text{Median}(\text{Top}_\rho \{d_{n,i} \mid i \in \mathcal{I}_n^{\text{vis}}\}). \quad (14)$$

高响应选择抑制了静态背景轨迹，而中值聚合降低了对孤立跟踪误差的敏感性。因此，抓取完成由被操作物体的观测运动决定，而非夹爪的指令运动。

语言条件下的跨视角放置验证已加载的释放并不保证所需的物体-目标关系已建立。对于每个放置子目标，AGM 推导出归一化成就查询

$$q_k = \mathcal{Q}(g_k), \quad (15)$$

该查询描述所需关系，同时去除重复索引。当 $e_{\tau_n} = R^+$ 时，AGM 从前方和腕部相机提取释放前后的事件相对窗口。令 $\bar{I}_{v,n}^-$ 和 $\bar{I}_{v,n}^+$ 表示视角 $v \in \{f, w\}$ 的时间聚合事件前后观测。冻结的视觉-语言编码器生成

$$z_{v,n}^- = \text{Enc}_\omega^{\text{img}}(\bar{I}_{v,n}^-), \quad z_{v,n}^+ = \text{Enc}_\omega^{\text{img}}(\bar{I}_{v,n}^+), \quad (16)$$

and

$$z_{q,n} = \text{Enc}_\omega^{\text{text}}(q_{p_{\tau_n}}), \quad \omega \text{ fixed}. \quad (17)$$

事件表示结合了跨视角外观、事件引起的变化、本体感受上下文以及请求的物体-目标关系：

$$\mathbf{f}_n = [z_{f,n}^-, z_{f,n}^+, z_{f,n}^+ - z_{f,n}^-, z_{w,n}^-, z_{w,n}^+, z_n^{\text{prop}}; z_{q,n}], \quad (18)$$

$\mathbf{z}_n^{\text{prop}}$ 其中概括了事件周围的物体感知窗口。前视图差异捕捉主导状态变化，而腕部视图提供互补的近场证据。一个轻量级多层感知器 h_ψ 预测放置达成概率：

$$s_n^P = [\text{Softmax}(h_\psi(\mathbf{f}_n))]_{\text{achieved}}. \quad (19)$$

The verification head contains 2.43M trainable parameters, while the feature encoders remain frozen.

基于成就的记忆转移 抓取和放置分支产生不同形式的证据，因此分别进行阈值判定：

$$\hat{v}_n = \begin{cases} \mathbb{I}[r_n^G \geq \delta_G], & e_{\tau_n} = G^+, \\ \mathbb{I}[s_n^P \geq \kappa_{c_{p_{\tau_n}}}], & e_{\tau_n} = R^+, \end{cases} \quad (20)$$

其中 δ_G 是一致性提升阈值， κ_c 是放置类型特定的接受阈值。令 $p_n^- = p_{\tau_n}$ 和 p_n^+ 表示第 n 次记忆写入前后的进度指针。令 $\zeta_k \in \{0, 1\}$ 指示子目标 k 是否允许回滚，并令 $B(p)$ 返回其关联的恢复子目标。名义转移为

$$p_n^+ = \begin{cases} \min(p_n^- + 1, T), & \hat{v}_n = 1, \\ \mathcal{B}(p_n^-), & \hat{v}_n = 0 \wedge \zeta_{p_n^-} = 1, \\ p_n^-, & \text{otherwise}. \end{cases} \quad (21)$$

更新后的记忆为

$$\mathcal{M}_{\tau_n}^+ = (\mathcal{G}, p_n^+). \quad (22)$$

已验证的成就推进到下一个子目标。被拒绝的抓取保持当前状态，而失败的可恢复放置返回到其关联的抓取子目标，以便完整的抓取-放置操作可以重复执行。因此，记忆写入支持推进、保持和回滚，而非简单的尝试计数。

容器放置在释放后不可恢复。错误拒绝可能导致智能体插入额外物体并使计数失效；因此，AGM 对这些事件使用更宽松的接受阈值，并限制连续拒绝次数。可恢复的平面放置使用更严格的阈值，因为不成功的结果可以通过重新抓取来纠正。在最终终止动作之前，AGM 使用视觉占用测试独立重新检查最近的可恢复放置。重新检查失败会将指针返回到关联的抓取子目标。此终止前检查独立于学习的验证头。基于成就的更新仅应用于兼容性函数 χ 允许的子目标。其他子目标委托给冻结的基础策略。仅当证据仍然不可用或重复拒绝否则会使控制器死锁时，才使用有界超时和重试规则。

部署对齐的验证器训练 验证头在官方 RoboMME 训练划分上收集的 788 个执行事件上离线训练，种子与评估不相交。事件来自两个互补的控制器：AGM 本身，覆盖部署分布；以及一个基于尝试的控制器，它在没有验证的情况下推进进度，提供规划器生成的演示中稀缺的漏抓、错放物体和错误进度。环境谓词仅用于构建标签，在评估期间不可用：物体提升用于抓取，目标区域包含用于平面放置，容器计数增加用于容器放置。抓取和释放事件共享式 (18) 的特征图，抓取窗口括住提升运动；抓取样本仅提供辅助监督，因为部署完全通过点跟踪测试决定抓取完成。对于不可逆放置，释放后窗口在部署验证时间精确采样，因为即使 20 帧的不匹配也会显著降低下游性能，详见补充材料。该头使用类别加权交叉熵进行优化以补偿标签不平衡；仅更新其 2.43M 参数，策略、编码器和点跟踪器保持冻结。

实验

我们的实验解决四个问题：基于成就的记忆是否比冻结执行和现有记忆增强方法提高任务成功率 (Q1)；收益是否源于任务进度跟踪而非低级技能 (Q2)；视觉抓取证据和可逆性感知阈值各自贡献多少 (Q3)；以及该框架是否在物理机器人上提供相同的收益 (Q4)。

实验设置 对于仿真，我们在 RoboMME 计数套件 (Dai 等人, 2026 年) 上评估 (PickXTimes、BinFill、SwingXTimes、




图 2：仿真中的错误纠正。 指令要求将三个蓝色和两个绿色立方体放入箱子。第二次抓取失败；验证拒绝该尝试，指针被保留，策略成功重试。基于尝试的记忆会将失败记录为进度，并少放一个立方体。

以及停止立方体 (StopCube)，在官方 50 集测试分割上报告成功率，种子与训练集不相交；只有当机器人在 1300 步预算内，在精确执行指定次数后按下停止按钮，该集才算成功。基线包括带有过去动作上下文的冻结 $\pi_{0.5}$ 、 $\pi_{0.5}$ 、SAM2Act+ (Fang 等人, 2025 年)、使用 LoRA 微调的 Qwen3-VL-4B 或提示的 Gemini-2.5-Pro 的 SimpleSG，以及 MemER (Sridhar 等人, 2025 年)，均在官方评估下进行。我们的流程复现了发布的 $\pi_{0.5}$ (在 PickXTimes/BinFill 上的智能 et al. 2025) at 42.0/30.0，与官方 42.89/30.00 紧密匹配，AGM 条目为两次独立运行的平均值。AGM 在冻结的 3.35B 骨干网络上添加了冻结的 CoTracker3 跟踪器 (25.4M) (Karaev 等人, 2024 年)、冻结的 SigLIP-base 编码器 (203.2M) (Zhai 等人, 2023 年) 以及 2.43M 验证头，这是其唯一训练的部分；所有阈值、夹爪负载状态机和转换规则在任务和集间共享。对于跨骨干网络研究，我们在官方演示上使用 LoRA 训练了一个子目标条件的 π_0 (Black 等人, 2024 年)，因为该套件没有官方检查点。更多细节见补充材料。此外，我们在物理硬件上部署了 AGM 用于 PickXTimes 和 BinFill，在相同的成功标准下，对每个计数 $N=1, \dots, 5$ 运行 10 次试验 (每个任务 50 次)。按照基准配置，裸策略在仅以任务指令为条件的真实演示上重新训练，其 AGM 对应部分在匹配的数据预算下以子目标条件进行训练，并在两个骨干网络上共享的单一验证头在真实执行事件上重新训练。

主要结果 (问题 1)

表 1 总结了任务成功率和参数化情况。AGM 达到了最佳的四任务平均值 (55.96%)，比最强基线 MemER (48.83%) 高出 7.1 个百分点，几乎是冻结 $\pi_{0.5}$ (28.78%) 的两倍。在锚定于夹爪交互的两个任务上，感知混叠的破坏性最大，增益是决定性的：在 Pick- 上 100.00%

表 1: RoboMME 计数测试分割上的成功率 (%) (每个任务 50 集) ; AGM 结果为两次独立运行的平均值。外部: 在冻结的 3.35B $\pi_{0.5}$ 骨干网络之外添加的参数; 可训练: 为每种方法更新的参数。†: 未锚定于夹爪交互的子目标, 其中 AGM 遵循冻结的基础策略。‡: 独立训练的策略, 不基于 $\pi_{0.5}$ 构建。API: 未公开大小的专有模型; n/r : 未报告。每列最佳以粗体显示。

Method	Success Rate (%)					Params.	
	PickXTimes	BinFill	SwingXTimes	StopCube	Avg.	External	Trainable
Frozen $\pi_{0.5}$	42.89	30.00	35.56	6.67	28.78	0	0
$\pi_{0.5}$ w/ past actions	58.33	26.67	26.67	4.67	29.09	0	$\approx 3.35B$
SAM2Act+‡	76.00	40.00	25.33	0.00	35.33	–	n/r
SimpleSG + Qwen3-VL-4B	95.30	77.60	5.10	0.40	44.60	4B	LoRA (n/r)
SimpleSG + Gemini-2.5-Pro	63.00	46.00	45.00	2.00	39.00	API	0
MemER	79.33	56.67	59.33	0.00	48.83	4B	LoRA (n/r)
AGM (Ours)	100.00	84.00	35.56†	6.67†	55.96	231M (frozen)	2.43M

表 2: 按指令重复次数划分的成功率 (%) N . 模拟行使用官方测试集; $\pi_{0.5}$ 是我们对官方检查点的复现, π_0 是子目标条件化的低秩适配 (LoRA), 标记为 †, 因为完整任务指令对其而言是分布外的。真实行每个次数进行 10 次试验, 策略和验证头在平台下重新训练, 框架保持不变。每列最佳值以粗体显示。

	Method	PickXTimes					BinFill				
		$N=1$	$N=2$	$N=3$	$N=4$	$N=5$	$N=1$	$N=2$	$N=3$	$N=4$	$N=5$
Sim	$\pi_0^\dagger$	12.5	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	π_0 +AGM	50.0	40.0	33.3	50.0	50.0	30.0	10.0	0.0	0.0	0.0
	$\pi_{0.5}$	100.0	30.0	16.7	0.0	0.0	90.0	20.0	18.8	12.5	0.0
	$\pi_{0.5}$ +AGM	100.0	100.0	100.0	100.0	100.0	100.0	95.0	84.4	62.5	66.7
Real	π_0	20.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	π_0 +AGM	60.0	50.0	30.0	60.0	50.0	30.0	20.0	0.0	0.0	0.0
	$\pi_{0.5}$	100.0	20.0	10.0	0.0	0.0	100.0	10.0	0.0	0.0	0.0
	$\pi_{0.5}$ +AGM	100.0	100.0	100.0	100.0	100.0	100.0	100.0	80.0	70.0	60.0

XTimes 和 84.00% 在 BinFill 上均取得新的最先进结果。过去动作条件化 (29.09%) 几乎无法弥补差距, 证实缺失的信息是任务进度而非短期上下文。AGM 也显著更经济: SimpleSG 和 MemER 附加了一个经低秩适配微调的 4B 外部视觉语言模型 (VLM), 而 AGM 增加 231M 参数, 全部冻结, 仅训练 2.43M 的头部。在 SwingXTimes 和 StopCube 上, 其子目标不锚定于夹爪交互, AGM 按构造遵循冻结策略并与之完全一致。

重复深度的影响 (Q2) 表 2 按指令次数分解成功率 N 。冻结的 $\pi_{0.5}$ 在 $N=1$ (100.0/90.0 (PickXTimes/BinFill)) 上近乎完美, 但在两个任务上到 $N=5$: 时崩溃至 0.0; 策略具备所需技能, 仅缺少决定继续或停止的任务状态, 因此计数误差随 N 累积。使用 AGM 后, PickXTimes 在每个 N 上保持 100.0%, 完全消除进度漂移, 而 BinFill 逐渐衰减至 66.7%, 剩余失败集中在后期物理上更困难的重复中, 而非进度跟踪。子目标条件化的 π_0 单独几乎无法工作, 但相同配置 (未重新调整阈值或规则) 将其提升至 44.0%/8.0%:

表 3: 抓取验证模式与可逆性感知阈值的消融 (成功率%, 官方测试集, 每格 $n=50$, 与表 1 相同的冻结 $\pi_{0.5}$ 和验证头)。第 1 行为完整方法 (BinFill: 两次运行的平均值)。仅本体感觉将点跟踪抓取检查替换为夹爪负载和末端执行器提升测试; 扁平化移除可逆性相关的阈值切换。

Grasp verification	Thresholds	PickXTimes	BinFill
CoTracker (full)	reversibility-aware	100.0	84.0
Proprioception only	reversibility-aware	98.0	78.0
CoTracker	flattened	98.0	74.0

成就基础的书写是接口的属性, 而非特定策略的属性。图 2 展示了完整回合中的机制: 失败的抓取被验证拒绝, 指针保留, 回合恢复且无进度错误。

Ablations (Q3)

表 3 隔离了两个验证设计选择, 其余部分固定。将点跟踪测试替换为




图 3：真实机器人执行过程。用三个红色方块填满箱子，将蓝色方块三次放置在目标上，以及在人类于任务中途补充方块的情况下用三个绿色方块填满箱子。叠加显示每个时刻发出的子目标，每个回合在恰好达到指定次数后终止。

仅本体感知检查（稳定的夹爪负载加上末端执行器提升）在 98.0% 处保持了 PickXTimes，并在 BinFill 上达到 78.0%：验证写入本身带来了大部分收益，即使这种无视觉变体也超越了最强的外部 VLM 基线，而连贯运动测试通过确认物体本身随夹爪移动，增加了一致的剩余优势。将可逆性感知阈值展平对 PickXTimes 影响甚微（98.0%），其泄漏的失败被回滚吸收，但将 BinFill 从 84.0% 降至 74.0%：严格接受错误地拒绝了正确的不可逆放置，且物体已在容器中时，指针在已完成的子目标上停滞，直到预算耗尽。因此，情况划分的价值集中在不可逆一侧。

真实机器人验证（Q4）

表 2 的下半部分报告了物理部署。即使使用真实演示重新训练，裸策略仍表现出推动本方法的相同进度跟踪失败： $\pi_{0.5}$ 在两个任务上解决了 $N=1$ ，在 $N=2$ 处降至 20.0% 和 10.0%，并在 $N=4$ 时在两个任务上达到零，尽管它能胜任地执行单个抓取和放置。因此，重新训练提升了技能，但无法提供缺失的任务状态。为平台配备 AGM 恢复了该状态：PickXTimes 在每个重复次数下达到 100.0%，BinFill 在 $N=2$ 之前保持 100.0%，随后在 $N=5$ 处衰减至 60.0%。较弱的 π_0 骨干单独几乎无法工作，但相同的 AGM 配置，

在两个骨干之间共享验证头，显著提升了它，因此收益再次来自接口而非骨干。BinFill 在大 N 时的剩余差距是物理性的而非表征性的：失败集中在后期重复中，此时容器越来越满，放置本身变得更困难，而进度指针在我们检查的试验中始终与已执行的成就保持一致。图 3 展示了两个任务的完整执行过程，包括一个回合，其中人类在执行过程中在桌上补充方块，而验证计数仍然保持正确。

结论

本文提出了 AGM，一个轻量级框架，通过将紧凑任务记忆的每次更新都建立在可观测的执行证据之上，从而闭合冻结 VLA 策略的回路：夹爪事件决定何时验证，冻结的基础模型提供运动学和语义证据以表明达成了什么，而判定结果则推进、保留或回退进度指针。仅训练一个 243 万参数的头，AGM 在 PickXTimes 和 BinFill 上取得了新的最先进结果，并拥有最佳的四任务平均成绩，无需重新调参即可跨骨干网络迁移，且在框架不变的情况下于实体机器人上实现了同样决定性的提升。其验证词汇仍锚定于夹爪交互；将其扩展到非抓取事件之外并扩大实体评估是后续步骤。更广泛地，对于长程自主性，决定性问题的关键在于智能体拥有多少记忆，而在于什么证据使其有权写入记忆。

参考文献

- Ahn, M.; Brohan, A.; Brown, N.; Chebotar, Y.; Cortes, O.; David, B.; Finn, C.; Fu, C.; Gopalakrishnan, K.; Hausman, K.; et al. 2022. Do as i can, not as i say: Grounding language in robotic affordances. *arXiv preprint arXiv:2204.01691*.
- Black, K.; Brown, N.; Driess, D.; Esmail, A.; Equi, M.; Finn, C.; et al. 2024. π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*.
- Brohan, A.; Brown, N.; Carbajal, J.; Chebotar, Y.; Chen, X.; Choromanski, K.; Ding, T.; Driess, D.; Dubey, A.; Finn, C.; et al. 2023. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*.
- Brohan, A.; Brown, N.; Carbajal, J.; Chebotar, Y.; Dabis, J.; Finn, C.; Gopalakrishnan, K.; Hausman, K.; Herzog, A.; Hsu, J.; et al. 2022. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*.
- Dai, Y.; Fu, H.; Lee, J.; Liu, Y.; Zhang, H.; Yang, J.; Finn, C.; Fazeli, N.; and Chai, J. 2026. Robomme: Benchmarking and understanding memory for robotic generalist policies. *arXiv preprint arXiv:2603.04639*.
- Doersch, C.; Gupta, A.; Markeeva, L.; Recasens, A.; Smaira, L.; Aytar, Y.; Carreira, J.; Zisserman, A.; and Yang, Y. 2022. Tap-vid: A benchmark for tracking any point in a video. *Advances in Neural Information Processing Systems*, 35.
- Doersch, C.; Yang, Y.; Vecerik, M.; Gokay, D.; Gupta, A.; Aytar, Y.; Carreira, J.; and Zisserman, A. 2023. Tapiir: Tracking any point with per-frame initialization and temporal refinement. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*.
- Driess, D.; Xia, F.; Sajjadi, M. S.; Lynch, C.; Chowdhery, A.; et al. 2023. Palm-e: An embodied multimodal language model. *arXiv preprint arXiv:2303.03378*.
- Du, Y.; Konyushkova, K.; Denil, M.; Raju, A.; Landon, J.; Hill, F.; de Freitas, N.; and Cabi, S. 2023. Vision-language models as success detectors. *arXiv preprint arXiv:2303.07280*.
- Duan, J.; Pumacay, W.; et al. 2024. Aha: A vision-language-model for detecting and reasoning over failures in robotic manipulation. *arXiv preprint arXiv:2410.00371*.
- Fang, H.; Grotz, M.; Pumacay, W.; et al. 2025. Sam2act: Integrating visual foundation model with a memory architecture for robotic manipulation. *arXiv preprint arXiv:2501.18564*.
- Guo, Y.; Wang, Y.-J.; et al. 2023. Doremi: Grounding language model by detecting and recovering from plan-execution misalignment. *arXiv preprint arXiv:2307.00329*.
- Huang, W.; Xia, F.; Xiao, T.; Chan, H.; Liang, J.; Florence, P.; Zeng, A.; Thompson, J.; Mordatch, I.; Chebotar, Y.; et al. 2022. Inner monologue: Embodied reasoning through planning with language models. *arXiv preprint arXiv:2207.05608*.
- Intelligence, P.; Black, K.; Brown, N.; Darpinian, J.; Dhabalia, K.; Driess, D.; Esmail, A.; Equi, M.; Finn, C.; Fusai, N.; et al. 2025. $\pi_{0.5}$: A vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*.
- Kaelbling, L. P.; Littman, M. L.; and Cassandra, A. R. 1998. Planning and acting in partially observable stochastic domains. *Artificial Intelligence*, 101(1-2): 99–134.
- Karaev, N.; Makarov, I.; Wang, J.; Neverova, N.; Vedaldi, A.; and Rupprecht, C. 2024. Cotracker3: Simpler and better point tracking by pseudo-labelling real videos. *arXiv preprint arXiv:2410.11831*.
- Kim, M. J.; Pertsch, K.; Karamcheti, S.; Xiao, T.; Balakrishna, A.; et al. 2024. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*.
- Liang, J.; Huang, W.; Xia, F.; Xu, P.; Hausman, K.; Ichter, B.; Florence, P.; and Zeng, A. 2023. Code as policies: Language model programs for embodied control. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, 9493–9500. IEEE.
- Liu, Z.; Bahety, A.; and Song, S. 2023. Reflect: Summarizing robot experiences for failure explanation and correction. *arXiv preprint arXiv:2306.15724*.
- O’Neill, A.; Rehman, A.; Maddukuri, A.; Gupta, A.; Padalkar, A.; Lee, A.; Pooley, A.; Gupta, A.; Mandlekar, A.; Jain, A.; et al. 2024. Open x-embodiment: Robotic learning datasets and rt-x models: Open x-embodiment collaboration 0. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, 6892–6903. IEEE.
- Park, J. S.; O’Brien, J.; Cai, C. J.; Morris, M. R.; Liang, P.; and Bernstein, M. S. 2023. Generative agents: Interactive simulacra of human behavior. In *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*, 1–22.
- Shinn, N.; Cassano, F.; Gopinath, A.; Narasimhan, K.; and Yao, S. 2023. Reflexion: Language agents with verbal reinforcement learning. *Advances in Neural Information Processing Systems*, 36.
- Sridhar, A.; Pan, J.; Sharma, S.; and Finn, C. 2025. Memer: Scaling up memory for robot control via experience retrieval. *arXiv preprint arXiv:2510.20328*.
- Team, O. M.; Ghosh, D.; Walke, H.; Pertsch, K.; Black, K.; Mees, O.; et al. 2024. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*.
- Vecerik, M.; Doersch, C.; Yang, Y.; Davchev, T.; Aytar, Y.; Zhou, G.; Hadsell, R.; Agapito, L.; and Scholz, J. 2023. Robotap: Tracking arbitrary points for few-shot visual imitation. *arXiv preprint arXiv:2308.15975*.
- Wang, G.; Xie, Y.; Jiang, Y.; Mandlekar, A.; Xiao, C.; Zhu, Y.; Fan, L.; and Anandkumar, A. 2023. Voyager: An open-ended embodied agent with large language models. *arXiv preprint arXiv:2305.16291*.
- Wen, C.; Lin, X.; So, J.; Chen, K.; Dou, Q.; Gao, Y.; and Abbeel, P. 2023. Any-point trajectory modeling for policy learning. *arXiv preprint arXiv:2401.00025*.
- Zhai, X.; Mustafa, B.; Kolesnikov, A.; and Beyer, L. 2023. Sigmoid loss for language image pre-training. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 11975–11986.

Zhou, E.; Su, Q.; Chi, C.; Zhang, Z.; Wang, Z.; Huang, T.; Sheng, L.; and Wang, H. 2025. Code-as-monitor: Constraint-aware visual programming for reactive and proactive robotic failure detection. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, 6919–6929.

A. 实现细节

除非另有说明，以下数值均为表 1 和表 3 中每个数字背后的仿真配置。实体机器人的数值如有不同，见 D 节。没有针对每个任务或重复次数调整阈值；一套配置适用于全部四个任务和每个回合。

A.1 子目标序列

指令展开为 $T = 2N+1$ 个子目标，抓取和放置交替进行 N 次重复，并以终止动作结束。重复索引由抓取子目标携带，而放置子目标在表述时不带该索引。在 BinFill 中，抓取子目标表述为“拿起第{序数}个{颜色}方块”，每次放置表述为“将其放入箱中”；在 PickXTimes 中，抓取子目标表述为“第{序数}次拿起{颜色}方块”，每次放置表述为“将{颜色}方块放到目标上”。每次指针转换时生效的子目标可见于图 4–6 的叠加层中。放置验证是唯一以语言为条件的分支。式 (15) 的归一化查询将仅在重复索引上不同的子目标映射到同一查询，因此放置必须证明的是物体–目标关系，而非其在序列中的位置。进行到哪一次重复由指针携带。

A.2 夹爪负载状态机

式 (7) 的滞回状态机消耗夹爪开口宽度 w_t 并发出 $e_t \in \{\emptyset, G^+, R^+, R^0\}$ 。A，在归一化宽度单位下，闭合在低于 0.030 时进入，在高于 0.035 时释放，且窄于 0.008 的闭合计为空。进入与退出阈值之间的间隙抑制了手指柔顺接触时的事件抖动，且负载状态必须连续保持五帧才能被确认。只有确认的转换才发出事件。其中，只有式 (6) 的兼容性函数 χ 所允许的配对才到达验证器： G^+ 与抓取子目标， R^+ 与任一放置类型。空释放和不匹配的配对被丢弃，不消耗验证。

A.3 相干运动抓取验证

式 (9) 将抓取瞬间的末端执行器位置投影到前视图，并在该投影周围以半宽 22 像素播种规则 6×6 查询网格 ($N_q = 36$)，覆盖 45 像素见方区域。提升片段没有固定时长。帧从抓取事件开始累积，直到末端执行器上升 0.03 m，此时片段关闭并传递给跟踪器，因此式 (11) 中的长度 L 跟随实际执行的运动而非固定时长。表 4 给出了其经验分布。当轨迹的最终可见性超过 $\eta_{\text{vis}} = 0.5$ （式 (12)）时，该轨迹存活。在存活的轨迹中，保留向上位移最大的 $\rho = 1/3$ 比例，并设置至少六个点的下限，以便在少数轨迹存活时聚合仍有定义。它们的中位数是式 (14) 的响应 r_n^G ，且抓取在 $r_n^G \geq \delta_G = 4 \text{ px}$ 处被接受。

Task	Min	Median	Mean	Max
PickXTimes ($n = 126$)	7	12	13.2	22
BinFill ($n = 140$)	5	14	15.3	30

表 4：所报告运行中提升片段长度 L （以帧计）。片段在观察到 0.03 米的提升后关闭，因此 L 反映实际执行的提升而非固定时长。

Layer	Simulation	Real robot
Linear($\cdot, 512$)	2,369,024	2,368,000
Linear(512, 128)	65,664	65,664
Linear(128, 2)	258	258
总计	2,434,946	2,433,922

表 5：验证头的参数数量，验证头是 AGM 中唯一经过训练的部分。输入宽度分别为 4626 和 4624。冻结的 SigLIP 编码器 (203.2M) 和 Co-Tracker3 跟踪器 (25.4M) 不贡献可训练参数。

A.4 语言条件放置验证

事件前后窗口从每个相机聚合 $K = 4$ 帧。释放后窗口在可恢复平面放置的稳定延迟 30 帧和不可逆容器放置的 40 帧之后打开。这些是验证器训练事件采样的偏移量（第 B.1 节），因此视觉证据在训练和部署时取自相同的释放后时刻；第 B.4 节报告了不一致时的情况。式 (18) 的特征图拼接了五个 768 维视觉嵌入、一个 768 维文本嵌入以及宽度 $2d + 2$ 的本体感受摘要，其中 d 是原始本体感受维度，两个额外条目是窗口内夹爪列的极值。在仿真中 $d = 8$ 输入宽度为 4626。

表 5 分解了由此产生的参数数量。

A.5 转换与安全防护

接受阈值。放置接受条件为 $\kappa_c = 0.5$ （可恢复平面放置）和 $\kappa_c = 0.05$ （不可逆容器放置）。可恢复侧的误拒绝代价是重新抓取；不可逆侧则会插入额外物体并使计数失效。

回滚。被拒绝的可恢复放置将指针返回到同一重复的抓取子目标，使抓取和放置作为一个整体重复执行。被拒绝的抓取保持指针不变。不可逆放置不允许回滚，因此其接受阈值是宽松的而非严格的。

死锁界限。连续拒绝次数在可恢复放置中上限为两次，在不可逆放置和抓取中上限为三次。达到上限后，无论判定结果如何，指针都会前进，因此持续拒绝的验证器无法使回合停滞。若抓取负载持续存在且 80 个控制步内没有合格提升，则通过卡住超时将其从待定状态释放。

Symbol	Quantity	Value
<i>Event localization</i>		
—	Closure entry width	0.030
—	Closure exit width	0.035
—	Empty-closure width	0.008
—	Hold-confirm	5 frames
<i>Grasp verification</i>		
N_q	Query grid	6×6
—	Query half-width	22 px
η_{vis}	Visibility threshold	0.5
ρ	Retained fraction	1/3 (min. 6 pts)
δ_G	Coherent-lift threshold	4 px
—	Lift closing the clip	0.03 m
—	Stuck timeout	80 steps
<i>Placement verification</i>		
K	Frames per window	4
—	Settling, recoverable	30 frames
—	Settling, irreversible	40 frames
κ_c	Acceptance, recoverable	0.5
κ_c	Acceptance, irreversible	0.05
—	Feature width	4626
<i>Transitions</i>		
—	Rejection bound, recoverable	2
—	Rejection bound, irreversible	3
—	Rejection bound, grasp	3
—	Occupancy overlap	12 px

表 6: 完整的仿真超参数集, 在所有四个任务和所有回合中共享。

预终止检查。在终止子目标之前, 且仅当前一个子目标是可恢复放置时, AGM 通过不涉及学习头的视觉占用测试重新验证该放置。该测试将操作对象的色调掩码与目标区域的膨胀掩码相交, 并在重叠达到十二个像素时接受。检查失败则将指针返回到该重复的抓取子目标。

A.6 超参数

表 6 汇总了上述引入的所有常量。该集合规模较小, 一个配置即可服务于所有四个任务和每种重复次数; 没有按任务、按次数或按回合选择任何内容。只有一对参数是刻意不对称的, 即两个接受阈值 κ_c , 它们根据所判定的放置是否可撤销而相差一个数量级。主论文的表 3 恰好对该对参数进行了消融。

B. 验证器训练与分析

每次写入内存都依赖于验证决策, 因此做出这些决策的头部值得单独说明: 其训练事件从何而来、如何拟合、以及它能和不能区分什么。

B.1 事件数据集

验证头在官方 RoboMME 训练划分上收集的 788 个执行事件上进行训练。表 7 给出了

Type	Total	Achieved	Failed
grasp	384	282	102
place-rev	278	221	57
place-irrev	126	87	39
Total	788	590	198

表 7: 按成就类型划分的 788 个训练事件。失败占语料库的 25.1%。

Controller	Type	Ach.	Fail
AGM (PickXTimes)	grasp	137	27
	place-rev	165	0
Attempt-based (PickX)	grasp	40	72
	place-rev	56	57
AGM (BinFill)	grasp	105	3
	place-irrev	87	39

表 8: 按采集控制器划分的相同事件, 分别来自 61、40 和 40 个回合。

按成就类型划分的构成, 表 8 按采集控制器划分。表 8 解释了为什么需要两个控制器。在 AGM 下, PickXTimes 上的平面放置产生了 165 次成功且完全没有失败: 一个验证自身进展的控制器很少在其迹中留下失败, 因此仅在其数据上训练将呈现给头部一个几乎纯正的语料库。基于尝试的控制器在没有验证的情况下推进, 贡献了 72 次失败的抓取和 57 次失败的放置, 并提供了头部学习的大部分负面证据。

种子不相交性。采集利用基准训练划分: 100 个 PickXTimes 回合, 种子在 [1000, 10900] 中, 以及 100 个 BinFill 回合, 种子在 [4000, 13902] 中。所有报告的评估利用测试划分, 每个任务 50 个回合, 种子在 [510000, 514900] 和 [540000, 544900] 中。我们通程序验证了两个任务的种子集不相交, 因此没有评估回合对验证器训练有贡献。

标签谓词。环境谓词构建离线标签, 且在评估时不可用。当物体在主动夹爪-物体接触谓词下升高超过 0.05 米时, 抓取被标记为已实现; 当物体位于目标中心 0.05 米范围内且已离开夹爪时, 标记为可恢复放置; 当容器占用计数增加时, 标记为不可逆放置。释放后窗口在部署验证时刻采样, 容器放置为 40 帧, 其余情况为 30 帧。

B.2 训练配置

头部为线性层 (4626, 512) - 修正线性单元 - 随机失活 (0.3) - 线性层 (512, 128) - 修正线性单元 - 线性层 (128, 2), 使用 AdamW 优化器, 学习率 10^{-3} , 权重衰减 10^{-4} , 进行 300 次全批量梯度步骤。类别加权交叉熵补偿标签不平衡, 权重设为逆

Subset	n	Acc.	failed class		
			P	R	F1
All	138	91.3	87.5	70.0	77.8
grasp	69	92.8	100.0	68.8	81.5
place-rev	41	100.0	100.0	100.0	100.0
place-irrev	28	75.0	see text		

表 9: 测量模型在保留集上的 argmax 性能, 以百分比表示。抓取事件被纳入是因为它们提供辅助监督, 尽管部署时抓取由点跟踪而非该头部决定。

类别频率并归一化至类别数之和。未应用早停。抓取和放置事件共享式 (18) 的特征图, 并在一个头部中联合训练。部署时抓取分支从不查询该头部, 因为抓取实现由点跟踪决定, 因此抓取事件仅作为共享表示的辅助监督。

测量模型与部署模型。必须区分两种模型。对于测量, 事件在固定的回合键排列下按回合级别划分, 五分之一留出, 得到 650 个训练事件和 138 个保留事件; 在 650 个事件上拟合的头部在 138 个事件上评分。对于部署, 随后在相同设置下对所有 788 个事件拟合头部, 该重新拟合的头部产生论文中所有 AGM 结果。所有 788 个事件均来自训练划分, 评估使用不相交的测试划分种子, 因此重新拟合不会污染报告的任务成功率。这意味着下面的保留数据描述的是训练过程, 而非特定部署权重。

B.3 保留验证性能

表 9 报告了在固定种子下, 按成就类型划分的 138 个留出事件的测量模型。指标针对失败类别给出, 因为遗漏的失败会将错误进展写入记忆。两种放置类型表现截然不同, 这一差异正是第 A.5 节阈值分割所响应的。在可恢复的平面放置上, 头部是精确的。所有 41 个留出事件在部署阈值 0.5 下均被正确分类, 包括失败事件。这是拒绝被严格执行的分支, 在该分支上, 拒绝会将指针返回到前一个抓取。在不可逆的容器放置上, 头部并非可靠的判别器。留出分割包含 28 个此类事件, 其中 4 个为失败, 在 argmax 下四个失败均未被捕获。四个负例太少, 无法可靠地估计判别能力, 但方向是明确的, 且与该分支的部署方式一致: 在 $\kappa_c = 0.05$ 处的接受并不要求头部区分成功与失败, 仅要求在确认为负时拒绝接受。在报告的 BinFill 运行中, 这种情况发生了五次, 分数介于 0.000 和 0.044 之间。

该设计在此并不依赖于判别能力, 主论文的表 3 衡量了假设它应该如此的成本:

将分割扁平化, 使容器放置被严格判断, 会使 BinFill 从 84.0% 降至 74.0%, 因为严格接受会拒绝正确的放置, 并使指针停滞在已完成的子目标上。验证在可恢复侧获得了其准确率; 在不可逆侧, 其作用是避免破坏已经正确的计数。

B.4 释放后窗口的对齐

释放后窗口在部署验证的确切时间采样。早期配置中, 收集偏移比部署偏移多 20 帧, 在 BinFill 上达到 66.0%, 而匹配偏移下的两次运行分别为 86.0% 和 82.0%。两种配置在验证器的训练语料上也不同, 后者更大且部分来自更长的窗口, 因此我们将这一差距呈现为促使对齐偏移的观察结果, 而非仅对偏移的孤立测量。机制仍然是具体的: 容器放置拍摄过晚, 显示的是已稳定的场景, 其外观不再能区分成功放置与进入后反弹的物体, 头部失去了其被训练读取的证据。

C. 仿真评估

以下是表 1 和表 3 背后的协议、一个隔离已验证写入贡献的受控比较, 以及在基准测试中最深重复次数下的完整展开。

C.1 协议

评估使用四个 RoboMME 计数任务各自的官方 50 回合测试分割, 种子范围见 B.1 节。一个回合只有在机器人在 1,300 步预算内按精确指令计数后按下停止按钮才算成功; 计数正确但未终止, 以及计数错误后终止, 均记为失败。AGM 条目取两次独立运行的平均值, 两次运行仅随机种子不同, 阈值、转移规则和验证器权重均相同。验证在进程外运行。点跟踪器和验证头作为独立服务托管, 并通过本地套接字查询, 因此评估进程本身既不加载跟踪器也不加载视觉-语言编码器。

替换仅指令计划。子目标序列默认从基准分解中读取。为检验 AGM 不依赖特权结构, 我们还使用仅读取指令字符串、不接触环境状态或任务真值的解析器生成的计划运行完整测试分割。在 PickXTimes 上得到 98.0%, 在 BinFill 上得到 82.0%, 而使用基准分解时分别为 100.0% 和 86.0%。解析器生成规范子目标措辞, 与基准措辞逐字不同, 但保留序列的类型、对象和长度, 因此该比较界定了 AGM 性能中有多少可归因于所提供的分解, 而非记忆纪律。

Subgoal source	PickXTimes	BinFill
AGM (verified writes)	100.0	84.0
Attempt-based (unverified writes)	32.0	82.0
Whole instruction (no pointer) [†]	36.0	40.0

表 10: 在官方 50 回合测试分割上, 按决定当前子目标的方式划分的成功率 (%)。AGM 和基于尝试的控制器共享一个子目标条件检查点, 区别仅在于指针是否等待证据。

[†]: 一个针对全指令条件训练的策略, 而非表 1 中发布的检查点, 因为给定整个指令的子目标条件检查点超出分布, 不能作为此对照。AGM 条目取两次运行平均值; 其他两项为单次运行。

C.2 已验证写入的贡献

主论文主张, 每次尝试都推进的进度记忆可能比完全不携带进度记忆更差。表 10 单独比较了这一情况。三种配置共享一个子目标接口, 仅在决定当前子目标的方式上有所不同: AGM 在验证达成后推进; 基于尝试的控制器与 AGM 相同, 只是两个验证分支都被关闭, 因此任何夹爪开合循环都会推进指针; 以及一个在整个回合中接收完整指令且没有指针的对照组。

在 PickXTimes 任务上, 差距是决定性的。相同的策略、相同的子目标序列和相同的指针, 在写入等待证据时达到 100.0%, 而在不等待证据时仅为 32.0%, 并且未经验证的写入并不比将完整指令交给策略更好。分解并不是产生结果的原因。一个在尝试时推进的指针将每次短暂的抓取或放置失败转化为永久计数错误, 而在物体保持可恢复的任务上, 这些错误的累积速度超过了分解带来的帮助。

在 BinFill 任务上, 基于尝试的控制器几乎与 AGM 持平。解释是结构性的: 释放到容器中的立方体从场景中移除, 因此达到释放的尝试几乎总是达成, AGM 所区分的两个量几乎重合。验证几乎没有什么可区分的, 这与 B.3 节从另一个方向测量的情况相同, 即头部对容器放置没有可靠的判别能力。在该任务上, 情况划分仍然带来的好处是防止错误拒绝, 根据主论文表 3, 这价值十个点。

这两个任务共同定位了机制, 而不仅仅是确认了它。经验证的写入的收益与尝试未能成为达成的频率成正比。当失败的动作使世界保持可恢复时, 这一差距很大, 验证决定结果; 当动作不可逆且自我证明时, 差距缩小, 分解承担了大部分结果。

C.3 定性回放

图 4–6 展示了在基准测试中最深重复次数 $N=5$, 处的完整仿真回合, 以及冻结策略得分为零的那个回合。每个面板在指针转换时捕获, 并带有帧索引、任务指令、当前动作和状态向量, 以及该时刻生效的子目标。两次 PickXTimes 展开使混叠问题变得可见。图 5 的面板 1、3、5、7 和 9 是同一场景: 桌上一个立方体, 一个空目标, 一个夹爪正在接近。这些图像中没有任何内容表明正在进行哪一次重复, 而必须从当前观察中恢复这一事实的策略无从恢复。每个叠加层中打印的子目标由指针提供, 而指针正是区分这五个在其他方面无法区分状态的关键。

D. 真实机器人部署

本节记录了物理平台、演示收集、自动子目标标注、策略训练、AGM 运行时对硬件的适配, 以及表 2 中 Real 模块背后的评估协议。AGM 机制原样迁移。任务记忆 $\mathcal{M}_t = (\mathcal{G}, p_t)$ 、式 (7) 的状态机、式 (14) 和 (19) 的验证、式 (21) 的转换规则、死锁界限以及预终止检查均逐行移植。修改仅限于接口层: 传感器维度、相机几何、阈值重新校准和服务可靠性。每一项如下所述。

D.1 物理平台

机器人。跟随臂是 6 自由度 AgileX PiPER 机械臂, 带有 1 自由度平行夹爪, 指令行程为 0 – 0.08 米, 通过 CAN 总线以 30 Hz 控制。状态和动作空间为 7 维: 六个关节位置 (弧度) 加上夹爪宽度 (米)。实测夹爪宽度 (而非指令宽度) 作为独立通道暴露, 并为状态机提供 w_t 。

相机。两台英特尔实感 D435 RGB-D 相机以 640×480 和 30 帧每秒运行: 一台前置相机安装在工作台上方 (第三人称, 眼在手外), 另一台腕部相机安装在末端执行器上 (眼在手上)。策略同时使用两路 RGB 流; 对齐的深度信息被记录但未使用。前置相机的内参 K 和公式 (9) 中的眼在手外外参 E 通过 ChArUco 标定板进行校准, 平移残差约为 23 毫米, 旋转残差为 5.4° , 重投影误差约为 15 至 40 像素。这足以初始化公式 (10) 的查询网格, 后续流程无需更高精度: 校准决定观察位置, 而达成判定则读取跟踪窗口内的相对点运动。

分布式推理。推理在独立于机器人主机的 GPU 工作站上运行, 通过 SSH 隧道上的 WebSocket 连接进行通信。机器人主机运行一个轻量客户端, 负责相机采集、机械臂驱动和安全层。每个控制周期, 客户端发送一条观测消息 (JPEG 质量 90, 30 赫兹时约 3 兆字节每秒) 给编排服务, 该服务推进指针, 重建




图 4：在 $N=5$ 下使用 AGM 的 BinFill 仿真过程。每个面板对应一次指针转换，叠加显示帧索引、任务指令、动作和状态向量以及当前子目标。十一个子目标——五组抓取-放置对和最终的按钮按下——按顺序发出，指针仅在验证达成后推进，因此回合在恰好五个立方体进入箱中后终止。

当前子目标的语言条件，当客户端的动作块耗尽或子目标改变时请求新的动作块，并返回子目标以及任何新动作和停止标志。放置头和点跟踪通道作为另外两个服务运行，同步调用。当子目标切换时，客户端丢弃剩余动作并执行在新条件下生成的动作块，复现仿真实实现中的执行器重新预备。

D.2 任务套件

基准中的两个长时程任务族在硬件上使用 26 毫米彩色塑料立方体、一个箱子、一个平面目标垫和一个桌面按钮进行复现，按钮按下即结束回合：• 装箱（BinFill (N , 颜色)）——“将 N 个{颜色}立方体放入箱子，然后按下按钮停止。”• 拾取多次（PickXTimes (N , 颜色)）——“拾取{颜色}立方体并放置在目标上，重复此动作 N 次，然后按下按钮停止。”同一个立方体被抓取并放置 N 次，操作者在重复之间将其放回

工作区，遵循基准的重置约定。每个任务展开为 $\mathcal{G} = [\text{拾取}, \text{放置}] \times N + [\text{按钮}]$ ，即 $T = 2N+1$ 个子目标，最多在 $N=5$ 处达到十一个。子目标措辞逐字取自基准模板，这对训练-部署一致性很重要（第 D.4 节）。

演示并评估了重复深度。演示覆盖装箱的 $N \leq 4$ 和拾取多次的 $N \leq 5$ ，而评估覆盖两者的 $N = 1, \dots, 5$ 。因此， $N=5$ 处的装箱不在演示语料库中；第 D.8 节分析了后续情况。任务和子目标词汇表是从 $N = 1, \dots, 5$ 上的模板程序化枚举的，而不是从语料库中收集的，因此 $N=5$ 处发出的每个字符串在第 D.4 节的奇偶校验中保持词汇表内，所涉及的泛化是视觉运动而非词汇层面的。

D.3 演示与自动子目标

标注 遥操作。演示通过主从式遥操作收集，主端是第二个运动学




图 5：在 AGM 下，PickXTimes 在 $N=5$ 处的仿真推演，绿色立方体。同一个立方体被抓取并放置五次，因此每次抓取时的场景在视觉上几乎相同；重复索引只出现在指针提供的子目标中。

相同的 PiPER。关节目标通过一个截止频率为 0.4 Hz 和 $\beta = 5.0$ 的一欧元滤波器。夹爪通道未经过滤以保持抓取时序，并且领导者夹爪范围线性映射到跟随者的 $0 - 0.08 \text{ m}$ 行程。

语料库。194 个回合，100 个 BinFill 和 94 个 PickXTimes，

总计 237,517 帧，约 2.2 小时（30 Hz），每个回合包含两个相机流、7 维本体感觉和末端执行器位姿。

分割。回合根据夹爪信号程序化分割，而非手工或通过视觉语言模型，反映了 AGM 在部署时使用的事件逻辑。指令夹爪边缘标记操作者意图；与持握立方体一致且持续五帧的测量宽度平台确认抓取；释放事件结束每个循环。在 0.040 m 处的平台宽度检查拒绝空抓。期望的子目标序列从任务字符串解析，检测到的循环数与 N 核对，作为质量门控闭环。多色 BinFill 回合中的颜色归属使用抓取瞬间腕部相机的 HSV 统计。边界放置在确认帧，即部署的验证器推进指针的瞬间，使标注成为 AGM 的离线模拟。

online transition.

审计。一条独立的视觉复核流程覆盖了全部 194 个片段，抽样了 2442 帧，并进行了程序级和信号级的重新推导。所有 194 个片段均被正确标注，拾取边界在 30 赫兹下与独立视觉估计相差不超过 4 帧（拾取次数）和 7 帧（装箱填充）。

D.4 策略训练与语言条件化

两种架构， π_0 和 $\pi_{0.5}$ ，在两种条件化格式下进行微调，得到表 2 中的四个检查点。融合检查点在以下帧级提示上进行训练，其文本通道同时携带完整任务和当前子目标；这些是与 AGM 兼容的策略。合并检查点在相同的片段上训练，但每帧的提示被缩减为仅包含任务指令，并在表 2 中显示为 π_0 和 $\pi_{0.5}$ 。所有四个都是从官方基础检查点进行完整微调，视觉编码器冻结，采用相同的优化设置和相同的 194 个片段，因此 π_0 与 $\pi_{0.5}$ 以及融合与合并都是受控比较。观测为前置和腕部图像，经信箱式调整为 224×224 ，加上 7 维本体感受状态；动作为 7 维关节加夹爪目标，以 20 帧的块输出，其中客户端



图 6：在 AGM 下，拾取次数在 $N=5$ 处的仿真推演，红色方块。指令、物体和目标与图 5 不同，而阈值、转换规则和验证器权重完全相同。

Hyperparameter	Value (identical across all four)
Training steps	40,000
Batch size	128
Optimizer	AdamW, gradient-norm clip 1.0
Learning rate	linear warmup to 5×10^{-5} over 10k steps, constant thereafter
EMA decay	0.999
Action horizon	20 frames
Vision encoder	frozen (SigLIP)
Normalization	architecture default, statistics computed on this corpus

表 11：真实机器人实验的策略微调配置。 $\pi_{0.5}$ 使用分位数归一化， π_0 使用 z 分数归一化，遵循每种架构的默认设置。

executes 10 (0.33 s) before replanning.

融合提示。 帧级标注以任务：{完整任务指令} 当前子目标：{当前子目标} 的形式进入训练。

从而使一个文本通道承载全局上下文与当前活跃子目标。在部署时，编排器重建该字符串

从 g_{p_t} 通过用于标注的同一模板模块，作为所有措辞的唯一真实来源。每次运行前的奇偶校验要求部署可能发出的每个字符串都逐字出现在训练词汇表中，这使得部署时的条件分布与训练中观察到的分布可证明地相同。我们建议将该检查作为子目标条件部署的通用实践，因为否则条件漂移是静默的。

D.5 硬件上的 AGM 运行时间

仅重新训练放置头。其余更改重新校准常量，这些常量的仿真值以不适用于物理平台的单位表示。

D.5.1 状态机与校准 状态机原样迁移，包括五帧保持确认。仅其阈值通过脚本化探测在三种构型下重新校准至物理夹爪：夹持立方体、空载闭合、完全张开。同一探测在机器人基坐标系中将料箱、目标和按钮区域注册为轴对齐矩形，并给出按钮的按压高度，供第 D.5.3 节的本体感知门控使用。

Quantity	Calibrated value
Measured width, fully open	0.0692 m
Measured width, holding 26 mm cube	0.0260 m
Measured width, empty closure	0.0031 m
Closure entry	0.0476 m
Closure exit	0.0541 m
Empty-closure threshold	0.0146 m
Hold-confirm	5 frames
Plateau sanity width	0.040 m

表 12: 物理平台上的状态机校准。

D.5.2 抓取验证 拾取仅在验证通过后提交，而释放会取消任何待处理的拾取，因此空闭包永远无法推进指针。本体感觉通道要求末端执行器在负载持续期间上升 0.03 米。点跟踪通道原样移植公式 (9) – (14)，仅重新缩放其几何量。抓取瞬间的末端执行器位置通过标定的 K 和 E 投影到前置摄像头中，并带有 0.12 米的法兰到指尖偏移，且在半宽为 60 像素的范围内播种 6×6 网格。CoTracker3 从抓取时刻到当前帧跟踪该片段，当 r_n^G 像素时确认拾取。该对重新缩放仿真值 $\delta_G = 8$ (4, 22) : 硬件上焦距 exceeds (8, 60)

在 640^2 处为 $f_x \approx 610$ ，而仿真中在 256^2 处为 128，且 0.03 米的提升在我们的工作距离下约对应 16 像素。重复拒绝与仿真中一样有界，且在 2.7 秒的负载保持而无提升时的卡住超时提供了最终后备。

D.5.3 放置验证 放置头是唯一为硬件重新训练的已学习组件，因为其特征布局取决于本体感觉维度。架构不变：冻结的 SigLIP (base-patch16-224) 对释放前后来自两个摄像头的 $K = 4$ 帧的均值池化窗口进行编码，且该头消耗公式 (18) 的特征图，

$$f_n = \begin{bmatrix} z_{f,n}^-; z_{f,n}^+; z_{f,n}^+ - z_{f,n}^-; \\ z_{w,n}^-; z_{w,n}^+; z_n^{\text{prop}}; z_{q,n} \end{bmatrix}.$$

在硬件上使用 $d = 7$ 时， z_n^{prop} 的宽度为 16，输入宽度为 4624。训练在片段级划分下使用类别加权交叉熵，且文本嵌入 $z_{q,n}$ 使用放置子目标措辞，在采集、训练和服务中保持一致。

训练数据。 正样本为 526 个放置事件，其中 238 个在目标上，288 个在箱内，由部署时使用的同一状态机从 194 个演示片段中自动提取。负样本为 75 个事件，在 20 个专用片段中通过遥操作故意失败，涵盖目标边缘的擦边、正确放置立方体的碰落、箱沿的反弹以及严重脱靶；约 84% 是视觉上类似成功的困难负样本。每个负样本都经过人工审查释放前后数秒的视频，意外成功的样本被重新标记。训练

Check	Result
$\mathcal{G}$ matches annotated sequence	194 / 194
Pointer reaches terminal subgoal	194 / 194
Episode stop emitted	192 / 194
Median transition offset	7.5 frames (0.25 s)
Transitions within 15 frames (0.5 s)	96.5%

表 13: 部署控制器在所有 194 个演示片段上的离线回放，不消耗机器人时间。

混合保留全部 75 个负样本，并对 175 个正样本进行子采样，失败率为 30%。

决策规则。 目标放置需要 $s_n^P \geq 0.5$ 。箱体放置使用宽松阈值 0.05，并结合本体感觉门控，要求末端执行器在已注册的箱体区域内释放，因为箱体遮挡使得视觉证据在此处不可靠。这是第 A.4 节中可恢复性感知划分在硬件上的实现。被拒绝的放置会将指针回退到关联的抓取子目标，目标处连续拒绝次数上限为两次，箱体处为三次，强制推进以打破死锁，终止前检查会在最终子目标之前重新验证最后一次放置。

D.5.4 故障安全语义 验证在两种设置中均在进程外运行；在硬件上，它还通过隧道链路跨越两台机器，这扩大了可能中断查询的传输和服务故障集合。因此，物理部署是故障安全的：服务故障返回哨兵值而非判定结果，此时 AGM 保守地保持状态并在冷却后重试，任何真正的死锁由卡住超时打破。判定结果绝不会从失败的查询中合成。服务在回合开始时进行探测，发生故障的回合会被作废而非继续，因此没有任何报告的回合依赖于降级的验证路径。

D.5.5 安全层 所有机械臂共享一个安全层：从当前配置到回合开始时第一个策略动作的 1.5 s 斜坡，当该动作偏差达到 0.05 弧度或以上时激活；每帧关节增量限制为 0.1 弧度；以及对动作和状态维度的硬断言。按钮子目标最多等待 20 秒，之后回合终止，该子目标标记为未完成。

D.6 离线回放验证

在任何硬件部署之前，所有 194 个演示片段均通过部署控制器进行回放，使用真实的夹爪信号、真实的末端执行器轨迹和真实的时间，并将其行为与真实标注进行对比。因此，基于成就的指针推进在真实传感器信号上能够正确运行，无需消耗任何硬件时间。我们建议将此流程作为闭环具身系统启动的实践方法。

D.7 评估协议

每个骨干网络在两种配置下进行评估，这两种配置仅在子目标是否来自 AGM 上有所不同。裸策略

智能体接收整个回合的完整任务指令；AGM 配置接收由已验证指针索引的子目标 g_{pt} 。两者通过相同的条件接口进入，并在匹配的数据预算下进行（第 D.4 节），因此差异可归因于子目标的来源。回合时长上限为 240 秒，频率为 30 赫兹。操作员根据书面协议在回合之间重置场景，在工作空间内重新随机化立方体、目标和干扰物的位置，而箱子和按钮保持其标定姿态。每个回合记录机器可读的迹，涵盖每个状态机事件、指针转换、验证器查询与裁决、强制推进和停止，全部带有墙钟时间戳，同时记录机器人视角视频和用于评分的独立第三人称 4K 录像。成功根据录像按子目标评分，回合成功要求所有 $2N+1$ 个子目标，包括按钮按压。

D.8 超出演示的重复深度

BinFill 在 $N=5$ 处未出现在任何演示中，然而 $\pi_{0.5} + \text{AGM}$ 在该处达到 60.0%，而在演示过的 $N=4$ 处为 70.0%。跨越分布边界的代价与相邻演示计数之间的代价大致相当，因此跨越边界不会增加除箱子逐渐被占用这一物理难度之外的额外惩罚。这源于将进度外部化到指针中。冻结策略一次只以一个子目标为条件，组成 $N=5$ 回合的子目标各自都在分布内；只有它们的数量是新的，而数量存储在记忆中而非策略中。因此，可实现的重复深度由记忆而非语料库中出现的计数决定，这一特性源于接口，任何需要在内部表示进度的策略都无法获得。裸 $\pi_{0.5}$ 从另一面说明了这一点：它在 $N=4$ 和 $N=5$ 处得分均为零，在到达边界之前就已失败，因此限制它的是缺失的任务状态，而非未见过的计数。PickXTimes 通过 $N=5$ 进行演示，因此其统一的 100.0% 是分布内结果，上述声明仅针对 BinFill。

D.9 定性结果

图 7–9 展示了在 $N=5$ 处的完整物理回合，每个子目标对应一个面板，最后是终止场景。三者均成功，且均未修改地运行第 D.5 节的框架配置。

图 7 是第 D.8 节中未演示的设置。工作区中有三种颜色的立方体，因此每次抓取按颜色选择，而指针跟踪已交付的指定颜色立方体数量；这两个量是独立的，混淆它们正是导致回合少一个立方体而结束的失败原因。PickXTimes 回合在硬件上重复了仿真回放中的混叠模式：奇数编号的面板是同一物理场景重复五次。

D.10 可复现性总结

表 14 汇总了复现物理实验所需的平台、控制、训练和验证设置。

Component	Setting
Control / camera rate	30 Hz, $640 \times 480 \text{ RGB} \times 2$
State / action	7-D (6 joints + gripper width)
Action chunk	20 frames; replan every 10 frames or on subgoal switch
Policy input images	front + wrist, letterboxed 224^2
Policy fine-tuning	40k steps, batch 128, lr 5×10^{-5} after 10k warmup, frozen encoder
Grasp verification	lift 0.03 m (proprioceptive); $\delta_G = 8 \text{ px}$, 6×6 grid, 60 px half-width
Placement head	frozen SigLIP + MLP, 4624-D input, $K = 4$ frames per side
Placement thresholds	target 0.5; bin 0.05 with in-bin release gate
Rejection bounds	target 2, bin 3; grasp stuck timeout 2.7 s
Placement settling	0.4 s before verification
Safety	1.5 s ramp; Δjoint 0.1 rad/frame; button wait 20 s
Episode budget	240 s, operator scene reset between episodes
Demonstrations	194 episodes / 237,517 frames (100 BinFill, 94 PickXTimes)
Verifier data	526 positive / 75 hard-negative placement events; 30% failure rate in the training mix

表 14: 真实机器人部署的可复现性总结。

措辞模板、状态机阈值和验证常量通过一个配置模块在标注流水线与部署运行时之间共享，当部署时生成的条件字符串与训练词汇不完全匹配时，系统拒绝运行。

E. 扩展局限性

验证词汇以抓握为锚定 事件。AGM 从夹持器负载事件中定位候选转换，因此其成就词汇表恰好覆盖那些完成由抓取或释放括起来的子目标。在持续抓取下的推动、滑动、关节物体操作和工具使用不会产生兼容事件，并回退到冻结策略。这就是为什么 AGM 在两个子目标不以夹持器为锚的基准任务上与基础策略相当而非改进。扩大覆盖范围需要更广泛的交互检测器家族，而不是不同的记忆：指针对事件如何定位不敏感。

该任务是一个序列，而非图。此处的记忆是一个有序的子目标序列，带有一个单一指针，这对于重复性和基于计数的操作是足够的，因为其结构本质上是线性的。它无法表达分支计划、部分有序的子目标或可无序满足的子目标，并且回滚只能到达当前重复所关联的抓取。可恢复性同样是子目标类型的一个属性，在指令展开时即被固定。

Task: *put five green cubes into the bin, then press the button to stop*




图 7: BinFill 在 $N=5$ 处的真实机器人执行过程, 该重复次数未出现在演示语料库中 (第 D.2 节)。三种颜色的立方体共享工作空间, 因此每次抓取都需选择颜色, 而指针则计数指定颜色的投放次数。该回合在恰好完成五次放置后终止。

而非从场景中直接读取, 因此对于因类型标签未预料到的原因而变得不可达的物体, 会不断重试, 直到拒绝界限强制推进。

有界拒绝以一种失败模式换取另一种失败模式。死锁界限确保持续拒绝的验证器不会使回合停滞, 但其实现方式是在未验证的子目标上推进指针, 从而将活性失败转化为可能的进度错误。界限较小, 且不可逆放置的判定较为宽松, 因此很少达到界限, 但 AGM 所保证的是未验证写入是罕见且有界的, 而非从不发生。

验证质量制约任务性能。每次写入都依赖于验证决策, 因此框架继承了验证器的错误特征。错误接受会记录未发生的进度; 错误拒绝则会消耗预算重复已完成的子目标。可恢复放置与不可逆放置之间的阈值不对称性回应了这些成本的不对称性, 但它管理了权衡而非消除权衡。

物理评估的范围。真实机器人研究涵盖了一个六自由度平台上的两个任务系列, 使用单一的夹爪几何形状和物体类别。该框架在测试的两种骨干网络之间无需重新调参即可迁移, 但我们并未声称校准阈值可跨平台迁移; 第 D.5 节记录了重新校准程序。

Task: pick up the *green cube* and place it on the target repeating this action *five* times then press the button to stop




图 8: 真实机器人执行 PickXTimes 任务, $N=5$, 绿色立方体。立方体在重复之间返回工作空间, 因此面板 1、3、5、7 和 9 是同一场景; 仅指针区分它们。

Task: pick up the *red cube* and place it on the target repeating this action *five* times then press the button to stop




图 9: 真实机器人执行 PickXTimes 任务, $N=5$, 红色立方体, 在与图 8 相同的验证头和阈值下。