

AutoIntervene: 面向动作分块模仿学习策略的校准干预

Jinhe Tang¹ and Weiming Zhi^{1,2,3,*}

¹School of Computer Science and ²Australian Center For Robotics, The University of Sydney, Australia

³College of Connected Computing, Vanderbilt University, TN, USA

*Corresponding author: Weiming.Zhi@sydney.edu.au

Project website: <https://aus.bot/research/autointervene/>

摘要——动作分块视觉运动策略通过预测短动作序列而非单步指令，从演示中学习并提升时序一致性。然而，感知误差与执行漂移可能使机器人偏离演示分布，而策略仍持续生成与观测状态不一致的平滑动作块。本文提出 AutoIntervene，一种在线框架，在部署期间选择性地在动作分块策略与操作员之间转移控制权。AutoIntervene 依据成功任务执行构建的视觉-动作支持记忆评估候选动作块，结合视觉相似性与候选动作和参考动作之间的一致性。阶段局部支持在当前任务阶段内管理策略到操作员的转移，而全局支持管理操作员恢复后返回策略控制。我们根据留出专家演示上评估级分数的经验分位数，为两个方向分别校准切换阈值，避免直接手动调节分数截断值。从成功回滚中保留的干预片段针对学习者诱导的状态，并为后续策略更新提供纠正性监督。在真实世界双臂操作任务上的实验表明，与手动干预相比，适应后任务成功率更高，操作员控制时间更短。视频与更多结果见 <https://aus.bot/research/autointervene/>。

1. 引言

模仿学习 (Imitation Learning) 为从演示中学习机器人策略提供了一种实用的框架 [1]，包括能够适应环境变化的稳定运动生成器 [2]，而离线人类数据已使复杂的多阶段和长时程操作成为可能 [3], [4]。近期的动作分块策略通过预测未来动作的短序列而非单步指令来提升时序一致性，使视觉运动策略无需手工设计的控制器即可执行接触丰富的操作任务 [5]。然而，这些策略在部署时面对分布偏移仍显脆弱 [6]。DART 通过注入噪声来扩大演示覆盖范围，但未提供部署时机制来检测不受支持的策略行为或请求纠正性控制 [7]。微小的感知误差、错过的接触或累积的执行误差都可能使机器人进入演示数据覆盖不足的状态。一旦发生这种情况，动作分块策略可能继续生成平滑的动作块，却不再推进任务进展，从而导致抓取错位或子任务未完成等失败。




图 1: AutoIntervene 在自主策略与操作员之间转移控制权，从而引导有针对性的干预数据收集。我们在多种操作任务中对该系统进行了评估。

转换 [8]、[9]。本文提出 AutoIntervene，一种在线干预框架，旨在提升动作分块策略的部署可靠性。AutoIntervene 将每个提议的动作块与成功的视觉-动作支持进行比对，当提议反复缺乏支持时转移控制权。它利用相位局部参考来决定控制权何时应从策略移交给操作员，并利用全局参考来决定何时应返回给策略，从而允许在操作员纠正后从任何受支持的任务相位恢复自主性。在每一轮适应中，通过在相应检索范围内对留出的成功专家演示重新计算提议和支持分数，离线校准独立的切换阈值。来自成功执行的操作员控制片段被保留用于后续策略更新，形成一个选择性的 DAgger 风格循环 [10]、[11]。与标准 DAgger 在整个执行过程中在学习者访问的状态上查询专家动作不同 [6]，AutoIntervene 仅在自动识别的无支持期间请求监督。这将部署时的监控与有针对性的数据聚合连接起来。图 1 展示了代表性执行过程，包括对毛巾和织物手提袋等可变形材料的操作。

本工作的贡献有三方面：

- 1) 我们提出了一种用于动作分块模仿策略的双向干预框架，利用相位局部支持实现策略到操作员转移，并利用全局支持实现返回策略控制。
- 2) 我们开发了一种模式特定的视觉-动作校准程序，该程序使用留出的成功专家演示，在每一轮适应中根据各自的检索范围重新计算独立的干预和恢复阈值。
- 3) 我们在九个真实世界任务上评估了 AutoIntervene，并表明有针对性的干预轨迹支持迭代策略改进，与收集额外的完整演示相比，操作员控制时间显著减少。

II. 相关工作

视觉运动模仿策略。视觉运动模仿策略在表示时间扩展动作的方式上存在差异。动作分块直接预测短动作序列，而扩散和流匹配策略通过迭代或连续时间过程生成这些序列 [5]、[12]、[13]。流式轨迹也可以在训练后加以约束 [14]。尽管这些方法改进了动作生成，但它们本身并不能确定部署的提议何时已超出演示支持范围，或干预后控制权应何时返回。AutoIntervene 独立于动作头处理这一部署层。我们使用动作分块变换器 (ACT)、扩散策略和流匹配头对其进行评估。

交互式模仿学习。交互式策略自适应传统上依赖操作员监控策略执行并手动决定何时接管和交还控制权。机器人门控方法则根据部署时信号自动请求干预。LazyDAgger 利用策略与专家动作差异触发专家介入，而 RND-DAgger 使用随机网络蒸馏估计的状态新颖性 [15]、[16]。AutoIntervene 遵循这一机器人门控方向，但将控制转移视为基于支持的双向过程：阶段局部支持控制策略到操作员的转移，全局支持控制操作员到策略的返回，保留的恢复片段为后续策略自适应提供纠正数据。

运行时策略监控。运行时监控器可根据其检查的信号和检测后采取的动作进行比较。误差感知模仿学习从遥操作数据中检测潜在失败 [17]，ConditionNET 学习动作条件前提和效果 [18]。Sentinel 将时间动作不一致性与视觉语言进展检查相结合 [8]，而 FAIL-Detect 仅从成功数据中估计失败不确定性 [19]。轨迹级分布外检测也已直接使用扩散模型在 SE(3) 位姿序列上形式化 [20]。PATCH 将局部潜在块创新条件化于当前动作分块，以在局部场景干扰下暂停和恢复策略执行 [21]。

Rewind-IL 进一步将校准后的块间差异与在语义验证安全状态下的重生相结合 [9]。这些方法分别针对轨迹级分布外检测、局部瞬态扰动或基于检查点的重生。AutoIntervene 则利用基于检索的视觉-动作支持来管理策略到操作员以及操作员到策略的转移，然后将操作员控制的恢复转化为纠正性训练数据。

III. AUTOINTERVENE

AutoIntervene 旨在通过将自动触发的操作员干预转化为有针对性的监督，来改进已部署的动作分块视觉运动策略。如图 2 所示，它由两个阶段组成。第一阶段，干预循环，监控已部署的策略，在需要干预时将控制权转移给操作员，当策略提出的动作重新获得足够支持时将控制权返回给策略，并记录产生的干预片段。该循环依次通过三个模块进行：(A) 视觉-动作查询构建，(B) 视觉-动作支持评估，以及 (C)

双向控制权选择。这些模块共同根据当前视觉观测和策略提出的动作块构建视觉-动作查询，将其映射为视觉支持和动作风险分数，并使用校准后的接受标准选择控制权。第二阶段，策略适应，利用保留的干预片段更新当前策略。更新后的策略随后被重新部署，干预循环为下一轮适应收集新的干预片段。

控制设置。我们使用 ALOHA 风格的领导者-跟随者遥操作实现干预循环，并采用 TriPilot-FF 风格的手臂侧力反射 [5]、[22]。领导者手臂作为操作员输入，而跟随者手臂与任务交互。在策略控制下，领导者和跟随者手臂接收相同的策略生成的关节和夹爪命令并保持对齐。当控制权转移给操作员时，每个跟随者手臂切换到跟踪相应的操作员操纵的领导者手臂，从而无需重新定位领导者手臂即可开始纠正。

A. 视觉-动作查询构建

在部署过程中，视觉上相似的观测可能在需要不同动作的任务阶段重复出现 [23] – [25]。因此，仅凭视觉相似性不足以判断策略所提议的运动是否恰当。这促使 AutoIntervene 将当前观测与策略即将执行的动作块联合评估。在评估时刻 t ，当前策略 π 以当前相机图像作为输入。其视觉编码器将这些图像映射为嵌入 $E_t = (e_t^{(1)}, \dots, e_t^{(C)})$ ，其中 C 表示相机视角的数量。策略的动作头预测一个 H 步的动作块，监控器使用其前 H_r 步进行评估，其中 $1 \leq H_r \leq H$ 。我们将该预测前缀记为 A_t 。




图 2: AutoIntervene 概览。在第一阶段，干预循环依次 (A) 从当前视觉观测和策略提议的动作块构建视觉-动作查询，(B) 评估视觉支持度和动作风险分数，(C) 使用校准后的接受标准选择控制权。保留的干预片段随后用于第二阶段的自适应策略，之后更新后的策略被重新部署。

对于我们的双臂系统，我们将 A_t 中的命令按手臂分组：一组包含左臂关节和夹爪命令，另一组包含相应的右臂命令。视觉嵌入和预测动作前缀共同构成视觉-动作查询 $Q_t =$

(E_t, A_t) 。

B. 视觉-动作支持评估

给定视觉-动作查询 Q_t ，AutoIntervene 使用由行为参考构建的视觉-动作记忆 $\mathcal{M}$ ，并将其高维比较总结为两个标量：视觉支持分数和动作风险分数。视觉-动作记忆与模式特定检索。视觉-动作记忆由用于训练当前策略的所有轨迹构建 π 。假设有 N 条这样的轨迹，收集在 $\mathcal{D} = \{\tau_i\}_{i=1}^N$ 中，其中 τ_i 是集合中的第 i 条轨迹。 $\mathcal{D}$ 中的每条轨迹用于生成相应的视觉-动作记忆条目。对于任意轨迹 $\tau_i \in \mathcal{D}$ ，其长度为 $|\tau_i|$ 个记录时间步，并贡献 $|\tau_i| - H_r + 1$ 个记忆条目。这些条目对应于所有可以提取完整 H_r 步动作块的起始时间步。对于任意这样的条目，令

$u \in \{1, \dots, |\tau_i| - H_r + 1\}$ 为其起始时间步。从时间步 u 到时间步 $u + H_r - 1$ 记录的 H_r 个动作构成动作块 $A_{i,u} = (a_{i,u}, \dots, a_{i,u+H_r-1})$ ，而 $E_{i,u}$ 是轨迹 τ_i 在同一起始时间步的多视角视觉嵌入。 $A_{i,u}$ 和 $E_{i,u}$ 共同构成记忆条目 $m_{i,u} = (E_{i,u}, A_{i,u})$ 。收集所有轨迹中所有有效起始时间步生成的条目，得到完整的视觉-动作记忆 $\mathcal{M}$ ，如图 3 所示。一旦视觉-动作记忆 $\mathcal{M}$ 构建完成，AutoIntervene 在部署期间以模式特定的评估频率使用它来持续评估当前的视觉-动作查询。在每个评估时间 t ，由策略或操作员控制双臂系统，因此 AutoIntervene

根据主动控制模式确定用于当前评估的记忆条目。令 $\beta \in \{\text{pol}, \text{op}\}$ 表示该模式，其中 $\beta = \text{pol}$ 表示策略控制双手系统， $\beta = \text{op}$ 表示操作员控制该系统。相应的检索集记为 $\mathcal{R}_{\beta,t} \subseteq \mathcal{M}$ 。当 $\beta = \text{op}$ 时，操作员控制双手系统，而策略继续在后台生成预测。操作员的恢复可能改变物体状态或完成部分任务，因此当前状态不必保持在干预开始时的任务阶段附近。为使策略能够在恢复后到达的任何有效任务阶段重新获得支持，AutoIntervene 从完整的视觉-动作记忆中检索。我们将在此完整记忆检索范围内评估的支持称为全局支持。当 $\beta = \text{pol}$ 时，策略控制双手系统，任务进度在连续评估之间局部连续。然而，来自不同任务阶段的记忆条目可能包含相似的视觉嵌入但记录的动作块不同。反复搜索完整记忆可能因此引入来自错误阶段的匹配 [24]。每当策略开始控制双手系统时，其首次评估将当前视觉嵌入 E_t 与每个记忆条目 $m_{i,u} \in \mathcal{M}$ 中包含的视觉嵌入 $E_{i,u}$ 进行比较。AutoIntervene 保留每条训练轨迹 τ_i 上最佳匹配的记忆条目，然后选择保留条目匹配最强的 J 条轨迹。每条选中的轨迹贡献一个前向窗口，其中包含其匹配条目及至多后续 $B-1$ 个条目。后续评估仅在这些窗口内检索。每执行 U_{win} 个策略动作后，每个窗口根据新匹配的条目沿其轨迹前进，而不返回较早的任务阶段。令 $\mathcal{W}_{j,t}$ 表示评估时间 t 时第 j 条选中轨迹的窗口，其中 $j = 1, \dots, J$ 。因此，模式特定的检索集定义如下。我们将这些前向窗口内评估的支持称为相位局部支持。

$$\mathcal{R}_{\beta,t} = \begin{cases} \mathcal{M}, & \beta = \text{op}, \\ \mathcal{W}_{1,t} \cup \dots \cup \mathcal{W}_{J,t}, & \beta = \text{pol}. \end{cases}$$

为符号简洁起见，在视觉邻居检索和动作风险评分中，我们将通用记忆条目写为 $m = (E, A)$ ，并省略其轨迹和时间步。

indices.

视觉邻居检索。对于参考条目 $m \in \mathcal{R}_{\beta,t}$ ，我们取其多视角视觉分量 $E = (e^{(1)}, \dots, e^{(C)})$ ，并将其与当前查询嵌入 $E_t = (e_t^{(1)}, \dots, e_t^{(C)})$ 逐视角比较， $\sim$ 。Their minimum 跨视角视觉相似度为

$$s_t(m) = \min_{1 \leq c \leq C} \text{sim}(e_t^{(c)}, e^{(c)}), \quad (1)$$

在式 (1) 中，相似度 (sim) 为 ℓ_2 归一化嵌入之间的余弦相似度。取最小值可防止某一视图中的高相似度掩盖另一视图中的不匹配，因此每个视图




图 3: 记忆构建与模式特定检索。\$\mathcal{R}_{op,t}\$ 使用所有条目，而 \$\mathcal{R}_{pol,t}\$ 结合来自 \$J\$ 所选轨迹的前向 \$B\$ 条目窗口。

必须支持匹配。从 \$\mathcal{R}_{\beta,t}\$ 中，AutoIntervene 保留相似度最大的 up to \$K\$ 个条目作为 \$\mathcal{N}_{\beta,t}\$。动作风险评分。给定 \$\mathcal{N}_{\beta,t}\$，我们将提出的动作块 \$A_t\$ 与每个条目 \$m \in \mathcal{N}_{\beta,t}\$ 中存储的动作分量 \$A\$ 进行比较。该提议是在策略控制下等待执行的动作块，以及在操作员控制下的背景策略预测。按照上述定义的动作分组，每个组 \$g\$ 的这些块之间的归一化距离如下所示，其中上标 \$(g)\$ 选择该组的动作维度：

$$d_{t,g}(m) = \left\| \frac{A_t^{(g)} - A^{(g)}}{\sigma_g} \right\|_2, \quad (2)$$

在式 (2) 中，\$\sigma_g\$ 包含组 \$g\$ 在 \$\mathcal{M}\$ 中记录动作的逐维度标准差，且除法按元素进行。欧氏距离在所有保留步骤和动作维度上计算。对于每个动作组 \$g\$，令动作选择集 \$\mathcal{P}_g\$ 包含 \$\mathcal{N}_{\beta,t}\$ 中距离最小的 \$M\$ 个条目。聚合这些参考可降低对偶然匹配的敏感性，同时限制来自动作相关性较低的视觉邻居的干扰。令 \$g^*\$ 为其所选条目具有最大平均距离的动作组，从而使风险由支持度最低的组决定，而非被匹配较好的组所掩盖。使用相同的参考，模式相关的动作风险与视觉支持为

$$\begin{aligned} r_{\beta,t} &= \frac{1}{M} \sum_{m \in \mathcal{P}_{g^*}} d_{t,g^*}(m), \\ s_{\beta,t} &= \frac{1}{M} \sum_{m \in \mathcal{P}_{g^*}} s_t(m). \end{aligned} \quad (3)$$

如式 (3) 所定义，两种评分均采用相同的动作选择参考。最后，\$\bar{r}_{\beta,t}\$ 在当前控制区间内对至多 \$W\$ 个最近的动作风险值进行平均，并利用所有可用数据

评估前的数值 \$W\$。视觉支持保持即时性，因此先前的匹配不会掩盖视觉对应关系的突然丢失。该阶段返回分数对，并 \$(s_{\beta,t}, \bar{r}_{\beta,t})\$ 在策略控制下返回选定的参考 \$\mathcal{P}_{g^*}\$ 用于检索窗口更新。

策略端检索窗口更新。每执行 \$U_{win}\$ 个策略动作后，所选参考 \$\mathcal{P}_{g^*}\$ 更新相位局部检索窗口。对于第 \$j\$ 条所选轨迹 \$\tau_{i_j}\$，令 \$u_{j,t}\$ 表示其当前窗口位置。我们将该位置更新为其当前位置与来自同一轨迹的所选参考的起始时间步索引中的最大值：

$$u_{j,t+1} = \max(\{u_{j,t}\} \cup \{u \mid m_{i_j,u} \in \mathcal{P}_{g^*}\}). \quad (4)$$

(4) 中的更新是非递减的，因此每个轨迹窗口向前移动或保持在其当前位置。C. 双向控制权限选择 控制权限选择器接收当前控制模式 \$\beta \in \{\text{pol}, \text{op}\}\$ 的分数对 \$(s_{\beta,t}, \bar{r}_{\beta,t})\$，并在评估 \$t\$ 后决定是保留还是切换控制。该决策需要针对两种控制模式分别设置视觉支持和动作风险阈值。令 \$\mathcal{D}_{cal}\$ 为从策略训练和视觉动作记忆中排除的固定保留成功专家轨迹集。在每个适应轮次部署策略之前，我们对 \$\mathcal{D}_{cal}\$ 分别在策略控制和操作员控制下应用相同的支持评估。这为模式 \$\beta\$ 生成视觉支持集合 \$S_{cal}^\beta\$ 和动作风险集合 \$R_{cal}^\beta\$。令 \$\alpha_s^\beta\$ 和 \$\alpha_r^\beta\$ 分别表示规定的下尾率和上尾率。用 \$Q_p\$ 表示经验 \$p\$ 分位数，则相应的阈值为

$$\theta_s^\beta = \hat{Q}_{\alpha_s^\beta}(S_{cal}^\beta), \quad \theta_r^\beta = \hat{Q}_{1-\alpha_r^\beta}(R_{cal}^\beta). \quad (5)$$

在 (5) 中，\$\theta_s^\beta\$ 是视觉支持下阈值，\$\theta_r^\beta\$ 是动作风险上阈值。两种模式分别校准，因为它们的检索范围产生不同的分数分布。在部署期间，当 \$s_{\beta,t} \geq \theta_s^\beta\$ 且 \$\bar{r}_{\beta,t} \leq \theta_r^\beta\$ 时接受策略提议，否则拒绝。在策略控制下，拒绝、空的相位局部参考集或所有相位局部检索窗口到达其最终有效块都会增加策略侧拒绝计数器 \$c_{pol,t}\$。接受则将其重置。在操作员控制下，策略在后台评估，\$c_{op,t}\$ 统计连续接受次数。被拒绝的提议将其重置。给定所需的持续长度 \$L_{pol}\$ 和 \$L_{op}\$，权限更新 \$\beta^+\$ 为

$$\beta^+ = \begin{cases} \text{op}, & \beta = \text{pol} \text{ and } c_{pol,t} \geq L_{pol}, \\ \text{pol}, & \beta = \text{op} \text{ and } c_{op,t} \geq L_{op}, \\ \beta, & \text{otherwise.} \end{cases} \quad (6)$$

(6) 中的持续长度要求相应决策在连续评估中保持一致，防止短暂的分数波动导致不必要的控制变更。

D. 策略适应

在适应轮次 k 中，干预循环部署策略 $\pi^{(k)}$ ，该策略基于累积的轨迹集合 $\mathcal{D}^{(k)}$ 进行训练。操作员控制系统的每个区间被保留为一个干预片段，并作为单独的干预轨迹存储。该片段从控制权由策略切换至操作员时开始，到控制权返回策略或回合终止时结束。从成功执行中保留的干预轨迹构成 $\Delta \mathcal{D}^{(k)}$ 。将它们分开存储可防止训练样本跨越控制源的变化，并将监督集中于需要操作员纠正的状态 [6]、[10]。在轮次 k 结束时，新的干预数据被添加到当前训练集中。对于任意轨迹集合 $\mathcal{D}$ ，令 $p_{\mathcal{D}}$ 表示对其有效 H 步训练样本的均匀采样。下一个训练集和适应采样分布为

$$\begin{aligned}\mathcal{D}^{(k+1)} &= \mathcal{D}^{(k)} \cup \Delta \mathcal{D}^{(k)}, \\ p^{(k+1)} &= \lambda_{\text{mix}} p_{\mathcal{D}^{(k)}} \\ &\quad + (1 - \lambda_{\text{mix}}) p_{\Delta \mathcal{D}^{(k)}}, \quad 0 \leq \lambda_{\text{mix}} \leq 1, \quad (7)\end{aligned}$$

式 (7) 中的混合保留了先前的训练数据，同时赋予新的干预数据固定的采样权重 [26]、[27]。下一个策略 $\pi^{(k+1)}$ 通过从 $p^{(k+1)}$ 采样的样本上进行标准行为克隆来训练。随后，利用 $\pi^{(k+1)}$ 的视觉编码器从 $\mathcal{D}^{(k+1)}$ 重建视觉-动作记忆。在重新部署之前，基于 $\mathcal{D}_{\text{cal}}$ 重新校准模式特定阈值，之后 $\pi^{(k+1)}$ 进入下一个干预循环。重复此循环可逐步纳入部署期间遇到的不受支持任务区域的干预数据。

四、实证评估

我们在九个真实世界双手操作任务上评估 AutoIntervene，包括一个七任务主基准和两个更长时域的扩展任务。实验围绕四个问题组织：问题 1：与初始策略和额外的完整演示相比，针对性干预是否提高了策略成功率？问题 2：与手动切换和收集额外完整演示相比，自动切换是否实现了更好的成功率-控制数据权衡？问题 3：AutoIntervene 能否支持长时域任务上的迭代适应，并与不同的动作生成头保持兼容？问题 4：与先前的监视器相比，AutoIntervene 执行双向交接的可靠性如何，哪些组件有助于策略到操作员和操作员到策略的切换？

实验设置。所有实验均使用两台 AgileX PiPER-X 六自由度机械臂，配备原装平行夹爪和三台 RGB 相机：一台顶视相机以及每只手腕各一台。策略观测包含 28 维双臂状态，包括 14 个关节与夹爪值及其对应的 14 个实测力矩值，而动作则为 14 维关节与夹爪指令。对于扩散策略（Diffusion Policy）和流匹配（Flow Matching）变体，我们保留了相同的

表 I：所评估任务的定义。

Task	Description
Peg Disassembly	Disassemble a pegged object and place all parts into the box.
Potato Transfer	Transfer a wooden potato between hands and place it into the box.
Towel Folding	Fold a towel from a fixed initial configuration.
Towel Bagging	Fold a towel, pack it and the pegs into a bag, and move the bag to the target side.
Lidded Box Packing	Open the box, pack the objects inside, and close the lid.
Plant Sorting	Place three wooden plant objects into their matching box slots.
Towel Box Packing	Remove pegs, fold the towel, reposition the box, and place the towel inside.
Two-Towel Box Packing	Remove pegs, fold two towels, and place both into the box.
Towels-and-Cable Bagging	Fold two towels, pick up the cable, and place all three items into the bag.

机器人、观测和部署接口，仅替换动作生成头。我们的固定基座设置省略了 TriPilot-FF 的踏板和移动基座通道。我们使用 DINOv3 ConvNeXt-Base [28] 实例化策略的视觉编码器。我们使用两个动作组，分别对应左臂和右臂。

数据与评估协议。对于每个任务，36 条初始轨迹中的 30 条构成 $\mathcal{D}^{(0)}$ ，其余 6 条构成固定的 $\mathcal{D}_{\text{cal}}$ 。后续干预轨迹同时扩充训练集和视觉-动作记忆，但不扩充固定校准集。对于人工干预（Human）和自动干预（AutoIntervene），每轮自适应均保留每个任务五次成功部署 rollout 中的干预轨迹。除非另有说明，每个任务-方法的成功率均在 25 次无辅助物理 rollout 上测量。成功要求完成表 I 中的每个子任务。主基准包含七个双臂操作任务，而两个更长时域扩展则评估迭代自适应。表 I 定义了全部九个任务。图 4 和图 6 展示了代表性执行过程。

实现细节。策略使用 256×256 图像和 $H = 100$ 个未来动作的动作块时域。所有策略变体使用相同的编码器-解码器主干，由一个编码器层和四个解码器层组成，而 ACT、扩散策略和流匹配仅在动作生成机制上有所不同。对于自适应，累积的轮次前训练数据和新收集的第 k 轮干预数据按 2:1 比例采样（ $\lambda_{\text{mix}} = 2/3$ ）。监视器使用 $J = K = 16$ 、和。在策略控制下，经过 1 秒预热后，策略动作以 30 Hz 执行，而自动干预评估以 5 Hz 执行。因此，相位局部检索窗口每执行 $U_{\text{win}} = 6$ 个策略动作更新一次。在操作员控制下，遥操作指令以 200 Hz 执行，而自动干预评估以 30 Hz 执行。两个方向都需要连续两次决策（ $L_{\text{pol}} =$ ）

$$\begin{aligned}L &= (0.05, 0.05) \quad (\alpha_s^{\text{op}}, \alpha_r^{\text{op}}) = (0.30, 0.30). \\ &= 2). \text{ 每轮重新计算其阈值, 使用 } (\alpha_s^{\text{pol}}, \alpha_r^{\text{pol}}) \text{ 和}\end{aligned}$$

表二：七项任务的成功率（%）及记录的控制数据时间。人类与自动干预分别采用手动和自动触发的干预。R1 和 R2 表示适应轮次。 Δt 为累计额外操作员控制时间，而初始与额外完整数据报告总演示时间。

Task	Initial		Human R1		Human R2		AUTOINTERVENE R1		AUTOINTERVENE R2		Additional Full Data	
	Succ. (%)	Time (s)	Succ. (%)	Δt (s)	Succ. (%)	Δt (s)	Succ. (%)	Δt (s)	Succ. (%)	Δt (s)	Succ. (%)	Time (s)
Peg Disassembly	16%	1173.7	52%	123.6	56%	286.9	64%	49.3	72%	127.1	60%	1853.0
Potato Transfer	44%	368.7	52%	20.7	80%	74.2	48%	29.6	76%	50.2	64%	547.3
Towel Folding	56%	766.2	60%	36.4	100%	144.8	76%	61.4	96%	140.4	68%	1100.0
Towel Bagging	24%	1761.1	32%	130.2	36%	266.5	44%	121.6	60%	171.0	40%	2536.7
Lidded Box Packing	8%	989.6	20%	107.5	92%	246.7	52%	63.1	100%	130.2	60%	1440.0
Plant Sorting	24%	450.2	52%	88.8	56%	157.1	52%	76.6	72%	128.9	32%	693.1
Towel Box Packing	44%	1332.4	52%	36.4	60%	83.3	80%	61.4	84%	112.3	68%	1930.5
Average	30.9%	977.4	45.7%	77.7	68.6%	179.9	59.4%	66.1	80.0%	122.9	56.0%	1442.9



图 4：采用自动干预调整的策略在毛巾与线缆装袋任务中处理可变形物体，包括布料、线缆和手提袋。




图 5：R2 后跨任务平均成功率及总记录控制数据时间，包括共享的初始演示。

基线监控设置。在受控比较中，我们实现了部署时交接监控器，这些监控器从 LazyDAgger [15] 和 RND-DAgger [16] 适配到 ACT 部署设置，同时遵循其原始切换标准和报告的阈值设定程序。对于 RND-DAgger，我们遵循其报告的阈值规则，将阈值设为训练集 RND 分数均值的两倍，并且

tested $W_{\text{rec}} \in \{5, 30\}$.

比较方法。主要基准比较了四种设置。初始仅使用 30 个原始训练演示进行训练。额外完整数据为每项任务从标称初始状态分布中添加十条完整专家轨迹。人类使用与本文方法相同的干预学习流程，但由操作员手动选择策略到操作员和操作员到策略的切换。其保留的干预片段作为独立的干预轨迹与先前训练数据混合。自动干预使用所提出的视觉-动作支持评估来自动触发两个切换方向。对于两种基于干预的方法，R1 和 R2 表示连续的适应轮次。

度量。主要度量指标为任务成功率。为进行测量

在数据效率方面，本文还报告了记录的控制数据时间。表二报告了初始与附加完整数据的演示时间，以及人工干预与自动干预的附加操作员控制时间。对于所有方法，图五通过将共享的初始演示时间与干预方法的时间相加，报告了总时间。

A. 针对性干预提升策略适应性（问题 1）

在表 II 的七项任务基准中，定向干预持续改善策略适应：经过两轮后，人类和自动干预在总体上均优于初始策略和额外全量数据。自动干预带来最强改进，将跨任务平均成功率提升 49.1 个百分点，且在全部七项任务上均有增益。这些结果支持自动干预作为一种从学习者引发的失败状态中收集定向纠正监督的有效方法。

B. 自动切换实现更高效策略适配

干预 (Q2) 如表 II 和图 5 所示，AUTOINTERVENE 实现了比人工和额外全数据更高的平均成功率，同时使用的额外记录控制数据时间比额外全数据少约 74%。相对于手动切换，AUTOINTERVENE 在恢复状态和策略动作回到演示支持范围后，将控制权交还给策略，使每个保留的干预片段聚焦于失败和恢复过程。人工选择的操作员到策略切换依赖于操作员判断和按钮时机，因此片段可能延伸到恢复之后，进入策略已经能够处理的状态。在这些额外尾部数据上训练会稀释纠正效果。




图 6: 采用自动干预 (AutoIntervene) 调整的策略在植物分拣任务中执行精确操作, 包括插入和交接。




图 7: 一次自动干预在销钉拆卸任务中的展开过程, 包含两个策略-操作员-策略干预循环。上方: 四个控制开关。下方: 对应的时间线, 其中策略控制以灰色表示, 操作员控制以红色表示。

通过在已支持的区域添加监督来进行更新。额外的完整数据也缺乏针对性, 因为它将收集时间花费在完整的标称轨迹上, 而不是学习者引发的失败状态上。图 7 展示了单个销钉拆卸轨迹中的两个策略-操作员-策略循环, 说明自动干预可以从一次展开中收集多个干预片段。

C. 面向更长时域任务的迭代适应 (问题 3)

为了在更长的任务执行上评估自动干预, 我们在两个更长时域的操作任务上进行了三轮适应。如表 III 所示, 两个任务的成功率在每轮适应后都有所提升, 且最终策略优于使用额外完整数据训练的策略。这些结果表明, 自动干预不仅限于纠正单个局部失败: 通过从每次部署中遇到的问题收集干预数据并用于更新策略, 它能够在更长、更复杂的任务执行中持续提升性能。

D. 跨 ACT、扩散和流匹配的适应

头部 (问题 3) 为了测试自动干预是否能够迁移到 ACT 之外, 我们将 ACT 动作头替换为扩散策略和流匹配头, 同时保持共享主干、机器人接口和监控器不变。如表 IV 所示, 三种动作头在连续适应中均有所提升

表 III: 在两个长时域任务上经过三轮自动干预适应后的成功率 (%)。

Training Stage	Two-Towel Box Packing	Towels-and-Cable Bagging
Initial Policy	28%	8%
AutoIntervene R1	44%	20%
AutoIntervene R2	64%	28%
AutoIntervene R3	88%	48%
Additional Full Data	52%	28%

表 IV: 在双毛巾盒打包任务上, 使用扩散策略 (DP)、流匹配 (FM) 和 ACT 动作头经过三轮自动干预适应后的成功率 (%)。

Training Stage	DP	FM	ACT
Initial Policy	32%	32%	28%
AutoIntervene R1	40%	36%	44%
AutoIntervene R2	56%	48%	64%
AutoIntervene R3	92%	80%	88%
Additional Full Data	44%	40%	52%

rounds, and their R3 policies outperform both the Initial policies and Additional Full Data. *AutoIntervene* therefore transfers across different action-generation mechanisms without head-specific modification.

E. 自动干预通过互补组件超越先前的交接监控器 (问题 4)

协议与度量。在有盖盒装箱任务中, 交接在开盖期间进行评估, 使用相同的 20000 步策略检查点、物理配置和预先指定的监控器参数。每种方法在固定 5 厘米盒子平移后进行 10 次展开测试, 以及 10 次标称展开测试, 完成、60 秒或五个交接周期中的任一条件终止展开。扰动条件测试监控器是否在策略失败后将控制权转移给操作员, 并在操作员恢复后将控制权交还给策略。标称条件测试在无需干预时, 成功的自主执行是否保持不间断。有效切入发生在位移与随后失败抓取后 3 秒之间。有效切出是操作员恢复盒子并引导夹爪到盖子后, 操作员到策略的切换。对于扰动展开上的四个转换度量, 令 V_d , M_d 和 E_d 分别表示 $d \in \{\text{切入}, \text{切出}\}$ 的有效转换、错失机会和额外转换的数量。我们计算

$$\text{Recall}_d = \frac{V_d}{V_d + M_d}, \quad \text{Precision}_d = \frac{V_d}{V_d + E_d}. \quad (8)$$

对于 (8) 中的度量, 分母为零时报告为不适用。有效切出必须跟随有效切入。因此, 切出召回率以有效切入为条件, 而切出精确率考虑所有尝试的操作员到策略切换。误触发率是标称展开中包含至少一次不必要切入的比例, 每次展开最多计数一次, 无论重复触发多少次。比较包括惰性数据集聚合 [15] 和随机网络蒸馏数据集聚合 [16], 两种随机网络蒸馏数据集聚合设置仅在恢复持续性 W_{rec} 上有所不同。消融保留了检索和邻居选择, 仅从接受标准中移除视觉支持或动作风险。

表五：有盖盒装箱上的受控交接比较，每种方法使用 10 次扰动和 10 次标称展开，最多五个完整交接周期。数值为比率。不适用表示分母未定义。

Method	Perturbed				Nominal
	Cut-in Recall $\uparrow$	Cut-in Prec. $\uparrow$	Cut-out Recall $\uparrow$	Cut-out Prec. $\uparrow$	False-trigger Rate $\downarrow$
AutoIntervene	1.00	1.00	1.00	1.00	0.00
<i>Prior handoff monitors</i>					
LazyDAgger [15]	0.40	1.00	0.00	N/A	0.80
RND-DAgger ($W_{\text{rec}} = 5$) [16]	0.80	0.16	0.00	0.00	0.90
RND-DAgger ($W_{\text{rec}} = 30$) [16]	0.80	0.16	0.75	0.12	0.90
<i>Ablations of visual support and action risk</i>					
w/o visual support	0.00	N/A	N/A	N/A	0.00
w/o action risk	0.90	1.00	0.56	0.56	0.00

检索和邻居选择，仅从接受标准中移除视觉支持或动作风险。

与先前监控器的比较。如表 V 所示，仅在名义执行期间实现可靠的双向切换且无多余策略至操作员切换的是 AutoIntervene。LazyDAgger 因策略与操作员在恢复期间分歧较大，会遗漏失败并保持操作员控制。RND-DAgger 对两个方向使用同一新颖性阈值。在操作员至策略切换后，分数增加可能越过同一阈值并立即将控制权交还操作员。增加恢复持续性仅延迟返回策略控制，而 AutoIntervene 使用分别校准的、模式特定的切换准则来实现迟滞切换并抑制立即反转。

视觉支持与动作风险的消融。如表 V 所示，无视觉支持时，AutoIntervene 会遗漏工作空间位移，因为即使视觉对应较弱，动作风险也可能保持较低。无动作风险时，大多数策略至操作员切换仍然存在，但当视觉对在提案匹配成功参考动作之前恢复时，返回策略控制可能不太可靠。因此，视觉支持检测何时需要干预，动作风险防止过早的操作员至策略切换。两者都是可靠双向切换所必需的。策略侧检索窗口更新的消融。除分数组件外，我们通过降低目标物体同时保持相似的 RGB 外观来评估策略侧检索窗口更新，导致名义抓取失败。在每种设置 10 次运行中，带检索窗口更新的 AutoIntervene 实现了 1.00 的切入召回率。在重复抓取失败期间，更新推进相位局部窗口，直到它们全部到达最终有效块，递增策略侧拒绝计数器，直到控制权转移给操作员。没有这些更新，策略可能重复失败的抓取而不转移控制权，切入召回率为 0.30。

V. 结论

AutoIntervene 结合了相位局部视觉-动作监控、双向切换和干预数据聚合

在九项真实世界双手操作任务中，该方法在连续轮次中改进了策略，所需的额外控制数据少于完整演示，平均成功率高于手动切换，且平均操作员控制时间更短。结合针对两个切换方向分别校准的标准，这些组件将操作员控制集中在无支持时段，并在策略提议回到已演示支持范围后恢复自主运行。未来工作将把在线校准扩展到更广泛的任务、扰动和操作员。

参考文献

- [1] T. Osa, J. Pajarinen, G. Neumann, J. A. Bagnell, P. Abbeel, and J. Peters, “An algorithmic perspective on imitation learning,” *Foundations and Trends in Robotics*, 2018.
- [2] W. Zhi, T. Lai, L. Ott, and F. Ramos, “Diffeomorphic transforms for generalised imitation learning,” in *Proceedings of the 4th Annual Learning for Dynamics and Control Conference*, ser. Proceedings of Machine Learning Research, vol. 168, 2022, pp. 508–519.
- [3] A. Mandlekar *et al.*, “What matters in learning from offline human demonstrations for robot manipulation,” in *Proceedings of the 5th Conference on Robot Learning*, 2022.
- [4] A. Mandlekar, D. Xu, R. Martín-Martín, S. Savarese, and L. Fei-Fei, “GTI: Learning to generalize across long-horizon tasks from human demonstrations,” in *Robotics: Science and Systems*, 2020.
- [5] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning fine-grained bimanual manipulation with low-cost hardware,” in *Proceedings of Robotics: Science and Systems*, 2023.
- [6] S. Ross, G. J. Gordon, and J. A. Bagnell, “A reduction of imitation learning and structured prediction to no-regret online learning,” in *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics*, 2011.
- [7] M. Laskey, J. Lee, R. Fox, A. Dragan, and K. Goldberg, “DART: Noise injection for robust imitation learning,” in *Proceedings of the 1st Annual Conference on Robot Learning*, 2017.
- [8] C. Agia *et al.*, “Unpacking failure modes of generative policies: Runtime monitoring of consistency and progress,” in *Proceedings of the 8th Conference on Robot Learning*, 2025.
- [9] G. Zheng, S. Seenivasan, M. Johnson-Roberson, and W. Zhi, “Rewind-IL: Online failure detection and state respawning for imitation learning,” arXiv preprint arXiv:2604.16683, 2026.
- [10] M. Kelly, C. Sidrane, K. Driggs-Campbell, and M. J. Kochenderfer, “HG-DAgger: Interactive imitation learning with human experts,” in *IEEE International Conference on Robotics and Automation*, 2019.
- [11] Z. Hu *et al.*, “RaC: Robot learning for long-horizon tasks by scaling recovery and correction,” arXiv preprint arXiv:2509.07953, 2025.
- [12] C. Chi *et al.*, “Diffusion policy: Visuomotor policy learning via action diffusion,” in *Proceedings of Robotics: Science and Systems*, 2023.
- [13] Q. Zhang, Z. Liu, H. Fan, G. Liu, B. Zeng, and S. Liu, “FlowPolicy: Enabling fast and robust 3D flow-based policy via consistency flow matching for robot manipulation,” in *AAAI Conference on Artificial Intelligence*, 2025.
- [14] J. Long, D. Liu, W. Cai, I. Manchester, and W. Zhi, “Safe policies post-training: Constraining streaming flow models for adapting learned robot trajectory distributions,” *IEEE Robotics and Automation Letters*, vol. 11, no. 9, pp. 10 656–10 663, 2026.
- [15] R. Hoque *et al.*, “LazyDAgger: Reducing context switching in interactive imitation learning,” in *IEEE International Conference on Automation Science and Engineering*, 2021.
- [16] E. Biré, A. Kobanda, L. Denoyer, and R. Portelas, “Efficient active imitation learning with random network distillation,” in *International Conference on Learning Representations*, 2025.
- [17] J. Wong *et al.*, “Error-aware imitation learning from teleoperation data for mobile manipulation,” in *Proceedings of the 5th Conference on Robot Learning*, 2022.
- [18] D. Sliwowski and D. Lee, “ConditionNET: Learning preconditions and effects for execution monitoring,” *IEEE Robotics and Automation Letters*, 2025.
- [19] C. Xu *et al.*, “Can we detect failures without failure data? Uncertainty-Aware runtime failure detection for imitation learning policies,” in *Proceedings of Robotics: Science and Systems*, 2025.

- [20] H. Cheng, T. Zheng, T. Zhang, M. Johnson-Roberson, and W. Zhi, "DOSE3: Diffusion-based out-of-distribution detection on $SE(3)$ trajectories," arXiv preprint arXiv:2502.16725, 2025.
- [21] Y. Zhou, R. Qiu, Y. Chen, J. Cui, and W. Zhi, "PATCH: Action-chunk-conditioned latent patch innovation monitoring for robot manipulation," arXiv preprint arXiv:2606.16690, 2026.
- [22] Z. Li, Y. Zhou, R. Qiu, H. Wu, G. Ren, and W. Zhi, "TriPilot-FF: Coordinated whole-body teleoperation with force feedback," arXiv preprint arXiv:2602.09888, 2026.
- [23] P. Sermanet *et al.*, "Time-contrastive networks: Self-supervised learning from video," in *IEEE International Conference on Robotics and Automation*, 2018.
- [24] Z. Ouyang, K. Wang, J. Liu, H. Lu, and W. Zhang, "SCIL: Stage-conditioned imitation learning for multi-stage manipulation," *IEEE Control Systems Letters*, 2025.
- [25] Z. Li, R. Qiu, Y. Chen, G. Ren, and W. Zhi, "TRACE: Trajectory-routed causal memory for delayed-evidence visuomotor imitation," arXiv preprint arXiv:2606.14551, 2026.
- [26] A. Mandlekar, D. Xu, R. Martín-Martín, Y. Zhu, L. Fei-Fei, and S. Savarese, "Human-in-the-loop imitation learning using remote teleoperation," *arXiv preprint arXiv:2012.06733*, 2020.
- [27] D. Rolnick, A. Ahuja, J. Schwarz, T. P. Lillicrap, and G. Wayne, "Experience replay for continual learning," in *Advances in Neural Information Processing Systems*, vol. 32, 2019.
- [28] O. Siméoni *et al.*, "DINOv3," *Transactions on Machine Learning Research*, 2026.