

EventVLA: 事件驱动的视觉证据记忆，用于长期愿景-语言-行动政策

杨甘霖^{1,2*}、屠张正^{4,3*}、杨玉强^{2*}、毛思同⁵、董俊逸⁵陈天行⁶、彭嘉琪^{7,2}、熊静^{8,2}、曹家飞²、戴继峰⁷、周文刚¹姚木^{3,2,6†}、王泰^{2†}

¹中国科学技术大学²上海人工智能实验室³上海交通大学⁴大连理工大学⁵华为技术有限公司⁶香港大学⁷清华大学⁸北京大学

项目页面: EventVLA

摘要: 内存仍然是长视距机器人操作的关键瓶颈，因为当任务相关线索随着时间的推移被遮挡或不可观察时，标准视觉-语言-动作 (VLA) 策略通常会失败。虽然现有的记忆增强方法利用历史背景，但它们要么遭受严重的信息瓶颈，通过解耦双系统导致高延迟，要么依赖积累大量视觉冗余的非选择性缓冲区。为了解决这些限制，我们引入了 EventVLA，这是一个基于稀疏视觉证据记忆概念的端到端框架，它包含两个核心组件：保留初始和短期上下文的基础 *visual anchors* 和动态 *Keyframe Evidence Memory (KEM)* 模块。具体来说，KEM 直接从 VLA 的潜在嵌入预测未来关键帧概率，以自动捕获和存储稀疏的、任务关键型视觉事件。这种前瞻性驱动的机制使政策能够动态评估当前观察结果的未来因果效用，在短暂的视觉证据变得不可观察之前保留它。此外，我们提出了 RoboTwin-MeM，这是一种专门设计用于通过交互式视觉证据评估非马尔可夫操作任务的诊断基准。广泛的评估表明，在 17 项需要内存的模拟任务和 4 项现实世界的双手任务中，EventVLA 的平均成功率比最先进的内存增强 VLA 提高了 40%。代码、模型和数据集可在 <https://github.com/InternRobotics/EventVLA> 中获取。

关键词: 内存、机器人操作、机器人基准

1 简介

最近的视觉-语言-行动 (VLA) 政策在可概括和细粒度的操作方面表现出色[1,2,3,4,5]，但它们主要在严格的马尔可夫假设下运作。这隐含地假设所有与任务相关的信息始终保持可见。实际上，物理工作空间会动态变化，智能体必须不断保留中间状态，例如移位物品的原始位置，以指导后续操作。为了解决这一非马尔可夫挑战，内存感知 VLA 出现在三种范式中 [6]。首先，双系统内存 VLA [7,8,9] 将认知与控制分离，但会遭受高延迟和严重的错误传播。其次，循环架构 [10, 11] 将历史压缩为隐藏状态，从而产生丢弃细粒度视觉细节的信息瓶颈。第三，内存缓冲区[12, 13]保留了视觉保真度，但在没有选择机制的情况下盲目地积累冗余帧。

*Equal contribution. †Corresponding authors.




图 1: EventVLA 概述。EventVLA 通过存储稀疏的、任务关键型的视觉证据来处理长期、需要内存的操作任务。该图说明了 (a) 非马尔可夫挑战, (b) 我们提出和评估的基准, (c) 事件驱动的内存在设计, 以及 (d) 在模拟和现实世界任务中的巨大收益。

因此, 仍然存在一个关键问题: VLA 是否应该保留 *when* 和 *what* 视觉证据, 以在不压倒计算限制的情况下最大限度地提高执行成功率?

为了避免标准内存缓冲区的大量冗余[12, 14], 我们发现一组稀疏的历史关键帧为许多长期任务提供了足够的上下文。我们将它们定义为**基础视觉锚点**: 初始帧 (捕获不变的全局布局) 和短期历史窗口 (提供局部运动线索)。虽然这些启发式锚有效地解决了结构简单、需要记忆的任务, 但它们在复杂的交互场景中从根本上失败了, 在这些场景中, 任务关键型证据意外出现并随后消失。例如, 机器人在提起不透明的盖子时可能会短暂观察物体的颜色, 或者需要跟踪随后被遮挡的指定目标。这种短暂的视觉证据无法从初始或最近的帧中恢复; 它表现为必须主动捕获和保存的交互式 *sparse event*。

基于这一见解, 我们引入了 EventVLA, 这是一个植根于稀疏视觉证据记忆的端到端框架。EventVLA 通过将基础视觉锚点与动态关键帧证据记忆 (KEM) 模块无缝结合来消除历史冗余。与严格的、基于规则的启发式方法不同, KEM 建立了一种自主的、数据驱动的机制, 旨在主动捕获瞬态、交互驱动的事件。具体来说, 通过在即将到来的执行范围内执行前瞻性驱动的关键帧预测, KEM 使 VLA 策略能够主动调度关键中间状态的稀疏内存写入。这种预测策略确保在任务明确需要瞬态视觉证据之前就捕获它们, 从而无缝地弥合其短暂出现和最终在下游执行中使用之间的时间间隙。为了在没有令人望而却步的手动注释的情况下学习这种功能, 我们开发了一个基于 Qwen3-VL [15] 的离线自动标记管道, 可以从演示中提取精确的关键帧监督。

除了算法设计之外, 评估记忆增强策略还需要能够准确捕捉现实世界操作中的非马尔可夫动态的基准, 其中任务关键型证据通常仅在中间交互过程中短暂显现。由于像 RMBench [8] 这样的现有基准在很大程度上可以仅通过基本的视觉锚点来解决, 因此我们引入了 RoboTwin-Mem,

明确具有这种真正的非马尔可夫场景的诊断模拟基准。它包含 8 项具有挑战性的任务，其中所需的中间关键帧系统地从 1 扩展到 5。广泛的评估证明了 EventVLA 在不同领域的优越性。它在传统的面向内存的任务上树立了新的最先进水平（RMBench 上为 67.8%），并在新的需要瞬态内存的 RoboTwin-MeM 上实现了 75.2% 的平均成功率，远远优于现有的基于内存的 VLA。此外，在要求严格的现实世界双手任务中，EventVLA 显著超越了反应性 ($\pi_{0.5}$ [1]) 和记忆增强 (π_{MEM} [9]) 基线，成功率高达 80%，证实了其强大的非马尔可夫态势感知能力。

2 相关工作

2.1 用于长视野操作的记忆增强策略

最近的视觉-语言-动作（VLA）基础模型[1,2,16,17,5,3,4,18,19,20,21,22,23,24,25]实现了显著的通用性，但基本上是无记忆的。它们在严格的马尔可夫假设下运行，难以处理关键视觉信息短暂或被遮挡的非马尔可夫任务。为了解决这个问题，内存增强 VLA 已经出现在三种范式中。首先，*dual-system Memory-VLAs* [7,8,9,26,27]使用高级 VLM 进行规划，但会遭受错误传播和高推理延迟的影响。其次，*recurrent memory architectures* [10,11,28,29,30]将历史压缩为隐藏状态，从而创建丢弃细粒度视觉细节的信息瓶颈。第三，*Memory Buffers* [31, 12, 13, 32, 33, 34, 14]保留历史帧以绕过压缩；然而，现有的方法盲目地积累冗余帧，淹没了稀疏的关键证据并产生沉重的开销。EventVLA 通过仅保留稀疏的视觉证据来优化此范例。通过将静态 *visual anchors* 与动态 *Keyframe Evidence Memory (KEM)* 相结合，EventVLA 有选择地捕获瞬态，平衡稳健的任务执行与实时计算效率。

2.2 面向内存的操作基准

标准模拟套件 [35,36,37,38,39] 强调长期执行而不是显式内存推理，因为任务相关信息通常保持持续可见。虽然最近以记忆为中心的基准测试 [40,41,42,43,44] 试图解决这个问题，但它们通常规模有限，专门为强化学习量身定制，或者仍然具有可观察的状态。与我们最接近的套件，RMBench [8] 和 RoboMME [6]，系统地分层了内存需求，但很大程度上可以仅通过静态视觉锚点来解决，而严格的非马尔可夫中间状态尚未得到充分探索。为了弥补这一方法论差距，我们引入了 RoboTwin-MeM。与现有基准不同，RoboTwin-MeM 隔离了真正的非马尔可夫操纵任务，其中关键视觉证据在交互过程中短暂出现并随后消失，提供了严格的诊断平台来评估 VLA 策略的中间状态保留能力。

3 事件VLA框架

3.1 问题表述和基础视觉定位

或斯

我们将长视野机器人操作形式化为非马尔可夫决策过程。标准反应式 VLA 策略将当前观察 o_t 和语言指令 l 直接映射到操作，即 $a_t = \pi(o_t, l)$ ，当关键信息随着时间的推移变得被遮挡或不可观察时，该策略从根本上失败。为了解决这个问题，EventVLA 结合了一个显式的外部稀疏视觉证据内存缓冲区 M_t 来条件操作生成以及即时观察：

$$a_t = \pi(o_t, M_{t-1}, l) \quad (1)$$

其中 M_{t-1} 有选择地存储关键历史帧以保留必要的视觉证据，同时最大限度地减少信息和计算冗余。

内存缓冲区的结构为 $M_t = A_t \cup E_t$ ，无缝地结合了基础 *visual anchors* A_t 和交互驱动的事件关键帧 E_t 。视觉锚点 A_t 表示确定性的、基于规则的基线，旨在捕获永久场景布局 and 即时时间上下文。具体来说，时间步 t 处的视觉锚点由初始工作空间配置 o_0 和大小为 K 的短期历史滑动窗口组成：

$$A_t = o_0 \cup o_{t-K}, \dots, o_{t-1} \quad (2)$$

这里，初始帧 o_0 用作永久空间锚点，允许 VLA 模型在发生任何位移之前保留原始场景布置的不变记忆。同时，短期历史记录 o_{t-i} 为模型提供了关键动作和任务进展线索，从而实现平稳、连续的动作生成。然而，由于这些刚性锚点无法捕获复杂交互过程中出现的不可预测的瞬态证据，因此它们通过关键帧证据记忆（KEM）模块生成的 E_t 动态增强，如第 3.2 节所述，整体框架如图 2 所示。

3.2 关键帧证据记忆（KEM）模块

为了主动捕捉基础视觉锚点本质上错过的瞬态、交互驱动的事件，例如被遮挡物体的短暂曝光，我们引入了关键帧证据记忆（KEM）模块。为了有效地实现这一机制，KEM 被设计为一个轻量级的并行预测头，直接与主要动作头一起运行。关键帧预测头不是利用孤立的特征，而是摄取从 VLA 自回归变压器的最后一层提取的精确隐藏状态 $h_t \in \mathbb{R}^{H \times d}$ ，作为动作范围 H 。由于 h_t 自然地封装了视觉观察和动作条件查询标记的联合嵌入，因此关键帧头继承了对模型未来执行计划的主动感知。具体来说，关键帧头将这些共享隐藏状态 h_t 投影到向量




图 2：EventVLA 框架。EventVLA 维护由基础视觉锚点和交互驱动的事件关键帧组成的稀疏视觉证据记忆，并使用 KEM 模块主动将关键任务的未来关键观察结果提交到记忆中。

跨越未来块范围 H 的关键帧概率 $\hat{\mathbf{p}}_t$ ：

$$\hat{\mathbf{p}}_t = \sigma(\text{KEM}_{\text{mlp}}(h_t)) = [\hat{p}_t^1, \hat{p}_t^2, \dots, \hat{p}_t^H]^T \in [0, 1]^H \quad (3)$$

其中 $\sigma(\cdot)$ 表示逐元素 sigmoid 函数，每个标量 $\hat{p}_t^i \in [0, 1]$ 明确表示第 i 个未来执行步骤是任务关键关键帧的预测概率。这种分块预测的基本原理很简单：纯粹的逐步分类器将完全错过在执行窗口中途短暂出现和消失的任务关键事件（例如，在步骤 $t+i$ 处，其中 $0 < i < H$ ）。这一限制促使 KEM 采用前瞻性驱动的分块范式 $\hat{\mathbf{p}}_t$ ，使 VLA 策略能够在整个即将到来的执行范围内主动制定“内存调度”。

在此预测向量 $\hat{\mathbf{p}}_t$ 的驱动下，只要预测概率超过阈值 ($\hat{p}_t^i \geq \tau_{\text{commit}}$)，EventVLA 就会触发稀疏内存写入 *event*，动态提交原始图像




图 3: RoboTwin-MeM 基准测试中 8 项评估任务的概述。为了严格评估中间视觉证据保留的能力，每个任务都通过 n (范围从 1 到 5) 进行显式参数化，表示必须记住才能成功的瞬态、交互驱动的关键帧的确切数量。这些任务关键型中间事件以蓝色边框突出显示。

在 $t + i$ 到事件缓冲区 E_t 。为了满足实时约束， E_t 受到最大容量 $N_{\max}$ 的限制，通过先进先出 (FIFO) 驱逐策略进行管理。在任何执行步骤 t 中，这些动态累积的事件关键帧 E_{t-1} 与基础视觉锚点 A_t 和即时观察 o_t 无缝组合成单个按时间排序的序列：

$$I_{\text{input}} = \text{concatenate}([A_t, E_{t-1}, o_t]) \quad (4)$$

将这个统一的序列直接输入到 VLM 的视觉编码器中，使自注意力层能够动态提取稀疏历史帧中的复杂时间相关性，从而本身赋予模型强大的态势感知能力，以进行长视野操作。

3.3 端到端训练和推理细节

为了在没有高昂的手动注释成本的情况下训练 KEM 模块，我们采用离线 Qwen3-VL [15] 自动化管道来提取任务关键事件的真实时间戳。为了减轻物理交互固有的时间模糊性，我们通过序列平均 BCE 目标 (L_{kem}) 使用时间平滑的软标签来监督分块关键帧预测。该框架与标准动作生成损失一起进行了端到端优化 (L_{action})：

$$L = L_{\text{action}} + \lambda L_{\text{kem}} \quad (5)$$

为了弥合训练与测试分布的转变，同时保持早期训练的稳定性，我们应用了预定的师生课程，逐渐将记忆构建从真实情况过渡到自主预测。在在线推理过程中，连续关键帧概率自然地聚集在展开的语义事件周围。为了强制实施严格的内存稀疏性并防止冗余缓冲区泛洪，我们使用一维非极大值抑制 (NMS) 和时间冷却管道将这些密集预测提炼为离散写入事件。有关软标签、课程、NMS 算法和自动标记管道的综合数学公式请参见附录 A。此外，附录 B.3 详细介绍了完整的网络结构和训练配置。

4 RoboTwin-MeM 基准测试

为了系统地评估 VLA 策略捕获和保留瞬时视觉证据的能力，我们引入了 RoboTwin-MeM，一种诊断模拟基准。在 RoboTwin 2.0 [35] 模拟平台内开发，并构建在 SAPIEN [45] 物理引擎之上，

RoboTwin-MeM 支持统一管道内的自动数据合成和集成策略评估。该基础设施确保可扩展的数据生成以及一致的、可重复的机器人操作基准测试。此外，我们提供与每个动作观察对严格对齐的细粒度语言注释。这些注释为低级交互和状态转换分配了明确的语言描述，提供了结构化且密集的监督信号，这对于训练下游记忆模块非常有益。

RoboTwin-MeM 与现有以内存为中心的套件之间的核心区别在于其对中间内存需求的显式隔离和量化。虽然以前的基准通常允许策略仅依靠初始静态锚点或短期历史来取得成功，但 RoboTwin-MeM 迫使模型主动记住执行中途生成的不可预测的视觉证据。为了严格诊断此功能，我们使用 n 显式参数化任务复杂性：必须动态保留的中间事件关键帧的确切数量。如图 3 所示，RoboTwin-MeM 包含 8 个真正的非马尔可夫任务，具有极长的执行范围，平均每集 430 到 1544 步。在整个基准测试中，所需的中间关键帧计数 n 系统地范围从 1 到 5，为非马尔可夫控制建立了分层难度层次结构。详细的任务统计数据 and 语言说明见表 4。

至关重要的是，这种 n 参数化设计使 RoboTwin-MeM 能够评估除简单历史串联之外的各种内存功能。首先，像 *Pick the Unhidden Block* ($n = 3$) 和 *Cover Blocks Hard* ($n = 4$) 这样的任务需要 *transient memory*；当盖子被揭开时，重要的视觉证据会短暂暴露出来，一旦关闭，就会完全消失，需要政策立即锚定这些转瞬即逝的信息。其次，基准测试通过 *Press Button Keyframe* ($n \in [2, 5]$) 等任务评估序列跟踪和计数逻辑，其中每次按下按钮都代表一个执行关键事件，必须按顺序注册该事件才能指示任务成功。最后，*Reproduce Route* 任务 ($n = 4$) 测试模型的 *in-context learning* 能力，要求代理观察演示，提取随机空间关键点，并在上下文中利用这些线索来复制路线。瞬态识别、事件计数和上下文模仿的覆盖范围使 RoboTwin-MeM 成为评估记忆增强机器人策略的严格基准。

5 实验

5.1 仿真基准性能

为了彻底评估 EventVLA 的功效，我们将我们的框架与一整套最先进的基线进行基准测试，分为两个主要范式。对于标准的反应性（非基于内存的）VLA 策略，我们选择 DP [3]、ACT [5]、 $\pi_{0.5}$ [1]、X-VLA [17] 和 QwenOFT [46]。对于内存增强方法，我们评估双系统架构，包括 MemER [7] 和 Mem-0 [8]，以及端到端 MemoryVLA [12] 框架，我们根据官方 OpenVLA-OFT [47] 和 QwenOFT [46] 实现重现其变体。我们提出的 EventVLA 也是基于相同的开源 QwenOFT 主干作为其基础模型构建的。

对 RMBench 和视觉锚点功效的评估：首先，我们在 RMBench [8] 上评估我们的方法，如表 1 所示。由于该套件中的任务主要依赖于持久空间布局和固定运动风格，而不是隐藏的中间状态，因此我们仅利用基础视觉锚点部署了 EventVLA 的简化版本。前任-

实验结果表明，这种配置的平均成功率为 67.8%，确保了最先进的性能，并证明基于规则的锚点提供了足够的上下文

表 1: RMBench 的总体平均成功率。详细的每项任务细分参见附录表 8。

Methods	Average (%)
<i>Non Memory-based VLAs</i>	
DP	5.8
ACT	5.9
$\pi_{0.5}$	10.4
X-VLA	9.8
QwenOFT	5.6
<i>Dual-system Memory-VLAs</i>	
MemER	8.7
Mem-0	42.0
<i>End-to-end Memory-VLAs</i>	
MemoryVLA (OpenVLA)	19.4
MemoryVLA (QwenOFT)	41.7
<i>EventVLA & Ablations</i>	
EventVLA (w/o initial)	33.7
EventVLA (w/o short-term)	23.8
EventVLA (VA only)	67.8

表 2: RoboTwin-MeM 基准测试结果。（粗体：最好；下划线：第二好）。

Tasks	n=1	n=2	n=3		n=4			n=5	Total average
	Rearrange Blocks Hard	Put Back Block Hard	Pick Objects in Order	Pick the Unhidden Block	Cover Blocks Hard	Find Seal Stamp	Reproduce Route	Press Button Keyframe	
▼ Non Memory-based Vision-language-action Models:									
$\pi_{0.5}$	20%	19%	1%	14%	0%	8%	0%	0%	7.8%
QwenOFT	3%	26%	0%	0%	0%	0%	0%	1%	3.8%
▼ Dual-system Memory-based Vision-language-action Models:									
MemER	32%	4%	12%	2%	0%	26%	3%	5%	10.5%
Mem-0	0%	0%	0%	0%	0%	0%	0%	0%	0.0%
▼ End-to-end Memory-based Vision-language-action Models:									
Memory VLA (OpenVLA)	12%	0%	0%	1%	0%	10%	2%	14%	4.9%
Memory VLA (QwenOFT)	39%	0%	1%	9%	1%	11%	0%	25%	10.8%
EventVLA (VA only)	62%	13%	5%	20%	0%	26%	0%	18%	18.0%
EventVLA (VA+KEM)	62%	93%	90%	54%	94%	63%	98%	48%	75.2%
EventVLA (implicit memory bank)	51%	9%	16%	37%	1%	68%	2%	15%	24.9%
EventVLA (hard label)	59%	77%	28%	62%	85%	36%	6%	37%	48.8%
EventVLA (w/o NMS)	62%	93%	49%	36%	10%	35%	97%	45%	53.4%
EventVLA ($N_{\max} = 2$)	51%	35%	28%	33%	39%	53%	0%	17%	32.0%
EventVLA (chunk size=30)	22%	98%	18%	28%	16%	29%	0%	38%	31.1%
EventVLA (chunk size=15)	16%	30%	2%	17%	6%	16%	10%	12%	13.6%

用于简单的需要内存的长视野操作。为了验证这些组件的结构必要性，我们进行了两项消融研究。删除初始帧（EventVLA w/o initial）或丢弃短期历史记录（EventVLA w/o Short-term）会导致整体成功率分别骤降至 33.7% 和 23.8%。这证实了初始全局空间参考和短期运动线索对于有效的视觉锚定都是不可或缺的。

对 RoboTwin-MeM 的评估和 KEM 的必要性：虽然基础视觉锚在 RMBench 上表现出色，但在 RoboTwin-MeM（我们的诊断套件专门设计用于测试中间状态记忆）上进行评估时，它们的局限性变得非常明显。如表 2 所示，仅依靠规则驱动的视觉锚点（仅限 VA）的平均成功率仅为 18.0%。这种急剧下降表明，固定的历史窗口从根本上不足以满足需要 VLA 策略保留执行过程中生成的瞬时视觉证据的任务。为了克服这一非马尔可夫瓶颈，完整的 EventVLA 框架通过动态关键帧证据记忆 (KEM) 模块 (VA+KEM) 增强了这些视觉锚点。实验结果揭示了质的飞跃：完整的 EventVLA 实现了 75.2% 的成功率，大幅优于所有基线模型。这种惊人的性能增量（从 18.0% 到 75.2%）令人信服地表明，KEM 的动态事件捕获和预见驱动的写入机制对于解决依赖于瞬时中间存储器的复杂、长期任务是不可或缺的。

标准马尔可夫基准评估：

为了验证 EventVLA 保留基本的反应控制，我们在 RoboTwin-2.0 [35]（表 3）中的标准马尔可夫任务上对其进行评估。我们的内存机制并没有降低性能，而是略微提高了无内存 QwenOFT 基线的成功率（Easy 上为 80.0% 到 83.8%；Hard 上为 78.0% 到 81.6%），无缝补充了标准闭环执行。

表3: RoboTwin2.0基准测试结果。Event VLA 在马尔可夫任务上优于其基线基础模型 QwenOFT。

Tasks	π_0	$\pi_{0.5}$	X-VLA	QwenFast	QwenOFT	EventVLA
Easy	65.9%	82.7%	72.8%	72.5%	80.0%	83.8%
Hard	58.4%	76.8%	72.8%	83.2%	78.0%	81.6%

5.2 EventVLA的消融分析

为了系统地验证关键帧证据记忆 (KEM) 模块的结构设计，我们对具有挑战性的 RoboTwin-MeM 套件进行了消融研究（表 2，底部为灰色）。

核心机制：我们观察到，用隐式潜在在记忆库替换显式原始图像串联会导致成功率从 75.2% 急剧下降至 24.9%，从而造成严重的信息瓶颈。同样，用刚性二元目标替换时间平滑的软标签会破坏预测头的稳定性，将性能降低至 48.8%。

缓冲区和水平线管理：删除 NMS 后处理或限制缓冲区容量 ($N_{\max} = 2$) 会导致冗余帧泛洪和关键早期的 FIFO 过早驱逐




图 4: ARX ACONE 双手机器人的真实实验设置和结果。我们评估四个内存密集型操作任务：*Find Block Easy*、*Find Block Hard*、*Pick-X-Times* 和 *Pick in Order*。

证据，成功率分别降至 53.4% 和 32.0%。最后，缩小执行块大小（从 50 到 30 或 15）会严重截断 KEM 的预见窗口，阻止主动事件调度并将性能骤降到 31.1% 和 13.6%。

对这些消融模式的全面深入分析以及实时推理速度分析将在附录 C.2 中进行。

5.3 现实世界的机器人评估

为了在物理环境中评估 EventVLA，我们在 ARX ACONE 双手机器人上部署了我们的框架，涵盖了四个非马尔可夫操作任务，每个任务都经过了 20 多个独立试验。这些任务明确评估现实世界设置下的不同认知记忆能力：1) **Find Block Easy** 和 **Find Block Hard** 要求模型仅在短暂的视觉暴露后记住隐藏块的空间位置。2) **Pick-X-Times** 测试计数逻辑，要求机器人读取随机数并相应地操作块。3) **Pick in Order** 通过要求机器人重现最初由一根棍子指出的随机序列来评估上下文记忆。我们针对最先进的非内存模型 $\pi_{0.5}$ [1] 和重现的内存增强基线 π_{MEM} [9] 对 EventVLA 进行了基准测试。

如图 4 所示，纯反应式 $\pi_{0.5}$ 策略在所有任务中几乎完全失败（仅实现 0% 到 10% 的成功率），因为它从根本上缺乏推断遮挡状态所需的历史背景。虽然内存增强的 π_{MEM} 基线展示了部分改进（例如，在 *Find Block Easy* 上提高了 50%），但由于长期历史记录的有效压缩，其性能在更复杂的多事件需求任务（例如 *Pick-X-Times* (30%) 和 *Pick in Order* (40%)）上显着下降。与此形成鲜明对比的是，EventVLA 在这四项任务中分别实现了 90%、60%、90% 和 75% 的成功率。这种强大的物理性能验证了 KEM 模块可以有效地提取和保留关键的瞬态视觉线索，从而使 VLA 模型能够在现实世界中具有长视野记忆感知能力。

6 局限性

虽然 EventVLA 有效地捕获瞬态视觉证据，但其有限的事件缓冲区限制了具有高事件密度的超长视野任务（例如，> 10 分钟）的可扩展性。这种情况可能会导致缓冲区饱和和过早驱逐早期历史线索。未来的工作将探索分层内存或压缩表示来管理大量事件序列。

7 结论

我们引入了 EventVLA，这是一个端到端框架，通过稀疏视觉证据记忆来处理非马尔可夫长视野操纵。通过将基于规则的视觉锚点与前瞻性驱动的关键帧证据内存（KEM）模块相结合，EventVLA 主动捕获任务关键型瞬态事件，完全避免了密集内存的冗余。此外，我们提出了 RoboTwin-MeM，一种用于评估中间存储器功能的诊断基准。对 17 个模拟和 4 个实际任务的广泛评估表明，EventVLA 的性能显著优于最先进的内存增强 VLA，确保了需要内存的长范围物理执行的稳健性。

致谢

蒂 工作得到上海人工智能实验室支持

保守党。

参考

- [1] P. Intelligence、K. Black、N. Brown、J. Darpinian、K. Dhabalia、D. Driess、A. Esmail、M. Equi、C. Finn、N. Fusai 等人。 $\pi_{0.5}$ ：具有开放世界泛化的视觉-语言-动作模型。 *arXiv preprint arXiv:2504.16054*, 2025. [2] P. Intelligence、A. Amin、R. Aniceto、A. Balakrishna、K. Black、K. Conley、G. Connors、J. Darpinian、K. Dhabalia、J. DiCarlo 等人。 $\pi_{0.6}^*$ ：从经验中学习的vla。 *arXiv preprint arXiv:2511.14759*, 2025. [3] C. Chi、Z. Xu、S. Feng、E. Cousineau、Y. Du、B. Burchfiel、R. Tedrake 和 S. Song。扩散政策：通过行动扩散进行视觉运动政策学习。 *The International Journal of Robotics Research*, 44(10-11):1684–1704, 2025. [4] Y. Ze, G. 张, K. 张, C. Hu, M. Wang, 和 H. Xu. 3d 扩散策略：通过简单的 3d 表示进行可推广的视觉运动策略学习。 *arXiv preprint arXiv:2403.03954*, 2024 年。 [5] T.Z.Zhao、V.Kumar、S.Levine 和 C.Finn。使用低成本硬件学习细粒度双手操作。 *arXiv preprint arXiv:2304.13705*, 2023. [6] Y. Dai、H. Fu、J. Lee、Y. Liu、H. Zhang、J. Yang、C. Finn、N. Fazeli 和 J. Chai。Robomme：机器人通才策略的基准测试和理解内存。 *arXiv preprint arXiv:2603.04639*, 2026 年。 [7] A. Sridhar、J. Pan、S. Sharma 和 C. Finn。M emer：通过经验检索扩大机器人控制的内存。 *arXiv preprint arXiv:2510.20328*, 2025. [8] T. Chen, Y. Wang, M. Li, Y. qin, H. Shi, Z. Li, Y. Hu, Y. Zhang, K. Wang, Y. Chen, et al. Rmbench：依赖于内存的机器人操作基准，具有对策略设计的见解。 *arXiv preprint arXiv:2603.01229*, 2026. [9] M. Torne、K. Pertsch、H. Walke、K. Vedder、S. Nair、B. Ichter、A. Z. Ren、H. Wang、J. Tang、K. Stachowicz 等人。Mem：视觉语言动作模型的多尺度具身记忆。 *arXiv preprint arXiv:2603.03596*, 2026 年。
- [10] 肖立，李建，高建，叶芳，金玉，钱建，张建，吴勇，余旭。Ava-vla：通过主动视觉注意改进视觉-语言-动作模型。 *arXiv preprint arXiv:2511.18960*, 2025 年。
- [11] A.布拉托夫、Y.库拉托夫和M.布尔采夫。循环记忆变压器。 *Advances in Neural Information Processing Systems*, 35: 11079–11091, 2022。

- [12] 石浩, 谢本, 刘勇, 孙丽, 刘凤, 王天, 周鄂, 范浩, 张晓, 黄刚。Memoryvla: 机器人操作的视觉语言动作模型中的感知认知记忆。 *arXiv preprint arXiv:2508.19236*, 2025 年。
- [13] 李红, 杨树, 陈宇, 田宇, 杨晓, 陈晓, 王华, 王天, 赵峰, 林德, 等。Cronusvla: 跨时间传输潜在运动, 以进行操作中的多帧预测。 *arXiv e-prints*, 第 arXiv-2506 页, 2025 年。
- [14] 王X., 高X., 付J., 李Z., D. Fortier, G. Mullins, A. Kolobov, B. 郭。Lola: 用于一般机器人操作的长视野潜在动作学习。 *arXiv preprint arXiv:2512.20166*, 2025 年。
- [15] 白圣, 蔡阳, 陈瑞, 陈凯, 陈晓, 程子, 邓立, 丁伟, 高长, 葛长, 等。Qwen3-vl技术报告。 *arXiv preprint arXiv:2511.21631*, 2025 年。
- [16] 刘胜, 李斌, 马凯, 吴丽, 谭浩, 欧阳旭, 苏浩, 朱建。Rdt2: 探索 umi 数据对零样本跨实施例泛化的扩展限制。 *arXiv preprint arXiv:2602.03310*, 2026 年。
- [17] 郑家, 李家, 王正, 刘东, 康旭, 冯玉, 郑玉, 邹家, 陈玉, 曾家, 等。X-vla: 软提示变压器作为可扩展的跨实施视觉-语言-动作模型。 *arXiv preprint arXiv:2510.10274*, 2025 年。
- [18] 陈涛, 穆玉, 梁子, 陈子, 彭胜, 陈强, 徐明, 胡瑞, 张华, 李晓, 等。G3flow: 用于姿势感知和通用对象操作的生成 3D 语义流。在 *Proceedings of the Computer Vision and Pattern Recognition Conference*, 第 1735–1744 页, 2025 年。
- [19] 文建, 朱勇, 李建, 唐子, 沉春, 冯锋。Dexvla: 带有插件扩散专家的视觉语言模型, 用于通用机器人控制。 *arXiv preprint arXiv:2502.05855*, 2025 年。
- [20] 林明, 丁平, 王胜, 庄子, 刘勇, 童晓, 宋文, 吕胜, 黄胜, 王德。Hif-vla: 通过视觉-语言-动作模型的运动表示进行后见之明、洞察力和远见。 *arXiv preprint arXiv:2512.09928*, 2025 年。
- [21] 梁志强, 李勇, 杨涛, 吴成, 毛胜, 年涛, 裴丽, 周胜, 杨旭, 庞建, 等。离散扩散 vla: 将离散扩散引入视觉-语言-动作策略中的动作解码。 *arXiv preprint arXiv:2508.20072*, 2025 年。
- [22] 杨国强, 张涛, 郝华, 王伟, 刘勇, 王东, 陈国强, 蔡志强, 陈杰, 苏伟等。Vlaser: 具有协同体现推理的视觉-语言-动作模型。 *arXiv preprint arXiv:2510.11027*, 2025 年。
- [23] 沉文, 刘勇, 吴勇, 梁子, 顾思, 王东, 年天, 徐立, 秦勇, 庞建, 等。专业知识不需要垄断: 视觉-语言-动作学习专家的行动专业组合。 *arXiv preprint arXiv:2510.14300*, 2025 年。
- [24] 文建, 朱勇, 朱明, 唐子, 李建, 周子, 刘旭, 沉成, 彭勇, 冯锋。Diffusionvla: 通过统一扩散和自回归缩放机器人基础模型。在 *Forty-second International Conference on Machine Learning*, 2025 年。
- [25] 文建, 朱勇, 李建, 朱明, 唐子, 吴克, 徐子, 刘娜, 程荣, 沉成, 等。Tinyvla: 面向机器人操作的快速、数据高效的视觉语言动作模型。 *IEEE Robotics and Automation Letters*, 2025 年。
- [26] R.郑, Y.梁, S.黄, J.高, H.Daumé III, A.Kolobov, F.黄, J.杨。Tracevla: 视觉跟踪提示增强了通用机器人策略的时空意识。在 *International Conference on Learning Representations*, 2025 年卷, 第 54277–54296 页, 2025 年。

- [27] H. Tan, P. Co, Y. Xu, S. Rong, Y. Ji, C. Chi, X. Chen, Q. Zhang, Z. Zhao, P. Wang, et al. 动作草图: 通过视觉草图进行长视野机器人操作, 从推理到行动。 *arXiv preprint arXiv:2601.01618*, 2026 年。
- [28] 王浩, 静子, 敖建, 宋思, 李晓, 黄光, 白成。超越短视界: Vq-内存可在非马尔可夫模拟基准中实现稳健的长视界操作。 *arXiv preprint arXiv:2603.09513*, 2026 年。
- [29] M. Torne, A. Tang, Y. Liu 和 C. Finn。通过过去的代币预测来学习长上下文扩散策略。 *arXiv preprint arXiv:2505.09561*, 2025 年。
- [30] Y.-L. Wei, H. Liao, Y. Lin, P. Wang, Z. Liang, G. Liu, 和 W.-S. 郑。Cyclemanip: 通过有效的历史感知和理解实现循环任务操作。 *arXiv preprint arXiv:2512.01022*, 2025。 [31] H. Jang, S. Yu, H. Kwon, H. Jeon, Y. Seo 和 J. Shin。Contextvla: 具有摊销多帧上下文的视觉-语言-动作模型。 *arXiv preprint arXiv:2510.04246*, 2025 年。
- [32] 林明, 梁X., 林B., L.敬之, 焦子, 李K., 马Y., 刘Y., 赵S., 庄Y., 等。Echovla: 具有用于移动操作的协同陈述性记忆的机器人视觉-语言-动作模型。 *arXiv preprint arXiv:2511.18112*, 2025 年。
- [33] 雷勇, 梁志强, 张浩, 罗鹏。Vpwem: 具有工作记忆和情景记忆的非马尔可夫视觉运动策略。 *arXiv preprint arXiv:2603.04910*, 2026 年。
- [34] L. Tan, J. Li, G. Jing。Memoact: 阿特金森希弗林启发的机器人操作记忆增强视觉运动策略。 *arXiv preprint arXiv:2603.18494*, 2026 年。
- [35] 陈涛, 陈子, 陈本, 蔡子, 刘勇, 李子, 梁Q, 林X, 葛Y, 顾子, 等。Robotwin 2.0: 可扩展的数据生成器和基准, 具有强大的域随机化功能, 可实现稳健的双手机器人操作。 *arXiv preprint arXiv:2506.18088*, 2025 年。
- [36] S. Nasiriany, A. Maddukuri, L. 张, A. Parikh, A. Lo, A. Joshi, A. Mandlekar 和 Y. Zhu。Robocasa: 通用机器人日常任务的大规模模拟。 *arXiv preprint arXiv:2406.02523*, 2024 年。
- [37] S.Tao, F.Xiang, A.Shukla, Y.Qin, X.Hinrichsen, X.Yuan, C.Bao, X.Lin, Y.Liu, T.-k. 陈, 等人。Maniskill3: GPU 并行机器人模拟和渲染, 用于通用化的具体化人工智能。 *arXiv preprint arXiv:2410.00425*, 2024 年。
- [38] C. Li, R. 张, J. Wong, C. Gokmen, S. Srivastava, R. Martín-Martín, C. Wang, G. Levine, M. Lingelbach, J. Sun 等。Behaviour-1k: 体现人工智能的基准, 具有 1,000 项日常活动和真实模拟。在 *Conference on Robot Learning* 中, 第 80-93 页。PMLR, 2023。
- [39] X. Li, K. Hsu, J. Gu, K. Pertsch, O. Mees, H. R. Walke, C. Fu, I. Lunawat, I. Sieh, S. Kirmani 等人。在模拟中评估现实世界的机器人操纵策略。 *arXiv preprint arXiv:2405.05941*, 2024 年。
- [40] H. Fang, M. Grotz, W. Pumacay, Y. R. Wang, D. Fox, R. Krishna 和 J. Duan。Sam2act: 将视觉基础模型与机器人操作的内存架构集成。 *arXiv preprint arXiv:2501.18564*, 2025 年。
- [41] E. Cherepanov, N. Kachaev, A. K. Kovalev 和 A. I. Panov。内存、基准测试和机器人: 通过强化学习解决复杂任务的基准测试。 *arXiv preprint arXiv:2502.10550*, 2025 年。
- [42] B.刘, Y.朱, C.高, Y.冯, Q.刘, Y.朱, P.斯通。Libero: 机器人终身学习知识转移的基准测试。 *Advances in Neural Information Processing Systems*, 36: 44776–44791, 2023。

[43] 韩S., 邱B., 廖Y., 黄S.黄, C.高, S.严, 和S.刘。Robocerebra: 长视野机器人操作评估的大型基准。 *Advances in Neural Information Processing Systems*, 38, 2026. [44] 雷海、宋伟、张海、裴杰、陈杰、严海、赵海、丁平、张志、黄丽等。Robomemarena: 全面且具有挑战性的机器人记忆基准测试。 *arXiv preprint arXiv:2605.10921*, 2026. [45] 向芳, 秦玉, 莫克, 夏玉, 朱华, 刘芳, 刘明, 江华, 袁宇, 王华, 等。Sapien: 基于部件的模拟交互环境。 *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 第 11097–11107 页, 2020 年. [46] S. Community。Starvla: 用于视觉-语言-动作模型开发的类似乐高的代码库。 *arXiv preprint arXiv:2604.05014*, 2026. [47] M. J. Kim、C. Finn 和 P. Liang。微调视觉-语言-动作模型: 优化速度和成功。 *arXiv preprint arXiv:2502.19645*, 2025. [48] W. Kwon、Z. Li、S. Zhuang、Y. Shen、L. Cheng、C. H. Yu、J. E. Gonzalez、H. Zhang 和 I. Stoica。通过 pagedattention 服务的大型语言模型的高效内存管理。在 *Proceedings of the ACM SIGOPS 29th Symposium on Operating Systems Principles*, 2023 年。

附录

A EventVLA的实现细节

A.1 培训制定和课程策略

为了获得真实 (GT) 关键帧监督，我们利用由 Qwen3-VL [15] 提供支持的离线自动标记管道。通过解析原始演示视频和任务描述，VLM 提取任务关键中间事件的准确时间戳，表示为 t^* 。然而，在物理机器人执行中，关键帧语义本质上表现出时间模糊性——紧邻 t^* 之前或之后的帧通常对于捕获视觉证据同样有效。为了防止严格的二元监督引起的噪声梯度，我们利用升余弦核将注释平滑到软目标向量 $\mathbf{y}_t \in [0, 1]^H$ 中。具体地，对于 GT 事件 t^* 的膨胀半径 R 内的未来步骤 i ，软目标被定义为 $y_t^i = 0.5(1 + \cos(\pi \frac{|t+i-t^*|}{R}))$ 。

为了根据这些时间平滑注释监督分块关键帧预测，我们将关键帧证据记忆损失 L_{kem} 制定为序列平均二进制交叉熵 (BCE) 目标。这将整个未来行动范围 H 上的每个预测标量概率 $\hat{p}_t^i \in [0, 1]$ 与其相应的软目标 $y_t^i \in [0, 1]$ 明确对齐：

$$L_{\text{kem}} = -\frac{1}{H} \sum_{i=1}^H [y_t^i \log(\hat{p}_t^i) + (1 - y_t^i) \log(1 - \hat{p}_t^i)] \quad (6)$$

然后，通过将内存感知与精确的运动控制结合起来的联合目标，对整个框架进行端到端优化：

$$L = L_{\text{action}} + \lambda L_{\text{kem}} \quad (7)$$

其中 L_{action} 表示标准连续动作生成损失（例如，回归或流匹配），而 λ 用作平衡系数以适当缩放内存监督。

在训练期间，在早期阶段根据模型自身的预测动态构建事件缓冲区 E_t 会导致严重的训练不稳定，而完全依赖 GT 关键帧会引入关键的训练测试分布偏移，因为 GT 关键帧在测试时不可用。为了弥补这一差距，我们实施了预定的师生课程。我们引入了一个退火参数 α ，它在训练期间从 1 线性衰减到 0。在每一步中，框架都会决定是使用 GT 关键帧以概率 α (teacher-forcing) 向 E_t 提交观察，还是依靠其自己的阈值预测 ($\hat{p}_t^i \geq \tau_{\text{commit}}$) 以概率 $1 - \alpha$ 提交观察。这种逐步过渡确保了稳定的初始收敛，同时迫使 VLA 策略最终适应其自己的自主内存更新节奏。

A.2 在线推理和后处理

在在线推理过程中，分块预测 $\hat{\mathbf{p}}_t$ 自然会围绕展开的语义事件产生聚类的、时间连续的高概率分数。为了防止同一视觉事件的冗余帧淹没有界缓冲区 E_t ，我们通过严格的后处理提取管道将 H 维概率向量压缩为离散、稀疏的写入事件。

首先，我们通过应用置信阈值 τ_{commit} 和一维非极大值抑制 (NMS) 算法来识别一组局部概率峰值 $\mathcal{K}_t$ 。具体来说，如果未来步骤索引 i 的概率超过阈值并且表示半径为 w 的滑动时间窗口内的局部最大值，则选择该未来步骤索引 i 作为候选峰值：

$$\mathcal{K}_t = \left\{ i \in \{1, \dots, H\} \mid \hat{p}_t^i \geq \tau_{\text{commit}} \wedge \hat{p}_t^i = \max_{j \in \mathcal{N}_w(i)} \hat{p}_t^j \right\} \quad (8)$$

其中 $\mathcal{N}_w(i) = [\max(1, i - w), \min(H, i + w)]$ 表示 NMS 邻域。

虽然 NMS 有效隔离局部峰值，但快速连续事件仍可能触发过多的内存写入。为了严格执行操作稀疏性，评估时间冷却期 C

依次超过候选人。候选峰值 $i \in \mathcal{K}_t$ is officially validated and committed to E_t 当且仅当 $(t + i) - t_{\text{last}} > C$, 其中 t_{last} 表示最近提交的关键帧的绝对物理时间戳。通过这种级联提取机制, 该框架以数学方式将密集的预测景观提炼成最佳的、高度稀疏的子集。这保证了内存分配仍然严格依赖于新颖的交互证据, 最大限度地保留信息, 同时无缝地遵守实时执行约束和有界内存缓冲区大小 N_{max} 。

A.3 自动关键帧注释管道

为了规避与长期任务的密集手动帧注释相关的高昂成本, 我们开发了一种由大型视觉语言模型 (VLM) 提供支持的自动化、高度可扩展的关键帧标记管道。具体来说, 我们使用 vLLM [48]s 框架在配备 8 个 NVIDIA A800 GPU 的本地服务器上部署最先进的 Qwen3-VL-235B-A2 2B-Instruct-FP8 [15] 模型。

数据预处理和情境学习。我们不是将难以管理的长连续视频流直接输入 VLM, 而是将时间范围统一采样为一组离散的帧 (例如, 每集 128 帧)。为了确保强大的空间意识, 特别是在涉及严重遮挡的场景中, 我们为每个采样时间步长提取并连接多视图观察结果 (例如, 全局头部摄像头和手腕摄像头)。至关重要, 为了使 VLM 的输出与我们对瞬时视觉证据的具体定义保持一致, 我们采用了上下文学习 (ICL) 策略。该提示包括来自相同或相似任务的几个镜头演示, 包含采样帧及其真实关键帧步骤, 为时间对齐和 JSON 格式的输出建立严格的模板。

用于自动化管道的确切系统提示如下:

基于 VLM 的关键帧注释的系统提示

系统提示: 您是机器人视频关键帧注释专家。关键要求: - 注释必须严格遵循 `task_instruction`。- 将 `task_instruction` 视为主要目标定义; 如果视觉效果不明确, 请优先考虑与其的一致性。剧集元数据: - `episode_id`: <剧集 ID> - `task_instruction`: <任务说明> - `total_frames`: <总帧数> - `required_keyframe_count`: <关键帧数> - `provided_views`: <所选视图>

注释内容:

1. 找到该任务的关键状态转换 (例如, 获得稳定的抓取、放置物体、循环转换)。2. 在整个任务进程中保持关键帧的代表性和时间顺序。3. 对于重复的拾取/放置循环, 选择每个循环中最稳定和可识别的时刻。输出格式限制: 1. 仅返回 JSON。没有降价, 没有解释。2. 格式: { "关键帧步骤": [int, int, ...] } 3. `keyframe_steps` 必须: - 长度恰好为 `<num_keyframes>` - 严格递增 - 在 `[0, <total_frames - 1>]` 中 - 不包含重复项

注释可靠性和错误分析。为了严格验证该自动化管道的可靠性, 我们进行了全面的交叉验证研究。在模拟环境中, 我们将 Qwen3-VL-235B 模型自动注释的关键帧与直接从 RoboTwin 2.0 [35] 物理引擎获取的精确算法真实 (GT) 状态进行比较。结果表明, VLM 的预测表现出平均绝对时间误差小于 10 个时间步长。此外, 当部署到四个复杂的现实世界双手任务时, 与人工注释的地面实况相比, 预测误差保持在 50 个时间步以内。鉴于我们的评估片段具有极长的视野 (通常超过 1500 到 2000 步), 这种可以忽略不计的时间方差, 自然可以通过我们的时间平滑软

标签，有力地证实了我们由 VLM 驱动自动注释管道高度可靠、精确，并且可以进行可扩展部署。

B 实验设置和基准

B.1 RoboTwin-MeM 基准详细信息

Table 4: 我们提出的 RoboTwin-MeM Ben 的详细统计 标记。

Task Name	Episodes	Avg. #Steps	Intermediate Keyframes	Task Instruction
Press Button Keyframe	50	430	[2,5]	Read the two number cards, press the left button as many times as the left card shows, press the middle button as many times as the right card shows, then press the right button once.
Pick the Unhidden Block	50	699	3	Open the covers one by one to identify the hidden colors, close them after inspection, then pick up the visible block whose color is not hidden.
Rearrange Blocks Hard	50	879	1	Move a chosen block from its mat to the center and press the button, return the same block to its mat and press again, then move the other block to the center and press once more.
Pick Objects in Order	50	1124	3	Open the covers one by one to observe the objects inside, close them after inspection, then pick up the objects in the observed order.
Find Seal and Seal Stamp	50	1338	[1,4]	Open the covers one by one to find and take out the seal, close the cover after inspection, stamp with it, then return it under its original cover.
Reproduce Route	50	1417	4	Move the center red block to the four blue pads in a random order, returning it to the center. Then use the outside red block to repeat the same pad order.
Put Back Block Hard	50	1468	2	For each row, move the center block to a randomly selected outer pad in the same row, move the arm back, return the block to the center, move the arm back again, and press the button. Finally, move both blocks back to the same outer pads they first visited, then press the button.
Cover Blocks Hard	50	1544	4	Open the covers one by one, close them after inspection, then reopen them in the order: red, green, blue, yellow.

正如第 2 节中介绍的那样。正文第 4 部分中，RoboTwin-MeM 是一个诊断模拟套件，专门用于隔离和评估真正的非马尔可夫机器人操作。与工作空间状态持续可见的传统长视野环境不同，RoboTwin-MeM 强制执行严格的视觉遮挡和时间延迟。在这些任务中，关键的视觉证据，例如块的隐藏颜色、覆盖物下物体的身份或随机生成的空间序列，仅在中间交互过程中短暂显现，然后变得完全不可观察。

为了系统地量化记忆容量，RoboTwin-MeM 涵盖 8 项复杂的双手操作任务，执行范围极长，平均每集 430 到 1,544 步。每个任务的难度由 $n \in [1, 5]$ 显式参数化，它定义了




图 5: EventVLA 跨四个操作任务的扩展现实世界执行序列。策略自动捕获并提交到内存的特定任务关键中间关键帧以蓝色边框突出显示。

机器人必须自主捕获和保留以成功完成指令的中间关键帧事件的确切数量。

例如，像 *Cover Blocks Hard* ($n = 4$) 和 *Pick Objects in Order* ($n = 3$) 这样的内存密集型任务需要机器人抬起不透明的盖子来检查隐藏的属性，在盖子关闭后记住它们，并根据存储的内存执行后续的拾取和放置操作。类似地，*Press Button Keyframe* 要求机器人读取随机数字卡并将其转化为顺序计数和按压逻辑。如图 3 所示，这些瞬态、交互驱动的关键帧（以蓝色边框突出显示）充当过去观察和未来行动之间的关键信息桥梁。

全面的任务统计数据，包括平均步骤数、所需的中间关键帧计数 n 以及所有 8 个评估任务的特定语言指令，详细信息如表 4 所示。

B.2 现实世界任务细节

为了补充图 4 中提供的单帧任务概述，图 5 展示了四个现实世界操作任务的扩展的逐步时间序列。这些完整的执行展示准确地说明了物理交互过程中何时出现短暂的视觉证据。策略必须自主捕获并提交到其动态事件缓冲区的关键任务中间关键帧，例如短暂暴露隐藏块、读取随机数或观察棒指出的特定序列，均以蓝色边框明确突出显示。通过成功地隔离和保留这些稀疏状态，EventVLA 有效地弥补了非马尔可夫控制所需的时间间隙。

B.3 Network Architecture and Hyper-parameters

对于RMBench和RoboTwin-MeM，我们的EventVLA框架建立在开源QwenOFT [46]架构之上，该架构利用Qwen3-VL-4B-Instruct作为基础视觉语言模型（VLM）。视觉观察结果在被视觉编码器处理之前被调整为 224×224 。

在训练阶段，整个框架使用 AdamW 优化器进行了 80,000 个训练步骤的端到端优化。我们应用差分学习率策略来确保稳定收敛：预训练的 VLM 主干以较低的学习率 1×10^{-5} 进行微调，而新初始化的组件（动作头和关键帧证据记忆预测头）则以较高的学习率 1×10^{-4} 进行训练。所有任务的动作预测范围 (H) 均设置为 50 个步骤。

为了明确反映我们评估的基准测试的不同内存需求，我们以不同的方式配置内存模块。对于主要评估基础视觉锚定而不需要中间瞬时记忆的 RMBench，该策略仅使用初始和短期视觉锚定进行训练。表 5 总结了 RMBench 的详细网络架构和训练超参数。

表 5: RMBench 的网络架构和训练超参数。

Configurations	Values
<i>Network Architecture</i>	
Base VLM	Qwen3-VL-4B-Instruct
Action Model Type	Optimized Fine-Tuning (OFT)
Action Dimension	14
Action Horizon (H)	50
Image Resolution	224×224
<i>Training Hyper-parameters</i>	
Optimizer	AdamW
Training Steps	80,000
Base VLM Learning Rate	1×10^{-5}
Action Head Learning Rate	1×10^{-4}
Per-Device Batch Size	4
Gradient Accumulation Steps	1
Memory Module Status	Visual Anchors Only
Visual Anchors A_t	o_0, o_{t-30}, o_{t-15}

相反，对于严格非马尔可夫 RoboTwin-MeM，完整的关键帧证据记忆（KEM）模块被激活。为了确保早期训练的稳定性并弥合训练-测试分布变化，我们应用了预定的教师对学生课程，其中教师强制概率 α 在训练过程中从 1.0 线性衰减到 0.0

持续时间。如表 6 所示，我们还引入了特定的超参数来管理在线内存提取管道。使用提交置信度阈值 $\tau_{\text{commit}} = 0.55$ 过滤按块的关键帧预测。为了强制执行严格的内存稀疏性，我们应用半径为 $w = 8$ 的一维非极大值抑制 (NMS) 滑动窗口，然后在连续内存写入之间设置 $C = 10$ 个步骤的临时冷却期。最后，动态事件缓冲区的最大容量为 $N_{\text{max}} = 5$ ，由 FIFO 逐出策略管理以满足实时计算约束。

对于现实世界机器人平台上的物理部署，我们利用 $\pi_{0.5}$ [1] 作为基础视觉-语言-动作模型来调整我们的框架。动作头被配置为在 $H = 50$ 个步骤的范围内预测 32 维连续动作。在对实际演示进行微调期间，整个框架使用 AdamW 优化器联合优化了 60,000 个步骤，全局批量大小为 32 (bfloat16 精度)。我们对基础 VLM 和新初始化的头应用 5×10^{-5} 的统一峰值学习率，遵循具有 2,000 个预热步骤的余弦衰减时间表。为了在物理执行期间管理关键帧证据记忆 (KEM) 模块，我们将提交置信度阈值保持为 $\tau_{\text{commit}} = 0.55$ ，最大事件缓冲区容量为 $N_{\text{max}} = 5$ ，NMS 时间窗口半径为 $w = 8$ ，提交冷却期为 $C = 10$ 。关键帧损失权重 λ 设置为 0.1，同时安排师生课程，其中 α 从 1.0 线性衰减到 0.0。表 7 总结了实际任务的综合网络架构和训练细节。

表 6: RoboTwin-MeM 的网络架构和 KEM 超参数。

Configurations	Values
<i>Network Architecture & Basic Training</i>	
Base VLM	Qwen3-VL-4B-Instruct
Action Model Type	Optimized Fine-Tuning (OFT)
Action Horizon (H)	50
Optimizer	AdamW
Training Steps	80,000
Base VLM Learning Rate	1×10^{-5}
KEM & Action Head Learning Rate	1×10^{-4}
Per-Device Batch Size	4
Gradient Accumulation Steps	1
<i>Keyframe Evidence Memory (KEM) Settings</i>	
Memory Module Status	Full EventVLA (VA + KEM)
Visual Anchors A_t	o_0, o_{t-30}, o_{t-15}
Teacher-Forcing Annealing (α)	Linear decay ($1.0 \rightarrow 0.0$)
Commit Confidence Threshold (τ_{commit})	0.55
Max Event Buffer Size (N_{max})	5
NMS Temporal Window Radius (w)	8
Commit Cooldown Period (C)	10
Keyframe Loss Weight (λ)	0.1

表 7: 真实机器人的网络架构和 KEM 超参数。

Configurations	Values
<i>Network Architecture & Basic Training</i>	
Base VLM	PaliGemma ($\pi_{0.5}$)
Image Resolution	224×224
Text Sequence Length	200
Action Horizon (H)	50
Action Dimension	32
Optimizer	AdamW
Optimizer Hyper-parameters	$\beta_1 = 0.9, \beta_2 = 0.95, eps = 1e - 8$
Weight Decay	0.01
Training Steps	60,000
Warm-up Steps	2,000
Base VLM Learning Rate	5×10^{-5}
KEM & Action Head Learning Rate	5×10^{-5}
Minimum Learning Rate	5×10^{-6}
Learning Rate Schedule	cosine decay with minimum LR
Global Batch Size	32
Numerical Precision	bfloat16
<i>Keyframe Evidence Memory (KEM) Settings</i>	
Memory Module Status	Full EventVLA (VA + KEM)
Visual Anchors A_t	$o_0, o_{t-60}, o_{t-40}, o_{t-20}$
Teacher-Forcing Annealing (α)	linear decay ($1.0 \rightarrow 0.0$)
Commit Confidence Threshold (τ_{commit})	0.55
Max Event Buffer Size (N_{max})	5
NMS Temporal Window Radius (w)	8
Commit Cooldown Period (C)	10
Keyframe Loss Weight (λ)	0.1

C Extended Experimental Results and Analysis

表 8: RMBench 基准测试结果。（粗体：最好；下划线：第二好）。

Tasks	Observe and Pick Up	Rearrange Blocks	Put Back Block	Swap Blocks	Swap T	Battery Try	Blocks Ranking Try	Cover Blocks	Press Button	Total average
▼ Non Memory-based Vision-language-action Models:										
DP	1%	0%	0%	11%	20%	10%	10%	0%	0%	5.8%
ACT	1%	29%	0%	2%	2%	19%	0%	0%	0%	5.9%
$\pi_{0.5}$	9%	13%	11%	24%	15%	16%	6%	0%	0%	10.4%
X-VLA	9%	13%	18%	16%	3%	26%	1%	2%	0%	9.8%
QwenOFT	0%	0%	0%	0%	0%	14%	37%	0%	0%	5.6%
▼ Dual-system Memory-based Vision-language-action Models:										
MemER	7%	17%	0%	14%	7%	27%	0%	6%	0%	8.7%
Mem-0	4%	89%	90%	67%	14%	28%	18%	68%	0%	42.0%
▼ End-to-end Memory-based Vision-language-action Models:										
MemoryVLA (OpenVLA)	0%	22%	50%	17%	9%	25%	12%	40%	0%	19.4%
MemoryVLA (QwenOFT)	2%	53%	81%	<u>76%</u>	9%	33%	53%	<u>69%</u>	0%	41.7%
EventVLA (w/o initial)	10%	64%	63%	16%	8%	39%	87%	15%	<u>2%</u>	33.7%
EventVLA (w/o short-term)	15%	34%	20%	18%	94%	16%	14%	4%	0%	23.8%
EventVLA (visual anchors only)	21%	96%	95%	96%	<u>87%</u>	<u>35%</u>	<u>81%</u>	97%	3%	67.8%

C.1 RMBench 上每个任务的详细细分

由于正文篇幅限制，我们在表 8 中展示了 RMBench 套件上所有基线和消融模型的全面任务级别细分，这是表 1 的特定于任务的扩展版本。

详细的细分清楚地表明，我们的简化配置 EventVLA（仅视觉锚点）在绝大多数任务中显著优于非内存和先前的内存增强基线。值得注意的是，在 *Rearrange Blocks* (96%)、*Put Back Block* (95%)、*Swap Blocks* (96%) 和 *Cover Blocks* (97%) 等内存密集型结构操作任务上，EventVLA 实现了近乎完美的成功率。这表明我们基于规则的视觉锚定机制有效地捕获了传统的面向内存的场景所需的持久空间布局 and 固定运动风格，而不需要复杂的状态压缩。此外，消融变体（没有初始和没有短期）在几乎所有任务中都显示出严重的性能下降，这证实了初始全局空间参考和短期运动线索都是视觉锚点不可或缺的组成部分。

C.2 扩展消融分析和推理效率

扩展消融分析。为了深入了解关键帧证据记忆 (KEM) 模块中各个设计选择的贡献，我们扩展了在 RoboTwin-MeM 套件上进行的消融研究（在正文第 5.2 节和表 2 中进行了总结）。

- 内存表示（显式图像与隐式存储库）：在隐式存储库变体中，捕获的关键帧被聚合到压缩的潜在嵌入中，而不是作为显式原始图像附加。当处理需要保留多个不同事件（例如， $n \geq 3$ ）的复杂任务时，将不同的历史特征压缩到单个潜在向量中会产生严重的信息瓶颈。显式的原始图像串联避免了这种有损压缩，为 VLA 的多帧注意机制提供完整、无损的上下文证据。
- 监督策略（软标签与硬标签）：物理关键帧事件自然跨越连续的时间窗口。用严格的二元目标替换我们的升余弦软标签会导致标签极度稀疏，并严重惩罚有效的相邻帧。这种严格的监督会破坏预测头的稳定性，最终导致其无法触发必要的内存写入。软标签为具有执行差异的环境中的稳健事件捕获提供必要的时间容差。
- 缓冲区管理（NMS和容量的必要性）：如果没有一维非最大抑制（NMS）后处理算法，相邻帧会出现冗余

表 9: EventVLA 推理速度的消融研究。 *Latency* 表示生成每个块所需的平均时间（秒/块），而 *Throughput* 表示平均每秒生成块的数量（块/秒）。

Tasks		n=1	n=2	n=3		n=4		n=5	Total average
		Rearrange Blocks Hard	Put Back Block Hard	Pick Objects in Order	Pick the Unhidden Block	Cover Blocks Hard	Find Seal Stamp	Reproduce Route	Press Button Keyframe
QwenOFT	<i>Latency</i>	0.31	0.36	0.36	0.39	0.41	0.39	0.30	0.32
	<i>Throughput</i>	3.21	2.82	2.82	2.56	2.57	2.62	3.46	3.20
EventVLA (visual anchors only)	<i>Latency</i>	0.92	0.78	1.08	0.83	1.05	1.02	0.95	1.08
	<i>Throughput</i>	1.11	1.35	0.93	1.21	0.96	1.02	1.07	0.94
EventVLA (VA+KEM)	<i>Latency</i>	0.90	0.88	1.20	0.97	1.22	1.11	1.25	1.22
	<i>Throughput</i>	1.13	1.16	0.84	1.03	0.83	0.92	0.81	0.83

快速淹没有界动态事件缓冲区。相反，严格最小的缓冲区（例如， $N_{\max} = 2$ ）本质上缺乏复杂的多阶段任务所需的结构容量。这两种情况都会导致缓冲区过早饱和并触发早期 FIFO 驱逐，从而在使用之前错误地丢弃基础历史证据（例如第一个观察到的隐藏颜色）。这强调了 NMS 驱动的事件稀疏性和足够的内存容量都至关重要。

- Foresight Horizon（操作块大小的影响）：执行块大小控制 KEM 的前瞻窗口。缩小这个范围会截断模型的预测能力，阻止关键帧头部有效地预测和调度即将到来的瞬态事件，从而抵消 KEM 的主动内存承诺能力。

推理效率。为了验证 EventVLA 是否可以有效部署在物理机器人上，我们仔细评估了其实时推理速度。表 9 详细介绍了我们的框架在 RoboTwin-MeM 基准测试中的延迟和吞吐量。

纯反应式 QwenOFT 基线实现了 2.91 Hz 的平均吞吐量和 0.36 秒的延迟。由于扩展的多帧输入序列，合并外部视觉锚点会稍微增加计算量，从而导致平均吞吐量为 1.07 Hz。当部署完整的 EventVLA 框架（包含动态 KEM）时，它保持 0.94 Hz 的平均吞吐量（1.09 秒延迟）。鉴于 VLA 策略通常作为高级规划器与低级高频控制器一起运行，因此这种吞吐量可以轻松满足现实世界机器人部署的操作限制。这证实了我们的稀疏内存承诺策略在鲁棒的非马尔可夫推理和实际的实时执行效率之间取得了最佳平衡。

D 定性可视化

D.1 RoboTwin-MeM 中的模拟展示

为了直观地理解 EventVLA 的动态内存调度和执行过程，我们在 RoboTwin-MeM 基准测试中可视化了所有 8 个严格非马尔可夫任务的定性展示。图 6 说明了四个内存密集型任务的成功执行序列：Rearrange Blocks Hard、Pick the Unhidden Block、Put Back Block Hard 和 Cover Blocks Hard。图 7 演示了其余四个任务的执行管道：Press Button、Keyframe、Pick Objects in Order、Find Seal and Seal Stamp 和 Reproduce Route。

在这些不同的场景中，可视化清楚地突出了 KEM 模块如何在瞬时视觉证据出现的确切时刻主动触发稀疏内存写入（例如，在揭开不透明盖子后立即观察块的隐藏颜色，或读取随机数）。通过这些关键中间状态变得不可观察之前将其锁定到事件缓冲区中，EventVLA 有效地弥合了时间间隙并无缝地指导后续的长范围操作。



图 6: EventVLA 在四个 RoboTwin-MeM 模拟任务上的定性展示: *Rearrange*、*Blocks Hard*、*Pick the Unhidden Block*、*Put Back Block Hard* 和 *Cover Blocks Hard*。

D.2 现实世界的机器人执行序列

为了进一步验证我们框架的实际功效，我们提供了部署在现实世界 ARX ACONE 双手机器人上的 EventVLA 的定性执行序列。图 8 显示了四个内存密集型操作任务的成功完成：

Find Block Easy、*Pick-X-Times*、*Find Block Hard* 和 *Pick in Order*。

可视化结果表明，尽管存在现实世界的遮挡和随机的空间放置，EventVLA 仍可以稳健地捕获并保留关键的中间视觉线索。无论是从纸上读取随机数字来指示计数逻辑，还是观察一根棍子指向瓶子来记住上下文序列，该策略都成功地利用了其稀疏的视觉证据记忆





图 7: EventVLA 在其余四个 RoboTwin-MeM 模拟任务上的定性推出: *Press Button Keyframe*、*Pick Objects in Order*、*Find Seal and Seal Stamp* 和 *Reproduce Route*。

执行复杂的多阶段物理任务，表现出强大的非马尔可夫记忆和空间泛化能力。


轻松找到方块：用最近的杯子覆盖方块，然后提起覆盖方块的杯子并抬起方块。



拾取 X 次：按照纸上所示的次数拾起并放下方块。



找块困难：从左到右将桌子上的杯子一个接一个地提起，检查下面是否有隐藏的立方体，然后将杯子放下。最后，打开装有立方体的杯子并拿起立方体。



顺序挑选：按照开始时棍子所指的顺序，将桌子上的瓶子一一拿起并放下。




图 8: EventVLA 在四个任务上的定性现实世界机器人执行序列: *Find Block*、*Easy*、*Find Block Hard*、*Pick-X-Times* 和 *Pick in Order*。