

MEM: 面向视觉语言动作模型的多尺度具身记忆

Marcel Torne^{*12†} Karl Pertsch^{*1} Homer Walke^{3†} Kyle Vedder¹ Suraj Nair¹ Brian Ichter¹
Allen Z. Ren¹ Haohuan Wang¹ Jiaming Tang^{14†} Kyle Stachowicz^{13†} Karan Dhabalia¹ Michael Equi¹
Quan Vuong¹ Jost Tobias Springenberg¹ Sergey Levine¹ Chelsea Finn¹ Danny Driess¹

<https://pi.website/research/memory>




图 1: 多尺度具身记忆 (MEM) 为视觉语言动作模型 (VLA) 配备记忆, 以大规模解决长时程任务。它包含两个关键组件: 用于短时程图像记忆的高效视频编码器, 以及用于捕获长时程记忆的基于语言的记忆机制。在多样化的机器人与非机器人数据语料上训练后, MEM VLA 能够解决需要长达十五分钟记忆的任务, 处理部分可观测性, 并执行操作策略的上下文自适应。

摘要——传统上, 端到端机器人学习中的记忆涉及将过去观测序列输入到学习策略中。然而, 在复杂的多阶段现实世界任务中, 机器人的记忆必须在多个粒度级别上表示过去事件: 从捕获抽象语义概念的长期记忆 (例如, 机器人做晚餐时应记住食谱的哪些阶段已完成) 到捕获近期事件并补偿遮挡的短期记忆 (例如, 机器人记住其手臂遮挡后想要拾取的物体)。在这项工作中, 我们的主要洞见是, 用于长时程机器人控制的有效记忆架构应结合多种模式以捕获这些不同的抽象级别。我们引入了多尺度具身记忆 (MEM), 这是一种用于机器人策略中混合模式长时程记忆的方法。MEM 将基于视频的短时程记忆 (通过视频编码器压缩) 与基于文本的长期记忆相结合。它们共同使机器人策略能够执行长达十五分钟的任务, 例如清理厨房或准备烤奶酪三明治。此外, 我们发现记忆使 MEM 策略能够在上下文中智能地调整操作策略。

1. 引言

高效且有效地赋予机器人策略记忆需要多个层次的抽象。虽然原则上我们可以简单地将整个过去观测序列编码到策略的上下文中, 但这对于长任务来说变得难以处理, 需要非常短的序列或显著的子采样。然而, 在实际设置中, 长期和短期记忆所需的表示很可能非常不同。例如, 机器人可能需要记住最近的观测以处理遮挡, 并且可能需要记住在烹饪时已经添加了其中一种食材。但这些记忆在本质上是不同的: 前者可能需要在短时间内存储几张图像, 后者可能需要长期记忆但只需少量信息。用于机器人策略的有效记忆架构应使用多种模式来表示这些不同抽象层次的记忆。对于短时记忆, 基于图像的密集记忆非常适合解决遮挡问题, 并允许

* 同等贡献, † 在 PI 实习期间完成的工作。1 物理智能, 2 斯坦福大学, 3 加州大学伯克利分校, 4 麻省理工学院

使机器人能够快速调整其操作策略，例如在抓取物体失败后改变抓取方式。对于长时程记忆，我们通常只需在语义层面跟踪事件，例如哪些食材已经添加到菜肴中。在这种情况下，基于语言的表示比原始观测提供了更好的压缩效果，并允许我们在长时间内存储高层记忆。基于这些观察，我们提出了多尺度具身记忆（Multi-Scale Embodied Memory, MEM），这是一个为策略配备多模态、长时程记忆的系统。MEM 结合了两个关键要素，使长时程记忆变得可行。首先，我们使用视频编码器架构，将数秒的密集图像记忆有效编码为紧凑表示。其次，我们引入了一种基于语言的记忆机制，策略以压缩的语言格式跟踪语义事件。该记忆系统不仅能适应非常长时程的任务，还能通过利用短期记忆实现多种新能力，例如上下文适应以纠正错误，以及对部分可观测性和自遮挡的鲁棒性。为了评估 MEM，我们将其集成到 $\pi_{0.6}$ 模型 [35] 中，这是一个在机器人、视觉语言和视觉数据的多样化混合上训练的通用 VLA。我们表明，所得到的策略在广泛的复杂操作任务中达到了最先进的性能。我们还表明，MEM 使我们的策略能够解决长时程任务，如清理整个厨房或准备烤奶酪三明治，这些任务需要保持长达十五分钟的记忆。总之，我们介绍了一个用于机器人策略的多尺度、长时程记忆系统。通过分别用视频和语言表示有效表示短期和长期记忆，MEM 允许机器人策略在数十分钟内跟踪记忆，而不牺牲运行时约束。为了实现 MEM，我们使用了高效的视频编码器架构和基于语言的记忆系统，并通过在各种机器人任务中的最先进性能证明了它们的有效性。借助 MEM，我们使机器人策略能够执行复杂任务，如清理整个厨房，这些任务可能持续长达十五分钟。

II. 相关工作

具有记忆的视觉语言动作模型。近期研究已证明，基于大规模多样化机器人经验训练得到的机器人控制策略，能够实现可泛化的操作能力，例如在未见过的环境中 [19, 18, 43, 46, 31, 52]。视觉语言动作模型（Vision Language Action Models, VLAs）[15, 8, 33, 32, 13, 22, 5, 49, 54, 2, 41, 34, 44, 50, 4, 51, 45] 是训练此类通用策略的一种流行方法，其通过机器人经验对预训练的视觉语言模型进行微调。尽管当前许多最先进的视觉语言动作模型在训练时未引入记忆机制，仅依据环境的当前观测进行动作决策 [22, 18, 19, 43, 46, 31]，但越来越多的研究开始探索在策略训练中加入记忆，因为记忆是解决众多现实世界任务的核心需求。早期研究

探索具有循环记忆模块的架构 [37, 28]，近期采用变换器（Transformer）架构的工作则直接将先验观测的稠密历史输入策略 [38, 23, 32]；计算与延迟约束使得此类方法难以扩展以支持超长时域记忆。部分工作研究了潜在记忆架构 [24, 39, 17, 12]，但仅在短时域记忆任务上进行了评估。其他工作提出了多种启发式方法来压缩记忆信息，例如仅依赖本体感知记忆 [53]、二维点轨迹 [55, 9]、仅保留先前时间步的关键帧 [40, 48, 29]，或以自然语言表示记忆 [26]。所有这些方法面临的挑战在于，难以找到一种适用于机器人记忆的通用单模态解决方案，每种表示都会导致能力上的折衷：例如，仅使用本体感知、点轨迹或自然语言会丢失关于抓取角度和高度的精确空间信息，而这些信息对于纠正滑脱的抓取是必要的。另一方面，关键帧需要大幅稀疏化观测历史，以使长时域任务中的推理在计算上可行，但可能丧失估计环境和机器人动态的能力，而这通常需要更密集采样的观测。与这些先前工作不同，本文提出一种多模态记忆系统，将短时域、基于视觉的稠密记忆与长时域、基于语言的记忆相结合。这使我们能够解决部分可观测性问题、进行上下文适应并完成长时域任务，同时不牺牲效率。最后，一条正交的研究路线提出了缓解因果混淆 [11, 55] 的方法，其中具有记忆的策略会错误地学习复制先前的动作，例如通过引入辅助目标 [47]。虽然类似方法可以与我们的记忆系统结合，但我们的实验表明，无需此类目标即可实现高策略性能，这可能归因于我们大规模且多样化的训练数据。

长上下文模型。在机器人学之外，大量工作探索了长上下文语言与视觉语言模型的训练 [27, 42, 30]。特别是在视频处理领域，关于为长视频输入设计高效编码器的文献十分丰富 [1, 3, 25]。本文借鉴了 [3, 1] 中利用稀疏注意力操作高效处理视频输入类似思想。然而，在机器人学背景下，现实世界施加的延迟约束要求额外的效率考量：即使在现代硬件上，在几百毫秒的延迟预算内处理超过十分钟的高频多帧视频也颇具挑战。因此，本文结合了短时程、基于视频的记忆架构与显著更压缩的、基于语言的记忆架构，以实现有效的长时程上下文。

三、面向视觉语言动作模型的多尺度具身记忆

本节描述所提出的系统，该系统为视觉语言动作模型配备多时间尺度的记忆。对于决定下一步动作的机器人策略而言，相关上下文往往跨越多个时间尺度。最近的

时间步有助于理解机器人与场景的动态变化，解决自遮挡问题，并快速适应细粒度操作策略，如重新抓取。另一方面，长期记忆对于理解例如食谱中哪些步骤已完成，或哪个子任务反复失败是必需的。理论上，这两种上下文都可以通过将策略条件化于其所有先前观测的密集序列来提供。然而，对于跨越数十分钟的任务，这很快变得不可行。我们设计多尺度具身记忆（Multi-Scale Embodied Memory, MEM）的目标是实现高效的短期和长期记忆。对于短期记忆，我们采用高效的视频编码器架构，将数秒的观测序列传递给策略，从而实现快速的上下文适应和对自遮挡的鲁棒性。对于长期记忆，我们设计了一种基于语言的记忆表示，并训练模型在语义层面以自然语言跟踪过去事件。这样，我们可以在不牺牲运行时延迟约束的情况下，为策略配备长达 15 分钟的记忆。我们首先概述 MEM 记忆系统（第 III-A 节），然后详细描述基于语言的记忆（第 III-B 节）和视频编码器架构（第 III-C 节），最后详细说明我们的记忆系统在 $\pi_{0.6}$ -MEM 视觉-语言-动作模型（VLA）中的实例化（第 III-D 节）。

A. 多尺度具身记忆（MEM）

图 2 展示了我们的 MEM 系统概览。我们的目标是训练一个策略 $\pi(a_{t:t+H}|o_{t-T:t}, g)$ ，该策略预测连续机器人动作块 $a_{t:t+H}$ ，条件化于自然语言的任务目标 g ，以及作为输入提供的密集观测序列（例如图像、本体感受状态）。相比之下，大多数先前的视觉-语言-动作模型仅条件化于单个观测 o_t ，而我们希望策略处理多个（ T ）观测。如上所述，将过去观测的数量扩展到跨越数分钟，从而作为长期记忆的一种形式是不可行的。因此，我们将动作预测问题分解如下：

$$\begin{aligned} \pi(a_{t:t+H}, l_{t+1}, m_{t+1}|o_{t-T:t}, m_t, g) \\ \approx \pi_{LL}(a_{t:t+H}|o_{t-K:t}, l_{t+1}, g) \\ \pi_{HL}(l_{t+1}, m_{t+1}|o_t, m_t, g), \end{aligned}$$

其中我们将动作概率分离为低层策略 π_{LL} 与高层策略 π_{HL} 。低层策略在任务目标 g 、较短的观测序列（ $K \ll T$ ）以及子任务指令 l_{t+1} 的条件下对动作序列进行建模。子任务指令则由高层策略生成，该策略不仅以任务目标为条件，还以先前语义事件的自然语言摘要 m_t 为条件。下文将此摘要称为语言记忆。该方法使我们能够大幅减少输入模型的密集观测数量 $K \ll T$ ，同时不牺牲捕捉数分钟量级记忆的能力。

虽然先前工作已采用类似的高层与低层策略划分，并以子任务指令作为接口，但本文的关键新颖之处在于 π_{HL} 基于其自身先前的预测 m_t 额外预测更新后的语言记忆 m_{t+1} 。

B. 用于长期记忆的语言记忆

语言记忆 m_t 是对策略在解决任务过程中发生的先前语义事件的摘要。主要思想是训练高层策略

$\pi_{HL}(l_{t+1}, m_{t+1}|o_{t-K:t}, m_t, g)$ ，使其根据先前的摘要 m_t 以及当前的观测和任务来预测相关摘要 m_{t+1} 。这样，模型显式地决定何时以及如何更新其记忆表示。例如，对于一个厨房清洁机器人，它已经将盘子放入橱柜，并且刚刚完成拿起下一个碗，记忆更新可能如下所示： m_t : 我将一个盘子放入橱柜并移动到台面。



m_{t+1} : 我将一个盘子放入橱柜，移动到台面，并拿起一个碗。

为了训练 π_{HL} ，我们需要获取合适的训练数据，包括我们希望高层策略采取的总结动作。为此，我们开发了一条流水线，用于生成 m_t 与 m_{t+1} 之间转换的训练数据，具体如下。给定一个带有子任务语言标注 $l_{0:T}$ 的机器人回合，我们将子任务指令以及子任务执行成功或失败的指示传递给一个现成的预训练语言模型（LLM），并要求它总结所有来自先前子任务且对未来任务执行仍然相关的信息。我们收集相应的输出，并用它来标记序列，以训练高层策略。重要的是，我们指示语言模型在适当的时候删除或压缩语言记忆中的信息。例如，与其记住所有被操作物体的精确属性（“我把一个浅绿色的碗、一个深蓝色的碗和一个亮黄色的碗放进了右上角的柜子里”），通常只需记住碗被放置的位置（“我把三个碗放在了右上角的柜子里”）就足够了。压缩语言记忆有助于保持其简洁（从而使推理更快），并减少训练与推理之间分布偏移的潜在风险，因为在时间步之间传递的信息比特更少。我们发现，当提示仅保留最小相关信息集时，当前一代语言模型在此任务上表现有效。

C. 用于密集短期视觉记忆的视频编码器

如上一节所述，语言记忆机制可以捕获长期语义概念。为了使我们的策略能够推理细粒度细节、动态并解决自遮挡问题，需要访问先前观测的密集序列 $o_{t-K:t}$ 作为输入，输入到




图 2: MEM 记忆系统通过两个关键组件为诸如 $\pi_{0.6}$ 的视觉语言动作模型配备长时程记忆: (1) 训练高层策略, 通过更新语言记忆 m_t 来跟踪长时程语义事件 (左侧, 第 III-B 节), (2) 低层策略使用基于短期观测的记忆, 该记忆通过视频编码器高效编码 (右侧, 第 III-C 节)。




图 3: 将观测序列直接输入视觉-语言-动作模型的主干网络会迅速增加推理延迟。本文提出的高效视频编码器架构允许使用大量观测帧, 同时保持在关键实时推理阈值 [6, 7] 以下。计时测量针对 $\pi_{0.6}$ 视觉-语言-动作模型, 在单个 NVIDIA H100 图形处理器上使用四路输入相机流。

策略。在大多数视觉-语言-动作模型中, 观测编码 (尤其是图像编码) 在训练期间占用了最大比例的计算量, 并显著影响推理速度。因此, 如图 3 所示, 随着上下文增长到超过几个时间步, 逐个编码观测序列并将其输入视觉-语言-动作模型主干网络很快变得不可行。视觉-语言-动作模型将迅速产生超出先前工作认为可接受的推理延迟, 以避免灵巧操作任务中机器人性能显著下降 [6, 7]。为解决这一问题, 本文提出使用视频编码器, 在将编码输入视觉-语言模型主干网络之前, 在时间维度上压缩帧。本文的视频编码器扩展了视觉变换器 (Vision Transformers, ViTs) [14], 后者通常作为大多数视觉-语言-动作模型中的视觉编码器, 用于编码视频输入。重要的是, 本文的编码器保持起始视觉-语言模型的单图像性能不变, 因此可用于赋予任何预训练视觉-语言模型高效 (且计算成本低) 的视觉记忆能力。视觉变换器以图像块为单位处理图像, 并反复执行




图 4: 本文提出使用高效视频编码器架构来压缩短程、基于图像的记忆。该架构扩展了标准视觉变换器以编码视频输入, 通过交替使用在每个观测内部应用双向空间注意力的层 (白色箭头) 与额外在观测之间应用因果时间注意力操作的层 (黑色箭头)。本文在视觉变换器的上层丢弃过去时间步的观测标记, 以压缩输入并减少传递给视觉-语言-动作模型主干网络的标记数量。

在多个层上对图像块嵌入 (patch embeddings) 进行双向注意力, 以得到最终的一组输出嵌入。我们保持相同的总体结构, 视频编码器首先分别对输入视频中的所有图像进行分块。受现有视频理解中时空可分离注意力工作的启发 (概述见 Bertasius 等人 [3]), 我们随后修改视觉 Transformer (ViT) 每第 4 层的注意力机制, 使其同时纳入空间上下文 (ViT 中的标准做法) 和时间上下文。为避免在时间和空间上对数量庞大的总图像块进行代价过高的联合注意力操作, 我们的架构将注意力分解为独立的空间注意力和时间注意力操作。每第 4 层通过使用因果注意力掩码 (“时间”) 对同一图像块在不同时间步的表示执行注意力, 从而在时间维度上附加地增加注意力

一种数学描述。这将每层相应注意力的计算复杂度从 $\mathcal{O}(n^2K^2)$ （对时间和空间进行朴素注意力）降低到 $\mathcal{O}(Kn^2 + nK^2)$ 。最后，为了减少后续视觉语言模型变换器主干处理的图像块数量，我们仅传递当前时间步及之后计算的表示（丢弃所有过去时间步图像块的表示）。因此，我们的视频编码器在无记忆的单时间步视觉语言模型中，与通常传入视觉语言模型主干的标记数量相匹配；并且我们有效地迫使视频编码器通过修改后的注意力机制，将时间信息融入为当前观测生成的表示中。我们的视频编码器的一个关键特性是，与标准的单图像视觉变换器相比，它没有引入新的可学习参数。视频编码能力是通过修改视觉变换器的注意力模式并添加固定的正弦时间位置编码来实现的。因此，我们可以像在无记忆视觉语言模型中一样，从任何标准视觉语言模型的预训练视觉变换器权重初始化我们的视频编码器权重。为了最大化特征迁移，我们确保对于 $K = 1$ ，即单图像输入，我们编码器的初始化与视觉语言模型完全匹配，这是通过一个正弦时间位置嵌入实现的，该嵌入在 $t = 0$ 时值为 0。总之，我们的视频编码器架构使我们能够有效地将基于观测的记忆扩展到数十秒，而不会在训练或推理过程中产生过高的计算开销（图 3），同时允许从预训练的视觉语言模型权重进行初始化。

D. 将记忆增强模块（MEM）集成到 $\pi_{0.6}$ 视觉语言动作模型（VLA）中。为了进行实验评估，我们通过调整 $\pi_{0.6}$ 视觉语言动作模型 [36] 的架构以支持第三节 C 部分的视频编码器，为其配备记忆增强模块记忆。与 $\pi_{0.6}$ 类似，带有记忆增强模块的 $\pi_{0.6}$ 视觉语言动作模型从预训练的 Gemma3-4B 视觉语言模型 [21] 初始化。遵循 Driess 等人 [16] 的方法，该模型同时使用离散快速动作标记预测 [34] 和具有 8.6 亿参数的流匹配动作专家 [18] 进行训练。梯度不会从动作专家流入视觉语言模型主干网络 [16]。模型以每个摄像头流 448x448 像素的输入分辨率进行训练，最多支持四个摄像头流（取决于机器人本体）。除了过去的摄像头帧外，带有记忆增强模块记忆的 $\pi_{0.6}$ 模型的观测记忆还包含过去的本体感受状态，例如关节角度。 $\pi_{0.6}$ 视觉语言动作模型以文本形式表示机器人状态。然而，对于过去状态序列，这很快会导致大量状态文本标记。为防止这种情况，我们改用连续状态嵌入，通过线性投影将每个本体感受状态投影到主干嵌入空间中。这样，对于长度为 K 的观测记忆，我们仅生成 K 个本体感受状态标记。我们在多样化的数据混合上预训练 $\pi_{0.6}$ -记忆增强模块，这些数据包括遥操作机器人演示、策略展开数据，

以及类似于 Physical Intelligence 等人 [36] 的人工修正、视觉语言任务和视频语言任务（如视频字幕）。在预训练期间，我们使用六个观测序列（五个过去观测和当前观测）训练模型，间隔步长为一秒。在后训练期间，我们发现可以灵活扩展这一时间范围，并容纳更长的基于观测的记忆（在我们的实验中，基于观测的记忆最长可达 18 帧和 54 秒），这与语言模型和视觉语言模型训练中观察到的现象类似 [10]。我们使用推理时实时分块（RTC, [6]）或训练时实时分块 [7] 进行异步实时推理，运行所有机器人实验。

四、实验评估

我们的实验评估旨在回答以下问题：（1）MEM 是否使视觉语言动作模型（VLA）能够执行需要长达 15 分钟长期记忆的任务？（2）MEM 是否基于近期失败的短期记忆，为 VLA 模型解锁了新能力，例如操作策略的上下文自适应？（3）MEM 的性能与先前为 VLA 模型添加记忆的方法相比如何？

A. 记忆增强模型解决需要长时程记忆的任务

我们通过两个具有挑战性的场景来评估本方法在实现长时程任务方面的潜力，这些场景要求记忆保持长达十五分钟（见图 5，第 1 行和第 2 行）：（1）食谱准备：机器人接收到一个详细的提示，指定烹饪食谱所需的食材和炊具及其位置，并被要求从各种橱柜、抽屉或例如冰箱中取出所有物品，并将它们放置在特定位置，例如炉灶或特定的台面上。需要记忆来跟踪所有已收集的物品，并记得在任务完成后关闭抽屉、橱柜或冰箱。我们在多样化的厨房场景中训练了 42 个食谱，并在未见过的厨房和未见过的物体上评估其中五个食谱。（2）清洁

上层厨房：机器人需要清理杂乱的厨房环境，包括将物品放入冰箱、擦拭台面、用肥皂和流水清洗餐具，并将餐具放入沥水架。记忆对于记住清理过程中的步骤（例如，清洗前是否已向餐具添加肥皂，餐具的正面和背面是否都已清洗）、记住哪些表面已经清洁，以及记住在物品收纳后关闭橱柜是必需的。该任务不仅在记忆方面具有挑战性，还要求策略执行多种灵巧操作，从擦拭表面到小心处理水和肥皂。有关训练数据、评估条件和进度评分标准的更多细节，请参见第 B 节。所有评估对每个策略和任务或配方使用 10 次运行，我们在所有图中报告均值 $\pm$ 标准误。

图 6 展示了结果：在没有记忆的情况下，即使是最先进的模型，如 $\pi_{0.6}$ ，也难以完成这些具有挑战性的任务




图 5：我们在多个具有挑战性的长时程灵巧操作任务上测试了记忆增强策略（MEM），这些任务要求保持记忆长达十五分钟，包括准备食谱、清理厨房（第 IV-A 节）以及制作烤芝士三明治（第 IV-C 节）。




图 6：策略在具有挑战性的长时程操作任务上的性能。没有记忆，即使是最先进的通用策略如 $\pi_{0.6}$ 也难以完成这些任务。我们通过消融记忆组件表明，将短时程基于观测的记忆与长时程基于语言的记忆相结合，可以解决这些任务。未经压缩的朴素语言指令记忆在训练与推理的分布偏移下表现不佳。

长时程任务。尽管先前工作已展示策略能够在较长时间内执行操作 [36]，但解决具有灵活子任务序列和频繁部分可观测性的真实世界任务从根本上需要记忆。结果表明，MEM 在短时程和长时程时间间隔内都能有效为策略提供所需上下文，并显著提高策略成功率。为了更好地理解 $\pi_{0.6}$ -MEM 强大性能的贡献因素，我们对方法的不同组件进行了详细的消融实验。结果报告于

图 6。我们与移除短时程视频记忆或长时程语言记忆的策略版本进行比较，结果表明两者对于解决挑战性任务都至关重要。没有视频记忆，机器人可能难以判断它已经洗盘子或擦拭表面多长时间，从而无限期地“卡住”。视频记忆还有助于增强鲁棒性

通过上下文自适应（见第 IV-B 节）实现操作任务。另一方面，长时程语言记忆对于记住较远过去的语义事件至关重要。它使策略能够跟踪食谱中的步骤，或记住关闭它打开过的门。我们还评估了策略的一个版本，该版本移除了应用于基于语言记忆的压缩（见第 III-B 节）：不是训练模型压缩并丢弃不再需要的信息，而是简单地将所有先前的子任务指令拼接起来，直到达到高层策略输入的最大长度。我们发现，这种“朴素”语言记忆的效果显著差于模型预测的摘要。“朴素”语言记忆的核心挑战是训练与推理之间巨大的分布偏移：在训练期间，大多数回合对任何给定的子任务指令只说出一次（例如，“拿起碗”→“将碗放入柜中”），因为它们通常是接近最优的人类演示。然而，在推理期间，策略可能在某个子任务上反复失败，导致高层策略在最终成功并继续之前反复产生相同的子任务（“拿起碗”→“拿起碗”→“拿起碗”→“将碗放入柜中”），从而导致分布偏移，可能降低整体策略性能。相比之下，MEM 的语言记忆机制在碗被成功拿起之前不会更新记忆表示。这种上下文压缩（例如，丢弃失败的尝试）因此减少了分布偏移并提高了整体性能。

B. 操作策略的上下文自适应

在上一节中，我们展示了 MEM 可以使视觉语言动作模型（VLA）解决非常长时程的任务。在本节中，我们研究为 VLA 配备记忆是否能够解锁性能提升，即使在乍一看可能不需要记忆的较短时程任务上也是如此。直观上，虽然记忆




图 7: 具有记忆的 VLA 可以执行操作策略的上下文自适应, 例如调整抓取高度或开门方向。没有记忆, 策略会陷入次优策略。

跨数十分钟的记忆有助于跟踪整体任务进度, 而短时程记忆 (short-horizon memory) 则能使策略在上下文中调整行为并智能地应对错误: 策略不再反复以相同方式失败, 而是可以利用先前失败尝试的上下文, 例如修改拾取物体的方式或开门的方法。为检验记忆增强模型 (MEM) 是否解锁此类上下文适应能力, 我们设置了两项当前最先进的视觉-语言-动作模型 (VLA) 如 $\pi_{0.6}$ 难以完成的任务 (图 7): 在分布外桌面高度上拾取筷子等扁平物体, 导致频繁误抓; 以及打开门方向不明确的冰箱, 导致反复开门失败。为教授策略上下文适应策略, 我们遵循 [36] 并收集针对性的人类反馈: 策略失败后, 人类介入并提供修正操作策略的示范, 例如调整拾取筷子的抓取高度。对于开门任务, 我们收集探索性轨迹, 其中示范者最初不知道开门机制, 因此数据自然包含失败尝试和随后的修正示范。随后, 我们仅使用该修正数据微调 $\pi_{0.6}$ -MEM 策略, 在训练期间将修正前的失败尝试保留在模型的短时程记忆中。结果, 模型学会在看到短时程记忆中的错误时调整其操作策略。我们将此与在相同干预数据上微调无记忆 $\pi_{0.6}$ 策略进行比较。图 7 的结果表明, 具有记忆的 MEM-VLA 在利用修正方面更为有效, 并学会即时调整操作策略。无记忆策略无法记住之前尝试过的策略, 因此无法在犯错后智能地改变策略。相比之下, 具有记忆的策略可以利用上下文理解已尝试并失败的策略, 并相应调整。

C. 分析实验

任务。 为了将我们的方法与现有在广泛能力范围内为视觉语言动作模型配备记忆的方法进行比较, 我们开发了一套具有挑战性的操作任务, 用于衡量策略高效使用记忆和执行灵巧操作的能力 (任务可视化见图 8 和图 10)。这些任务涵盖了单臂、双臂和移动机器人的多种场景。它们测试核心记忆能力, 例如处理部分可观测性 (例如, 记住人类将物体放入哪个抽屉; 拆开购物袋并记住是否还有物体未取出; 在咖啡机下放置和取出多个杯子)、计数 (例如, 数出加入咖啡研磨机的咖啡勺数)、计时 (例如, 记住烤奶酪三明治已烹饪多长时间, 见图 5) 以及空间记忆 (例如, 记住窗户的哪些部分已经擦拭过)。这些任务还要求策略执行精确操作 (例如, 折叠一叠衣物或组装纸箱)。因此, 它们非常适合测试现有记忆方法的极限, 并与无记忆的最先进视觉语言动作模型的性能进行比较。遵循先前工作 [18], 我们为最具挑战性的操作任务和记忆任务收集小规模后训练数据集, 并对其余所有任务直接评估策略 (图 10)。我们在第 B 节中提供了所有任务设置的详细描述。比较。许多先前工作利用基于观测的 (较短视界) 记忆, 并通过积极压缩过去时间步的观测来应对其计算挑战。我们将我们的方法与两个代表性的先前工作进行比较, 以理解不同记忆表示的权衡:

(1) 池化记忆, 类似于 Jang 等人 [20], 我们使用平均池化将所有过去观测压缩为单个“记忆标记”。我们通过使用预训练的单帧视觉 Transformer 分别编码每个过去观测, 然后在将帧编码传入视觉语言动作模型主干之前对其应用平均池化操作来实现。当前时间步的观测被单独编码并传入视觉语言动作模型, 不进行池化; (2) 本体感觉记忆, 仅以低维机器人状态的历史为条件, 类似于 [53], 以避免高维图像记忆的计算成本。所有过去时间步的本体感觉状态分别通过线性投影, 然后输入视觉语言动作模型主干。为确保公平比较, 我们在其上重新实现了所有方法

$\pi_{0.6}$ VLA 主干网络, 并使用不含基于语言的长时记忆的模型版本。为测试策略在最灵巧任务上的性能, 本文还与无记忆的 $\pi_{0.6}$ 进行比较, 后者是在复杂操作任务上表现优异的最先进 VLA [35]。最后, 为深入理解预训练对记忆效能的影响, 本文与 **MEM-Posttrain-Only** 进行对比, 该消融实验仅在目标任务的后训练阶段引入视频编码器, 从预训练的 $\pi_{0.6}$ 检查点开始, 类似于 Li 等人 [24] 的做法。




图 8: 为 VLA 配备记忆的方法在核心记忆能力（处理部分可观测性、计数、视觉记忆）方面的比较。无记忆的 VLA 难以完成这些任务。只有 MEM 的记忆方法在所有核心能力上表现良好。




图 9: 在包含机器人与非机器人视频数据的多样化数据集上预训练 MEM，使其更有效地利用记忆解决多样化操作任务。仅在后续训练阶段引入记忆会导致性能显著下降。

结果如图 8 所示。本文首先在测试核心记忆能力的任务上比较不同记忆方法（图 8）。正如预期，无记忆的 $\pi_{0.6}$ VLA 在这些任务上表现不佳，常常只能依赖随机猜测，例如在四个抽屉中选择一个以找到隐藏物体（成功率为 25%）或决定是否再添加一勺咖啡（成功率为 50%）。相比之下，现有记忆方案提升了性能，尤其是在仅需少量记忆的简单记忆任务上，例如记住已向料斗中添加了多少勺咖啡。本文发现，Pool-Memory 通过平均池化对观测进行激进压缩，导致其在需要较长时记忆的任务上尤其吃力，例如记住多个咖啡杯的过往位置或回忆杂货袋中还有多少物品待取出。另一方面，Proprio-Memory 仅在机器人需要记住自身状态的任务中有效，而在需要记住环境状态的场景中表现不佳，例如回忆哪个抽屉装有特定物体。相比之下，MEM VLA 是唯一在所有测试的记忆能力上均取得优异性能模型。

它能够可靠地应对部分可观测性挑战，例如记住物体的位置，并能在诸如拆开一袋杂货等灵巧任务中利用这些能力。值得注意的是，在包含机器人和非机器人数据的多样化数据混合上对基于观测的记忆进行预训练，显著提升了模型利用其记忆的能力

——即使在训练后记忆时长显著扩展的情况下（例如，从预训练时的 5 秒扩展到训练后最长 1 分钟）。仅在训练后引入记忆的模型版本在利用过去时间步信息方面明显较差（见图 9）。

我们强调，该模型仍然从在相同多样化机器人数据上预训练的 $\pi_{0.6}$ 基础检查点初始化，但在预训练期间并未发展出记忆能力。最后，我们的模型（仅训练后）与池化记忆的直接对比表明，即使没有预训练，我们的视频编码器设计在从先前时间步提取信息方面也比分别编码每个时间步并进行平均池化更有效。通过在视觉 Transformer 的各层中交错时间注意力操作，我们的视频编码器能够更有效地提取和压缩相关信息。

除了测试核心记忆能力外，我们还在多种具有挑战性的灵巧操作任务上测试了 MEM 的性能（图 10）。我们发现，MEM 视觉-语言-动作模型不仅在需要记忆的任务中有效利用记忆，而且还能在具有挑战性的灵巧操作任务中达到与 $\pi_{0.6}$ 视觉-语言-动作模型相当的最先进性能。这一点值得注意，因为许多先前工作报告了向策略添加记忆会导致性能下降，例如由于因果混淆 [11, 55]。我们将 MEM 的强劲性能在很大程度上归因于我们多样化的预训练数据混合，其中包含不同最优性、速度和控制频率的片段，以及多样化的互联网视频。这种多样性可以防止视频编码器在较小、




图 10: 除了有效利用其记忆外, MEM 还在不需要记忆的挑战性操作任务中达到了与最先进的无记忆视觉-语言-动作模型相当的性能。

更均匀的机器人数据集上训练时可能出现的虚假相关性, 并导致先前工作中报告的记忆策略的脆弱性和性能下降。

五、结论

我们提出了多尺度具身记忆 (Multi-Scale Embodied Memory, MEM), 一种为视觉-语言-动作模型 (VLA) 配备长时程记忆的方法。MEM 使 VLA 能够执行需要数十分钟记忆的长时程任务, 同时满足现实世界的延迟约束。MEM 还支持操作策略的上下文自适应, 并且当与 $\pi_{0.6}$ VLA 结合时, 在广泛的操纵任务中达到了最先进的性能。为实现这一目标, MEM 引入了一种混合模态记忆架构, 将基于视频的短时程记忆与基于语言的长时程记忆机制相结合。我们相信, MEM 只是构建能够有效管理极长时程记忆的机器人策略的第一步。未来的工作可以探索如何将记忆扩展到超越单个回合的时程, 跨越数周、数月或数年的部署, 并使我们能够构建在部署时持续学习的机器人。

致谢

与任何这种规模的机器人研究工作一样, 我们的工作涉及一个庞大的团队, 他们在数据收集、评估、机器人操作和维护方面提供了帮助。我们感谢 Pi 机器人操作员和标注人员在数据收集、评估和标注方面的帮助。我们感谢运营团队在后勤和调度方面的帮助。我们感谢硬件团队保持所有机器人的正常运行。我们还感谢 Lili Yu 对视频编码器架构的有益讨论。我们感谢 Claudio Guglieri 在博客文章可视化方面的帮助, 以及 Donald Jewkes 在视频拍摄和编辑方面的帮助。

参考文献

[1] Anurag Arnab, Mostafa Dehghani, Georg Heigold, Chen Sun, Mario Lučić, and Cordelia Schmid. ViViT: A video

vision transformer. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 6836–6846, 2021.

- [2] Suneel Belkhale and Dorsa Sadigh. Minivla: A better vla with a smaller footprint, 2024. URL <https://github.com/Stanford-ILIAD/openvla-mini>.
- [3] Gedas Bertasius, Heng Wang, and Lorenzo Torresani. Is space-time attention all you need for video understanding? In *International Conference on Machine Learning (ICML)*, volume 2, page 4, 2021.
- [4] Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, et al. Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*, 2025.
- [5] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- [6] Kevin Black, Manuel Y Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. *arXiv preprint arXiv:2506.07339*, 2025.
- [7] Kevin Black, Allen Z Ren, Michael Equi, and Sergey Levine. Training-time action conditioning for efficient real-time chunking. *arXiv preprint arXiv:2512.05964*, 2025.
- [8] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, Pete Florence, Chuyuan Fu, Montse Gonzalez Arenas, Keerthana Gopalakrishnan, Kehang Han, Karol Hausman, Alex Herzog, Jasmine Hsu, Brian Ichter, Alex Irpan, Nikhil Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Lisa Lee, Tsang-Wei Edward Lee, Sergey Levine, Yao Lu, Henryk Michalewski, Igor Mordatch, Karl Pertsch, Kanishka Rao, Krista Reymann, Michael

- Ryoo, Grecia Salazar, Pannag Sanketi, Pierre Sermanet, Jaspiar Singh, Anikait Singh, Radu Soricut, Huong Tran, Vincent Vanhoucke, Quan Vuong, Ayzaan Wahid, Stefan Welker, Paul Wohlhart, Jialin Wu, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *arXiv preprint arXiv:2307.15818*, 2023.
- [9] Jingjing Chen, Hongjie Fang, Chenxi Wang, Shiquan Wang, and Cewu Lu. History-aware visuomotor policy learning via point tracking. *arXiv preprint arXiv:2509.17141*, 2025.
- [10] Shouyuan Chen, Sherman Wong, Liangjian Chen, and Yuandong Tian. Extending context window of large language models via positional interpolation. *arXiv preprint arXiv:2306.15595*, 2023.
- [11] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, 2025.
- [12] Nhat Chung, Taisei Hanyu, Toan Nguyen, Huy Le, Frederick Bumgarner, Duy Minh Ho Nguyen, Khoa Vo, Kashu Yamazaki, Chase Rainwater, Tung Kieu, et al. Rethinking progression of memory state in robotic manipulation: An object-centric perspective. *arXiv preprint arXiv:2511.11478*, 2025.
- [13] Ria Doshi, Homer Walke, Oier Mees, Sudeep Dasari, and Sergey Levine. Scaling cross-embodied learning: One policy for manipulation, navigation, locomotion and aviation. In *Conference on Robot Learning*, 2024.
- [14] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2020.
- [15] Danny Driess, Fei Xia, Mehdi SM Sajjadi, Corey Lynch, Aakanksha Chowdhery, Brian Ichter, Ayzaan Wahid, Jonathan Tompson, Quan Vuong, Tianhe Yu, et al. Palm-e: An embodied multimodal language model. *arXiv preprint arXiv:2303.03378*, 2023.
- [16] Danny Driess, Jost Tobias Springenberg, Brian Ichter, Lili Yu, Adrian Li-Bell, Karl Pertsch, Allen Z Ren, Homer Walke, Quan Vuong, Lucy Xiaoyang Shi, et al. Knowledge insulating vision-language-action models: Train fast, run fast, generalize better. *arXiv preprint arXiv:2505.23705*, 2025.
- [17] Haoquan Fang, Markus Grotz, Wilbert Pumacay, Yi Ru Wang, Dieter Fox, Ranjay Krishna, and Jiafei Duan. Sam2act: Integrating visual foundation model with a memory architecture for robotic manipulation. *arXiv preprint arXiv:2501.18564*, 2025.
- [18] Physical Intelligence. π_0 : A vision-language-action flow model for general robot control, 2024. URL <https://arxiv.org/abs/2410.24164>.
- [19] Physical Intelligence. $\pi_{0.5}$: a vision-language-action model with open-world generalization, 2025. URL <https://arxiv.org/abs/2504.16054>.
- [20] Huiwon Jang, Sihyun Yu, Heeseung Kwon, Hojin Jeon, Younggyo Seo, and Jinwoo Shin. Contextvla: Vision-language-action model with amortized multi-frame context. *arXiv preprint arXiv:2510.04246*, 2025.
- [21] Aishwarya Kamath, Johan Ferret, Shreya Pathak, Nino Vieillard, Ramona Merhej, Sarah Perrin, Tatiana Matejovicova, Alexandre Ramé, Morgane Riviére, Louis Rouillard, et al. Gemma 3 technical report. *arXiv preprint arXiv:2503.19786*, 4, 2025.
- [22] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- [23] Seungjae Lee, Yibin Wang, Haritheja Etukuru, H. Jin Kim, Nur Muhammad Mahi Shafiullah, and Lerrel Pinto. Behavior generation with latent actions. *arXiv preprint arXiv:2403.03181*, 2024.
- [24] Hao Li, Shuai Yang, Yilun Chen, Xinyi Chen, Xiaoda Yang, Yang Tian, Hanqing Wang, Tai Wang, Dahua Lin, Feng Zhao, et al. Cronusvla: Towards efficient and robust manipulation via multi-frame vision-language-action modeling. *AAAI*, 2025.
- [25] Kunchang Li, Xinhao Li, Yi Wang, Yinan He, Yali Wang, Limin Wang, and Yu Qiao. Videomamba: State space model for efficient video understanding. In *European conference on computer vision*, pages 237–255. Springer, 2024.
- [26] Fanqi Lin, Ruiqian Nai, Yingdong Hu, Jiacheng You, Junming Zhao, and Yang Gao. Onetwovla: A unified vision-language-action model with adaptive reasoning. *arXiv preprint arXiv:2505.11917*, 2025.
- [27] Jiaheng Liu, Dawei Zhu, Zhiqi Bai, Yancheng He, Huanxuan Liao, Haoran Que, Zekun Wang, Chenchen Zhang, Ge Zhang, Jiebin Zhang, et al. A comprehensive survey on long context language modeling. *arXiv preprint arXiv:2503.17407*, 2025.
- [28] Ajay Mandlekar, Danfei Xu, Josiah Wong, Soroush Nasiriany, Chen Wang, Rohun Kulkarni, Li Fei-Fei, Silvio Savarese, Yuke Zhu, and Roberto Martín-Martín. What matters in learning from offline human demonstrations for robot manipulation. *CoRL*, 2021.
- [29] Max Sobol Mark, Jacky Liang, Maria Attarian, Chuyuan Fu, Debidatta Dwibedi, Dhruv Shah, and Aviral Kumar. Bpp: Long-context robot imitation learning by focusing on key history frames. *arXiv preprint arXiv:2602.15010*, 2026.
- [30] Bolin Ni, Houwen Peng, Minghao Chen, Songyang Zhang, Gaofeng Meng, Jianlong Fu, Shiming Xiang, and Haibin Ling. Expanding language-image pretrained models for general video recognition. In *European conference on computer vision*, pages 1–18. Springer, 2022.
- [31] NVIDIA. Gr00t n1: An open foundation model for

- generalist humanoid robots, 2025. URL <https://arxiv.org/abs/2503.14734>.
- [32] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Charles Xu, Jianlan Luo, Tobias Kreiman, You Liang Tan, Lawrence Yunliang Chen, Pannag Sanketi, Quan Vuong, Ted Xiao, Dorsa Sadigh, Chelsea Finn, and Sergey Levine. Octo: An open-source generalist robot policy. In *Proceedings of Robotics: Science and Systems*, Delft, Netherlands, 2024.
- [33] Open X-Embodiment Collaboration, Abhishek Padalkar, Acorn Pooley, Ajinkya Jain, Alex Bewley, Alex Herzog, Alex Irpan, Alexander Khazatsky, Anant Rai, Anikait Singh, Anthony Brohan, Antonin Raffin, Ayzaan Wahid, Ben Burgess-Limerick, Beomjoon Kim, Bernhard Schölkopf, Brian Ichter, Cewu Lu, Charles Xu, Chelsea Finn, Chenfeng Xu, Cheng Chi, Chenguang Huang, Christine Chan, Chuer Pan, Chuyuan Fu, Coline Devin, Danny Driess, Deepak Pathak, Dhruv Shah, Dieter Buehler, Dmitry Kalashnikov, Dorsa Sadigh, Edward Johns, Federico Ceola, Fei Xia, Freek Stulp, Gaoyue Zhou, Gaurav S. Sukhatme, Gautam Salhotra, Ge Yan, Giulio Schiavi, Hao Su, Hao-Shu Fang, Haochen Shi, Heni Ben Amor, Henrik I Christensen, Hiroki Furuta, Homer Walke, Hongjie Fang, Igor Mordatch, Ilija Radosavovic, Isabel Leal, Jacky Liang, Jaehyung Kim, Jan Schneider, Jasmine Hsu, Jeannette Bohg, Jeffrey Bingham, Jiajun Wu, Jialin Wu, Jianlan Luo, Jiayuan Gu, Jie Tan, Jihoon Oh, Jitendra Malik, Jonathan Tompson, Jonathan Yang, Joseph J. Lim, João Silvério, Junhyek Han, Kanishka Rao, Karl Pertsch, Karol Hausman, Keegan Go, Keerthana Gopalakrishnan, Ken Goldberg, Kendra Byrne, Kenneth Oslund, Kento Kawaharazuka, Kevin Zhang, Keyvan Majd, Krishan Rana, Krishnan Srinivasan, Lawrence Yunliang Chen, Lerrel Pinto, Liam Tan, Lionel Ott, Lisa Lee, Masayoshi Tomizuka, Maximilian Du, Michael Ahn, Mingtong Zhang, Mingyu Ding, Mohan Kumar Srirama, Mohit Sharma, Moo Jin Kim, Naoaki Kanazawa, Nicklas Hansen, Nicolas Heess, Nikhil J Joshi, Niko Suenderhauf, Norman Di Palo, Nur Muhammad Mahi Shafiullah, Oier Mees, Oliver Kroemer, Pannag R Sanketi, Paul Wohlhart, Peng Xu, Pierre Sermanet, Priya Sundareshan, Quan Vuong, Rafael Rafailov, Ran Tian, Ria Doshi, Roberto Martín-Martín, Russell Mendonca, Rutav Shah, Ryan Hoque, Ryan Julian, Samuel Bustamante, Sean Kirmani, Sergey Levine, Sherry Moore, Shikhar Bahl, Shivin Dass, Shuran Song, Sichun Xu, Siddhant Halder, Simeon Adebola, Simon Guist, Soroush Nasiriany, Stefan Schaal, Stefan Welker, Stephen Tian, Sudeep Dasari, Suneel Belkale, Takayuki Osa, Tatsuya Harada, Tatsuya Matsushima, Ted Xiao, Tianhe Yu, Tianli Ding, Todor Davchev, Tony Z. Zhao, Travis Armstrong, Trevor Darrell, Vidhi Jain, Vincent Vanhoucke, Wei Zhan, Wenxuan Zhou, Wolfram Burgard, Xi Chen, Xiaolong Wang, Xinghao Zhu, Xuanlin Li, Yao Lu, Yevgen Chebotar, Yifan Zhou, Yifeng Zhu, Ying Xu, Yixuan Wang, Yonatan Bisk, Yoonyoung Cho, Youngwoon Lee, Yuchen Cui, Yueh hua Wu, Yujin Tang, Yuke Zhu, Yunzhu Li, Yusuke Iwasawa, Yutaka Matsuo, Zhuo Xu, and Zichen Jeff Cui. Open X-Embodiment: Robotic learning datasets and RT-X models. <https://arxiv.org/abs/2310.08864>, 2023.
- [34] Karl Pertsch, Kyle Stachowicz, Brian Ichter, Danny Driess, Suraj Nair, Quan Vuong, Oier Mees, Chelsea Finn, and Sergey Levine. Fast: Efficient action tokenization for vision-language-action models. *Robotics: Science and Systems*, 2025.
- [35] Physical Intelligence. $\pi_{0.6}$ model card. 2025. URL https://website.pi-asset.com/pi06star/PI06_model_card.pdf.
- [36] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.
- [37] Rouhollah Rahmatizadeh, Pooya Abolghasemi, Ladislau Bölöni, and Sergey Levine. Vision-based multi-task manipulation for inexpensive robots using end-to-end learning from demonstration. In *2018 IEEE international conference on robotics and automation (ICRA)*, pages 3758–3765. IEEE, 2018.
- [38] Nur Muhammad Shafiullah, Zichen Cui, Ariuntuya Arty Altanzaya, and Lerrel Pinto. Behavior transformers: Cloning k modes with one stone. *Advances in neural information processing systems*, 35:22955–22968, 2022.
- [39] Hao Shi, Bin Xie, Yingfei Liu, Lin Sun, Fengrong Liu, Tiancai Wang, Erjin Zhou, Haoqiang Fan, Xiangyu Zhang, and Gao Huang. Memoryvla: Perceptual-cognitive memory in vision-language-action models for robotic manipulation. *arXiv preprint arXiv:2508.19236*, 2025.
- [40] Ajay Sridhar, Jennifer Pan, Satvik Sharma, and Chelsea Finn. Memer: Scaling up memory for robot control via experience retrieval. *arXiv preprint arXiv:2510.20328*, 2025.
- [41] Andrew Szot, Bogdan Mazouze, Omar Attia, Aleksei Timofeev, Harsh Agrawal, Devon Hjelm, Zhe Gan, Zsolt Kira, and Alexander Toshev. From multimodal llms to generalist embodied agents: Methods and lessons. *arXiv preprint arXiv:2412.08442*, 2024.
- [42] Yunlong Tang, Jing Bi, Siting Xu, Luchuan Song, Susan Liang, Teng Wang, Daoan Zhang, Jie An, Jingyang Lin, Rongyi Zhu, et al. Video understanding with large language models: A survey. *IEEE Transactions on Circuits and Systems for Video Technology*, 2025.
- [43] Gemini Robotics Team. Gemini robotics 1.5: Pushing the frontier of generalist robots with advanced embodied reasoning, thinking, and motion transfer, 2025. URL <https://arxiv.org/abs/2510.03342>.
- [44] Gemini Robotics Team, Saminda Abeyruwan, Joshua Ainslie, Jean-Baptiste Alayrac, Montserrat Gonzalez Arenas, Travis Armstrong, Ashwin Balakrishna, Robert Baruch, Maria Bauza, Michiel Blokzijl, et al. Gemini robotics: Bringing ai into the physical world. *arXiv preprint arXiv:2503.20020*, 2025.

- [45] GigaBrain Team, Boyuan Wang, Chaojun Ni, Guan Huang, Guosheng Zhao, Hao Li, Jie Li, Jindi Lv, Jingyu Liu, Lv Feng, et al. Gigabrain-0.5 m*: a vla that learns from world model-based reinforcement learning. *arXiv preprint arXiv:2602.12099*, 2026.
- [46] TRI LBM Team. A careful examination of large behavior models for multitask dexterous manipulation. *arXiv preprint*, 2025. URL <https://arxiv.org/abs/2507.05331>.
- [47] Marcel Torne, Andy Tang, Yuejiang Liu, and Chelsea Finn. Learning long-context diffusion policies via past-token prediction. *arXiv preprint arXiv:2505.09561*, 2025.
- [48] Yi-Lin Wei, Haoran Liao, Yuhao Lin, Pengyue Wang, Zhizhao Liang, Guiliang Liu, and Wei-Shi Zheng. Cyclemanip: Enabling cyclic task manipulation via effective historical perception and understanding. *arXiv preprint arXiv:2512.01022*, 2025.
- [49] Junjie Wen, Yichen Zhu, Jinming Li, Minjie Zhu, Kun Wu, Zhiyuan Xu, Ning Liu, Ran Cheng, Chaomin Shen, Yaxin Peng, Feifei Feng, and Jian Tang. Tinyvla: Towards fast, data-efficient vision-language-action models for robotic manipulation. *arXiv preprint arXiv:2409.12514*, 2024.
- [50] Junjie Wen, Yichen Zhu, Jinming Li, Zhibin Tang, Chaomin Shen, and Feifei Feng. Dexvla: Vision-language model with plug-in diffusion expert for general robot control. *arXiv preprint arXiv:2502.05855*, 2025.
- [51] Wei Wu, Fan Lu, Yunnan Wang, Shuai Yang, Shi Liu, Fangjing Wang, Qian Zhu, He Sun, Yong Wang, Shuailei Ma, et al. A pragmatic vla foundation model. *arXiv preprint arXiv:2601.18692*, 2026.
- [52] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, You Liang Tan, Chuning Zhu, Jiannan Xiang, Ayaan Malik, Kyungmin Lee, William Liang, Nadun Ranawaka, Jiasheng Gu, Yinzhen Xu, Guanzhi Wang, Fengyuan Hu, Avnish Narayan, Johan Bjorck, Jing Wang, Gwanghyun Kim, Dantong Niu, Ruijie Zheng, Yuqi Xie, Jimmy Wu, Qi Wang, Ryan Julian, Danfei Xu, Yilun Du, Yevgen Chebotar, Scott Reed, Jan Kautz, Yuke Zhu, Linxi "Jim" Fan, and Joel Jang. World action models are zero-shot policies, 2026. URL <https://arxiv.org/abs/2602.15922>.
- [53] Zongzheng Zhang, Haobo Xu, Zhuo Yang, Chenghao Yue, Zehao Lin, Huan-ang Gao, Ziwei Wang, and Hao Zhao. Ta-vla: Elucidating the design space of torque-aware vision-language-action models. *arXiv preprint arXiv:2509.07962*, 2025.
- [54] Haoyu Zhen, Xiaowen Qiu, Peihao Chen, Jincheng Yang, Xin Yan, Yilun Du, Yining Hong, and Chuang Gan. 3d-vla: 3d vision-language-action generative world model. *arXiv preprint arXiv:2403.09631*, 2024.
- [55] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. Tracevla: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. *arXiv preprint arXiv:2412.10345*, 2024.

附录

A. 贡献

该项目由 HW 和 DD 发起。DD、HW 和 JTS 设计了视频编码器和短时程记忆系统。KP 设计了长时程记忆系统。MT、KP、HW、KV、SN 和 ME 设计了评估套件并进行了实验评估，包括模型后训练。DD、KP、AR 和 QV 开发了预训练方案和数据混合，并进行了大规模模型训练。HW、KD、KS 和 MT 开发了长上下文 VLA 训练的基础设施。JT 优化了 MEM VLA 的推理。SL 和 CF 在整个项目中提供了建议。MT、KP、DD、BI、KV、SN、SL 和 CF 参与了写作、插图和视频制作。

B. 任务细节

1) 长时程任务（第四节-A）：

a) 为食谱准备食材：该任务的目标是让机器人取出食谱所需的所有食材。这些食材被放置在厨房中各种随机的位置（冰箱、橱柜、抽屉、炉灶等）。策略的提示指定了应组装哪些物品、它们应放置的位置（台面、炉灶、水槽）以及它们在厨房中的初始位置。我们在下面列出了一些提示示例。机器人每取出并放置到指定位置的物品将获得 1 分。大多数食谱包含 6 到 7 个得分点。我们收集了超过 40 个食谱的数据，涉及大量不同的物体、场景、电器和提示。评估是在各种未见过的场景上进行的，使用已见过的食谱。

Mashed potatoes

取出食谱所需的用品。取下炉灶上锅的盖子，将盖子放在水槽左侧的台面上，然后拿起锅放入水槽。从冰箱中取出土豆、黄油、牛奶，并将它们放在水槽左侧的台面上。从水槽左侧最上面的抽屉中取出捣碎器，并将其放在炉灶左侧的台面上。

Fried rice

取出食谱所需的用品。从洗碗机右下方的橱柜中取出大米袋和午餐肉，并将它们放在水槽左侧的台面上。从冰箱中取出酱油，并将其放在水槽左侧台面的同一区域。从洗碗机右侧下方的橱柜中取出平底锅，并将其放在炉灶上。从洗碗机右侧最上面的抽屉中取出锅铲，并将其放在炉灶上的平底锅上。

Pizza

取出食谱所需的用品。从洗碗机左侧下方的橱柜中取出烤盘，并将其放在水槽左侧的台面上。从冰箱中取出披萨面团、意大利辣香肠包装和奶酪袋，并将它们放在水槽左侧的台面上。从炉灶右侧最上面的抽屉中取出擀面杖，并将其放在水槽左侧的台面上。

b) 清洁厨房：该任务要求清洁厨房，包括用海绵擦拭台面、用纸巾擦干台面、将台面上遗留的食物放入冰箱、将碗架上的所有餐具放入橱柜，以及清洗水槽中的所有餐具。评分标准为每完成一个子任务得 1 分，平均每个回合包含 8 个子任务。下面我们提供一个示例提示。

Clean kitchen

清理厨房。用海绵擦拭台面，然后用纸巾擦干，并将纸巾扔进水槽下方的垃圾桶。将芥末放入冰箱。将餐具放入冰箱左侧的底部橱柜。清洗蓝色盘子和黑色盘子，并将它们放入碗架。

2) 上下文适应（第四节-B）：

a) 筷子拾取：策略的任务是在高度可变的桌子上拾取一根筷子。在数据收集过程中，筷子被随机放置在桌子上，桌子高度在高度范围的上半部分随机取值。

每当策略抓取失败时，我们收集人类干预数据，然后使用这些数据训练有记忆和无记忆的策略，并在筷子随机放置在最低高度设置的桌子上进行评估。最终策略拾取筷子得 1 分，将其放入垃圾桶得 1 分，成功标准为得 2 分。b) 打开冰箱：任务目标是打开机器人前方的冰箱。冰箱没有明显的视觉线索表明门铰链在哪一侧，导致策略经常试图朝错误的方向打开冰箱。每当机器人朝错误方向打开冰箱时，我们收集人类干预数据。在评估中，如果一个回合在 ≤ 4 次抓取内打开门，则定义为成功，以测试有意的策略切换而非重复随机采样。

3) 分析实验（第四节第三部分）：a) 三向交换马克杯：目标是将三个咖啡杯依次放置在咖啡机下方。两个杯子起始于桌面随机位置，第三个杯子起始于咖啡机下方。评分规则为：每个杯子在不倾倒且不重复的情况下被放到咖啡机上，获得+1 分。咖啡机上一次只能放一个杯子，因此机器人需要在该杯子被放到咖啡机下方后，将其放回桌面随机位置，为下一个杯子腾出空间。b) 寻找物体：目标是在一个带有四个抽屉的柜子中取出隐藏的物体。回合开始时，一个人将物体放入随机抽屉。机器人需要记住物体被放入哪个抽屉，然后打开正确的抽屉，取出物品并放在桌子上。成功完成任务且未打开任何错误抽屉，将获得一分。c) 拆开杂货：目标是从杂货袋中取出所有物品，且不遗漏任何内部物品。从机器人的第三人称摄像头无法观察到袋子内部，且袋中物品数量在回合间随机变化。因此，要完成任务，机器人需要根据其过去的手腕摄像头观察记住袋中还剩多少物品。如果策略从袋中取出所有物品，并在取出所有物品后通过返回原位表示完成，则回合标记为成功。d) 舀咖啡：目标是将恰好两勺咖啡豆放入研磨机。机器人需要从研磨机料斗上取下盖子，拿起咖啡勺，从打开的咖啡豆包装中舀两勺咖啡放入研磨机，然后重新盖上盖子。如果恰好加入两勺咖啡且盖子被重新盖上，则回合标记为成功。e) 烤奶酪三明治：任务目标是制作一个烤奶酪三明治。机器人需要在平底锅中组装烤奶酪三明治，然后等待烤奶酪烹饪，翻面，等待另一面烹饪，最后将烤奶酪装盘。策略在组装三明治、烹饪时间正确（每面 30 秒至 3 分钟）、翻面和装盘时各获得+1 分。f) 擦窗：目标是擦拭电话亭的窗门。任务包括在窗户上喷洒玻璃清洁剂，从卷筒上撕下一张纸巾，然后擦拭整扇窗户，最后将纸巾扔进垃圾桶。机器人需要记住在清洁阶段哪些步骤已完成以及窗户的哪些部分已被擦拭。如果任务的所有步骤均完成，则回合标记为成功。如果策略未能擦拭窗户的某些部分，则视为失败。g) 清理餐桌：目标是将桌面上的 12 个物体分类放入 (A) 餐具收集箱（用于餐具和餐桌用具）和 (B) 垃圾桶（用于塑料容器、瓶子和包装纸）。策略每正确放置一个物品获得+1 分。h) 叠衬衫：机器人需要在桌面上折叠一件衬衫。回合开始时，衬衫平铺在桌上。如果衬衫成功折叠成矩形，且没有接缝外露或过多褶皱，则回合记为成功。i) 清理台面：目标是将台面上的物品清理到抽屉中。机器人需要打开抽屉，将台面上的所有物品放入抽屉，然后关闭抽屉。如果所有子任务均成功完成，则回合记为成功。j) 整理床铺：目标是通过拉直毯子并将所有枕头放在床头来整理床铺。如果所有枕头都放在床头且毯子被整理好，则回合记为成功。k) 厨房清理：目标是通过将台面上的多个盘子、碗和砧板放入附近的水槽来清理厨房台面。如果所有盘子都放入水槽，则回合记为成功。l) 批量折叠：与叠衬衫任务不同，这里衣物起始于桌子一侧的洗衣篮中。机器人需要从洗衣篮中取出衣物，将其展平、折叠，然后将其堆叠到桌上已有的衣物堆上。洗衣篮中可能包含各种 T 恤和短裤。如果衣物被折叠成矩形，且没有接缝外露或过多褶皱，则回合记为成功。

m) 盒子搭建：给定一块压平的纸板裁片，机器人需将纸板折叠成盒子。该任务需要多次精确且协调良好的双手操作来组装盒子。若盒子完整组装且未损坏，则该回合记为成功。

C. 采用时空可分离注意力的视频编码器 我们描述如何调整给定视觉变换器图像编码器中的某一层，以实例化我们的视频编码方案。设 $\mathbf{z}_{p,t}^{l-1}$ 表示第 l 层中空间块 p 和时间步 t （其中 $t \in [-K, 0]$ ）的输入嵌入。我们首先通过基于 t 添加正弦位置嵌入来修改嵌入，并将该步骤的输出记为

$$\hat{\mathbf{z}}_{p,t}^{l-1} = \mathbf{z}_{p,t}^{l-1} + e(t),$$

其中 $e(t)$ 表示正弦位置嵌入，我们设定边界条件 $e(0) = 0$ 。然后我们复用视觉变换器的标准查询、键和值投影，在我们的情况下表示为

$$\begin{aligned} \mathbf{q}_{p,t}^{l,a} &= W_Q^{l,a} \text{LN}(\hat{\mathbf{z}}_{p,t}^{l-1}), \\ \mathbf{k}_{p,t}^{l,a} &= W_K^{l,a} \text{LN}(\hat{\mathbf{z}}_{p,t}^{l-1}), \\ \mathbf{v}_{p,t}^{l,a} &= W_V^{l,a} \text{LN}(\hat{\mathbf{z}}_{p,t}^{l-1}), \end{aligned} \quad (1)$$

其中 a 索引注意力头，LN 表示层归一化实现（我们使用 RMSNorm，但此选择取决于我们初始的视觉变换器）。接下来，我们可以将一般注意力机制（为简化符号忽略归一化）定义为查询与键外积上的 Softmax 函数：

$$\alpha_{p,t}^{l,a}(\mathcal{S} = \{1, \dots, N\}, \mathcal{T} = \{1, \dots, T\})[\hat{\mathbf{z}}] = \text{SM}\left((\mathbf{q}_{p,t}^{l,a})^T \cdot [\mathbf{k}_{0,0}^{l,a} \{\mathbf{k}_{p',t'}^{l,a}\}_{p' \in \mathcal{S}, t' \in \mathcal{T}}]\right), \quad (2)$$

其中 SM 表示 Softmax 运算， $\mathcal{S} = \{1, \dots, N\}$ 和 $\mathcal{T} = \{1, \dots, T\}$ 分别表示我们希望执行注意力的空间和时间索引。根据这一一般定义，我们可以将仅空间注意力机制定义为实例化 $\alpha_{p,t}^{l,a}(\mathcal{S} = \{1, \dots, N\}, \mathcal{T} = \{\})$ ，将仅时间注意力机制定义为实例化 $\alpha_{p,t}^{l,a}(\mathcal{S} = \{\}, \mathcal{T} = \{1, \dots, T\})$ 。因此，我们的视频编码器中使用的注意力机制精确地表示为

$$\alpha_{p,t}^{l,a}(\mathcal{S} = \{1, \dots, N\}, \mathcal{T} = \{\})[\alpha_{p,t}^{l,a}(\mathcal{S} = \{1, \dots, N\}, \mathcal{T} = \{1, \dots, T\})[\hat{\mathbf{z}}]]. \quad (3)$$

此后，我们遵循变换器层的标准计算流程，即首先将注意力权重 α 与值 $\mathbf{v}$ 结合，并将相应输出传递给多层感知机，从而计算变换器的输出。