

MemER: 通过经验检索扩展机器人控制的记忆能力

Ajay Sridhar* Jennifer Pan* Satvik Sharma Chelsea Finn
Stanford University
{ajaysri, jrpan}@stanford.edu

摘要

人类通常依赖记忆来执行任务，然而大多数机器人策略缺乏这种能力；我们的目标是为机器人策略赋予同样的能力。简单地以长观测历史为条件在计算上代价高昂，且在协变量偏移下表现脆弱，而对历史进行不加区分的子采样会导致信息无关或冗余。本文提出一种分层策略框架，其中高层策略经过训练，从其经验中选择并跟踪先前相关的关键帧。高层策略在生成供低层策略执行的文本指令时，使用所选关键帧和最近的帧。该设计兼容现有的视觉-语言-动作（VLA）模型，并使系统能够高效地推理长时程依赖关系。在实验中，我们分别微调 Qwen2.5-VL-7B-Instruct 和 $\pi_{0.5}$ 作为高层和低层策略，使用补充了最少语言标注的演示数据。我们的方法 MemER 在三个需要数分钟记忆的真实世界长时程机器人操作任务上优于先前方法。视频和代码可在 <https://jen-pan.github.io/memer/> 获取。

1 引言

近年来，机器人在操作策略的语言遵循和泛化能力方面取得了显著进展（Brohan 等，2023；Intelligence 等，2025；Kim 等，2024；NVIDIA 等，2025；Team 等，2025）。尽管这些策略在真实世界部署中不断改进，但仍存在一个关键局限：缺乏长期记忆。记忆使人类能够应对环境中固有的部分可观测性。例如，如果一个人想要制作三明治，他必须回忆起在哪里看到过花生酱罐或刀，尤其是当这些物品最近没有被看到时。形成和检索记忆的能力是机器人解决复杂多步骤任务的关键一步。本文的目标是提供一种有效的方法，使现有的通用策略能够解决需要长期视觉记忆的任务。

由于以高维图像和视频序列的长序列为条件进行计算代价高昂，许多现有的通用端到端策略在训练时几乎不使用视觉历史。高昂的内存成本使得训练成本过高，模型部署速度慢得无法使用。此外，长观测历史常常会引入一种过拟合——捷径依赖输入与演示者动作之间的虚假相关性（Torne 等，2025）。策略在其自身状态分布下错误泛化，导致部署期间因演示者策略与学习策略访问状态之间的复合协变量偏移而性能下降。次优策略将生成与专家所见不同的历史，且随着观测历史变长，情况只会更糟。

一些过去的工作表明，可以通过辅助损失（Torne 等，2025）或通过微调具有原生记忆能力的预训练基础模型进行动作预测（Fang 等，2025）来扩展策略的观测上下文。尽管这些方法显著增加了机器人可执行任务的类型，但将其简单扩展到长历史仍具挑战性。* 同等贡献

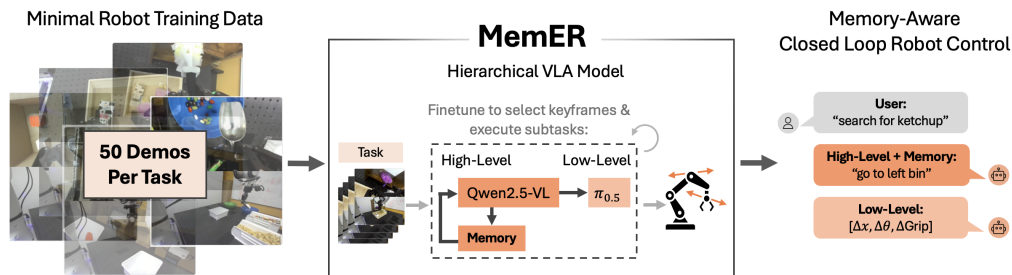


图 1: MemER 概览。我们提出 MemER，一个用于扩展机器人控制中记忆的框架。MemER 能够利用与任务相关的过往信息，通过仅使用少量专家演示训练的单一策略，有效推理三个复杂的长期任务。

为克服此问题，策略必须学会从完整历史上下文中过滤并存储与任务相关的信息，以防止在需要长程依赖的任务上内存占用爆炸式增长。

为此，本文提出采用分层框架来实现机器人策略的长期记忆。高层策略是一个经过微调的视频理解视觉语言模型（VLM），其训练目标是输出子任务，并且最重要的是，从其固定的近期上下文中选择关键帧，这些关键帧代表了解决任务所需记忆的重要信息。低层策略是一个经过微调的通用机器人策略，用于执行高层策略指定的子任务，处理需要高频推理的机器人特定挑战，例如运动学控制。本文利用了这些开源视觉语言模型在大量视频理解数据上微调的事实。凭借这一强大的先验，本文发现仅需 50 个带有子任务标注的遥操作机器人演示，即可使这些视觉语言模型适应机器人特定的基于记忆的任务（Bai 等人，2025 年）。

本文的贡献是 **MemER**，一个通过经验检索扩展机器人控制中记忆的框架。本文在三个复杂的长期任务上展示了 **MemER** 有效利用任务相关历史信息的能力，这些任务需要长达数分钟的记忆。据本文所知，本文的真实世界操作任务需要比先前工作更长时间范围的推理。

2 相关工作

长期上下文机器人策略的记忆。记忆对于通用机器人完成复杂任务至关重要。先前的工作主要在相对短视界任务的背景下研究记忆。例如，Torne 等人（2025）和 Fang 等人（2025）使用不同的方法将模仿策略的上下文从几帧扩展到最多二十几帧。我们进一步研究了需要从数百帧中构建记忆的任务。与我们的方法类似，Fang 等人（2025）将先前的帧存储在记忆中。然而，这些至多是上下文中 $N = 10$ 个最近的帧，而我们的方法可以选择包含整个回合中与任务相关的帧，这些帧可能超过一千帧。另一部分工作研究了策略上下文中图像的压缩。Li 等人（2025a）在像素空间中压缩相似的观测，这对于固定摄像机效果良好，但对于许多灵巧机器人任务所必需的腕部摄像机则不适用。Zheng 等人（2025a）将所有过去的观测压缩为末端执行器和场景中移动物体的运动的二维视觉迹。迹有助于模型推理近期的时空变化，但这种方法难以扩展到需要长期记忆的任务。记忆在机器人导航研究中也发挥了重要作用。一些导航工作用环境的显式几何和/或语义地图来表示记忆（Henry 等人，2012；Yu 等人，2024）。环境的空间地图难以应用于操作任务，因为机器人经常修改环境。其他工作直接向基于 API 的视觉语言模型提供视频上下文，以决定机器人应导航到何处（Chiang 等人，2024；Sharma 等人，2023；Chen 等人，2024）。我们发现现有的基于 API 的视觉语言模型不足以

推理我们长视界操作任务中的机器人可供性，因此我们转而微调开放权重模型。

机器人学中的基础模型。视觉-语言-动作模型（Vision-Language-Action Models, VLAs）的最新进展使机器人领域展现出令人瞩目的通用性。VLAs 将网络规模的预训练与表达力强的动作解码机制相结合，以执行现实世界任务。大多数 VLAs 通常遵循两种范式之一：1) 单一端到端模型，以图像和语言任务为输入，直接输出动作（Black 等, 2024; Brohan 等, 2023）；或 2) 高层策略，以图像和语言任务为输入，输出某种中间嵌入、语言子任务或路径点，低层策略在输出动作时以这些信息为条件（Shi 等, 2024; Li 等, 2025b; Yide Shentu 与 Abbeel, 2024）。我们的工作建立在第二种范式之上；我们训练高层策略以纳入关键帧过滤器，从而能够为低层策略预测准确的语言子任务以供执行。

视频关键帧选择。在机器人领域之外，计算机视觉领域的先前工作也研究了为视觉-语言模型（VLMs）引入更长上下文（Goletto 等, 2024; Manigrasso 等, 2025）。与我们的工作类似，其他工作已使用关键帧选择来改进视频理解和问答（Yu 等, 2023; Ranasinghe 等, 2025）。许多此类方法因通过单独的多模态大语言模型调用来估计帧重要性而产生较高的每帧成本。这些方法不能直接应用于机器人任务，因为增加视频上下文长度将无法推理过程中的任务延迟约束。Hu 等（2025a）使用轻量级模型在单次传递中对所有帧进行评分，从而降低了每帧成本，但缺乏连续流式传输图像观测的能力。与现有用于视觉问答的 VLM 工作不同，Hu 等（2025a）通过轻量级评分模型进行非均匀帧采样；相比之下，我们在不增加额外模型的情况下实现了非均匀采样。我们的方法专为现实世界机器人设计，强调低成本推理和流式支持。

3 MEMER

3.1 预备知识

语言条件控制策略。语言条件机器人策略通常被训练来建模条件分布 $\pi(\mathbf{A}_t|o_t)$ ，其中 $\mathbf{A}_t = [a_t, a_{t+1}, \dots, a_{t+H-1}]$ 是从当前时间步 t , up to H 到未来时间步建模的动作块（Zhao 等人, 2023），而 o_t 是机器人当前的传感器观测。当前观测通常被表述为 $o_t = [\mathbf{I}_t, l_t, \mathbf{q}_t]$ ，其中 $\mathbf{I}_t = [I_t^1, I_t^2, \dots, I_t^n]$ 是来自多个摄像头的图像， l_t 是语言指令， $\mathbf{q}_t$ 是来自机器人的本体感知输入（即关节角度和夹爪状态）（Black 等人, 2024; Team 等人, 2024）。

基于记忆的任务。我们考虑一组任务，由于环境中的部分可观测性，机器人策略必须利用过去的信息才能成功完成。换句话说，训练用于建模 $\pi(\mathbf{A}_t|o_t)$ 的机器人策略无法完成任务，但训练用于建模 $\pi(\mathbf{A}_t|o_{0:t})$ could. 模

Hierarchical Policies. In order to execute complex, long-horizon tasks, we follow Shi et al. (2025) and hierarchically decompose the robot policy into a low-level control policy (π_l) and a high-level policy (π_h) that generates instructions.

$$\pi(\mathbf{A}_t|o_t) = \pi_l(\mathbf{A}_t|[\mathbf{I}_t, l'_t, \mathbf{q}_t])\pi_h(l'_t|\mathbf{I}_t, l_t) \quad (1)$$

高层策略建模条件分布 $\pi_h(l'_t|\mathbf{I}_t, l_t)$ ，其中 l'_t 是当前语言子任务，低层策略基于该子任务来执行以完成整体指令 l_t 。高层策略可以表示为独立的视觉语言模型（VLM）（Shi 等, 2025），或与低层控制策略共享相同的权重（Intelligence 等, 2025）。在我们的方法中，高层策略将负责关于记忆的推理。

分层策略的数据收集。与先前工作类似，我们使用语言子任务 l'_t 来标注轨迹中的每个观测（Shi 等, 2024; 2025; Intelligence 等, 2025）。最终我们得到一个由以下元组 $(\mathbf{I}_t, \mathbf{q}_t, l_t, l'_t, a_t)$ 组成的轨迹数据集，用于训练我们的高层和低层策略。例如，我们可以将任务“寻找番茄酱”分解为以下子任务：“查看左侧箱子”、“查看右侧箱子”和“从右侧箱子取出番茄酱”。每个任务的子任务和图像观测示例见图 4。




图 2: MemER 架构。高层策略处理任务指令、选定的关键帧（如有）以及来自基座和腕部摄像头的近期图像，以生成低层语言子任务和候选关键帧（如有）。低层策略使用子任务、当前图像和机器人关节状态来产生动作。候选关键帧经过关键帧过滤器处理，以获得用于下一步推理输入的选定关键帧。

在我们的数据收集设置中，操作员执行规定的子任务，并在完成后按键以进入下一个子任务。与先前工作一致，我们为低级策略训练集补充了 10 至 15 个干预演示，以提高部署时的鲁棒性（Hu 等人，2025b；Kim 等人，2025）。由于低级策略是马尔可夫的，我们可以通过将机器人初始化到部署期间观察到的常见失败状态来高效收集干预数据。然后，我们遥操作机器人回到分布内状态。

3.2 高级策略

我们的方法建立在常见的分层视觉-语言-动作范式之上，如 Shi 等人（2025）所述，并扩展了其处理需要记忆的长时程任务的能力。我们选择采用分层方法，因为像 Qwen2.5-VL-7B-Instruct 这样的开源视觉语言模型（VLM）从其训练所用的视频数据集中获得了强大的视频理解先验，因此可以适应基于记忆的规划（Bai 等人，2025）。我们使用微调后的视觉语言模型作为高级策略，在闭环控制期间既提名候选关键帧，又为低级策略预测子任务，如图 2 所示。随后，候选关键帧经过冗余过滤，并添加到一组选定的关键帧中，高级策略在预测下一个子任务和候选关键帧时持续以这些关键帧为条件。具体来说，在每个时间步，我们将以下内容输入高级记忆策略：1）每个摄像头的最后 N 帧 $R_t = I_{t-N+1:t}$ ，其中 N 是跨摄像头共享的整数上下文窗口，2）高级任务指令 l_t ，以及 3）先前选定的关键帧 $K_t \subseteq I_{0:t-N+1}$ ，实际中 $|K_t| \leq 8$ 。然后，高级策略预测两项内容：

(i) 当前要执行的子任务 l'_t 和 (ii) 候选关键帧 $J_t \subseteq R_t$ ，即近期上下文中的帧子集。总体而言，我们的高级策略建模 $\pi_h(l'_t, J_t | R_t, K_t)$ 。低级策略以 l'_t 为条件，预测机器人的直接关节速度，如第 3.3 节所述。同时， K_{t+1} ，即下一个高级推理时间步的选定关键帧，由自轨迹开始以来预测的所有候选关键帧序列 $J'_{0:t} = (J_0, J_1, \dots, J_t)$ 使用下文所述的简单一维单链接聚类算法计算得出。

构建视觉记忆。为构建视觉记忆，我们的关键帧过滤器将刚离开近期上下文的观测 R_t 整合进已选关键帧 K_t 。过滤过程基于这些关键帧的时间索引进行。该方法与任务无关，并使我们能够覆盖流中的所有帧。到时间步 t ，高层策略已给出 $i=0$ ，即截至时间步 t 被提名的候选集序列。我 $J'_{0:t} = (J_i$ 们首先提取该序列中每个被提名帧的时间索引，并将它们汇总为一个按时间排序的列表 $G_{0:t}$ 。重要的是，我们保留重复索引，因为这使得后续的中位数选择能够聚合重复提名，并产生最具代表性的帧。

each cluster.




图 3：基于提名帧的一维单链接。在每个时间步，高层策略提名候选关键帧（以橙色高亮）。所有候选关键帧使用合并距离为 $d = 5$ 帧的一维单链接在时间上聚合，形成不相交的簇。对于每个簇，彩色条表示该时间戳观测的提名，条高与收到的提名次数成正比。我们通过取所有候选中位数关键帧为每个簇选择一个代表帧，并将该帧加入记忆。

随后，我们为 $G_{0:t}$ 中的所有候选索引创建簇 C_i ，方法是将彼此相距不超过 d 的关键帧索引分组。例如，若 $G_{0:t}$ 的时间索引为 $\{1, 3, 3, 4, 10\}$ 和 $d = 5$ ，则我们将得到两个簇 $C_1 = \{1, 3, 3, 4\}$ 和 $C_2 = \{10\}$ 。构建簇序列 $(C_1, C_2, \dots)$ 后，我们从每个 C_i 中选取中位数索引作为该簇的代表关键帧。这些最终中位数索引对应的关键帧即代表 K_t ，时间步 t 的已选关键帧。为提高效率，索引小于 $t - N + 1 - d$ 的簇无需重新计算。图 3 展示了部署期间聚类 and 关键帧选择的可视化。我们在附录 D 中提供了详细伪代码，并在项目网站 <https://jen-pan.github.io/memer/> 上提供了聚类算法运行的视频演示。

3.3 MEMER 的实用实现

训练低层策略。对于我们的低级机器人策略，我们微调了一个在 DROID 数据集 (Khazatsky 等人, 2025) 上训练的 $\pi_{0.5}$ (Intelligence 等人, 2025) 版本。给定轨迹 t, a_t ，我们训练低层策略来建模条件分布 $\pi_l(A_t | I_t, q_t, l'_t)$ 。我们微调在 DROID 数据集上训练的 $\pi_{0.5}$ 检查点，因为它在所有实验中使用的 DROID 设置上表现出强大的开箱即用行为。因此，我们发现只需要 50 个长时程轨迹演示和每个任务 10-15 个干预示例，就能微调出一个强大的低级策略。我们在所有三个任务上微调了一个单的低级策略。具体训练参数参见附录 A。

训练高级策略。对于我们的高级策略，我们微调 Qwen2.5-VL-7B-Instruct 来预测两件事：1) 当前要执行的子任务，以及 2) 从最近帧中需要记住的任何与任务相关的关键帧（如第 3.2 节所述）。我们在所有三个任务上微调了一个单一的高级策略，因为它带来了更强的对象泛化能力（与 MemER 的单任务变体的比较见附录 C）。在微调过程中，我们冻结了视觉编码器和投影层的权重，以提高训练效率。具体训练参数参见附录 A，训练提示的格式参见附录 F。

为高级策略标注关键帧。为了给每个任务标注关键帧，我们采用了一种半自动标注流程。首先，我们识别连续子任务之间的转换点，并提取边界帧作为候选关键帧。接下来，人工标注员审查少量演示，为每个子任务确定一个简单的标注规则——指定在该子任务段内选择第一帧、最后一帧还是不选择帧，具体取决于哪种选项能最有效地捕捉视觉上信息丰富的状态。例如，规则可能指示在“查看中央箱内部”中选择最后一帧，在“清扫底层架子”中选择第一帧，或者在“重置铲斗位置”中不选择帧。

一旦确定，该规则就固定为每个子任务类型，并自动应用于相应任务的所有演示，从而在每个子任务段中最多产生一个关键帧。生成的关键帧集合构成了用于训练高级策略的真实目标。我们三个任务中所有子任务的具体关键帧标注规则见附录 E。

模型合并。促成我们策略成功的一个重要因素是 Qwen2.5-VL-7B-Instruct (Bai 等人, 2025) 中强大的视频理解先验。然而，训练高层策略以准确预测低层策略所使用的语言子任务，大约需要 5,000 个梯度步 (10 – 15 个训练轮次)。经过这一数量的微调后，高层策略往往会失去对低层策略冻结和重试行为的一些鲁棒性，因为其训练数据仅由最优专家演示组成。同期工作表明，将通用预训练模型的权重与在同一模型上针对狭窄、任务特定数据进行微调后的权重进行线性插值，有助于保留预训练模型的鲁棒性和泛化能力，同时仍能适应新任务 (Anonymous, 2025)。我们发现这也适用于高层策略。具体来说，我们将高层策略的权重设置为：

$$\theta = (1 - \alpha) \cdot \theta_{\text{pre}} + \alpha \cdot \theta_{\text{ft}} \quad (2)$$

其中 θ_{pre} 是 Qwen2.5-VL-7B-Instruct 的权重， θ_{ft} 是该模型在所有三个基于记忆的任务上微调后的权重。我们遵循 Anonymous (2025) 的做法，并为我们测试的所有基线设置 $\alpha = 0.8$ 。图 6 (右) 显示，模型合并改善或保持了所有任务上的性能。

闭环部署。我们的策略分解如下：

$$\pi(\mathbf{A}_t | \mathbf{O}_{0:t}) = \pi_l(\mathbf{A}_t | \mathbf{I}_t, \mathbf{q}_t, l'_t) \pi_h(l'_t, \mathbf{J}_t | \mathbf{I}_{t-N+1:t}, \mathbf{K}_t) \quad (3)$$

低层策略与高层策略在闭环部署中的交互如图 2 所示。低层策略以 $\sim 2\text{Hz}$ 的频率预测 π_l 个动作块，而高层策略 π_h 以大约 $\sim 1\text{Hz}$ 的频率预测关键帧和子任务。我们在各自的服务器上运行这两个策略。与 Shi 等人 (2025) 一样，我们选择异步运行这些策略，因为我们发现这能提高部署期间的响应性和稳定性。当高层策略正在预测下一个子任务时，低层策略以最新预测的子任务为条件。我们将以 2Hz 子采样的图像观测添加到队列中，然后在当前高层策略预测完成后，将该队列发送给高层策略以查询下一个子任务预测。

4 实验

在本节中，我们旨在评估我们的方法和替代方法在多大程度上能够应对需要记忆的长时程操作任务。我们首先描述我们的任务和评估协议，然后讨论以下问题：

1. 与无记忆策略（即当前的机器人基础模型）、人类高层 (Human)
1. 高层策略与其他朴素方法相比如何？2. 从开源视觉语言模型微调得到的高层策略，与专有现成视觉语言模型相比如何？
3. 用图像表示记忆与其他模态相比如何？

我们设计了三个复杂的真实机器人任务，这些任务需要以多种不同方式使用记忆，包括记住物体位置、跟踪先前完成的动作以及计数重复步骤，如图 4 所示。由于所有任务都是长时程的，我们为每个任务记录不同的度量，以提供任务完成情况的细粒度视图。

物体搜索。在此任务中，我们将三到五个物体随机放置在三个不透明箱子中。然后，机器人依次被要求寻找三个物体；每条新指令仅在前一个物体被尝试取回后才发出。我们的目标是优化搜索：机器人记住它已经检查过哪些箱子（以及看到了什么），跳过重复搜索，仅在必要时探索其他箱子。如果它已经看过目标箱子内部，则应直接前往该箱子。

1	OBJECT SEARCH	TASK	"search for the ketchup"		"search for the red block"		"search for the wooden block"	
		SUBTASK	look inside the left bin	take ketchup from left bin and place in white bin	look inside the center bin	look inside the right bin	take red block from right bin and place in white bin	take wooden block from right bin and place in white bin
		ROBOT EXECUTION						
2	COUNTING	TASK	"put three scoops of peanuts in the green bowl, and three scoops of jelly beans in the blue bowl"					
		SUBTASK	place a scoop of peanuts in the green bowl	place a scoop of peanuts in the green bowl	place a scoop of peanuts in the green bowl	place a scoop of jelly beans in the blue bowl	place a scoop of jelly beans in the blue bowl	place a scoop of jelly beans in the blue bowl
		ROBOT EXECUTION						
3	DUST & REPLACE	TASK	"remove the items from the shelves, dust the shelves, and place the items back on the shelves"					
		SUBTASK	remove the item from bottom shelf	remove the item from top shelf	dust bottom shelf	dust top shelf	place purple plushie on bottom shelf	place milk carton on top shelf
		ROBOT EXECUTION						

图 4: 评估中使用的任务。在三个领域中，我们评估复杂指令、中间子任务和关键帧预测。我们报告每种方法每个任务 20 次试验的性能。




图 5: 主要结果。我们的方法在三个基于记忆的长时程任务上明显优于无历史、短历史（8 帧上下文）和长历史（32 帧上下文）基线。它与人类高层策略相当。

此前。该任务测试跨情景记忆，因为找到每个物体需要其自身的 l_t ，因此需要回忆在执行先前指令时收集的信息。我们使用同一组 15 个物体进行训练和测试，这些物体是各种小玩具（见附录 C 中的图 9）。评估度量。我们通过两个标准衡量任务完成情况，针对三个物体中的每一个：成功取回和遵循最优路径且无多余探索，最高得分为 6 分（每个物体 2 分）。我们在表 1 中报告结果，并在图 5 中报告总体准确率。




图 6：（左）模态结果。仅使用图像表示记忆的性能优于仅使用文本或同时使用文本和图像的性能。我们假设高层策略过度依赖记忆中的文本标记，导致其忽略视觉输入中的重要细节。（右）模型合并结果。将微调后的高层策略权重与预训练的 Qwen2.5-VL-7B-Instruct 权重合并，在所有任务上均有助于或维持性能。

计数舀取。在此任务中，机器人被要求将两种不同配料精确数量的舀取放入两个不同的碗中。机器人需要跟踪每种配料已舀取的数量。该计数任务曾出现在先前工作中（Torre 等人，2025），我们通过增加舀取数量和配料种类，并在不同指令中改变舀取数量，使其需要更长的推理范围。此任务具有挑战性，因为与每种配料对应的关键帧几乎无法区分，因此遗漏或重复的关键帧会导致高层策略误判其进度。我们使用花生和软糖进行训练和测试（见附录 C 中的图 9）。评估度量。任务完成度通过每种配料请求舀取数与实际获得舀取数之差的绝对值来衡量，因此度量值越低越好。我们在表 1 中报告结果，并在图 5 中给出满足指令的 0-1 成功率。

除尘与替换。在本任务中，机器人被要求从两层架子上移除物体，拿起一个掸子，给每层架子除尘，并将物体放回原位。在给两层架子除尘之间，我们将掸子放回一个模糊的位置，使得从最近的上下文中无法确定哪层架子已经除尘。该任务具有挑战性，因为机器人必须同时记住两类信息：物体的原始位置以及哪层架子（如果有的话）已经除尘。我们在 17 个物体的集合上进行训练，并用训练集中的 9 个物体子集进行测试，这些物体是各种毛绒玩具。测试时我们移除了一些物体，因为底层策略无法操纵它们，而我们主要评估高层策略的能力（见附录 C 中的图 9）。评估度量。任务完成度通过每个物体被正确放回架子上以及每层架子被除尘的二元成功来衡量，最高得分为 4。我们在表 1 中报告结果，并在图 5 中报告总体任务准确率。

评估设置：我们的机器人设置类似于 DROID（Khazatsky 等人，2025）中使用的设置，配备 Franka 机械臂、平行夹爪和两个摄像头（第三人称 ZED 摄像头和腕部安装的 miniZED 摄像头）。对于所有任务， π_h 以 $\sim 1\text{Hz}$ 运行， π_l 以 $\sim 2\text{Hz}$ 运行。 π_l 输出一个动作块 A_t ，包含以 15Hz 采样的 15 个动作，我们开环执行 8 个动作后重新规划。摄像头以 15Hz 传输 320×180 分辨率的图像，但我们将其下采样到 2Hz 作为分层策略的输入。

4.1 主要结果

问题 1：与其他方法相比，我们的方法在多大程度上能够处理需要记忆的任务 方法？所有被评估的方法都包含一个 π_h 和 π_l ，基线方法在改变高层策略的输入上下文 π_h 的同时使用相同的 π_l 。我们与以下基线进行比较：1) 无历史：一种无记忆的高层策略，仅观察当前帧（即当前的机器人基础模型），类似于（Shi 等人，2025）；2) 短历史：一种仅观察最近 N 帧（在我们的设置中为 $N = 8$ ）的策略；3) 长历史：一种简单接收更长上下文（为短历史的 $4 \times$ 倍或 $N = 32$ 个最近帧）的策略；以及 4) 人类高层：由人类提供正确的子任务。人类高层策略为所有任务建立了一个粗略的性能上限估计，其失败源于底层策略。从图 5 中可以看出，无历史和短历史基线表现不佳，因为所有任务都需要比所提供的更多的上下文。

Method	Object Search		Counting	Dust & Replace			
	# times object retrieved ($\uparrow$)	# times used optimal path ($\uparrow$)	# wrong scoops ($\downarrow$)	Dust bottom shelf ($\uparrow$)	Dust top shelf ($\uparrow$)	Replace bottom object ($\uparrow$)	Replace top object ($\uparrow$)
MemER (Ours)	59	57	1	20	19	18	20
No history	32	25	61	5	4	5	7
Short History	38	31	26	14	14	11	12
Long History	47	41	12	11	11	12	12
Human HL	58	58	0	19	19	18	17

表 1：详细主要结果。针对问题 1，对我们的方法和基线进行在线评估。我们提供了任务特定的评估指标以及每个任务组件在 20 次试验中的原始计数。粗体标记每行中最佳的非预言机方法。 $\uparrow$ 和 $\downarrow$ 分别表示越高越好和越低越好。

所提供的上下文。长历史基线表明，增加上下文可以略微有所帮助，但 32 帧（ ~ 16 秒的记忆）会产生 1 秒的推理成本，这接近闭环设置中可容忍的极限。长历史策略的平均性能仍比 MemER 差 34%，因此需要采用像我们这样整合关键帧而非简单扩展上下文的策略。最后，我们的方法在所有任务上具有 $> 90\%$ ，最常见的失败案例是低层策略在执行子任务时失败，这可以通过更好的低层修正数据来纠正。

问题 2：我们基于开源视觉语言模型微调的高层策略，与专有的现成视觉语言模型相比如何？由于我们的方法优于其他 π_h 的选择，并且表现与人类高层策略相似，我们研究了在现有最先进的视觉语言模型可能已经具备这种能力的情况下，我们的方法是否必要。我们测试了 GPT-5 和 Gemini Robotics - ER 1.5，前者具有强大的多模态推理性能，后者具有机器人特定的智能体能力。由于两者的应用程序编程接口延迟都在 10 到 15 秒之间，当我们在与其他基线相同的闭环评估中部署这些基于应用程序编程接口的高层策略时，它们导致了完全失败，因为其他基线需要小于 1 秒的延迟才能对环境做出相应反应。

为了仍然提供 π_h 与基于应用程序编程接口的高层策略之间的比较手段，我们设计了一个离线实验，使用由低层策略根据真实子任务指令 l_t^i 生成的留出轨迹集。这模拟了在真实行为（即抓取失败后的重试、停顿和抖动运动）下的闭环执行，同时允许模型以相同方式构建其视觉记忆。我们精心设计提示，包含特定任务相关指令和低层策略可遵循的所有可能动作的明确列表，并要求模型从中选择（附录 G）。与我们的设置一样，模型在每个时间步接收 $N = 8$ 个最近的上下文帧和选定的关键帧 K_t ，并输出供低层策略执行的子任务 l_t^i 以及候选关键帧 J_t 。我们测量轨迹准确率，即轨迹中每个时间步正确预测子任务的频率，因为我们知道低层策略在该时刻执行的真实子任务指令。我们还测量边界准确率，计算为以子任务间转换点为中心的固定窗口内的轨迹准确率。这些是揭示高层策略对任务进展把握的关键时刻，即知道何时进入下一个子任务；在部署期间，子任务间转换的正确时机在与低层策略的适当协调中起着重要作用。从表 2 中，我们观察到两种零样本基于应用程序编程接口的模型与我们的微调 Qwen2.5-VL 模型相比表现较差，主要失败原因是预测了过多非信息性候选关键帧，反映出其识别真正有用帧的能力有限。因此，即使使用显著更强的基座视觉语言模型（如 GPT-5 或 Gemini Robotics - ER 1.5），模型也缺乏解释机器人特定感知线索和识别有意义关键帧的能力，导致子任务预测不够准确，并需要额外的微调。

问题 3：通过图像表示记忆与其他模态相比如何？我们现在讨论哪种模态最适合构建记忆——视觉、文本或两者兼有。将记忆存储为

Method	Object Search		Counting		Dust & Replace	
	Trajectory acc. ($\uparrow$)	Boundary acc. ($\uparrow$)	Trajectory acc. ($\uparrow$)	Boundary acc. ($\uparrow$)	Trajectory acc. ($\uparrow$)	Boundary acc. ($\uparrow$)
MemER (Ours)	0.80	0.76	0.67	0.65	0.87	0.86
GPT-5	0.15	0.16	0.43	0.47	0.67	0.63
Gemini Robotics-ER 1.5	0.21	0.23	0.13	0.14	0.19	0.22

表 2：与基于应用程序编程接口的视觉语言模型比较。对 MemER、GPT-5 和 Gemini Robotics-ER 1.5 的子任务预测的逐任务轨迹和边界准确率进行离线评估，以将我们基于开源视觉语言模型微调的高层策略与专有视觉语言模型进行比较。

Method	Input Components			Object Search		Counting	Dust & Replace			
	Short History	Image Keyframes	Text Subtasks	# times object retrieved ($\uparrow$)	# times used optimal path ($\uparrow$)	# wrong scoops ($\downarrow$)	Dust bottom shelf ($\uparrow$)	Dust top shelf ($\uparrow$)	Replace bottom object ($\uparrow$)	Replace top object ($\uparrow$)
MemER (Ours)	✓	✓	×	59	57	1	20	19	18	20
Short History + Text	✓	×	✓	40	28	10	16	16	7	10
MemER + Text	✓	✓	✓	59	49	13	20	18	17	20

表 3：详细模态结果。对消融文本模态的方法进行在线评估。粗体标记最佳方法。 $\uparrow$ 和 $\downarrow$ 分别表示数值越高和越低越好。

文本具有天然优势，因为它可解释且更为凝练。我们测试了两种使用文本记忆的额外方法，其形式为与 K_t 中每个选定关键帧相关联的预测子任务 l'_t ：1) 短历史+文本使用最近的 $N = 8$ 帧和预测子任务；2) MemER+文本在记忆交错排列预测子任务和视觉关键帧。表 3 展示了每个基线的输入。

从图 6（左）可以看出，依赖文本记忆的表现不如我们仅使用视觉的方法。具体而言，用文本替换视觉记忆（短历史+文本）导致最显著的性能下降。此外，在我们的视觉记忆中增加文本（MemER+文本）没有带来任何益处，在所有任务上持续表现不佳，尤其是在计数任务上。我们发现两个基线的子任务预测都很脆弱，主要原因是过度依赖记忆中存储的最近预测子任务。当策略重试或冻结使近期上下文偏离分布时，这会导致失败。在这种情况下，模型倾向于过度拟合专家演示中观察到的子任务规范顺序，并错误识别当前环境状态下正在执行的子任务。相比之下，将预测直接基于当前观测并结合稳健的视觉记忆被证明更为可靠。

对于短历史+文本基线，基于语言的子任务未能捕获成功完成任务所需的全部信息。例如，在物体搜索任务中，预测的语言子任务仅指定了机器人此前被要求定位或当前正在搜索的物体，而未涉及它已看到且可能在后续情节中需要取回的物体。对于记忆增强检索+文本基线，模型不成比例地关注存储在记忆中的文本，而该文本可能因上述原因而不准确，随后忽略了存储在视觉记忆中的重要信息。此类行为此前已在（Zheng 等人，2025b；il Lee 等人，2025）中被指出。因此，从我们的任务中，我们发现仅视觉记忆提供了最稳健的表示，尽管探索多模态记忆仍是一个有趣的未来方向。

5 讨论与未来工作

我们提出了 MemER，一个分层视觉-语言-动作框架，通过经验检索来扩展记忆。高层记忆策略处理流式观测，提名要保留的关键帧，并发出由低层控制器执行的语言子任务。一个简单的在线整合策略将每个时间步的候选关键帧转换为紧凑、稳定的情景记忆，并反馈给高层策略。在三个真实世界、长时程操作领域中，MemER 显著提升了需要数分钟回忆的任务性能，同时保持了低延迟推理和与现有视觉-语言-动作骨干的强兼容性。

尽管具有诸多优势，本文方法仍存在若干局限性。我们持续累积信息量大的关键帧，但目前缺乏在关键帧数量过多时将其丢弃的机制——对于需要数小时记忆的任务，这一问题可能尤为突出。使高层策略能够推理出不仅需要添加、还需要删除哪些关键帧，以实现可修改的长期记忆，是未来工作中一个令人振奋的方向。此外，我们的吞吐量还依赖于视觉语言模型骨干网络以及调度策略（例如， π_h at 1 Hz, π_l 以 2 赫兹运行），这可能限制极高频率的控制，并降低对快速环境变化的反应能力。引入改进的模型缓存和更优的分词方法可进一步降低推理延迟，从而实现更高频率的控制。另外，本文的记忆仅限于视觉观测；融合触觉或音频等其他感知模态是一个有前景的扩展方向。最后，我们仅研究了单一机器人形态，将其扩展至移动操作和多房间任务——在这些任务中，记忆必须将空间映射与情景召回交织在一起——将使系统更接近人类般的记忆。我们将 MemER 视为迈向机器人策略的一步，该策略能够决定记住什么，并在需要时利用这些记忆实现有效的长时程控制。

6 致谢

本研究得到了 ONR 基金 N00014-22-1-2621、机器人与人工智能研究所以及斯坦福以人为本人工智能研究院 (HAI) 的计算资源支持。我们感谢 Dorsa Sadigh、John Yao、Moo Jin Kim、Lucy Xiaoyang Shi、Brian Kim、Homer Walke、Marcel Torne、Yuejiang Liu、Anikait Singh、Andy Tang 和 Jennifer Grannen 富有启发性的讨论。感谢 Yuejiang Liu、John Yao、Alex Swerdlow 和 Ria Doshi 对本文早期版本提出的宝贵意见。同时感谢 Physical Intelligence 提供 $\pi_{0.5}$ 模型的测试版访问权限。Ajay Sridhar 受美国国家科学基金会研究生研究奖学金资助。

参考文献

- Anonymous. Robust fine-tuning of vision-language-action robot policies via parameter merging. In *ICLR 2026 Conference Submission (OpenReview)*, 2025. URL <https://openreview.net/forum?id=uWJwQ5SZoM>. conference submission on OpenReview.
- Shuai Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Sibao Song, Kai Dang, Peng Wang, Shijie Wang, Jun Tang, Humen Zhong, Yuezhi Zhu, Mingkun Yang, Zhaozhai Li, Jianqiang Wan, Pengfei Wang, Wei Ding, Zheren Fu, Yiheng Xu, Jiabo Ye, Xi Zhang, Tianbao Xie, Zesen Cheng, Hang Zhang, Zhibo Yang, Haiyang Xu, and Junyang Lin. Qwen2.5-vl technical report, 2025. URL <https://arxiv.org/abs/2502.13923>.
- Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Lucy Xiaoyang Shi, James Tanner, Quan Vuong, Anna Walling, Haohuan Wang, and Ury Zhilinsky. π_0 : A vision-language-action flow model for general robot control, 2024. URL <https://arxiv.org/abs/2410.24164>.
- Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, Pete Florence, Chuyuan Fu, Montse Gonzalez Arenas, Keerthana Gopalakrishnan, Kehang Han, Karol Hausman, Alexander Herzog, Jasmine Hsu, Brian Ichter, Alex Irpan, Nikhil Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Lisa Lee, Tsang-Wei Edward Lee, Sergey Levine, Yao Lu, Henryk Michalewski, Igor Mordatch, Karl Pertsch, Kanishka Rao, Krista Reymann, Michael Ryoo, Grecia Salazar, Pannag Sanketi, Pierre Sermanet, Jaspiar Singh, Anikait Singh, Radu Soricut, Huong Tran, Vincent Vanhoucke, Quan Vuong, Ayzaan Wahid, Stefan Welker, Paul Wohlhart, Jialin Wu, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. Rt-2: Vision-language-action models transfer web knowledge to robotic control, 2023. URL <https://arxiv.org/abs/2307.15818>.
- Annie S. Chen, Alec M. Lessing, Andy Tang, Govind Chada, Laura Smith, Sergey Levine, and Chelsea Finn. Commonsense reasoning for legged robot adaptation with vision-language models, 2024. URL <https://arxiv.org/abs/2407.02666>.

-
- Hao-Tien Lewis Chiang, Zhuo Xu, Zipeng Fu, Mithun George Jacob, Tingnan Zhang, Tsang-Wei Edward Lee, Wenhao Yu, Connor Schenck, David Rendleman, Dhruv Shah, Fei Xia, Jasmine Hsu, Jonathan Hoech, Pete Florence, Sean Kirmani, Sumeet Singh, Vikas Sindhwani, Carolina Parada, Chelsea Finn, Peng Xu, Sergey Levine, and Jie Tan. Mobility vla: Multimodal instruction navigation with long-context vlms and topological graphs, 2024. URL <https://arxiv.org/abs/2407.07775>.
- Haoquan Fang, Markus Grotz, Wilbert Pumacay, Yi Ru Wang, Dieter Fox, Ranjay Krishna, and Jiafei Duan. Sam2act: Integrating visual foundation model with a memory architecture for robotic manipulation, 2025. URL <https://arxiv.org/abs/2501.18564>.
- Gabriele Goletto, Tushar Nagarajan, Giuseppe Averta, and Dima Damen. Amego: Active memory from long egocentric videos. In *European Conference on Computer Vision*, pp. 92–110. Springer, 2024.
- Peter Henry, Michael Krainin, Evan Herbst, Xiaofeng Ren, and Dieter Fox. Rgb-d mapping: Using kinect-style depth cameras for dense 3d modeling of indoor environments. *International Journal of Robotic Research - IJRR*, 31:647–663, 04 2012. doi: 10.1177/0278364911434148.
- Kai Hu, Feng Gao, Xiaohan Nie, Peng Zhou, Son Tran, Tal Neiman, Lingyun Wang, Mubarak Shah, Raffay Hamid, Bing Yin, and Trishul Chilimbi. M-llm based video frame selection for efficient video understanding, 2025a. URL <https://arxiv.org/abs/2502.19680>.
- Zheyuan Hu, Robyn Wu, Naveen Enock, Jasmine Li, Riya Kadakia, Zackory Erickson, and Aviral Kumar. Rac: Robot learning for long-horizon tasks by scaling recovery and correction, 2025b. URL <https://arxiv.org/abs/2509.07953>.
- Kang il Lee, Minbeom Kim, Seunghyun Yoon, Minsung Kim, Dongryeol Lee, Hyukhun Koh, and Kyomin Jung. Vlind-bench: Measuring language priors in large vision-language models, 2025. URL <https://arxiv.org/abs/2406.08702>.
- Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Manuel Y. Galliker, Dibya Ghosh, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Devin LeBlanc, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Allen Z. Ren, Lucy Xiaoyang Shi, Laura Smith, Jost Tobias Springenberg, Kyle Stachowicz, James Tanner, Quan Vuong, Homer Walke, Anna Walling, Haohuan Wang, Lili Yu, and Ury Zhilinsky. $\pi_{0.5}$: a vision-language-action model with open-world generalization, 2025. URL <https://arxiv.org/abs/2504.16054>.
- Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, Peter David Fagan, Joey Hejna, Masha Itkina, Marion Lepert, Yecheng Jason Ma, Patrick Tree Miller, Jimmy Wu, Suneel Belkhale, Shivin Dass, Huy Ha, Arhan Jain, Abraham Lee, Youngwoon Lee, Marius Memmel, Sungjae Park, Ilija Radosavovic, Kaiyuan Wang, Albert Zhan, Kevin Black, Cheng Chi, Kyle Beltran Hatch, Shan Lin, Jingpei Lu, Jean Mercat, Abdul Rehman, Pannag R Sanketi, Archit Sharma, Cody Simpson, Quan Vuong, Homer Rich Walke, Blake Wulfe, Ted Xiao, Jonathan Heewon Yang, Arefeh Yavary, Tony Z. Zhao, Christopher Agia, Rohan Baijal, Mateo Guaman Castro, Daphne Chen, Qiuyu Chen, Trinity Chung, Jaimyn Drake, Ethan Paul Foster, Jensen Gao, Vitor Guizilini, David Antonio Herrera, Minh Heo, Kyle Hsu, Jiaheng Hu, Muhammad Zubair Irshad, Donovan Jackson, Charlotte Le, Yunshuang Li, Kevin Lin, Roy Lin, Zehan Ma, Abhiram Maddukuri, Suvir Mirchandani, Daniel Morton, Tony Nguyen, Abigail O’Neill, Rosario Scalise, Derick Seale, Victor Son, Stephen Tian, Emi Tran, Andrew E. Wang, Yilin Wu, Annie Xie, Jingyun Yang, Patrick Yin, Yunchu Zhang, Osbert Bastani, Glen Berseth, Jeannette Bohg, Ken Goldberg, Abhinav Gupta, Abhishek Gupta, Dinesh Jayaraman, Joseph J Lim, Jitendra Malik, Roberto Martín-Martín, Subramanian Ramamoorthy, Dorsa Sadigh, Shuran Song, Jiajun Wu, Michael C. Yip, Yuke Zhu, Thomas Kollar, Sergey Levine, and Chelsea Finn. Droid: A large-scale in-the-wild robot manipulation dataset, 2025. URL <https://arxiv.org/abs/2403.12945>.
- Ji Woong Kim, Joo-Tung Chen, Pascal Hansen, Lucy X. Shi, Antony Goldenberg, Samuel Schmidgall, Paul Maria Scheikl, Anton Deguet, Brandon M. White, De Ru Tsai, Richard Cha,

-
- Jeffrey Jopling, Chelsea Finn, and Axel Krieger. Srt-h: A hierarchical framework for autonomous surgery via language conditioned imitation learning, 2025. URL <https://arxiv.org/abs/2505.10251>.
- Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, Quan Vuong, Thomas Kollar, Benjamin Burchfiel, Russ Tedrake, Dorsa Sadigh, Sergey Levine, Percy Liang, and Chelsea Finn. Openvla: An open-source vision-language-action model, 2024. URL <https://arxiv.org/abs/2406.09246>.
- Haoxuan Li, Sixu Yan, Yuhan Li, and Xinggang Wang. Towards fast, memory-based and data-efficient vision-language policy, 2025a. URL <https://arxiv.org/abs/2503.10322>.
- Yi Li, Yuquan Deng, Jesse Zhang, Joel Jang, Marius Memmel, Raymond Yu, Caelan Reed Garrett, Fabio Ramos, Dieter Fox, Anqi Li, Abhishek Gupta, and Ankit Goyal. Hamster: Hierarchical action models for open-world robot manipulation, 2025b. URL <https://arxiv.org/abs/2502.05485>.
- Zaira Manigrasso, Matteo Dunnhofer, Antonino Furnari, Moritz Nottebaum, Antonio Finocchiaro, Davide Marana, Rosario Forte, Giovanni Maria Farinella, and Christian Micheloni. Online episodic memory visual query localization with egocentric streaming object memory, 2025. URL <https://arxiv.org/abs/2411.16934>.
- NVIDIA, :, Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi "Jim" Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, Joel Jang, Zhenyu Jiang, Jan Kautz, Kaushil Kundalia, Lawrence Lao, Zhiqi Li, Zongyu Lin, Kevin Lin, Guilin Liu, Edith Llontop, Loic Magne, Ajay Mandlekar, Avnish Narayan, Soroush Nasiriany, Scott Reed, You Liang Tan, Guanzhi Wang, Zu Wang, Jing Wang, Qi Wang, Jiannan Xiang, Yuqi Xie, Yinzhen Xu, Zhenjia Xu, Seonghyeon Ye, Zhiding Yu, Ao Zhang, Hao Zhang, Yizhou Zhao, Ruijie Zheng, and Yuke Zhu. Gr00t n1: An open foundation model for generalist humanoid robots, 2025. URL <https://arxiv.org/abs/2503.14734>.
- Kanchana Ranasinghe, Xiang Li, Kumara Kahatapitiya, and Michael S. Ryoo. Understanding long videos with multimodal language models, 2025. URL <https://arxiv.org/abs/2403.16998>.
- Satvik Sharma, Huang Huang, Kaushik Shivakumar, Lawrence Yunliang Chen, Ryan Hoque, Brian Ichter, and Ken Goldberg. Semantic mechanical search with large vision and language models, 2023. URL <https://arxiv.org/abs/2302.12915>.
- Lucy Xiaoyang Shi, Zheyuan Hu, Tony Z. Zhao, Archit Sharma, Karl Pertsch, Jianlan Luo, Sergey Levine, and Chelsea Finn. Yell at your robot: Improving on-the-fly from language corrections, 2024. URL <https://arxiv.org/abs/2403.12910>.
- Lucy Xiaoyang Shi, Brian Ichter, Michael Equi, Liyiming Ke, Karl Pertsch, Quan Vuong, James Tanner, Anna Walling, Haohuan Wang, Niccolo Fusai, Adrian Li-Bell, Danny Driess, Lachy Groom, Sergey Levine, and Chelsea Finn. Hi robot: Open-ended instruction following with hierarchical vision-language-action models, 2025. URL <https://arxiv.org/abs/2502.19417>.
- Gemini Robotics Team, Abbas Abdolmaleki, Saminda Abeyruwan, Joshua Ainslie, Jean-Baptiste Alayrac, Montserrat Gonzalez Arenas, Ashwin Balakrishna, Nathan Batchelor, Alex Bewley, Jeff Bingham, Michael Bloesch, Konstantinos Bousmalis, Philemon Brakel, Anthony Brohan, Thomas Buschmann, Arunkumar Byravan, Serkan Cabi, Ken Caluwaerts, Federico Casarini, Christine Chan, Oscar Chang, London Chappellet-Volpini, Jose Enrique Chen, Xi Chen, Hao-Tien Lewis Chiang, Krzysztof Choromanski, Adrian Collister, David B. D'Ambrosio, Sudeep Dasari, Todor Davchev, Meet Kirankumar Dave, Coline Devin, Norman Di Palo, Tianli Ding, Carl Doersch, Adil Dostmohamed, Yilun Du, Debidatta Dwibedi, Sathish Thoppay Egambaram, Michael Elabd, Tom Erez, Xiaolin Fang, Claudio Fantacci, Cody Fong, Erik Frey, Chuyuan Fu, Ruiqi Gao, Marissa Giustina, Keerthana Gopalakrishnan, Laura Graesser, Oliver Groth, Agrim Gupta, Roland Hafner, Steven Hansen, Leonard Hasenclever, Sam Haves, Nicolas Heess, Brandon Hernaez, Alex Hofer, Jasmine Hsu, Lu Huang, Sandy H. Huang, Atil Iscen, Mithun George Jacob, Deepali Jain, Sally Jesmonth, Abhishek Jindal, Ryan Julian, Dmitry Kalashnikov, M. Emre Karagozler, Stefani Karp, Matija Kecman, J. Chase Kew, Donnie Kim, Frank Kim, Junkyung

-
- Kim, Thomas Kipf, Sean Kirmani, Ksenia Konyushkova, Li Yang Ku, Yuheng Kuang, Thomas Lampe, Antoine Laurens, Tuan Anh Le, Isabel Leal, Alex X. Lee, Tsang-Wei Edward Lee, Guy Lever, Jacky Liang, Li-Heng Lin, Fangchen Liu, Shangbang Long, Caden Lu, Sharath Maddineni, Anirudha Majumdar, Kevis-Kokitsi Maninis, Andrew Marmon, Sergio Martinez, Assaf Hurwitz Michaely, Niko Milonopoulos, Joss Moore, Robert Moreno, Michael Neunert, Francesco Nori, Joy Ortiz, Kenneth Oslund, Carolina Parada, Emilio Parisotto, Amaris Paryag, Acorn Pooley, Thomas Power, Alessio Quaglino, Haroon Qureshi, Rajkumar Vasudeva Raju, Helen Ran, Dushyant Rao, Kanishka Rao, Isaac Reid, David Rendleman, Krista Reymann, Miguel Rivas, Francesco Romano, Yulia Rubanova, Peter Pastor Sampedro, Pannag R Sanketi, Dhruv Shah, Mohit Sharma, Kathryn Shea, Mohit Shridhar, Charles Shu, Vikas Sindhwani, Sumeet Singh, Radu Soricut, Rachel Sterneck, Ian Storz, Razvan Surdulescu, Jie Tan, Jonathan Tompson, Saran Tunyasuvunakool, Jake Varley, Grace Vesom, Giulia Vezzani, Maria Bauza Villalonga, Oriol Vinyals, René Wagner, Ayzaan Wahid, Stefan Welker, Paul Wohlhart, Chengda Wu, Markus Wulfmeier, Fei Xia, Ted Xiao, Annie Xie, Jinyu Xie, Peng Xu, Sichun Xu, Ying Xu, Zhuo Xu, Jimmy Yan, Sherry Yang, Skye Yang, Yuxiang Yang, Hiu Hong Yu, Wenhao Yu, Wentao Yuan, Yuan Yuan, Jingwei Zhang, Tingnan Zhang, Zhiyuan Zhang, Allan Zhou, Guangyao Zhou, and Yuxiang Zhou. Gemini robotics 1.5: Pushing the frontier of generalist robots with advanced embodied reasoning, thinking, and motion transfer, 2025. URL <https://arxiv.org/abs/2510.03342>.
- Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, Jianlan Luo, You Liang Tan, Lawrence Yunliang Chen, Pannag Sanketi, Quan Vuong, Ted Xiao, Dorsa Sadigh, Chelsea Finn, and Sergey Levine. Octo: An open-source generalist robot policy, 2024. URL <https://arxiv.org/abs/2405.12213>.
- Marcel Torne, Andy Tang, Yuejiang Liu, and Chelsea Finn. Learning long-context diffusion policies via past-token prediction, 2025. URL <https://arxiv.org/abs/2505.09561>.
- Aravind Rajeswaran Yide Shentu, Philipp Wu and Pieter Abbeel. From llms to actions: Latent codes as bridges in hierarchical robot control, 2024.
- Justin Yu, Kush Hari, Kishore Srinivas, Karim El-Refai, Adam Rashid, Chung Min Kim, Justin Kerr, Richard Cheng, Muhammad Zubair Irshad, Ashwin Balakrishna, Thomas Kollar, and Ken Goldberg. Language-embedded gaussian splats (legs): Incrementally building room-scale representations with a mobile robot. In *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 13326–13332, 2024. doi: 10.1109/IROS58592.2024.10802196.
- Shoubin Yu, Jaemin Cho, Prateek Yadav, and Mohit Bansal. Self-chained image-language model for video localization and question answering, 2023. URL <https://arxiv.org/abs/2305.06988>.
- Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware, 2023. URL <https://arxiv.org/abs/2304.13705>.
- Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. Tracevla: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies, 2025a. URL <https://arxiv.org/abs/2412.10345>.
- Xu Zheng, Chenfei Liao, Yuqian Fu, Kaiyu Lei, Yuanhuiyi Lyu, Lutao Jiang, Bin Ren, Jialei Chen, Jiawen Wang, Chengxin Li, Linfeng Zhang, Danda Pani Paudel, Xuanjing Huang, Yu-Gang Jiang, Nicu Sebe, Dacheng Tao, Luc Van Gool, and Xuming Hu. Mllms are deeply affected by modality bias, 2025b. URL <https://arxiv.org/abs/2505.18657>.

A 模型初始化与超参数

训练高层策略 微调 Qwen2.5-VL-7B-Instruct 高层策略的超参数详见表 4。

表 4: 高层策略 (Qwen2.5-VL-7B-Instruct) 微调超参数。

Hyperparameter	Value
Optimizer	AdamW
β_1	0.9
β_2	0.999
Weight Decay	0
Gradient Clip Norm	1.0
LR Schedule	Cosine
Warmup Ratio	0.05
Batch Size	256
Training	4500 gradient steps
Compute	96 H200 GPU hours
Frozen Layers	Vision Encoder, Projection Layer
Trainable Layers	LLM Backbone

训练低层策略 微调 $\pi_{0.5}$ 低层策略的超参数详见表 5。该模型从在 DROID 数据集 (Khazatsky 等人, 2025 年) 上训练的公开 $\pi_{0.5}$ 检查点进行微调。

表 5: 低层策略 ($\pi_{0.5}$) 微调的超参数。

Hyperparameter	Value
Optimizer	AdamW
β_1	0.9
β_2	0.95
Weight Decay	0
Gradient Clip Norm	1.0
LR Schedule	Cosine
Warmup Ratio	0.033
Batch Size	128
Training Steps	18000
Compute	48 H200 GPU hours

B 数据收集与子任务标注

为收集机器人轨迹数据, 我们遵循 Khazatsky 等人 (2025 年) 中使用 Oculus 遥操作装置的数据收集流程。为使子任务标注过程尽可能简便, 我们在数据收集前为整个任务轨迹生成子任务列表。在收集数据时, 我们只需遵循当前子任务, 并通过简单的键盘输入指示子任务何时完成。我们自动化高层任务, 以避免收集数据时的人为偏差。

C 跨任务物体泛化

为评估多任务训练的优势, 我们将 MemER 的单任务版本 (为每个任务单独训练的策略) 与多任务版本进行比较。我们在以物体为中心的任务上进行评估: 物体搜索和除尘与替换任务, 使用图 9 中的物体。首先, 我们通过在原始任务上评估 MemER 的两个版本来建立基线。如图 8 (左) 所示, 它们的性能大致相似。




图 7：三个任务的图像。视频可在 <https://jen-pan.github.io/memer/> 查看。




图 8：（左）单任务与多任务结果。MemER 的单任务和多任务版本在物体搜索和除尘与替换任务上的性能相近。（右）跨任务物体泛化结果。我们在评估期间交换物体搜索和除尘与替换（见图 9）任务中的物体。多任务策略能够在评估期间泛化到新的物体-任务组合，尽管在训练中从未见过这些组合。

多任务训练的主要优势在评估跨任务物体泛化时得以体现。在此评估中，我们交换任务之间的所有物体（例如，将物体搜索的物体用于除尘与替换任务，反之亦然）。这创建了模型在训练期间未见过的新的物体-任务组合。图 8（右）的结果表明，使用多任务模型具有明显优势，与单任务版本相比，它能更有效地泛化到新的物体-任务组合。这表明，我们方法的泛化能力通过扩大所训练的回忆型任务数量而得到提升。



图 9：（左）物体搜索任务的物体。（中）计数任务的物体。（右）除尘与替换任务的物体。

D 关键帧选择算法

Algorithm 1 Selecting Keyframes from Candidates

Input: A sequence of candidate keyframe sets $J'_{0:t} = (J_0, J_1, \dots, J_t)$
The merge distance d
Output: A list of the selected keyframes K_t

```
1: function BUILDVISUALMEMORY( $J'_{0:t}, d$ )
2:    $G_{0:t} \leftarrow \text{Sort}(\text{GetIndicesFromFrames}(J'_{0:t}))$  ▷ Extract the temporal indices.
3:   if  $G_{0:t}$  is empty then ▷ Handle case with no candidates.
4:     return  $\emptyset$ 
5:   end if
6:    $Clusters \leftarrow []$ 
7:    $C_{current} \leftarrow [G_{0:t}[0]]$ 
8:   for  $i = 1$  to  $|G_{0:t}| - 1$  do ▷ Build the clusters.
9:     if  $G_{0:t}[i] - G_{0:t}[i - 1] \leq d$  then
10:      Append  $G_{0:t}[i]$  to  $C_{current}$ 
11:     else
12:      Append  $C_{current}$  to  $Clusters$ 
13:       $C_{current} \leftarrow [G_{0:t}[i]]$  ▷ Start a new cluster.
14:     end if
15:   end for
16:   Append  $C_{current}$  to  $Clusters$ 
17:    $T_{selected} \leftarrow []$ 
18:   for each cluster  $C$  in  $Clusters$  do ▷ Select the median index of each cluster.
19:      $i_{median} \leftarrow \text{Median}(C)$ 
20:     Append  $i_{median}$  to  $T_{selected}$ 
21:   end for
22:    $K_t \leftarrow \text{GetFramesFromIndices}(T_{selected})$ 
23:   return  $K_t$ 
24: end function
```

E 关键帧标注规则

如第 3.3 节所述，我们对每个子任务区间使用简单的语义标注规则来构建构成真实目标的关键帧集合。三个任务的规则如下：

- 物体搜索
 - 选择“查看<位置>箱内”的最后一帧。
 - 从“将<物体>从<位置>箱中取出并放入白色箱”中不选择任何帧。
- 计数
 - 从“拿起铲子”中不选择任何帧。
 - 选择“在<颜色>碗中放一勺<物体>”的最后一帧。
 - 从“重置铲子位置”中不选择任何帧。
 - 从“放下铲子”中不选择任何帧。
- 除尘与更换
 - 从“移除底层架子上的物体”中选择最后一帧。
 - 选择“移除顶层架子上的物体”的最后一帧。
 - 选择“清洁底层架子”的最后一帧。
 - 不选择“重置除尘器”的任何帧。
 - 选择“清洁顶层架子”的最后一帧。
 - 不选择“放下除尘器”的任何帧。

- 选择“将<物体>放置在底层架子上”的最后一帧。
- 选择“将<物体>放置在顶层架子上”的最后一帧。

F 训练记忆体的提示

Example Object Search Prompt

```
[
  {
    "role": "system",
    "content": [
      {
        "text": "You are a robot program that predicts actions.
        The video input from the egocentric camera shows the
        most recent actions the robot has executed. The images
        are selected frames of particular importance from all
        the actions the robot has executed so far. Based on
        these, output the current subtask the robot should
        execute and nothing else.\n\nReturn a JSON with:\n-
        current_subtask: the action that should be executed at
        the current timestep\n- keyframe_positions: list of
        frame positions (1-indexed) from the video input where
        actions change\n"
      }
    ]
  },
  {
    "role": "user",
    "content": [
      {
        "text": "Task: The robot's wrist and third-person camera
        feed is shown below. What subtask should the robot
        execute to retrieve the fried chicken and put it in the
        white bin?\nHere are the selected frames from the
        entirety of the full video that are of particular
        importance:"
      },
      {
        "image": "<path_to_memory_frame_1.png>"
      },
      {
        "image": "<path_to_memory_frame_2.png>"
      },
      {
        "text": "\nHere is a video of the most recent actions the
        robot has executed:"
      },
      {
        "video": [
          "<path_to_context_frame_1.png>",
          "<path_to_context_frame_2.png>",
          "<path_to_context_frame_3.png>",
          "<path_to_context_frame_4.png>",
          "<path_to_context_frame_5.png>",
          "<path_to_context_frame_6.png>",
          "<path_to_context_frame_7.png>",
          "<path_to_context_frame_8.png>"
        ]
      }
    ]
  }
],
```

```
{
  "role": "assistant",
  "content": [
    {
      "text": "{\\"current_subtask\\": \\"take the fried chicken
        from the right bin and place in the white bin\\",
        \\"keyframe_positions\\": [7]}"
    }
  ]
}
```

Example Counting Prompt

```
[
  {
    "role": "system",
    "content": [
      {
        "text": "You are a robot program that predicts actions.
          The video input from the egocentric camera shows the
          most recent actions the robot has executed. The images
          are selected frames of particular importance from all
          the actions the robot has executed so far. Based on
          these, output the current subtask the robot should
          execute and nothing else.\n\nReturn a JSON with:\n-
          current_subtask: the action that should be executed at
          the current timestep\n- keyframe_positions: list of
          frame positions (1-indexed) from the video input where
          actions change\n"
      }
    ]
  },
  {
    "role": "user",
    "content": [
      {
        "text": "Task: What subtask should the robot execute to
          get three scoops of peanuts and put it in the green
          bowl, and two scoops of jelly beans and put it in the
          blue bowl?\nHere are the selected frames from the
          entirety of the full video that are of particular
          importance:"
      },
      {
        "image": "<path_to_memory_frame.png>"
      },
      {
        "text": "\nHere is a video of the most recent actions the
          robot has executed:"
      },
      {
        "video": [
          "<path_to_context_frame_1.png>",
          "<path_to_context_frame_2.png>",
          "<path_to_context_frame_3.png>",
          "<path_to_context_frame_4.png>",
          "<path_to_context_frame_5.png>",
          "<path_to_context_frame_6.png>",
          "<path_to_context_frame_7.png>"
        ]
      }
    ]
  }
]
```

```

        "<path_to_context_frame_8.png>"
    ]
}
],
{
    "role": "assistant",
    "content": [
        {
            "text": "{ \"current_subtask\": \"reset scooper position\",
                \"keyframe_positions\": []}"
        }
    ]
}
]

```

Example Dusting Prompt

```

[
  {
    "role": "system",
    "content": [
      {
        "text": "You are a robot program that predicts actions.
        The video input from the egocentric camera shows the
        most recent actions the robot has executed. The images
        are selected frames of particular importance from all
        the actions the robot has executed so far. Based on
        these, output the current subtask the robot should
        execute and nothing else.\n\nReturn a JSON with:\n-
        current_subtask: the action that should be executed at
        the current timestep\n- keyframe_positions: list of
        frame positions (1-indexed) from the video input where
        actions change\n"
      }
    ]
  },
  {
    "role": "user",
    "content": [
      {
        "text": "Task: What subtask should the robot execute to
        remove the items from the shelves, dust the shelves,
        and place the items back on the shelves?\nHere are the
        selected frames from the entirety of the full video
        that are of particular importance:"
      },
      {
        "image": "<path_to_memory_frame_1.png>"
      },
      {
        "image": "<path_to_memory_frame_2.png>"
      },
      {
        "image": "<path_to_memory_frame_3.png>"
      },
      {
        "image": "<path_to_memory_frame_4.png>"
      },
      {

```

```

        "text": "\nHere is a video of the most recent actions the
            robot has executed:"
    },
    {
        "video": [
            "<path_to_context_frame_1.png>",
            "<path_to_context_frame_2.png>",
            "<path_to_context_frame_3.png>",
            "<path_to_context_frame_4.png>",
            "<path_to_context_frame_5.png>",
            "<path_to_context_frame_6.png>",
            "<path_to_context_frame_7.png>",
            "<path_to_context_frame_8.png>"
        ]
    }
],
{
    "role": "assistant",
    "content": [
        {
            "text": "{ \"current_subtask\": \"remove the object on the
                top shelf\", \"keyframe_positions\": [5] }"
        }
    ]
}
]

```

G GPT-5 / G EMINI R OBOTICS – ER 1.5 评估提示

Object Search System Prompt

你是一个 AI 助手，控制单臂机器人在 3 个箱子中搜索特定物体。探索箱子中的物体时，按左箱、中箱、右箱的顺序查看。你将收到来自两个摄像头的图像：一个用于全局视图，一个位于机器人手腕上用于详细视图。你将获得显示机器人最近执行动作的近期图像。你还会获得选定的关键帧图像，这些帧是机器人迄今执行的所有动作中特别重要的帧。基于这些，从提供的列表中选择一个动作让机器人执行，以最好地实现用户的任务指令。从列表中提供确切的动作，无需任何解释。

你将从以下列表中选择动作：

- 查看<位置>箱内部
- 从<位置>箱中取出<物体>并放入白色箱子中

<位置>是“左”、“中”或“右”之一。<物体>是“绿色胶带”、“红色积木”、“玉米”、“法棍面包”、“蓝色积木”、“炸鸡”、“牛奶盒”、“番茄酱”、“橡皮擦”、“葡萄”、“草莓”、“番茄”、“梨”、“木块”或“橄榄油”之一。

你还需要返回一个 1-8 的数值列表，用于索引最近动作中哪些帧对机器人记忆特别重要。对于此任务，回忆每个箱子中有什么物体至关重要，因此如果最近帧中有任何帧提供了箱子的良好视图，你应返回这些帧的索引列表。

返回一个 JSON，包含：

- current_subtask: 应在当前时间步执行的动作，该动作使用上述 <OBJECT> 和 <LOCATION> 值从上述列表中选择

- `keyframe_positions`: list of frame positions from 1-8, if any, from the recent frames to keep track of which objects are in each bin

Counting System Prompt

你是一名人工智能助手，负责引导单臂机器人获取两种不同食材的特定勺数。每次舀取之间你会重置勺子，并在两种食材的所有勺数都获取完毕后放下勺子。你将收到来自两个摄像头的图像：一个用于全局视角，另一个安装在机器人手腕上用于细节视角。你将获得显示机器人最近执行动作的近期图像。你还会获得选定的关键帧图像，这些帧是机器人迄今执行的所有动作中特别重要的画面。基于这些信息，从提供的列表选择一个动作让机器人执行，以最好地实现用户的任务指令。请从列表中给出确切动作，无需任何解释。

你将从以下列表中选择动作：

- 拿起勺子
- 将一勺<OBJECT>放入<COLOR>碗中
- 重置铲斗位置
- 放下铲斗

<OBJECT> 是“花生”或“果冻豆”之一。

<COLOR> 是“绿色”或“蓝色”之一。

你还需要返回一个从 1 到 8 的数值列表，用于索引最近动作中哪些帧对机器人记忆而言似乎特别重要。对于这项任务，回忆每种食材已获取的勺数至关重要，因此你应当返回一个索引列表（如果有的话），这些索引来自最近帧中能够清晰展示已完成一勺的帧。

返回一个 JSON，包含：

- `current_subtask`: 当前时间步应执行的动作，从上述列表中使用指定的 <OBJECT> 和 <COLOR> 值选择
- `keyframe_positions`: list of frame positions from 1-8, if any, from the recent frames to keep track of scoops

Dusting System Prompt

你是一个 AI 助手，引导单臂机器人从每个架子上取下物体（先底层架子后顶层架子），拿起除尘掸，清洁底层架子，放回除尘掸，清洁顶层架子，放下除尘掸，并将物体放回原位（先底层架子后顶层架子）。你将收到来自两个摄像头的图像：一个用于全局视图，另一个位于机器人手腕上用于详细视图。你将获得显示机器人最近执行动作的近期图像。你还将获得选定的关键帧图像，这些帧是机器人迄今执行的所有动作中特别重要的帧。基于这些，从提供的列表选择一个动作让机器人执行，以最好地实现用户的任务指令。提供列表中的确切动作，无需任何解释。

你将从以下列表中选择动作：

- 取下底层架子上的物体
- 取下顶层架子上的物体
- 拿起除尘掸
- ~~拿起除尘掸~~ 清洁底层架子
- 清洁顶层架子
- 放下除尘掸
- 将<OBJECT>放在底层架子上

-
- 将<OBJECT>放在顶层架子上

<OBJECT>是“熊猫毛绒玩具”、“紫色毛绒玩具”、“斑马毛绒玩具”、“大象毛绒玩具”、“狮子毛绒玩具”、“笑脸球”、“凯蒂猫毛绒玩具”、“婴儿鞋”、“牛奶盒”之一。

你还需要返回一个 1 到 8 的数值列表，用于索引最近动作中哪些帧对机器人记忆尤为重要。对于此任务，回忆物品最初放在架子上的位置以及哪些架子已经除尘至关重要，因此你应返回最近帧中能提供良好指示的索引列表（如果有的话）。

返回一个 JSON，包含：

- `current_subtask`: 当前时间步应执行的动作，从上述列表中使用指定的<OBJECT>值进行选择
- `keyframe_positions`: 最近帧中 1 到 8 的帧位置列表（如果有的话），用于跟踪物品最初放在架子上的位置以及哪些架子已经除尘