



记忆视觉语言动作模型：感知认知记忆

机器人操作中视觉-语言-动作模型的理论

Hao Shi^{1†} Bin Xie² Yingfei Liu² Lin Sun^{4†} Fengrong Liu^{5†} Tiancai Wang²

Erjin Zhou² Haoqiang Fan² Xiangyu Zhang^{3,6} Gao Huang^{1✉}

¹Department of Automation, BNRist, Tsinghua University ²Dexmal

³MEGVII Technology ⁴Tianjin University ⁵Harbin Institute of Technology ⁶StepFun

shi-h23@mails.tsinghua.edu.cn gaohuang@tsinghua.edu.cn

[†] Work done during interning at Dexmal. [✉] Corresponding author.

摘要

时间上下文对于机器人操作至关重要，因为此类任务本质上具有非马尔可夫性，然而主流视觉-语言-动作模型通常忽视这一点，难以应对长时程、时间依赖的任务。认知科学表明，人类依靠工作记忆来缓冲短暂表征以进行即时控制，而海马系统则保留过去经验的逐字情景细节和语义要点，形成长期记忆。受这些机制启发，本文提出记忆视觉-语言-动作框架，一种用于长时程机器人操作的认知-记忆-动作框架。预训练的视觉-语言模型将观测编码为感知和认知令牌，构成工作记忆，而感知-认知记忆库存储从中整合的低层细节和高层语义。工作记忆从记忆库中检索与决策相关的条目，自适应地将其与当前令牌融合，并通过合并冗余更新记忆库。利用这些令牌，一个以记忆为条件的扩散动作专家生成具有时间感知的动作序列。本文在三个机器人上对 150 多个仿真和真实世界任务评估了记忆视觉-语言-动作框架。在简化环境-桥接、分形、自由基准-5 套件和米卡萨-机器人上，分别达到 71.9%、72.7%、96.5% 和 41.2% 的成功率，均优于最先进的基线认知行动和 π_0 ，在桥接上显著提升+14.6，在米卡萨-机器人上提升+11.8。在涵盖通用技能和长时程时间依赖的 12 个真实世界任务中，记忆视觉-语言-动作框架达到 84.0% 的成功分数，长时程任务相比最先进基线提升+26。项目页面：<https://shihao1895.github.io/MemoryVLA>

1 引言

视觉-语言-动作（Vision-Language-Action, VLA）模型（Brohan 等，2023；Kim 等，2024；Black 等，2024；Li 等，2024a；Sun 等，2025；Xie 等，2025），由大规模跨具身机器人数据集（O’Neill 等，2024；Brohan 等，2022；Khazatsky 等，2024；Bu 等，2025a）和预训练视觉语言模型（Vision-Language Model, VLM）（Karamcheti 等，2024；Liu 等，2023b；Bai 等，2023a）驱动，在机器人操作方面取得了显著进展。然而，主流 VLA 模型如 OpenVLA（Kim 等，2024）和 π_0 （Black 等，2024）仅依赖当前观测，从而忽略了时间依赖性，在长时程时间操作任务上表现不佳。如图 1（a）所示，按压按钮任务在按压前后几乎没有视觉差异，难以判断动作是否已经完成。这凸显了操作的非马尔可夫性质，即早期动作影响后续决策，需要时间建模。一种朴素策略是将连续帧拼接作为 VLM 的输入。然而，它面临两个关键局限性：（1）自注意力的二次复杂度严重限制了可用的时间上下文长度；（2）顺序帧输入与模型的单帧机器人预训练分布不一致。




图 1: (a) 在按压按钮任务中, 按压前后的状态几乎相同, 需要时间建模。(b) 人类通过双记忆系统处理操作任务: 工作记忆 (神经活动) 支持短期控制, 而情景记忆 (海马体) 保存长期经验。(c) 受此启发, MemoryVLA 引入感知-认知记忆库, 整合低级感知细节和高级认知语义, 用于时间感知决策。(d) MemoryVLA 优于最先进的基线。

认知科学研究 (巴德利与希奇, 1974; 图尔文等, 1972; 雷纳与布雷纳德, 1995) 表明, 人类通过双记忆系统处理操作任务 (图 1 (b))。大脑将多模态感官输入编码为感知表征和认知表征。这些表征通过瞬时神经活动在工作记忆中缓冲, 为即时决策提供短期保持。同时, 情景记忆 (Episodic Memory) 作为由海马体支持的长期记忆系统, 以两种形式编码带有时间索引的过往经验: 保留精确细节的字面表征和捕捉抽象语义的要点表征。在执行过程中, 工作记忆从情景记忆中检索与决策相关的上下文, 并将其与当前表征整合, 通过小脑控制指导行动, 同时将新经验巩固到情景记忆中。

借鉴认知科学的洞见, 本文提出 **MemoryVLA** (图 1 (c)), 一个用于机器人操作的认知-记忆-行动框架, 通过感知-认知记忆库 (PCMB) 显式建模时间依赖关系。首先, 视觉编码器从观测中提取感知令牌, 而大语言模型 (LLM) 将其与语言指令一起处理, 利用常识先验生成认知令牌。感知令牌和认知令牌共同构成工作记忆。其次, PCMB 在长时间跨度内存储低层感知细节和高层认知语义。在检索过程中, 工作记忆缓冲当前令牌, 并使用时间位置编码查询 PCMB, 以获取与决策相关的历史上下文, 这些上下文通过门控机制与当前令牌自适应融合, 同时更新 PCMB。当容量达到上限时, 时间上相邻且语义相似的条目被合并, 以紧凑地保留关键信息。最后, 以记忆为条件的扩散动作专家以认知令牌为条件, 感知令牌用细粒度细节丰富它们, 从而生成具有时间感知的机器人动作序列。

我们在仿真和真实世界中, 对 MemoryVLA 在 3 台机器人和 150 多个任务 (含 500 多种变体) 上进行了广泛评估。在 SimplerEnv (Li 等人, 2024b) 上, MemoryVLA 在 Bridge 和 Fractal 套件中分别取得了 71.9% 和 72.7% 的成功率, 比 CogACT 高出 14.6 和 4.6 个百分点, 进一步超越了 π_0 。在 LIBERO (Liu 等人, 2023a) 上, 它在 5 个任务中取得了 96.5% 的成功率

套件（空间、物体、目标、长程-10 和长程-90），超越了 CogACT 和 π_0 。在 Mikasa-Robo (Cherepanov 等人, 2025) 上，成功率达到 41.2%，比 π_0 高出 11.8 个百分点。在真实世界评估中，我们在 Franka 和 WidowX 机器人上引入了 12 项任务，涵盖 6 项通用任务和 6 项长时程时序任务。MemoryVLA 在通用任务和时序任务上分别取得 85% 和 83% 的得分，比 CogACT 高出 9 和 26 个百分点，并大幅超越 π_0 。此外，MemoryVLA 在涉及不同背景、干扰物、物体、容器、光照和遮挡的分布外条件下表现出强大的鲁棒性和泛化能力。

本文的贡献总结如下：• 受认知科学中人类记忆系统的启发，我们提出了记忆视觉语言动作框架（MemoryVLA），该框架利用视觉语言模型的常识先验、感知认知记忆机制以及扩散动作专家，来捕捉机器人操作中的长时程时间依赖性。• 我们设计了一个带有工作记忆的感知-认知记忆库，该记忆库能够实现跨高层认知与低层感知的决策相关上下文的记忆检索，通过记忆融合将这些上下文与当前表示自适应地整合，并通过记忆巩固合并时间上相邻且语义相似的条目。• MemoryVLA 在 SimplerEnv、LIBERO、Mikasa-Robo 以及真实世界环境中达到了最先进的性能。它还展现出强大的鲁棒性和泛化能力。在具有挑战性的长时程真实世界任务中，它以显著优势超越了 CogACT 和 π_0 ，凸显了时间记忆建模的重要性。

2 相关工作

视觉-语言-动作模型 在视觉基础模型（Visual Foundation Models）的进展推动下（Radford 等, 2021; Caron 等, 2021; Liu 等, 2024a; Zheng 等, 2024a; 2025a; Zhang 等, 2025b; Wu 等, 2025; Wang 等, 2025），机器人模仿学习发展迅速，但仍局限于小型、任务特定的策略，泛化能力有限（Shridhar 等, 2023; Zhao 等, 2023; Chi 等, 2023; Goyal 等, 2023; Shi 等, 2025）。为克服这些局限，视觉语言模型（VLM）的成功（Achiam 等, 2023; Touvron 等, 2023; Liu 等, 2023b; Bai 等, 2023b; Guo 等, 2025）以及大规模机器人数据集（如 OXE (O'Neill 等, 2024)、AgiBot (Bu 等, 2025a)）催生了视觉-语言-动作（VLA）范式（Kim 等, 2024; Black 等, 2024; Yue 等, 2024; Zhong 等, 2025; Gao 等, 2025; Yang 等, 2025b）。RT-2 (Zitkovich 等, 2023) 和 OpenVLA (Kim 等, 2024) 将连续动作离散化为离散标记，并利用 VLM 进行自回归预测，如同生成语言。相比之下， π_0 (Black 等, 2024)、CogACT (Li 等, 2024a)、DexVLA (Wen 等, 2025) 和 HybridVLA (Liu 等, 2025c) 采用基于扩散的策略（Chi 等, 2023; Liu 等, 2024b）作为动作头，利用迭代去噪采样连续控制轨迹，以捕捉多样的多模态行为。然而，这些方法均未显式建模时间依赖性。机器人操作本质上具有非马尔可夫性，忽略历史会导致在长时程时间任务上的失败。

机器人中的时间建模 时间建模在计算机视觉和自动驾驶领域已得到广泛研究（Wang et al., 2023; Liu et al., 2023c; Feng et al., 2023; Zhou et al., 2024），但在机器人操作中尚未被充分探索。Octo (Mees et al., 2024)、RoboVLMs (Liu et al., 2025b) 和 Interleave-VLA (Fan et al., 2025) 采用视觉语言模型（VLM）范式，以交错的图像-文本格式对机器人视频数据进行建模。虽然概念上优雅，但这种格式实现复杂且计算开销大，阻碍了其广泛应用。RoboFlamingo (Li et al., 2023) 将视觉-语言表示压缩为潜在标记，并通过长短期记忆网络（LSTM）（Hochreiter & Schmidhuber, 1997）进行传播。潜在表示的获取方式相对粗糙，细粒度的感知历史在很大程度上被丢弃。TraceVLA (Zheng et al., 2024b) 采用不同路线，将历史状态绘制为当前帧上的轨迹，但丢弃了丰富的语义细节。UniVLA (Bu et al., 2025b) 将过去动作纳入输入提示，对时间建模进行了初步尝试。然而，它仅作为思维链（Wei et al., 2022）过程，并未有效利用历史信息。相比之下，我们在记忆框架内同时建模高层认知语义和细粒度感知细节，从而为长程操作实现有效的时间建模。




图 2: MemoryVLA 的整体架构。RGB 观测和语言指令由 7B 视觉语言模型编码为感知和认知标记，形成短期工作记忆。工作记忆查询感知-认知记忆库（PCMB）以检索相关历史上下文，包括高层语义和低层视觉细节，自适应地将其与当前标记融合，并通过合并最相似的邻居来巩固 PCMB。记忆增强后的标记随后条件化扩散 Transformer 以预测未来动作序列。

3 METHOD

3.1 MemoryVLA 概述

问题表述 我们将视觉语言动作（VLA）模型中的机器人操作表述为序贯决策过程，其中视觉观测和语言指令被映射为用于真实世界交互的控制动作。给定当前 RGB 图像 $I \in \mathbb{R}^{H \times W \times 3}$ 和语言指令 L ，参数化策略 π 输出未来动作序列

$$\mathcal{A} = (a_1, \dots, a_T) = \pi(I, L), \quad (1)$$

其中每个动作 $a_t = [\Delta x, \Delta y, \Delta z, \Delta \theta_x, \Delta \theta_y, \Delta \theta_z, g]^\top$ 由相对平移、相对旋转（欧拉角）和二值夹爪状态 $g \in \{0, 1\}$ 组成。

概述 MemoryVLA 是一个用于机器人操作的端到端框架，如图 2 所示。当前的 RGB 观测和语言指令首先由视觉语言模型编码为感知和认知令牌，形成工作记忆，类似于与短期记忆相关的视觉和前额叶皮层中的神经活动。为了补充这种短期存储，我们引入了受海马体启发的感知-认知记忆库（PCMB），它维护长期的高级语义和细粒度的感知细节。工作记忆嵌入查询 PCMB 以检索与决策相关的历史，通过门控机制将其与当前表示自适应融合，并在容量达到时通过合并时间上相邻且语义相似的条目来巩固记忆。得到的表示随后被送入一个以记忆为条件的扩散动作专家，以生成 N 个未来的 7 自由度动作序列。

3.2 视觉-语言认知模块

我们基于一个 70 亿参数的 Prismatic 视觉语言模型（Karamcheti 等人，2024），该模型进一步在大规模跨具身真实机器人数据集 Open-X Embodiment（O’Neill 等人，2024）上进行了预训练。对于视觉编码，我们在当前第三人称 RGB 图像 I 上采用并行的 DINOv2（Oquab 等人，2023）和 SigLIP（Zhai 等人，2023）骨干网络，将它们的特征拼接成原始视觉令牌。然后，通过 SE 瓶颈（Hu 等人，2018）实现的感知压缩模块将这些令牌压缩为一组紧凑的感知令牌 $p \in \mathbb{R}^{N_p \times d_p}$ ，其中 $N_p = 256$ 。同时，原始视觉令牌通过线性层投影到语言嵌入空间，并与分词后的指令拼接，然后输入到 LLaMA-7B（Touvron 等人，2023）中。句子结束（EOS）位置的输出被作为认知令牌 $c \in \mathbb{R}^{1 \times d_c}$ ，以紧凑形式表示高级认知语义。最后，感知令牌 p 和认知令牌 c 被组合起来，形成供下游模块使用的短期工作记忆。




图 3：记忆模块细节。(a) 检索：当前感知令牌和认知令牌通过带时间步位置编码的交叉注意力查询感知-认知记忆库，以获取相关历史特征。(b) 门控融合：当前令牌与检索到的令牌通过门控机制自适应融合。(c) 巩固：融合后的令牌被更新到感知-认知记忆库中。当感知-认知记忆库达到容量上限时，计算相邻条目之间的相似度，并合并最相似的一对以保持紧凑性。

3.3 感知-认知记忆模块

The Vision–Language Cognition Module yields a working memory

$$M_{wk} = \{p \in \mathbb{R}^{N_p \times d_p}, c \in \mathbb{R}^{1 \times d_c}\}, \quad (2)$$

其中 p 和 c 分别表示当前感知令牌和认知令牌。然而，这种工作记忆仅反映当前时间步，缺乏时间依赖性。

为了解决这一问题，受人类记忆系统中海马体的启发，我们引入了感知-认知记忆库 (Perceptual – Cognitive Memory Bank, PCMB)：

$$M_{pcmb} = \{m^x \mid x \in \{\text{per}, \text{cog}\}\}, \quad (3)$$

$$m^x = \{m_i^x \in \mathbb{R}^{N_x \times d_x}\}_{i=1}^L, \quad x \in \{\text{per}, \text{cog}\}, \quad (4)$$

where each perceptual entry m_i^p stores fine-grained visual details and each cognitive entry m_i^c encodes a high-level semantic summary. The bank maintains up to L entries per stream.

记忆检索 在每个时间步，由当前感知令牌 $p \in \mathbb{R}^{N_p \times d_p}$ 和认知令牌 $c \in \mathbb{R}^{1 \times d_c}$ 组成的工作记忆 M_{wk} 作为双重查询，从感知-认知记忆库 M_{pcmb} 中检索当前决策所需的历史信息，如图 3(a) 所示。每个记忆条目通过正弦嵌入 $\text{TE}(\cdot)$ 与其情节时间步相关联，该嵌入作为位置编码添加。然后，我们将所有感知记忆堆叠成张量 $\in \mathbb{R}^{L N_p \times d_p}$ ，将所有认知记忆堆叠成张量 $\in \mathbb{R}^{L \times d_c}$ 。当前令牌与这些记忆张量之间的缩放点积注意力为两个流产生原始输出：

$$K^x = [m_1^x + \text{TE}(t_1); \dots; m_L^x + \text{TE}(t_L)], \quad V^x = [m_1^x; \dots; m_L^x], \quad (5)$$

$$\hat{H}^x = \text{softmax}\left(\frac{q^x(K^x)^\top}{\sqrt{d_x}}\right) V^x, \quad q^x \in \{p, c\}, x \in \{\text{per}, \text{cog}\}. \quad (6)$$

该注意力操作之后是一个前馈网络，以完成一个变换器层，应用两个这样的层得到最终的检索嵌入 H^p 和 H^c 。

记忆门控融合 如图 3 (b) 所示，门控融合过程通过可学习的门控机制，将检索到的嵌入 H^p 和 H^c 与当前工作记忆表征进行整合。对于感知流 ($x = p$) 和认知流 ($x = c$)，门控向量计算如下：

$$g^x = \sigma(\text{MLP}(\text{concat}[x, H^x])), \quad (7)$$

并应用于获得记忆增强表征：

$$\tilde{x} = g^x \odot H^x + (1 - g^x) \odot x. \quad (8)$$

此处， σ 表示 Sigmoid 激活函数， $\odot$ 表示逐元素乘法。所得的记忆增强特征 $\tilde{p}$ 和 $\tilde{c}$ 随后被传递至记忆巩固阶段。

记忆巩固 门控融合后，记忆增强表征 $\tilde{p}$ 和 $\tilde{c}$ 被传递至记忆条件动作专家，并同步更新至感知认知记忆库（PCMB）。当存储条目数超过 L 时，在每个流（感知流和认知流）内计算相邻条目之间的余弦相似度。选择每个流中相似度最高的一对，通过对其向量取平均进行合并，从而减少冗余。

$$i_x^* = \arg \max_{i=1, \dots, L-1} \cos(\tilde{x}_i, \tilde{x}_{i+1}), \quad m_{i_x^*}^x \leftarrow \frac{1}{2}(\tilde{x}_{i_x^*} + \tilde{x}_{i_x^*+1}), \quad x \in \{\text{per}, \text{cog}\}. \quad (9)$$

该巩固机制（图 3（c））通过减少冗余来缓解记忆膨胀，同时保留最显著的感知细节和语义抽象，从而维持紧凑表征以支持高效的长期记忆。

3.4 记忆条件动作专家

利用整合了历史感知与认知信息的记忆增强工作记忆 $\{\tilde{p}, \tilde{c}\}$ ，动作专家预测未来动作序列 $\{a_1, a_2, \dots, a_T\}$ ，步长为 $T = 16$ 。该预测使模型能够预判多步轨迹，减少累积误差，并为长时程执行提供前瞻性。由于真实世界机器人动作位于连续多模态控制空间中，我们采用基于扩散的变换器（DiT）（Peebles & Xie, 2023），并以去噪扩散隐式模型（DDIM）（Song et al., 2020）实现，使用 10 个去噪步骤以高效且准确地生成轨迹。该架构逐步对含噪动作标记序列进行去噪，从而产生精确的连续动作。

具体而言，在每个去噪步骤中，噪声动作令牌被注入去噪时间步的正弦编码，并与认知表征拼接 $\tilde{c}$ 。认知注意力层以高层语义指导调节该过程，而感知注意力层则从感知特征中补充细粒度视觉细节 $\tilde{p}$ 。随后，组合表征通过前馈网络进行精炼，以获得该步骤的去噪动作。模型使用预测动作与目标动作之间的均方误差（MSE）损失进行训练，最终的去噪向量通过多层感知机（MLP）生成连续的七自由度机器人动作。

4 实验

为全面评估 MemoryVLA，我们围绕六个核心问题组织实验：

（1）MemoryVLA 在 SimplerEnv 基准上与最先进方法相比如何？

（第 4.2 节）（2）它在 LIBERO 基准上的表现如何？（第 4.3 节）（3）它在 Mikasa-Robo 基准上的表现如何？（第 4.4 节）（4）它能否在真实机器人上同时处理一般操作和长时程时序任务？

（第 4.5 节）（5）每个组件的影响是什么？（第 4.6 节）（6）在多样环境条件下，它的鲁棒性和泛化能力如何？（附录 B）

4.1 实验设置

仿真与真实世界基准。

图 4 概述了我们在仿真和真实世界中的评估，涵盖 3 种机器人、6 个基准、150 多个任务及 500 多种变体。SimplerEnv（Li 等，2024b）包括使用 WidowX 机器人的 Bridge 套件和使用 Google 机器人的 Fractal 套件。Fractal 提供两种设置：视觉匹配（VM）和视觉聚合（VA）。LIBERO（Liu 等，2023a）使用 Franka 机器人，涵盖五个套件（空间、物体、目标、长时程-10 和长时程-90）。Mikasa-Robo（Cherepanov 等，2025）使用 Franka 机器人。在真实世界中，我们在 Franka 和 WidowX 机器人上评估通用套件和长时程时序套件。每个基准的任务细节和额外的定性结果见附录 K 和附录 M。

实现细节 本文在 8 块英伟达 A100 图形处理器上使用 PyTorch 全分片数据并行进行训练，每块图形处理器处理 32 个样本，全局批大小为 256，学习率为 2×10^{-5} 。模型以单张第三人称红绿蓝图像帧 224×224 和语言指令作为输入，输出七自由度动作。大语言模型参数量为 70 亿，扩散动作专家参数量为 ~ 3 亿。推理时采用去噪扩散隐式模型（Song 等，2020），采样步数为 10，无分类器引导（Ho 和 Salimans，2022）的引导尺度为 1.5。更多细节见附录 C 和 D。

3 种机器人, 6 个基准, 150 余项任务, 500 余种变体




图 4: 实验设置概览。上: 四个仿真基准, 简易环境-桥接、简易环境-分形、自由机器人操作基准和御坂机器人。下: 真实世界评估 (通用和长时程时序)、真实世界鲁棒性与泛化评估。总计在 6 个基准上评估 3 种机器人, 涵盖 150 余项任务和 500 余种变体。

4.2 简易环境上的仿真评估

训练与评估设置 本文在两个简易环境套件上进行评估: 桥接和分形。对于简易环境-桥接, 在桥接 v2 数据集 (Walke 等, 2023) 上训练 5 万步, 每 2500 步进行一次验证。结果报告于最佳验证步, 每项任务进行 24 次试验以计算成功率。对于简易环境-分形, 在机器人变换器 1 数据集 (Brohan 等, 2022) 上训练 8 万步, 每 5000 步进行一次验证。评估涵盖视觉匹配和视觉聚合两种设置。视觉匹配模拟真实设置以缩小仿真到真实的差距, 而视觉聚合通过改变背景、光照、干扰物和桌面纹理来压力测试鲁棒性。分形测试平台包含 336 种变体, 共产生 2856 次试验。

SimplerEnv-Bridge 上的评估结果如表 1 所示, MemoryVLA 相较于 CogACT-Large 基线平均成功率提升了 **71.9%**, **+14.6** 个百分点, 并超越了近期最先进的视觉语言动作模型 (VLA), 包括 π_0 (Black 等人, 2024)。在各任务上, 成功率分别为: 毛巾上的勺子 75.0%、盘子上的胡萝卜 75.0%、堆叠方块 37.5%、篮子里的茄子 100.0%。

SimplerEnv-Fractal 上的评估结果表 2 报告了视觉匹配和视觉聚合设置下的结果。MemoryVLA 实现了 **72.7%** 的总体成功率, 较 CogACT 提升+4.6 个百分点, 并超越了 π_0 。按设置划分, 视觉匹配平均为 **77.7%**, 视觉聚合平均为 **67.7%**, 分别较 CogACT 提升+2.9 和+6.4 个百分点。在 Open/Close Drawer (视觉匹配) 上, 达到 84.7%, 较 CogACT 提升+12.9 个百分点; 在视觉聚合下观察到更大增益, 包括 Open/Close Drawer 上的+24.9 和 Put in Drawer 上的+11.7。

4.3 LIBERO 上的模拟评估

训练与评估设置 我们在 LIBERO (Liu 等人, 2023a) 基准上使用 Franka 机器人进行评估, 涵盖五个套件: Spatial、Object、Goal、Long-10 和 Long-90。前四个套件各包含 10 个任务, Long-90 包含 90 个任务。遵循 OpenVLA (Kim 等人, 2024), 每个任务使用 50 个演示。Spatial、Object 和 Goal 分别训练独立模型, 各训练 20k 步, 而 Long-10 和 Long-90 联合训练 40k 步。验证每

表 1：在 SimplerEnv-Bridge (Li 等人, 2024b) 上使用 WidowX 机器人的性能比较。 CogACT-Large 是我们使用官方权重重新评估的基线，MemoryVLA 在平均成功率上实现了+14.6 的提升。带*的条目复现自 open-pi-zero，其利用了额外的本体感觉状态输入；它们还采用了均匀/贝塔时间步采样。

Method	Spoon on Towel	Carrot on Plate	Stack Cube	Eggplant in Basket	Avg. Success
RT-1-X (O'Neill et al., 2024)	0.0	4.2	0.0	0.0	1.1
OpenVLA (Kim et al., 2024)	4.2	0.0	0.0	12.5	4.2
Octo-Base (Team et al., 2024)	15.8	12.5	0.0	41.7	17.5
TraceVLA (Zheng et al., 2024b)	12.5	16.6	16.6	65.0	27.7
RoboVLMs (Liu et al., 2025b)	45.8	20.8	4.2	79.2	37.5
SpatialVLA (Qu et al., 2025)	16.7	25.0	29.2	100.0	42.7
Magma (Yang et al., 2025a)	37.5	29.2	20.8	91.7	44.8
CogACT-Base (Li et al., 2024a)	71.7	50.8	15.0	67.5	51.3
π_0 -Uniform* (Black et al., 2024)	63.3	58.8	21.3	79.2	55.7
CogACT-Large (Li et al., 2024a)	58.3	45.8	29.2	95.8	<u>57.3</u>
CronusVLA (Li et al., 2025a)	66.7	54.2	20.8	100.0	60.4
π_0 -Beta* (Black et al., 2024)	84.6	55.8	47.9	85.4	68.4
MemoryVLA (Ours)	75.0	75.0	37.5	100.0	71.9 (+14.6)

表 2：在 SimplerEnv-Fractal (Li 等人, 2024b) 上使用 Google 机器人的性能比较。 报告了视觉匹配 (VM) 和视觉聚合 (VA) 套件的成功率 (%)。MemoryVLA 较 CogACT 实现了总体 +4.6 的提升。O./C.表示 Open/Close，*遵循表 1。

Method	Visual Matching (VM)					Visual Aggregation (VA)					Overall
	Coke Can	Move Near	O. / C. Drawer	Put in Drawer	Avg.	Coke Can	Move Near	O. / C. Drawer	Put in Drawer	Avg.	
Octo-Base (Team et al., 2024)	17.0	4.2	22.7	0.0	11.0	0.6	3.1	1.1	0.0	1.2	6.1
RT-1-X (O'Neill et al., 2024)	56.7	31.7	59.7	21.3	42.4	49.0	32.3	29.4	10.1	30.2	36.3
OpenVLA (Kim et al., 2024)	18.0	56.3	63.0	0.0	34.3	60.8	67.7	28.8	0.0	39.3	36.8
RoboVLMs (Liu et al., 2025b)	76.3	79.0	44.9	27.8	57.0	50.7	62.5	10.3	0.0	30.9	44.0
TraceVLA (Zheng et al., 2024b)	45.0	63.8	63.1	11.1	45.8	64.3	60.6	61.6	12.5	49.8	47.8
RT-2-X (O'Neill et al., 2024)	78.7	77.9	25.0	3.7	46.3	82.3	79.2	35.5	20.6	54.4	50.4
Magma (Yang et al., 2025a)	75.0	53.0	58.9	8.3	48.8	68.6	78.5	59.0	24.0	57.5	53.2
SpatialVLA (Qu et al., 2025)	79.3	90.0	54.6	0.0	56.0	78.7	83.0	39.2	6.3	51.8	53.9
π_0 -Uniform* (Black et al., 2024)	88.0	80.3	56.0	52.2	69.1	—	—	—	—	—	—
π_0 -Beta* (Black et al., 2024)	97.9	78.7	62.3	46.6	71.4	—	—	—	—	—	—
CogACT (Li et al., 2024a)	91.3	85.0	71.8	50.9	<u>74.8</u>	89.6	80.8	28.3	46.6	<u>61.3</u>	<u>68.1</u>
MemoryVLA (Ours)	90.7	88.0	84.7	47.2	77.7	80.5	78.8	53.2	58.3	67.7	72.7 (+4.6)

每 1k 步进行一次验证，结果报告在最佳验证步。每个任务评估 50 次试验，并报告每个套件的平均成功率。

LIBERO 上的评估结果 如表 3 所示，MemoryVLA 实现了 **96.5%** 的总体成功率，比 CogACT 提高了 3.3 个百分点，并超越了 π_0 。各套件的成功率分别为：Spatial 98.4%、Object 98.4%、Goal 96.4%、Long-10 93.4% 和 Long-90 95.6%。值得注意的是，MemoryVLA 仅使用第三人称 RGB 图像，未使用腕部视图或本体感受状态。

4.4 MIKASA-ROBO 上的仿真评估

训练与评估设置 我们在 Mikasa-Robo (Cherepanov 等人, 2025) 基准上进行了评估。实验中，我们将 MemoryVLA 与 Mikasa-Robo 中使用的 VLA 风格基线进行了比较，包括 OpenVLA-OFT (Kim 等人, 2025)、PI-0 (Black 等人, 2024) 和 SpatialVLA (Qu 等人, 2025)。此外，我们还复现了 CronusVLA (Li 等人, 2025a)，这是一个同时期使用时间上下文的 VLA 模型。遵循标准的 Mikasa-Robo 协议，每个任务使用 250 条演示，分辨率为 128×128 ，每个任务 100 个评估回合，采用末端执行器控制。标准的 5 个任务联合训练 20k 步，每 1k 步进行一次验证，并报告最佳验证步的结果。

表 3: 使用 Franka 机器人在 LIBERO (Liu 等人, 2023a) 上的性能比较。报告了五个套件的成功率 (%)。* 表示使用了额外的本体感受和腕部摄像头输入的方法。CogACT 的结果由我们复现。对于没有 LIBERO-90 结果的方法, 我们报告前四个套件的平均值。

Method	Spatial	Object	Goal	Long-10	Long-90	Avg. Success
Diffusion Policy (Chi et al., 2023)	78.3	92.5	68.3	50.5	—	72.4
Octo (Team et al., 2024)	78.9	85.7	84.6	51.1	—	75.1
MDT (Reuss et al., 2024)	78.5	87.5	73.5	64.8	—	76.1
UniACT (Zheng et al., 2025b)	77.0	87.0	77.0	70.0	73.0	76.8
MaIL (Jia et al., 2024)	74.3	90.1	81.8	78.6	—	83.5
SpatialVLA (Qu et al., 2025)	88.2	89.9	78.6	55.5	46.2	71.7
TraceVLA (Zheng et al., 2024b)	84.6	85.2	75.1	54.1	—	74.8
OpenVLA (Kim et al., 2024)	84.7	88.4	79.2	53.7	73.5	75.9
CoT-VLA (Zhao et al., 2025)	87.5	91.6	87.6	69.0	—	81.1
π_0 -FAST* (Pertsch et al., 2025)	96.4	96.8	88.6	60.2	83.1	85.0
CronusVLA (Li et al., 2025a)	90.1	94.7	91.3	68.7	—	86.2
TriVLA (Liu et al., 2025d)	91.2	93.8	89.8	73.2	—	87.0
4D-VLA (Zhang et al., 2025a)	93.8	92.8	95.6	86.5	—	92.2
CogACT (Li et al., 2024a)	97.2	98.0	90.2	88.8	92.1	<u>93.2</u>
π_0^* (Black et al., 2024)	96.8	98.8	95.8	85.2	—	94.2
MemoryVLA (Ours)	98.4	98.4	96.4	93.4	95.6	96.5 (+3.3)

表 4: 使用 Franka 机器人在 Mikasa-Robo (Cherepanov 等人, 2025) 上的性能比较。报告了成功率 (%)。CronusVLA 的结果由我们复现。

Model	ShellGame Touch	Intercept Medium	Remb. Color3	Remb. Color5	Remb. Color9	Avg. Success
CronusVLA (Li et al., 2025a)	32	5	31	13	9	18.0
SpatialVLA (Qu et al., 2025)	23	27	27	17	11	21.0
OpenVLA-OFT (Kim et al., 2025)	47	14	59	16	6	28.4
PI-0 (Black et al., 2024)	33	42	35	22	15	29.4
MemoryVLA (Ours)	88	24	44	30	20	41.2 (+11.8)

Mikasa-Robo 上的评估结果 MemoryVLA 在所有任务上均持续取得最高性能, 平均比之前的最先进方法提高了 **11.8%**, 尤其是在 ShellGameTouch 任务上 **+41.0%**。结果如表 4 所示。

4.5 真实世界评估

训练与评估设置 我们在 Franka 和 WidowX 机器人上评估了两个真实机器人套件: 通用套件和长时程时序套件。两者均使用固定前视安装的英特尔实感 D435 RGB 相机。图像以 640×480 捕获并下采样至 224×224 。系统通过 ROS 集成。对于通用套件, 每个任务使用 50-150 个演示, 并从随机初始状态进行评估。采摘多样水果包含五个变体, 每个变体 5 次试验 (共 25 次); 所有其他通用任务使用 15 次试验。对于长时程时序套件, 每个任务使用 200-300 个演示, 并以 10-15 次试验进行评估, 采用逐步评分以反映子目标的进展。训练大约运行 5k – 20k 步, 具体取决于任务和数据规模。

真实世界评估结果 如表 5 所示, MemoryVLA 在通用任务上达到 **85%** 的平均成功率, 在长时程时序任务上达到 **83%**, 分别超过 CogACT **+9** 和 **+26** 个百分点, 并在两个套件上均超过 π_0 。在通用任务上, 它在每个任务上都超过了最强基线, 其中煎蛋入锅 (+13) 和煎蛋入烤箱 (+20) 的增益尤为显著。在长时程时序任务上, 改进更大, 包括顺序按按钮 +43、更换食物 +38、猜位置 +32 以及清洁桌面并计数 +17。这些结果展示了强大的真实世界能力, 并凸显了时序记忆的优势。

表 5: Franka 和 WidowX 机器人真实世界实验的性能比较。报告了六个通用任务和六个长时序任务的成功率 (%)。所有方法仅使用第三人称 RGB 观测和语言指令进行评估。

Method	General Tasks						
	Insert Circle	Egg in Pan	Egg in Oven	Stack Cups	Stack Blocks	Pick Diverse Fruits	Avg. Success
OpenVLA (Kim et al., 2024)	47	27	53	40	13	4	31
π_0 (Black et al., 2024)	67	73	73	87	53	80	72
CogACT (Li et al., 2024a)	80	67	60	93	80	76	76
MemoryVLA (Ours)	87	80	80	93	87	84	85 (+9)

Method	Long-horizon Temporal Tasks						
	Seq. Push Buttons	Change Food	Guess Where	Clean Table & Count	Pick Place Order	Clean Rest. Table	Avg. Success
OpenVLA (Kim et al., 2024)	6	3	0	15	27	0	9
π_0 (Black et al., 2024)	25	42	24	61	82	80	52
CogACT (Li et al., 2024a)	15	47	40	67	90	84	57
MemoryVLA (Ours)	58	85	72	84	100	96	83 (+26)

表 6: 记忆类型和长度的消融实验。我们报告 SimplerEnv-Bridge 任务上的平均成功率 (%)。

	Variant	Avg. Success
Memory Type	Cognitive Mem.	63.5
	Perceptual Mem.	64.6
	Both	71.9
Memory Length	4	67.7
	16	71.9
	64	67.7

表 7: 记忆检索、融合、巩固的消融实验。我们报告 SimplerEnv-Bridge 任务上的平均成功率 (%)。

	Variant	Avg. Success
Retrieval	w/o Timestep PE	69.8
	w/ Timestep PE	71.9
Fusion	Add	67.7
	Gate	71.9
Consolidation	FIFO	66.7
	Token Merge	71.9

4.6 消融研究

我们在 SimplerEnv-Bridge 上对记忆设计进行消融实验，以量化每个选择的影响。如表 6 所示，结合感知记忆和认知记忆可达到 71.9%，而仅使用认知记忆为 63.5%，仅使用感知记忆为 64.6%。记忆长度为 16 时性能最佳，达到 71.9%，而长度为 4 和 64 时性能下降至 67.7%。表 7 评估了检索、融合和巩固机制。添加时间步位置编码将性能从 69.8% 提升至 71.9%。门控融合达到 71.9%，而简单相加为 67.7%。令牌合并巩固达到 71.9%，而先进先出策略为 66.7%。

5 结论

受认知科学启发，我们提出了 MemoryVLA，一个用于机器人操作的认知-记忆-动作框架。它利用类似海马体的感知-认知记忆库与工作记忆协同工作，以捕捉时间依赖性。视觉语言模型的常识经验进一步支持高层认知，而记忆条件化的扩散动作专家生成具有时间感知的动作。在 SimplerEnv、LIBERO 和真实世界中，跨越 3 种机器人、150 多个任务和 500 多种变体的测试中，MemoryVLA 始终优于 CogACT 和 π_0 ，达到了最先进的性能，在具有挑战性的长时程时间任务上取得了显著提升。它还在各种分布外条件下表现出强大的鲁棒性和泛化能力。未来方向包括：(i) 开发记忆反思机制，将长期记忆对齐到大型语言模型输入空间，以实现嵌入空间中的思维链推理；(ii) 通过受生物启发的巩固机制构建终身记忆，将频繁重用的经验提炼为永久表征，从而支持跨场景、任务和具身形式的可扩展泛化。

致谢

本工作得到中国国家科技重大专项（批准号：2023ZD0121300）、国家自然科学基金（批准号：U24B20173 和 62321005）以及青年教师科研创新能力提升支持项目（批准号：ZYGXQNJSKYCXNLZCXM-I20）的资助。

可复现性声明

正文详细说明了模型架构、训练设置和实验方案，附录提供了关于超参数、数据集、预处理和数据增强、训练流程、评估方法和评分规则、鲁棒性和泛化分析、任务规范以及定性结果的额外细节。为了完全复现，我们发布了：

- **Code:** <https://github.com/shihao1895/MemoryVLA>
- **Models:** <https://huggingface.co/collections/shihao1895/memoryvla>
- **Logs:** <https://huggingface.co/collections/shihao1895/memoryvla>
- **Robotic videos:** <https://shihao1895.github.io/MemoryVLA>

参考文献

- Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*, 2023.
- Alan D Baddeley and Graham James Hitch. Working memory (vol. 8). *New York: GA Bower (ed), Recent advances in learning and motivation*, 1974.
- Jinze Bai, Shuai Bai, Yunfei Chu, Zeyu Cui, Kai Dang, Xiaodong Deng, Yang Fan, Wenbin Ge, Yu Han, Fei Huang, Binyuan Hui, Luo Ji, Mei Li, Junyang Lin, Runji Lin, Dayiheng Liu, Gao Liu, Chengqiang Lu, Keming Lu, Jianxin Ma, Rui Men, Xingzhang Ren, Xuancheng Ren, Chuanqi Tan, Sinan Tan, Jianhong Tu, Peng Wang, Shijie Wang, Wei Wang, Shengguang Wu, Benfeng Xu, Jin Xu, An Yang, Hao Yang, Jian Yang, Shusheng Yang, Yang Yao, Bowen Yu, Hongyi Yuan, Zheng Yuan, Jianwei Zhang, Xingxuan Zhang, Yichang Zhang, Zhenru Zhang, Chang Zhou, Jingren Zhou, Xiaohuan Zhou, and Tianhang Zhu. Qwen technical report. *arXiv preprint arXiv:2309.16609*, 2023a.
- Jinze Bai, Shuai Bai, Yunfei Chu, Zeyu Cui, Kai Dang, Xiaodong Deng, Yang Fan, Wenbin Ge, Yu Han, Fei Huang, et al. Qwen technical report. *arXiv preprint arXiv:2309.16609*, 2023b.
- Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. pi-0: A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.
- Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023.
- Qingwen Bu, Jisong Cai, Li Chen, Xiuqi Cui, Yan Ding, Siyuan Feng, Shenyuan Gao, Xindong He, Xuan Hu, Xu Huang, et al. Agibot world colosseum: A large-scale manipulation platform for scalable and intelligent embodied systems. *arXiv preprint arXiv:2503.06669*, 2025a.
- Qingwen Bu, Yanting Yang, Jisong Cai, Shenyuan Gao, Guanghui Ren, Maoqing Yao, Ping Luo, and Hongyang Li. Univla: Learning to act anywhere with task-centric latent actions. *arXiv preprint arXiv:2505.06111*, 2025b.
- Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *Proceedings of the IEEE/CVF international conference on computer vision*, pp. 9650–9660, 2021.
- Egor Cherepanov, Nikita Kachaev, Alexey K Kovalev, and Aleksandr I Panov. Memory, benchmark & robots: A benchmark for solving complex tasks with reinforcement learning. *arXiv preprint arXiv:2502.10550*, 2025.
- Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, pp. 02783649241273668, 2023.
- Cunxin Fan, Xiaosong Jia, Yihang Sun, Yixiao Wang, Jianglan Wei, Ziyang Gong, Xiangyu Zhao, Masayoshi Tomizuka, Xue Yang, Junchi Yan, et al. Interleave-vla: Enhancing robot manipulation with interleaved image-text instructions. *arXiv preprint arXiv:2505.02152*, 2025.
- Tingliang Feng, Hao Shi, Xueyang Liu, Wei Feng, Liang Wan, Yanlin Zhou, and Di Lin. Open compound domain adaptation with object style compensation for semantic segmentation. *Advances in Neural Information Processing Systems*, 36:63136–63149, 2023.
- Chongkai Gao, Zixuan Liu, Zhenghao Chi, Junshan Huang, Xin Fei, Yiwen Hou, Yuxuan Zhang, Yudi Lin, Zhirui Fang, Zeyu Jiang, et al. Vla-os: Structuring and dissecting planning representations and paradigms in vision-language-action models. *arXiv preprint arXiv:2506.17561*, 2025.

- Ankit Goyal, Jie Xu, Yijie Guo, Valts Blukis, Yu-Wei Chao, and Dieter Fox. Rvt: Robotic view transformer for 3d object manipulation. In *Conference on Robot Learning*, pp. 694–710. PMLR, 2023.
- Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.
- Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. *arXiv preprint arXiv:2207.12598*, 2022.
- Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8): 1735–1780, 1997.
- Jie Hu, Li Shen, and Gang Sun. Squeeze-and-excitation networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 7132–7141, 2018.
- Xiaogang Jia, Qian Wang, Atalay Donat, Bowen Xing, Ge Li, Hongyi Zhou, Onur Celik, Denis Blessing, Rudolf Lioutikov, and Gerhard Neumann. Mail: Improving imitation learning with selective state space models. In *8th Annual Conference on Robot Learning*, 2024.
- Siddharth Karamcheti, Suraj Nair, Ashwin Balakrishna, Percy Liang, Thomas Kollar, and Dorsa Sadigh. Prismatic vlms: Investigating the design space of visually-conditioned language models. In *Forty-first International Conference on Machine Learning*, 2024.
- Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, et al. Droid: A large-scale in-the-wild robot manipulation dataset. *arXiv preprint arXiv:2403.12945*, 2024.
- Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- Moo Jin Kim, Chelsea Finn, and Percy Liang. Fine-tuning vision-language-action models: Optimizing speed and success. *arXiv preprint arXiv:2502.19645*, 2025.
- Hao Li, Shuai Yang, Yilun Chen, Yang Tian, Xiaoda Yang, Xinyi Chen, Hanqing Wang, Tai Wang, Feng Zhao, Dahua Lin, et al. Cronusvla: Transferring latent motion across time for multi-frame prediction in manipulation. *arXiv preprint arXiv:2506.19816*, 2025a.
- Qixiu Li, Yaobo Liang, Zeyu Wang, Lin Luo, Xi Chen, Mozheng Liao, Fangyun Wei, Yu Deng, Sicheng Xu, Yizhong Zhang, et al. Cogact: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation. *arXiv preprint arXiv:2411.19650*, 2024a.
- Runhao Li, Wenkai Guo, Zhenyu Wu, Changyuan Wang, Haoyuan Deng, Zhenyu Weng, Yap-Peng Tan, and Ziwei Wang. Map-vla: Memory-augmented prompting for vision-language-action model in robotic manipulation. *arXiv preprint arXiv:2511.09516*, 2025b.
- Xinghang Li, Minghuan Liu, Hanbo Zhang, Cunjun Yu, Jie Xu, Hongtao Wu, Chilam Cheang, Ya Jing, Weinan Zhang, Huaping Liu, et al. Vision-language foundation models as effective robot imitators. *arXiv preprint arXiv:2311.01378*, 2023.
- Xuanlin Li, Kyle Hsu, Jiayuan Gu, Karl Pertsch, Oier Mees, Homer Rich Walke, Chuyuan Fu, Ishikaa Lunawat, Isabel Sieh, Sean Kirmani, et al. Evaluating real-world robot manipulation policies in simulation. *arXiv preprint arXiv:2405.05941*, 2024b.
- Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, 36:44776–44791, 2023a.
- Chenghao Liu, Jiachen Zhang, Chengxuan Li, Zhimu Zhou, Shixin Wu, Songfang Huang, and Huiling Duan. Ttf-vla: Temporal token fusion via pixel-attention integration for vision-language-action models. *arXiv preprint arXiv:2508.19257*, 2025a.

- Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. *Advances in neural information processing systems*, 36:34892–34916, 2023b.
- Huaping Liu, Xinghang Li, Peiyan Li, Minghuan Liu, Dong Wang, Jirong Liu, Bingyi Kang, Xiao Ma, Tao Kong, and Hanbo Zhang. Towards generalist robot policies: What matters in building vision-language-action models. *arXiv preprint arXiv:2412.14058*, 2025b.
- Jiaming Liu, Hao Chen, Pengju An, Zhuoyang Liu, Renrui Zhang, Chenyang Gu, Xiaoqi Li, Ziyu Guo, Sixiang Chen, Mengzhen Liu, et al. Hybridvla: Collaborative diffusion and autoregression in a unified vision-language-action model. *arXiv preprint arXiv:2503.10631*, 2025c.
- Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, et al. Grounding dino: Marrying dino with grounded pre-training for open-set object detection. In *European conference on computer vision*, pp. 38–55. Springer, 2024a.
- Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun Zhu. Rdt-1b: a diffusion foundation model for bimanual manipulation. *arXiv preprint arXiv:2410.07864*, 2024b.
- Yingfei Liu, Junjie Yan, Fan Jia, Shuailin Li, Aqi Gao, Tiancai Wang, and Xiangyu Zhang. Petrv2: A unified framework for 3d perception from multi-camera images. In *Proceedings of the IEEE/CVF international conference on computer vision*, pp. 3262–3272, 2023c.
- Zhenyang Liu, Yongchong Gu, Sixiao Zheng, Xiangyang Xue, and Yanwei Fu. Trivla: A unified triple-system-based unified vision-language-action model for general robot control. *arXiv preprint arXiv:2507.01424*, 2025d.
- Oier Mees, Dibya Ghosh, Karl Pertsch, Kevin Black, Homer Rich Walke, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, Jianlan Luo, et al. Octo: An open-source generalist robot policy. In *First Workshop on Vision-Language Models for Navigation and Manipulation at ICRA 2024*, 2024.
- Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023.
- Abby O’Neill, Abdul Rehman, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, Ajinkya Jain, et al. Open x-embodiment: Robotic learning datasets and rt-x models: Open x-embodiment collaboration 0. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 6892–6903. IEEE, 2024.
- William Peebles and Saining Xie. Scalable diffusion models with transformers. In *Proceedings of the IEEE/CVF international conference on computer vision*, pp. 4195–4205, 2023.
- Karl Pertsch, Kyle Stachowicz, Brian Ichter, Danny Driess, Suraj Nair, Quan Vuong, Oier Mees, Chelsea Finn, and Sergey Levine. Fast: Efficient action tokenization for vision-language-action models. *arXiv preprint arXiv:2501.09747*, 2025.
- Delin Qu, Haoming Song, Qizhi Chen, Yuanqi Yao, Xinyi Ye, Yan Ding, Zhigang Wang, JiaYuan Gu, Bin Zhao, Dong Wang, et al. Spatialvla: Exploring spatial representations for visual-language-action model. *arXiv preprint arXiv:2501.15830*, 2025.
- Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pp. 8748–8763. PmLR, 2021.
- Moritz Reuss, Ömer Erdiñç Yağmurlu, Fabian Wenzel, and Rudolf Lioutikov. Multimodal diffusion transformer: Learning versatile behavior from multimodal goals. *arXiv preprint arXiv:2407.05996*, 2024.
- Valerie F Reyna and Charles J Brainerd. Fuzzy-trace theory: An interim synthesis. *Learning and individual Differences*, 7(1):1–75, 1995.

- Hao Shi, Bin Xie, Yingfei Liu, Yang Yue, Tiancai Wang, Haoqiang Fan, Xiangyu Zhang, and Gao Huang. Spatialactor: Exploring disentangled spatial representations for robust robotic manipulation. *arXiv preprint arXiv:2511.09555*, 2025.
- Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. In *Conference on Robot Learning*, pp. 785–799. PMLR, 2023.
- Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. *arXiv preprint arXiv:2010.02502*, 2020.
- Lin Sun, Bin Xie, Yingfei Liu, Hao Shi, Tiancai Wang, and Jiale Cao. Geovla: Empowering 3d representations in vision-language-action models. *arXiv preprint arXiv:2508.09071*, 2025.
- Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*, 2024.
- Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, et al. Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*, 2023.
- Endel Tulving et al. Episodic and semantic memory. *Organization of memory*, 1(381-403):1, 1972.
- Homer Rich Walke, Kevin Black, Tony Z Zhao, Quan Vuong, Chongyi Zheng, Philippe Hansen-Estruch, Andre Wang He, Vivek Myers, Moo Jin Kim, Max Du, et al. Bridgedata v2: A dataset for robot learning at scale. In *Conference on Robot Learning*, pp. 1723–1736. PMLR, 2023.
- Shihao Wang, Yingfei Liu, Tiancai Wang, Ying Li, and Xiangyu Zhang. Exploring object-centric temporal modeling for efficient multi-view 3d object detection. In *Proceedings of the IEEE/CVF international conference on computer vision*, pp. 3621–3631, 2023.
- Yulin Wang, Yang Yue, Yang Yue, Huanqian Wang, Haojun Jiang, Yizeng Han, Zanlin Ni, Yifan Pu, Minglei Shi, Rui Lu, et al. Emulating human-like adaptive vision for efficient and flexible machine visual perception. *Nature Machine Intelligence*, pp. 1–19, 2025.
- Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems*, 35:24824–24837, 2022.
- Junjie Wen, Yichen Zhu, Jinming Li, Zhibin Tang, Chaomin Shen, and Feifei Feng. Dexvla: Vision-language model with plug-in diffusion expert for general robot control. *arXiv preprint arXiv:2502.05855*, 2025.
- Dongming Wu, Yanping Fu, Saiké Huang, Yingfei Liu, Fan Jia, Nian Liu, Feng Dai, Tiancai Wang, Rao Muhammad Anwer, Fahad Shahbaz Khan, et al. Ragnet: Large-scale reasoning-based affordance segmentation benchmark towards general grasping. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 11980–11990, 2025.
- Bin Xie, Erjin Zhou, Fan Jia, Hao Shi, Haoqiang Fan, Haowei Zhang, Hebei Li, Jianjian Sun, Jie Bin, Junwen Huang, et al. Dexbotoc: Open-source vision-language-action toolbox. *arXiv preprint arXiv:2510.23511*, 2025.
- Jianwei Yang, Reuben Tan, Qianhui Wu, Ruijie Zheng, Baolin Peng, Yongyuan Liang, Yu Gu, Mu Cai, Seonghyeon Ye, Joel Jang, et al. Magma: A foundation model for multimodal ai agents. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pp. 14203–14214, 2025a.
- Shuai Yang, Hao Li, Yilun Chen, Bin Wang, Yang Tian, Tai Wang, Hanqing Wang, Feng Zhao, Yiyi Liao, and Jiangmiao Pang. Instructvla: Vision-language-action instruction tuning from understanding to manipulation. *arXiv preprint arXiv:2507.17520*, 2025b.
- Yang Yue, Yulin Wang, Bingyi Kang, Yizeng Han, Shenzhi Wang, Shiji Song, Jiashi Feng, and Gao Huang. Deer-vla: Dynamic inference of multimodal large language models for efficient robot execution. *Advances in Neural Information Processing Systems*, 37:56619–56643, 2024.

- Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *Proceedings of the IEEE/CVF international conference on computer vision*, pp. 11975–11986, 2023.
- Jiahui Zhang, Yurui Chen, Yueming Xu, Ze Huang, Yanpeng Zhou, Yu-Jie Yuan, Xinyue Cai, Guowei Huang, Xingyue Quan, Hang Xu, et al. 4d-vla: Spatiotemporal vision-language-action pretraining with cross-scene calibration. *arXiv preprint arXiv:2506.22242*, 2025a.
- Yani Zhang, Dongming Wu, Hao Shi, Yingfei Liu, Tiancai Wang, Haoqiang Fan, and Xingping Dong. Grounding beyond detection: Enhancing contextual understanding in embodied 3d grounding. *arXiv preprint arXiv:2506.05199*, 2025b.
- Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, et al. Cot-vla: Visual chain-of-thought reasoning for vision-language-action models. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pp. 1702–1713, 2025.
- Tony Z Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023.
- Henry Zheng, Hao Shi, Yong Xien Chng, Rui Huang, Zanlin Ni, Tianyi Tan, Qihang Peng, Yepeng Weng, Zhongchao Shi, and Gao Huang. Densseg: Alleviating vision-language feature sparsity in multi-view 3d visual grounding. In *Autonomous Grand Challenge CVPR 2024 Workshop*, volume 2, pp. 6, 2024a.
- Henry Zheng, Hao Shi, Qihang Peng, Yong Xien Chng, Rui Huang, Yepeng Weng, zhongchao shi, and Gao Huang. Densseg: Improving dense language-vision semantics for ego-centric 3d visual grounding. In *The Thirteenth International Conference on Learning Representations*, 2025a.
- Jinliang Zheng, Jianxiong Li, Dongxiu Liu, Yinan Zheng, Zhihao Wang, Zhonghong Ou, Yu Liu, Jingjing Liu, Ya-Qin Zhang, and Xianyu Zhan. Universal actions for enhanced embodied foundation models. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pp. 22508–22519, 2025b.
- Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. Tracevla: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. *arXiv preprint arXiv:2412.10345*, 2024b.
- Yifan Zhong, Fengshuo Bai, Shaofei Cai, Xuchuan Huang, Zhang Chen, Xiaowei Zhang, Yuanfei Wang, Shaoyang Guo, Tianrui Guan, Ka Nam Lui, et al. A survey on vision-language-action models: An action tokenization perspective. *arXiv preprint arXiv:2507.01925*, 2025.
- Junbao Zhou, Ziqi Pang, and Yu-Xiong Wang. Rmem: Restricted memory banks improve video object segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 18602–18611, 2024.
- Brianna Zitkovich, Tianhe Yu, Sichun Xu, Peng Xu, Ted Xiao, Fei Xia, Jialin Wu, Paul Wohlhart, Stefan Welker, Ayzaan Wahid, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, pp. 2165–2183. PMLR, 2023.

附录

A 大语言模型使用情况 18

B 鲁棒性与泛化评估 18

B.1 真实世界评估 18

B.2 仿真评估 18

C 补充训练细节 19

C.1 超参数 19

C.2 训练数据 20

C.3 训练设置 22

C.4 数据增强 22

D 附加评估细节 23

D.1 SimplEnv 23

D.2 LIBERO 23

D.3 Mikasa-Robo 23

D.4 Real-world 23

E 记忆检索案例研究 24

F 数据长度统计 25

G 附加消融实验 25

H 推理效率 26

I 零样本任务泛化 27

J 与时间上下文视觉语言动作基线的比较 27

K 任务详情 27

K.1 Real-world Tasks 29

K.2 SimplEnv Tasks 29

K.3 LIBERO Tasks 30

L 真实世界任务中记忆依赖的可视化 30

M 定性结果 32

M.1 真实世界评估 32

M.2 仿真评估 33

A 大语言模型使用

大语言模型仅用于语法和措辞润色。所有研究内容和贡献完全由作者负责，大语言模型未参与其中。

B 鲁棒性与泛化评估

B.1 真实世界评估




图 5：真实世界中分布外（OOD）条件下的鲁棒性与泛化。(a,b) 两个代表性任务（按序拾取放置与清洁餐厅桌面）的分布外变体示例，包括未见背景、干扰物、光照、新物体/容器及遮挡。(c,d) 定量结果显示，MemoryVLA 在这些分布外变体上保持高成功率，展现出真实环境中强大的鲁棒性与泛化能力。

我们进一步在真实世界环境中评估 MemoryVLA 在多种分布外（OOD）变体下的鲁棒性与泛化能力。图 5 展示了两个代表性任务——按序拾取放置与清洁餐厅桌面——在未见背景、干扰物、新物体/容器、光照变化及遮挡条件下的评估结果。

对于按序拾取放置任务，MemoryVLA 在基础设置（100%）、未见背景（100%）、未见干扰物（92%）、未见光照（96%）、未见容器（100%）及遮挡（96%）下均取得近乎完美的成功率，仅在未见物体（89%）上出现适度下降。对于清洁餐厅桌面任务，基础成功率为 96%，未见背景（92%）、未见干扰物（86%）、未见光照（94%）、未见物体（94%）、未见容器（96%）及遮挡（94%）。

这些结果证实，MemoryVLA 在广泛的真实世界分布外条件下始终保持高性能，展现出强大的鲁棒性与泛化能力。

B.2 仿真评估

我们进一步在仿真环境中开展鲁棒性与泛化实验，涵盖拾取移动任务和铰链类物体操作任务。图 6 展示了拾取可乐罐任务的结果




图 6: 仿真中分布外 (OOD) 变体下的鲁棒性与泛化能力: 抓取与移动任务。(a) 抓取可乐罐和 (b) 移动靠近任务在未见背景、干扰物、光照、纹理和相机视角下进行评估。柱状图报告了相应的成功率, 表明 MemoryVLA 在大多数偏移下保持强劲性能, 在未见相机视角下性能下降最大。

以及移动靠近, 而图 7 涵盖开关抽屉和将苹果放入抽屉。这些任务在未见背景、干扰物、光照、纹理和相机视角下进行评估。

对于抓取可乐罐, MemoryVLA 的基础成功率为 92.0%, 未见干扰物 (90.7%)、未见背景 (86.7%)、未见光照 (90.7%) 和未见纹理 (86.7%), 而在未见相机视角下性能大幅下降 (42.0%)。对于移动靠近, 基础成功率为 76.0%, 未见干扰物 (84.0%)、未见背景 (86.0%)、未见光照 (84.0%)、未见相机视角 (58.0%) 和未见纹理 (86.0%)。对于铰链类物体操作, 开关抽屉的基础成功率为 46.3%, 未见背景 (56.4%)、未见光照 (49.1%) 和未见纹理 (57.4%)。对于将苹果放入抽屉, 基础成功率为 72.0%, 未见背景 (66.0%)、未见光照 (52.0%) 和未见纹理 (50.0%)。

这些结果表明, MemoryVLA 在中等分布偏移 (如干扰物、背景和纹理) 下泛化良好, 但在剧烈变化下 (尤其是未见相机视角) 性能下降更明显。

C 附加训练细节

C.1 超参数

我们总结了实验中使用的关键超参数。全局批大小为 256 (32×8 GPU), 学习率为 2×10^{-5} , 梯度裁剪的最大范数为 1.0。策略预测 16 步动作块, 感知令牌使用 256 个通道。扩散策略




图 7：仿真中分布外（OOD）变体下的鲁棒性与泛化能力：铰链类物体操作。（a）开关抽屉和（b）将苹果放入抽屉任务的 OOD 变体，包括未见背景、干扰物、光照、纹理和相机视角。定量结果表明，MemoryVLA 在中等偏移下泛化良好，而在相机视角变化时性能显著下降。

表 8：训练与模型超参数。

Hyperparameter	Value
Batch size	32×8
Learning rate	2×10^{-5}
Repeated diffusion steps	4
Action trunking size	16
Perceptual token channels	256
Max grad. norm	1.0
CFG scale (classifier-free guidance)	1.5

训练期间使用 4 次重复扩散步骤；推理采用 DDIM，包含 10 个采样步骤和无分类器引导尺度 1.5。简要总结见表 8。

C.2 训练数据

Bridge v2 对于 SimplerEnv-Bridge 基准，我们在 BridgeData v2 (Walke 等人, 2023) 上进行训练，这是一个大规模、语言条件的真实机器人操作数据集，包含约 60,000 条在 WidowX 机器人上收集的遥操作轨迹，涵盖多种桌面场景。每个片段将语言指令与技能演示配对，如拾取、放置、推动、堆叠和折叠。

RT-1 对于 SimplerEnv-Fractal 基准，我们使用 RT-1 (Brohan 等人, 2022)，这是一个大规模真实世界数据集，包含约 130,000 个片段，涵盖 700 多个任务，由 Google 机器人机群在 17 个月内收集，并配有自然语言指令。



图 8: Franka 机器人设置。



图 9: WidowX 机器人设置。

LIBERO LIBERO (Liu 等人, 2023a) 提供了使用 Franka 机器人的仿真任务, 涵盖五个套件: 空间、物体、目标、长程-10 和长程-90, 共计 130 个语言条件任务。每个任务提供 50 个演示。

Mikasa-Robo Mikasa-Robo (Cherepanov 等人, 2025) 包含五个依赖记忆的操作任务, 每个任务提供 250 个官方演示, 使用 Δ end-effector 控制。

真实世界 我们使用固定的第三人称 RGB 设置，在 Franka 和 WidowX 机器人上收集真实演示，如图 8 和图 9 所示。前置的 Intel RealSense D435 以 30 帧/秒捕获 640×480 RGB。Franka 在每个实验中使用单个末端执行器，即原装平行夹具或 Robotiq 平行夹具。演示通过操纵杆遥操作收集。通用套件每个任务使用 50-150 个演示，长程时序套件每个任务使用 200-300 个演示。系统集成在 ROS 中。

收集完成后，我们执行标准化的预处理流程。帧被下采样至 224×224 。然后，当末端执行器自上一保留帧以来的平移超过 0.01 米或方向变化超过 0.4 弧度时，我们保留该帧，并对视频流进行子采样，同时强制保留帧之间的最大间隔为 120 帧。处理后的片段被转换为 RLDS 格式，用于下游训练。

C.3 训练设置

SimplerEnv-Bridge 在 Bridge v2 上，模型使用流式数据加载器训练 5 万步。每个回合被解包为连续帧，并标记其回合 ID。训练期间，批处理尽可能按顺序填充来自单个回合的帧。如果回合在批处理完成前结束，剩余槽位由下一个回合的帧填充。新批处理接着从上一个批处理停止的位置继续，确保回合内的时间顺序始终得到保留。记忆长度固定为 16。

SimplerEnv-Fractal 模型在 RT-1 上训练 8 万步。该基准定义了两个协议：视觉匹配（Visual Matching, VM），模拟真实机器人设置；以及视觉聚合（Visual Aggregation, VA），通过扰动背景、光照、干扰物和纹理来测试鲁棒性。数据加载器设计和记忆长度与 SimplerEnv-Bridge 中的设置相同。

LIBERO 遵循 OpenVLA（Kim 等，2024），我们在移除数据集中失败轨迹后，每个任务使用 50 个演示进行训练。空间、物体和目标套件分别训练 2 万步，而 Long-10 和 Long-90 被视为一个长时程数据族，联合训练 4 万步。数据加载器采用分组采样策略：在每次迭代中，从单个回合内随机采样 16 帧，与整个训练过程中使用的记忆长度 16 相匹配。数据加载器采用分组采样策略，其中每个批处理被划分为多个组，每组由来自单个回合的若干帧组成。组内帧保持时间顺序。记忆长度设置为 16。

Mikasa-Robo 遵循 Mikasa-Robo（Cherepanov 等，2025），我们采用包含五个任务的标准协议，并在全部 1,250 个演示上联合训练 2 万步，使用 128×128 RGB 观测和 Δ end-effector 控制。我们复用与 LIBERO 相同的数据加载器设置，并将记忆长度设置为 16。

真实世界 模型根据任务和数据集大小训练 5 千至 2 万步。一般任务每个任务包含 50-150 个演示，而长时程时间任务每个任务使用 200-300 个演示。一般任务的记忆长度设置为 16，长时程时间任务设置为 256。

C.4 数据增强

训练期间，我们对第三人称 RGB 流应用标准的逐帧增强。增强按固定顺序应用：随机缩放裁剪、随机亮度、随机对比度、随机饱和度和随机色调。裁剪采样图像面积的 90%，宽高比为 1.0，并调整大小为 224×224 。亮度扰动幅度为 0.2，对比度和饱和度在 $[0.8, 1.2]$ 范围内缩放，色调最多偏移 0.05。评估时禁用所有增强。

D 附加评估细节

D.1 SIMPLERENV

评估遵循官方 CogACT 协议 (Li 等人, 2024a)。我们采用相同的评估脚本, 并使用 CogACT 中引入的自适应动作集成策略, 集成系数为 $\alpha = 0.1$, 集成视界在 Bridge 上设为 7, 在 Fractal 上设为 2。对于 Bridge, 模型训练 50k 步, 每 2.5k 步验证一次, 由于扩散模型的去噪目标不能可靠地指示策略质量, 我们报告最佳验证步的成功率。对于 Fractal, 训练运行 80k 步, 每 5k 步验证一次, 评估总共覆盖 336 个变体 (表 19), 我们同样报告最佳验证步的成功率, VM 和 VA 设置分别评估。

由于原始论文仅报告了 CogACT-Base 的每任务成功率, 而未报告 CogACT-Large 的, 我们在自己的设置中重新评估了已发布的 CogACT-Large 检查点, 并报告这些数字以保证公平性。对于 π_0 , 结果取自开源复现 open-pi-zero, 该复现提供了流匹配中均匀和 beta 时间步采样策略的实现。我们按照公开发布的方式报告 float32 精度下的结果。注意, open-pi-zero 未提供 Fractal 视觉聚合设置的数字, 因此这些数据缺失。

D.2 LIBERO

LIBERO (Liu 等人, 2023a) 上的评估在所有五个套件 (Spatial、Object、Goal、Long-10 和 Long-90) 上进行。模型每 1k 步验证一次, 每个任务评估 50 次试验。成功率在最佳验证步报告。与 SimplerEnv 不同, 我们的 LIBERO 实验未使用动作集成策略。

CogACT 的结果使用官方代码库复现以确保公平性。对于 π_0 和 π_0 -FAST, 我们采用已报告的数字, 并注意到这两种方法都利用了额外的腕部摄像头视图和本体感受状态, 而我们的方法仅依赖单一的第三人称 RGB 图像。尽管输入模态存在差异, 我们的方法仍持续超越, 在没有额外传感输入的情况下实现了更强的性能。

D.3 MIKASA-ROBO

对于 Mikasa-Robo (Cherepanov 等人, 2025), 我们每个任务评估 100 个回合。每 1000 个训练步进行一次验证, 并在验证性能最佳的检查点报告成功率。与 LIBERO 中一样, 我们在 Mikasa-Robo 实验中未使用任何动作集成策略。

D.4 真实世界

评估中, 通用任务使用 15-25 次试验, 长时程时序任务使用 10-15 次试验。对于通用任务, 采摘多样水果包含五种变体 (苹果、橙子、香蕉、辣椒、葡萄), 每种评估 5 次试验 (共 25 次)。所有其他通用任务各评估 15 次试验, 我们报告任务级成功率。

对于长时程时序任务, 顺序按压按钮包含三种按钮顺序 (蓝-粉-绿、蓝-绿-粉、绿-蓝-粉), 每种测试 5 次试验。所有其他任务评估 10 次试验, 并采用逐步评分来捕捉部分进展。评分规则如下:

- **顺序按压按钮:** 每按对一个正确按钮得 30 分, 若三个全部正确则额外奖励 10 分。允许宽松匹配 (轻微接触也算作按压)。
- **更换食物:** 抬起并移除初始食物 (30 分), 抓取新食物 (30 分), 并将其放置在盘子上 (30 分), 完全成功额外奖励 10 分。
- **猜测位置:** 抓取盖子 (30 分), 盖住积木 (30 分), 再揭开盖子 (40 分)。
- **清理桌面并计数:** 共五个物体。每个物体, 清理得 10 分, 按下计数器得 10 分。轻微计数错误 (按压不完整或额外按压一次) 得 5 分; 重大错误 (漏计或多次额外按压) 得 0 分。有明确计数意图的空抓取扣 5 分。

- **按顺序拾取放置：**胡萝卜、香蕉和橙子必须按顺序拾取并放置。每个正确步骤得 30 分，完全完成额外奖励 10 分。任何顺序违规将终止本次尝试。
- **清洁餐桌：**共五个物体。每个正确分类到垃圾桶或储物箱得 20 分。放错位置得 10 分，仅提起而未正确放置得 5 分。

E 记忆检索案例研究

为直观展示记忆机制的工作方式，图 10 可视化了在真实世界和仿真任务中检索到的记忆元素及其注意力权重。模型始终关注那些能够解决当前观测中缺失的决策相关歧义的去帧。

在真实世界的更换食物任务中，第一个食物被放到一旁后，当前帧中桌面上有两个食物，仅凭这一观测无法确定接下来应拾取哪一个。因此，MemoryVLA 强烈关注反映近期运动趋势的邻近帧，以及歧义出现前的最后一个决定性帧。在 Mikasa-Robo 仿真基准的触感贝壳游戏任务中，机器人在杯子覆盖之前短暂地看到了立方体的位置。模型始终关注最初的揭示帧，这些帧提供了识别正确杯子的唯一可靠线索。这些结果表明，MemoryVLA 检索了对于消除下一步动作歧义至关重要的有意义时间线索，而非简单地回忆冗余的视觉历史。




图 10：真实世界和仿真任务中记忆检索的案例研究。该图可视化了在真实世界更换食物任务（上）和 Mikasa-Robo 中仿真触感贝壳游戏任务（下）中检索到的记忆元素及其注意力权重。在两种设置下，模型始终关注那些能够解决当前观测中缺失的决策相关歧义的去帧。

F 数据长度统计

表 9 报告了所有任务套件的最大、最小、中位数和平均动作长度，包括 SimplerEnv 评估（Bridge、Fractal）、LIBERO（空间/物体/目标以及 10/90 任务套件），以及真实世界通用任务和时间任务。对于真实世界任务，我们还基于运动幅度阈值（连续帧之间的平移 > 1 厘米或旋转 > 0.4 弧度）提供了过滤后的统计数据，以移除末端执行器运动较小的帧。

表 9：所有仿真（SimplerEnv Bridge/Fractal、LIBERO Spatial/Object/Goal、LIBERO-10/90）和真实世界（General、Temporal）任务套件的动作长度统计。对于真实世界任务，“过滤”版本会移除末端执行器运动可忽略不计的帧（平移 < 1 厘米，旋转 < 0.4 弧度）。

Task Suite	Max	Min	Median	Average
SimplerEnv-Bridge / Fractal	200	80	117	119
LIBERO-Spatial / Object / Goal	270	75	131	130
LIBERO-10 / 90	505	58	144	156
Real-General (Original)	1575	281	575	575
Real-General (Filtered)	213	40	81	84
Real-Temporal (Original)	7704	412	981	1672
Real-Temporal (Filtered)	902	72	236	288

G 附加消融实验

对于记忆长度，它与每个基准的回合长度密切相关。如表 9 所示，SimplerEnv、LIBERO 和我们的真实世界通用任务具有相似的回合长度，而真实世界时序任务即使经过大量帧过滤后仍然显著更长。这自然促使我们为时序任务使用更大的记忆长度。我们进一步在一个具有代表性的真实世界时序任务（Clean Table & Count）上进行了消融实验。如表 10 所示，适中的记忆长度（256）表现最佳。

我们还增加了关于认知令牌数量的消融实验。如表 11 所示，将数量从 1 增加到 4 并没有带来性能提升。也许单个 4096 维的 EOS 令牌已经捕获了足够的语义信息，因此增加更多令牌并不能提供额外的好处。

此外，我们将关于融合类型（表 12）和整合策略（表 13）的消融实验扩展到了 LIBERO-Long-90 和一个真实世界长时程任务。

表 10：针对真实世界和 LIBERO-90 任务的记忆长度附加消融实验。 (a) 真实世界：Clean Table & Count

Memory Length	Success Rate
64	78
256 (Base)	84
512	81

(b) LIBERO-Long-90 任务

Memory Length	Success Rate
8	94.2
16 (Base)	95.6
32	95.6

表 11：认知令牌数量的消融实验。将认知令牌数量从 1 增加到 4 并不能提高性能。单个 4096 维的 EOS 令牌已经提供了足够的语义容量。

Num. Cog Token	Spoon on Towel	Carrot on Plate	Stack Cube	Eggplant in Basket	Avg. Success
1 (Base)	75.0	75.0	37.5	100.0	71.9
4	79.2	66.7	37.5	95.8	69.8

表 12: 针对真实世界与 LIBERO-90 的记忆融合类型附加消融实验。

Fusion Type	Clean Table & Count (Real-World)	LIBERO-Long-90 Tasks
Add	78	93.8
Gate	84	95.6

表 13: 针对真实世界与 LIBERO-90 的记忆整合附加消融实验。

Consolidation Type	Clean Table & Count (Real-World)	LIBERO-Long-90 Tasks
FIFO	76	94.9
Token Merge	84	95.6

表 14 提供了表 6 和表 7 的扩展版本，报告了 SimplerEnv-Bridge 上所有消融设置下每个任务的成功率。灰色行表示默认配置。

表 14: 消融研究细节。我们报告了在 SimplerEnv-Bridge 上改变五个因素时的平均成功率 (%) : (a) 记忆类型, (b) 记忆长度, (c) 记忆检索, (d) 记忆融合, 以及 (e) 记忆整合。灰色行表示默认配置。

Method		Spoon on Towel	Carrot on Plate	Stack Cube	Eggplant in Basket	Avg. Success
(a) Memory Type	Cog. Mem.	70.8	58.3	29.2	95.8	63.5
	Per. Mem.	83.3	54.2	20.8	100.0	64.6
	Both	75.0	75.0	37.5	100.0	71.9
(b) Memory Length	4	79.2	75.0	25.0	91.7	67.7
	16	75.0	75.0	37.5	100.0	71.9
	64	79.2	54.2	37.5	100.0	67.7
(c) Memory Retrieval	w/o Timestep PE	83.3	62.5	50.0	83.3	69.8
	w/ Timestep PE	75.0	75.0	37.5	100.0	71.9
(d) Memory Fusion	Add	75.0	62.5	33.3	100.0	67.7
	Gate	75.0	75.0	37.5	100.0	71.9
(e) Memory Update	FIFO	66.7	66.7	33.3	100.0	66.7
	Token Merge	75.0	75.0	37.5	100.0	71.9

H 推理效率

如表 15 所示, 在两种常用 GPU (RTX 4090 和 HGX H20) 上, 比较了本文方法与基线的延迟、吞吐量和 GPU 内存测量结果。以下结果为 bfloat16 精度下 300 次运行的平均值。

本文方法在 RTX 4090 上实现了 0.194 秒的延迟和 82.5 赫兹的吞吐量, 与基线相比仅增加了 3.6% 的开销。内存使用量为 16.6GB, 仅比基线多 0.8GB。这些结果表明, 记忆模块是轻量级的, 在推理过程中仅引入可忽略的额外成本。

开销保持较小是因为记忆模块被刻意设计为轻量级: 每个认知记忆条目由单个认知令牌表示, 感知记忆通过感知压缩模块压缩至 256 个通道, 并且记忆整合步骤持续合并冗余条目。这些设计共同使检索到的记忆大小和交叉注意力成本保持最小, 从而在推理过程中产生可忽略的额外延迟和内存使用。

表 15：推理效率比较。延迟、吞吐量和 GPU 内存是在 bfloat16 下、动作块长度设为 16、在 RTX 4090 和 HGX H20 GPU 上运行 300 次测量的。与基线相比，MemoryVLA 仅引入很小的开销。

Model	Latency (RTX 4090)	Throughput (RTX 4090)	Latency (HGX H20)	Throughput (HGX H20)	Memory
Baseline	0.187 s	85.6 Hz	0.236 s	67.8 Hz	15.8 GB
MemoryVLA	0.194 s	82.5 Hz	0.246 s	65.0 Hz	16.6 GB

I 零样本任务泛化

除了视觉分布外测试，我们还增加了任务泛化实验，以评估在未见任务类别上的零样本性能。如表 16 所示，我们使用 Apple To Basket 作为基础任务，并在三个未见任务上进行测试：Eggplant To Basket、Blush To Basket 和 Apple To Plate。如下表所示，我们的方法实现了良好的零样本任务泛化。

表 16：零样本任务泛化结果。Apple To Basket 被用作基础任务，评估在三个未见任务类别上进行。

Model	Apple To Basket (Base Task)	Eggplant To Basket (OOD Task)	Blush To Basket (OOD Task)	Apple To Plate (OOD Task)	Avg. Success (OOD Task)
MemoryVLA	4 / 5	3 / 5	2 / 5	2 / 5	0.47

J 与时间上下文 VLA 基线比较

如表 17 所示，我们为每个基准添加了时间上下文基线，包括 Mikasa-Robo（Cherepanov 等人，2025）、LIBERO（Liu 等人，2023a）和 SimplerEnv（Li 等人，2024b），以提供公平全面的比较。

在 Mikasa-Robo 基准中，这是一个依赖记忆的操作基准，官方发布中没有提供时间上下文 VLA 基线。为了确保公平比较，我们因此复现了 CronusVLA（Li 等人，2025a），这是一个同时期的强 VLA 模型，通过滑动窗口模块聚合多帧 VLM 特征来显式利用历史信息。这为 Mikasa-Robo 提供了一个时间上下文基线，而 MemoryVLA 在所有任务上显著优于它。

对于 LIBERO 基准，我们纳入了先前工作中常用的主要时间上下文 VLA 基线，包括 TTF-VLA（Liu 等人，2025a）、TraceVLA（Zheng 等人，2024b）、4D-VLA（Zhang 等人，2025a）、CronusVLA（Li 等人，2025a）和 MAP-VLA（Li 等人，2025b）。这些方法代表了在 LIBERO 上报告结果的最强公开可用的时间上下文 VLA 模型。MemoryVLA 获得了比这些基线更高的平均成功率。

对于 SimplerEnv 基准，我们纳入了先前工作中报告的时序上下文 VLA 基线，包括 TraceVLA（Zheng 等，2024b）、RoboVLMs（Liu 等，2025b）和 CronusVLA（Li 等，2025a）。这些方法引入了显式的时序建模，而 MemoryVLA 在这些基线上取得了更高的成功率。

K 任务细节

为了确保在仿真和真实世界环境中进行全面评估，我们总结了每个基准的任务设计。我们提供了任务模板、变化类型以及每个任务的变化数量，以阐明评估的多样性和难度。

表 17: 跨不同基准与时序上下文 VLA 方法的比较。 MemoryVLA 在记忆聚焦基准和通用操作基准 (包括 Mikasa-Robo、SimplerEnv 和 LIBERO) 上均优于时序上下文 VLA 基线。(a) SimplerEnv 基准

Method	Spoon on Towel	Carrot on Plate	Stack Cube	Eggplant in Basket	Avg. Success
TraceVLA (Zheng et al., 2024b)	12.5	16.6	16.6	65.0	27.7
RoboVLMs (Liu et al., 2025b)	45.8	20.8	4.2	79.2	37.5
CronusVLA (Li et al., 2025a)	66.7	54.2	20.8	100.0	60.4
MemoryVLA (Ours)	75.0	75.0	37.5	100.0	71.9

(b) LIBERO Benchmark

Method	Spatial	Object	Goal	Long-10	Avg. Success
TTF-VLA (Liu et al., 2025a)	73.0	84.0	81.0	58.0	74.0
TraceVLA (Zheng et al., 2024b)	84.6	85.2	75.1	54.1	74.8
4D-VLA (Zhang et al., 2025a)	88.9	95.2	90.9	79.1	88.6
CronusVLA (Li et al., 2025a)	93.8	92.8	95.6	86.5	92.2
MAP-VLA (Li et al., 2025b)	96.3	98.4	95.4	83.4	93.4
MemoryVLA (Ours)	98.4	98.4	96.4	93.4	96.7

(c) Mikasa-Robo Benchmark

Model	Shell Game Touch	Intercept Medium	Remb. Color3	Remb. Color5	Remb. Color9	Avg. Success
CronusVLA (Li et al., 2025a)	32	5	31	13	9	18.0
MemoryVLA (Ours)	88	24	44	30	20	41.2

表 18: 真实世界任务细节。我们列出了每个任务的指令模板、变化数量以及相应的变化类型。

Task Name	Language Instruction Template	# Variations	Variation Type
Seq Push Buttons	“Push the {color 1, color 2, and color 3} buttons in sequence”	3	Button color order
Change Food	“Move food off the plate, then put the other food on it”	2	Food object type in plate
Guess Where	“Place a cover over the block, then remove the cover”	1	–
Clean Table & Count	“Clean the table item by item, and push the button after each item cleaned”	1	–
Pick Place Order	“Pick up carrot, banana and orange in order and place them in the basket”	7	Background, distractors, lighting, object, container, occlusion
Clean Restaurant Table	“Place all trash into the trash bin and all tableware into the storage bin”	7	Background, distractors, lighting, object, container, occlusion
Insert Circle	“Insert the circle on the square”	1	–
Egg In Pan	“Put the egg into the pan”	1	–
Egg In Oven	“Put the egg into the oven”	1	–
Stack Cup	“Stack the green cup on the other cup”	1	–
Stack Block	“Stack the yellow block on the red block”	1	–
Pick Diverse Fruit	“Pick up {fruit} and place it in the basket”	5	Fruit category

表 19: 简化环境 (SimplerEnv) 任务详情。 *VM* = 视觉匹配, *VA* = 变体聚合。对于分形 (Fractal) 任务, 我们分别报告视觉匹配和变体聚合; 所有桥接 (Bridge) 任务使用单一设置。

	Task Name	Language Instruction Template	# Variations	Variation Type
<i>Bridge</i>	Spoon On Tower	“Put the spoon on the tower”	1	–
	Carrot On Plate	“Put the carrot on the plate”	1	–
	Stack Cube	“Stack the green cube on the yellow cube”	1	–
	Eggplant In Basket	“Put the eggplant in the basket”	1	–
<i>Fractal</i>	Pick Coke Can	“Pick up the coke can”	VM: 12 VA: 33	VM: can position $\times$ 3, URDF $\times$ 4. VA: base, backgrounds $\times$ 2, lighting $\times$ 2, textures $\times$ 2, camera views $\times$ 2, distractors $\times$ 2, can position $\times$ 3.
	Move Near	“Move the {object} near the {reference}”	VM: 4 VA: 10	VM: URDF $\times$ 4. VA: base, distractors, backgrounds $\times$ 2, lighting $\times$ 2, textures $\times$ 2, camera views $\times$ 2.
	Open/Close Drawer	“Open/close the {level} drawer”	VM: 216 VA: 42	VM: env {open/closed} $\times$ {top, middle, bottom}; URDF $\times$ 4; initial pose $\times$ 9. VA: base, backgrounds $\times$ 2, lighting $\times$ 2, cabinet styles $\times$ 2, env $\times$ 6.
	Put In Drawer	“Put the {object} into the {level} drawer”	VM: 12 VA: 7	VM: URDF $\times$ 4; initial pose $\times$ 3. VA: base, backgrounds $\times$ 2, lighting $\times$ 2, cabinet styles $\times$ 2.

K.1 真实世界任务

表 18 展示了用于真实世界评估的 12 项任务, 分为通用任务和长时程时序任务两个套件。

通用任务。插入圆环: 将圆环插入竖直柱体, 要求精确定位与插入。鸡蛋入锅: 将鸡蛋放入浅煎锅, 测试抓取稳定性与轻柔放置。鸡蛋入烤箱: 将鸡蛋放入小型烤箱容器, 相比煎锅涉及更受限的放置。叠杯子: 将一个塑料杯叠放在另一个之上, 评估竖直对齐与平衡。叠积木: 将黄色积木叠放在红色积木之上, 侧重于精确的空间对齐。拾取多样水果: 从桌面上十多种不同水果中拾取指定水果并放入篮子, 测试语义理解、视觉多样性及指令遵循。

长时程时序任务。顺序按按钮: 按指定颜色顺序按下三个按钮, 强调有序记忆及抗时序混淆能力。更换食物: 从盘中移除一种食物并替换为另一种, 要求多步排序及正确的时序顺序。猜位置: 用容器盖住积木, 稍后揭开, 测试可逆动作及随时间的一致追踪。清理桌面并计数: 逐一清理桌面物品, 每次移除后按下计数按钮, 将操作与显式进度监控相结合。按序拾取放置: 按固定顺序拾取胡萝卜、香蕉和橙子并放入篮子, 在时序依赖下强制序列敏感规划。清理餐厅桌面: 按类别整理桌面物品, 将垃圾放入垃圾桶, 餐具放入储物箱, 代表具有语义推理和复杂多阶段排序的长时程任务。

K.2 简化环境任务

表 19 总结了 SimplerEnv 基准中的任务, 该基准包含两个套件: Bridge 和 Fractal。

表 20: LIBERO 任务详情。我们列出了语言指令模板以及每个套件的任务总数。

Suite	Language Instruction Templates	#Tasks
Spatial	pick up the <i>OBJ SPATIAL_REL</i> and place it on the <i>TARGET</i>	10
Object	pick up the <i>FOOD</i> and place it in the <i>CONTAINER</i>	10
Goal	open/close the <i>CONTAINER</i> open the <i>DRAWER</i> and put the <i>OBJ</i> inside put the <i>OBJ</i> on/in the <i>TARGET</i> push the <i>OBJ</i> to the <i>POSITION</i> of the <i>TARGET</i> turn on the <i>APPLIANCE</i>	10
Long-10	put both <i>OBJ1</i> and <i>OBJ2</i> in the <i>CONTAINER</i> turn on the <i>APPLIANCE</i> and put the <i>OBJ</i> on it put the <i>OBJ</i> in the <i>CONTAINER/APPLIANCE</i> and close it place <i>OBJ1</i> on <i>TARGET1</i> and <i>OBJ2</i> on <i>TARGET2</i> /at <i>REL</i> of <i>TARGET2</i> pick up the <i>OBJ</i> and place it in the caddy <i>COMPARTMENT</i>	10
Long-90	打开/关闭容器 / 电器 [并将物体放入其中；可选地与另一个打开/关闭操作组合] 打开容器并将物体放入其中 将物体放置/放入/放在目标上/下或相对位置 将物体 1 堆叠在物体 2 上 [可选地将它们放入容器中] 拿起物体并将其放入容器（篮子/托盘）中 将杯子放在左侧/右侧的盘子或书架上/下 打开/关闭电器 [可选地将物体放在上面]	90

Bridge 套件包含 WidowX 机器人上的四个桌面操作任务：毛巾上的勺子、盘子上的胡萝卜、堆叠方块和篮子里的茄子。每个任务都配有一个单一的语言模板，侧重于物体放置和堆叠原语。

Fractal 套件基于 RT-1 数据和 Google 机器人构建，定义了四个任务：拿起可乐罐、移近、打开/关闭抽屉和放入抽屉。每个任务在两种协议下进行评估。视觉匹配（VM）通过改变物体位置和 URDF 来模拟真实世界设置，确保仿真与部署之间的对齐。视觉聚合（VA）引入了显著的视觉扰动，包括背景、纹理、光照、干扰物和相机视角的变化，以对鲁棒性和泛化能力进行压力测试。VM 和 VA 共同产生了 336 个变体，生成了 2352 个评估试验。

K.3 LIBERO 任务

表 20 概述了 LIBERO 基准的五套套件：Spatial、Object、Goal、Long-10 和 Long-90。LIBERO-Spatial 包含需要将同一物体放置在不同目标位置的任务。LIBERO-Object 侧重于在固定场景布局中处理多样化的物体。LIBERO-Goal 包含异构操作，例如打开容器、放置物体或打开电器，这些操作在不变的环境中进行。Long-10 引入了十个扩展任务，需要在不同场景中完成多个子目标，而 Long-90 将该设置扩展到九十多个任务，提供了一个更具挑战性的基准。总体而言，LIBERO 在仿真中使用 Franka 机器人提供了 130 个任务。

L 现实世界任务中记忆依赖性的可视化

为阐明为何现实世界的时间性任务需要记忆，图 11 突出了若干任务中的关键时刻，在这些时刻，正确的动作依赖于过去的信息而非当前的观测。图 12 进一步提供了更换食物任务中的一个逐步示例，展示了一个案例，其中仅凭单帧图像无法确定下一步动作，必须通过回忆

先前的步骤才能解决。这些示例表明，在真实机器人任务上取得的更大收益源于其固有的记忆依赖特性。




图 11：三个现实世界机器人任务中依赖记忆的方面。清洁桌面并计数、猜测位置和更换食物任务都需要追踪过去的事件以做出正确决策，凸显了它们固有的时间依赖性。




图 12：依赖记忆行为的逐步示例。来自现实世界更换食物任务的一个序列，展示了一个案例，其中若不回忆先前的步骤，下一步动作将变得模糊不清。

M 定性结果

M.1 现实世界评估

我们提供定性示例以补充定量评估。图 13 和图 14 展示了现实世界中长时程时间性任务的执行过程。图 15 展示了现实世界中的通用操作任务。




图 13: MemoryVLA 在真实世界长时程时序任务上的定性结果（一）。代表性示例包括顺序按钮、更换食物和猜位置任务。



图 14: MemoryVLA 在真实世界长时程时序任务上的定性结果 (二)。代表性示例包括擦桌子并计数、按顺序取放物品和清理餐厅桌子任务。

M.2 仿真评估

仿真环境中的结果如图 16 和图 17 所示，涵盖 Bridge 和 Fractal 套件。最后，图 18 提供了 LIBERO 上的代表性轨迹，覆盖全部五个套件。




图 15: MemoryVLA 在真实世界通用任务上的定性结果。代表性示例包括插入圆形、鸡蛋入锅、鸡蛋入烤箱、叠杯子、叠积木和抓取多样水果任务。




图 16: MemoryVLA 在 SimplerEnv-Bridge 任务上的定性结果。代表性示例包括勺子放塔上、胡萝卜放盘上、叠方块和茄子放篮中任务。




图 17: MemoryVLA 在 SimplerEnv-Fractal 任务上的定性结果。代表性示例包括拿可乐罐、移近、开关抽屉和放入抽屉任务。




图 18: MemoryVLA 在 LIBERO 任务上的定性结果。代表性示例包括来自空间、物体、目标、长时程-10 和长时程-90 套件的任务。