

# 存在但未被记住：审计冻结的视觉-语言-动作模型如何编码、部署和引导视觉历史

Chih-Ting Liao\* Xin Cao  
University of New South Wales

## 摘要

一个冻结的视觉-语言-动作模型（VLA）在每一步都被给予最近的过去，然而文献急于添加记忆，却没有首先询问模型已经如何处理它所拥有的历史。我们在时间轴上提供了这一缺失的诊断：策略如何跨时间步编码和部署观测。这正是此前唯一一项跨架构 VLA 机制研究所固定的轴，该研究在单帧内定位视觉-语言融合轴（视觉占主导，与架构无关）；我们定位正交的时间坐标，并得出相反的结构性质结论。通过分层线性探测和交换干预，我们发现了一个三层分离。（i）过去帧的内容在每个深度都可线性解码。（ii）然而，历史所独有的、超出当前帧的信息本质上为零，这一上限是在三个模型和两种架构家族的 81 种配置探测扫描中确立的：存储的历史是当前帧的冗余副本。

（iii）历史仅在当前帧几乎完全丢失时才被因果地部署到动作中，并且读出在网络中间层就切断了其对历史的依赖，这一点由第二个正交干预所证实。跨架构，编码是相同的（两者中均为  $A_4 \approx 0$ ），但部署机制发生了翻转：在相同的遮挡下，一个模型对历史的依赖上升（回退），而另一个模型则下降（持续使用）。我们将这四项测量构建为一个可复用的、无需训练的时序部署审计（算法 1），其注入部分增加了第三个因果的、架构条件化的轴：在回退机制中，重新提供历史是内容盲目的（它既不修复遮挡也不消除歧义），从因果上证实了冗余性；在持续使用机制中，同样的注入将动作引导向提供者。因此，历史是否可引导取决于部署机制，而非架构是否编码历史：一个单一的回退与持续使用轴组织了所有三个维度——编码了什么、何时部署、以及是否可被引导。VLA 并没有忘记过去；它们从未被构建为将过去视为与现在分离。这一诊断为记忆增强文献提供了一个具体的教训：注入过去所独有的信息，而不是更多的过去信息。

## 1 引言

越来越多的研究为视觉-语言-动作模型（VLA）配备了显式记忆模块、检索缓冲区、循环潜变量、轨迹叠加、学习摘要，并设立基准来检验增强后的策略能否利用过去信息 [15, 19, 30, 32, 34, 43]。据我们所知，所有这些努力都预设了一个尚未有人完成的诊断：在冻结的多帧策略上，过去是作为独立记忆存储，还是仅仅作为当前的冗余副本？它是否曾被因果性地读入动作？没有这一基线，添加记忆便是在缺乏明确故障特征的情况下寻找解决方案。答案取决于架构，且与直觉相悖：在相同的遮挡条件下，一种策略更依赖历史，而另一种则更少依赖；注入的历史能否引导动作也随之反转，尽管两者对过去的编码完全相同。

\* 通讯作者及项目负责人。mill.liao@unsw.edu.au

我们提供了时间轴上缺失的诊断。这有意与最接近的机制性工作保持正交。Grant 等人 [12] 是首个跨架构的 VLA 机制研究，定位了驱动动作的模式，发现视觉主导语言，且与架构无关，这是一个关于单一时间步内空间的问题。我们则探究跨时间步的时间历史如何被编码和部署。两者是同一机制图景的互补部分；下文将展示，Grant 的融合轴与架构无关，而时间轴则依赖于架构。

我们的方法在冻结的开环策略上包含两个部分：线性解码探针，用于询问过去帧的内容是否存在于表征中；以及交换干预，将供体的历史激活移植过来，并测量动作的相应偏移，这是对因果部署的直接、逐层检验。在小型、冻结、哈希刺激集上进行开环评估是有意为之：它使得在每个块上进行交换成为可能，而这种定位是闭环推演无法提供的。证据单元是因果干预下的受控刺激对，而非行为片段，我们依赖统计严谨性（多种子、置换、自助法）而非片段数量。

我们报告了一种三层解离，概括于论文标题中。当前：过去帧内容在每个深度都可线性解码，在网络中部达到峰值。冗余：历史独有的信息，即  $t-1$  中未包含在  $t$  中的部分，在 81 种配置的探针扫描中最高达到  $\approx 0.02$ ，并且在三个模型和两种架构家族（ $A_4/A_1 \lesssim 0.05$ ）中均为  $\approx 0$ ，因此可解码的历史几乎完全与当前冗余，这从机制上回答了为何历史未被部署：几乎没有独特内容可供部署。未被记住（回退部署）：历史仅在当前帧几乎完全丢失时才被因果部署（仅在完全遮挡时差距显著；较轻的退化不显著），且动作读出在网络中部之后不再读取历史。跨架构编码相同，但部署和内容可操控性随回退与常态机制发生符号翻转，这是论文的核心意外发现。

**贡献。**（1）首次对视觉-语言-动作模型记忆的时间轴进行机制研究，提出历史独有解码度量（ $A_4$ ），将保留的过去信息与当前帧冗余分离，这是对 Grant 等人 [12] 融合轴研究的时间维度补充。（2）一种无需训练、可复用的时间部署审计方法（算法 1），可剖析任何冻结的视觉-语言-动作模型：过去是否存在于当前（ $A_1$ ）、是否独有（ $A_4$ ）、部署位置及程度（ $\Delta_\ell$ ，截止点  $\ell^*$ ）、其机制（ $\sigma$ ），以及注入是否携带历史内容。（3）一种架构条件可操控性定律：跨家族编码相同（两者均为  $A_4 \approx 0$ ），但部署方向和内容可操控性随回退与常态机制发生符号翻转，通过注入因果确立（回退机制中无效，常态机制中可操控）。设计启示如下：有用的记忆必须添加过去独有的信息，并在我们定位的网络中部截止点之前注入。

## 2 相关工作

**视觉-语言-动作模型的机制可解释性。**最接近的工作定位了帧内模式轴：Grant 等人 [12] 表明，在多种架构中，视觉在驱动动作方面主导语言，且与架构无关，时间轴保持固定。其他工作操控帧内运动特征 [8, 13] 或解码前向世界模型 [24]；但均未涉及过去帧的因果部署。我们定位了正交的时间轴，并得出相反的结构结论：部署依赖于架构，因此这两条研究线索共同表明，视觉-语言-动作（VLA）机制在模式轴上共享，但在时间轴上存在分歧（表 1）。

**基准与记忆。**长时程操作基准如 LIBERO [22] 和 SimplerEnv [21] 评估策略是否能在行为层面解决依赖历史的任务；它们并未定位原生策略是否或在何处读取过去信息。He 等人 [14] 补充表明，扩散策略常常记忆训练动作，这是学习映射依赖存储内容的另一种含义。我们提供了上游的机制性解释：在冻结的多帧策略上，关于过去的信息保留了什么，以及这些信息是否被因果部署。

**记忆增强方法。**大量工作通过添加记忆来提升性能 [15, 30, 32, 34, 43]。这些方法是我们的动机，而非竞争对手：它们预设原生 VLA 对历史的利用不足，而我们的诊断既证实了这一点，又将其细化为可操作的教训（添加独特信息，而非更多历史）。

**表 1：定位：VLA × 机制可解释性。**先前工作定位帧内模态轴、操控帧内运动特征，或在缺乏诊断的情况下添加记忆；我们定位正交的时间轴，并刻画历史如何被编码、部署和操控，得出依赖于架构的结论。

| Work                     | Axis                                | Method                                    | Scope                 | Finding                                                                                   |
|--------------------------|-------------------------------------|-------------------------------------------|-----------------------|-------------------------------------------------------------------------------------------|
| Grant 2026               | modality fusion (within-frame)      | / SAE, injection, probes                  | 6 models, closed-loop | vision dominates, arch.-independent                                                       |
| Häon 2025                | motion features (within-frame)      | activation steering                       | 2 models, real robot  | zero-shot steering behavioral                                                             |
| Buurmeijer 2026          | feature obs./control (within-frame) | probe + linear interv.                    | closed-loop           | feature observability/control                                                             |
| Memory VLAs <sup>†</sup> | add memory (no diagnosis)           | new trained modules                       | closed-loop           | augmented policy can use past                                                             |
| <b>Ours</b>              | <b>time / history across frames</b> | decode, change, knockout, inject (frozen) | 2 regimes, open-loop  | present-but-redundant, fallback-deployed (L6); arch.-conditional; standing-only steerable |

<sup>†</sup> MemoryVLA, MemER, TraceVLA, ContextVLA, CronusVLA [15, 19, 30, 32, 43]。

**可解释性** 工具。我们基于线性探测 [1, 2]、因果中介与交换/激活修补干预 [11, 23, 36, 38]、字典学习与稀疏自编码器分析 [6, 10, 33]、线性表征与透镜文献 [3, 27] 以及激活引导 [35]，在此应用于此前未被考察的动作策略的时间基底。并行的视觉-语言-动作可解释性工作观察并控制视觉-语言-动作模型中的特征 [8]，同样是在时间步内轴上。

### 3 时间部署审计

#### 3.1 设置

**模型与机制。**基于预训练视觉-语言骨干的视觉-语言-动作模型现已涵盖离散动作标记策略 [7, 17, 28]、连续回归与扩散/流动作头 [5, 9, 18, 20, 29] 以及高效开放模型 [4, 31]，并在大规模跨具身语料上训练 [16, 26]。我们所有实验均在冻结的公开检查点上运行，以开环方式运行（我们从（图像，指令）中读取动作分布，不进行环境推演），在单个消费级图形处理器上完成，零训练。我们的主要模型是八爪鱼-小（Octo-Small, 27M, 两帧窗口，扩散动作头）[25]；我们加入八爪鱼-基（Octo-Base, 93M）以考察规模效应，并加入克洛诺斯视觉-语言-动作-0.5B（CronusVLA-0.5B, 千问级骨干，扩散变换器头，历史以逐帧认知特征携带）[19] 作为第二种架构家族。刺激为分布内的桥接（Bridge）[37] 元组（观测  $t_{-1}$ ，观测  $t$ ，指令）。

**马尔可夫与非马尔可夫。**该策略是一个窗口为 2 的条件  $\pi(a_t | o_{t-1}, o_t, c)$ ，基于前一观测与当前观测  $o_{t-1}, o_t$  及指令  $c$ ，其中  $s_t$  为底层场景状态。行为克隆演示近似马尔可夫：专家动作几乎仅依赖于当前状态， $a_t^* \approx f(s_t)$ ，so  $o_t$  是近似充分统计量，历史  $o_{t-1}$  是冗余的。当  $o_t$  不足以确定  $a_t^*$  且  $o_{t-1}$  携带无法从  $o_t$  (i.e.  $a_t^* = f(s_t, s_{t-1})$ ) 恢复的决策相关信息（其  $s_{t-1}$  依赖无法从  $o_t$  重建）时，该步骤为非马尔可夫。我们通过仅破坏当前帧来诱导受控的非马尔可夫性：马尔可夫条件保持  $o_t$  完好（当前充分，历史冗余），而遮挡黑色破坏  $o_t$ （迫使任何胜任的策略依赖  $o_{t-1}$ ）。部署差距  $\Delta_\ell$ （式 4）正是由该诱导的非马尔可夫性所创造的对历史的额外因果依赖，因此即使在此处也未能部署历史的策略在构造上便将过去视为冗余。

**冻结刺激集。**我们构建了一个冻结的、内容哈希的 250 个匹配对集合（哈希 bb4992ac8bbc6803, 213 条唯一指令），在任何分析之前记录，以防止事后筛选。指令在每个匹配单元内保持固定，因此动作的任何变化都归因于历史而非指令。

**读出。**动作是  $N$  个扩散样本预测的 7 自由度动作块的平均值，通过策略的数据集统计信息进行反归一化；我们报告样本离散度以及平均值。我们写作  $\Delta_{\text{action}}(A, B)$  表示两个反归一化动作之间的平均每维  $L_2$  距离。两个派生量锚定了本研究：历史解码@ $\ell$ （从第  $\ell$  层历史标记激活中对  $t-1$  场景的岭回归探针  $R^2$ ）和历史贡献@ $\ell$ （来自第  $\ell$  层交换的噪声校正动作偏移，归一化使得 0 表示无部署，1 表示完全部署）。在遮挡下与干净条件下该贡献之间的差距是我们全程跟踪的部署信号；在解码高的层上出现大的正差距是存在但未被记住的标志。

### 3.2 测量与审计程序

**解码分支：什么存在与什么是独特的。**我们区分两个问题：过去是否存在于表示中，以及其中是否有任何部分对过去是独特的？设  $\phi^{(\ell)}(x)$  为第  $\ell$  层的池化历史标记激活， $s_{t-1}$  为前一帧场景状态。岭回归探针  $g_\ell$  将  $s_{t-1}$  回归到  $\phi^{(\ell)}$  上，我们报告其交叉验证的决定系数，

$$A_1(\ell) = R^2(g_\ell(\phi^{(\ell)}), s_{t-1}), \quad (1)$$

这回答了存在。为了询问什么是独特的，我们将目标投影到当前帧已经解释的部分（ $\hat{s}_{t-1|t}$ ，来自当前帧探针对于  $s_{t-1}$  的线性读出），并仅解码残差，

$$A_4(\ell) = R^2(g_\ell(\phi^{(\ell)}), s_{t-1} - \hat{s}_{t-1|t}). \quad (2)$$

$A_4$  是承载关键的量：大的  $A_1$  且  $A_4 \approx 0$  意味着历史标记仅仅重新编码了当前。我们扫描 81 种探针配置（层、池化、目标、正则化）以建立  $A_4$  的上限，并使用打乱标签的对照来排除过拟合。

**部署阶段：噪声校正交换。**表征中的存在并不一定意味着在行动中被使用；部署分支直接测量使用情况。在第  $\ell$  层，我们用捐赠情节  $d$  的历史标记激活覆盖  $x$  的历史标记激活，并读取扩散平均动作  $a(\cdot)$  的变化，

$$C_\ell^{\text{raw}}(x, d) = \|a(\text{patch}_\ell(x; d)) - a(x)\|. \quad (3)$$

由于扩散头具有随机性，自交换（ $d=x$ ，其真实贡献为零）会留下非零的零基底  $\approx 0.15$ （图 2）；

$C_\ell^{\text{raw}} - C_\ell^{\text{null}}$  本文将其减去以获得修正后的贡献  $C_\ell =$ 。条件信号是当前帧退化条件与干净马尔可夫条件之间的部署差距，

$$\Delta_\ell = C_\ell^{\text{occ.black}} - C_\ell^{\text{markov}}, \quad (4)$$

报告了配对自助法 95% 置信区间。当  $\Delta_\ell$  排除零（早期频段）时，历史被部署，且其依赖性在  $\Delta_\ell \rightarrow 0$  处被切断：解离恰好  $A_1$  高

**退化阶梯。**我们并非采用单一遮挡，而是将部署解读为在分级阶梯上的剂量-反应关系：部分遮挡（对象区域在  $t$  中被隐藏但在  $t-1$  中可见）、重度遮挡、高斯模糊以及全黑遮挡（当前帧完全变黑，迫使依赖  $t-1$ ）。A 时间乱序单元（帧顺序交换）作为顺序盲对照。该阶梯使我们能够区分真正的条件部署与绑定于某一极端刺激的工件。

**第二，正交方法：注意力剔除。**为了在不依赖表征互换的情况下确认部署频段，我们额外屏蔽了读出令牌在每一层对历史令牌键的注意力，并测量由此产生的动作偏移。这是一种机制上截然不同的干预（移除访问权限而非替换内容）；两种方法在部署频段上的一致性有力地证明，该定位并非任一方法的工件。

**统计协议。**标题效应通过三种方式加以强化：配对自助法置信区间、多种子符号一致性（5 个种子），以及对合并的逐对差距进行符号翻转置换检验（5000 次重采样）。仅当三者一致时，我们才将某一效应报告为已部署。

**为何采用开环。**开环读取是实现分层可互换性的关键：我们能够在每个块进行干预并观察动作偏移，这是一种因果定位，而闭环展开无法提供。代价是证据单位是受控配对而非完整回合；我们

**Algorithm 1** Temporal-Deployment Audit (TDA) of a frozen VLA

---

**Require:** frozen VLA  $\pi$ ; matched pairs  $\mathcal{S} = \{(o_{t-1}, o_t, \text{instr})\}$ ; layers  $\mathcal{L}$ ; occlusion occ  
**Ensure:** profile  $(A_1, A_4, \{\Delta_\ell\}, \ell^*, \sigma, \text{CONTENT-BEARING})$

- 1: **for**  $\ell \in \mathcal{L}$  **do**
- 2:    $A_1(\ell), A_4(\ell) \leftarrow R^2$  of  $\phi^{(\ell)} \rightarrow s_{t-1}$  and  $\rightarrow (s_{t-1} - \hat{s}_{t-1|t})$  ▷ present / unique (Eq. 1–2)
- 3:    $\Delta_\ell \leftarrow (C^{\text{raw}} - C^{\text{null}})_\ell^{\text{occ}} - (C^{\text{raw}} - C^{\text{null}})_\ell^{\text{markov}}$ , paired CI ▷ deploy gap (Eq. 3–4)
- 4:    $\ell^* \leftarrow$  first  $\ell$  with  $\Delta_\ell$  CI  $\ni 0$ ;  $\sigma \leftarrow$  sign  $\Delta_\ell$  at early band ▷ cutoff; fallback (+) / standing (–)
- 5: inject own clean  $o_{t-1}$  at  $\ell < \ell^*$  under occ;  $r \leftarrow \|a_{\text{occ}} - a_{\text{full}}\| - \|a_{\text{inj}} - a_{\text{full}}\|$  ▷ injectability gate
- 6: **CONTENT-BEARING**  $\leftarrow (r > 0, \text{CI} \ni 0)$ ; **return**  $(A_1, A_4, \{\Delta_\ell\}, \ell^*, \sigma, \text{CONTENT-BEARING})$

---

通过多种子重复、置换检验和自助法区间加以补偿，并将规模视为与定位声明正交。

**综合：时间部署审计。** 这四项目测量组合成一个可复用、无需训练的程序（算法 1），该程序接受任何冻结的多帧视觉语言动作模型和匹配的刺激集，并返回历史部署画像：过去是否存在（ $A_1$ ），其中是否有任何部分是独特的（ $A_4$ ），在何处以及是否被部署（ $\Delta_\ell$  及截止点  $\ell^*$ ），部署机制（ $\sigma$ ：回退与常驻），以及截止点前的通路是否确实将注入的历史传递到动作中（可注入性门控，附录 G）。该审计无需权重更新，可在单块 GPU 上开环运行；我们下文使用它来剖析三个模型，并对冗余结果进行因果验证。

## 4 结果

### 4.1 存在，但只是当前帧的冗余副本

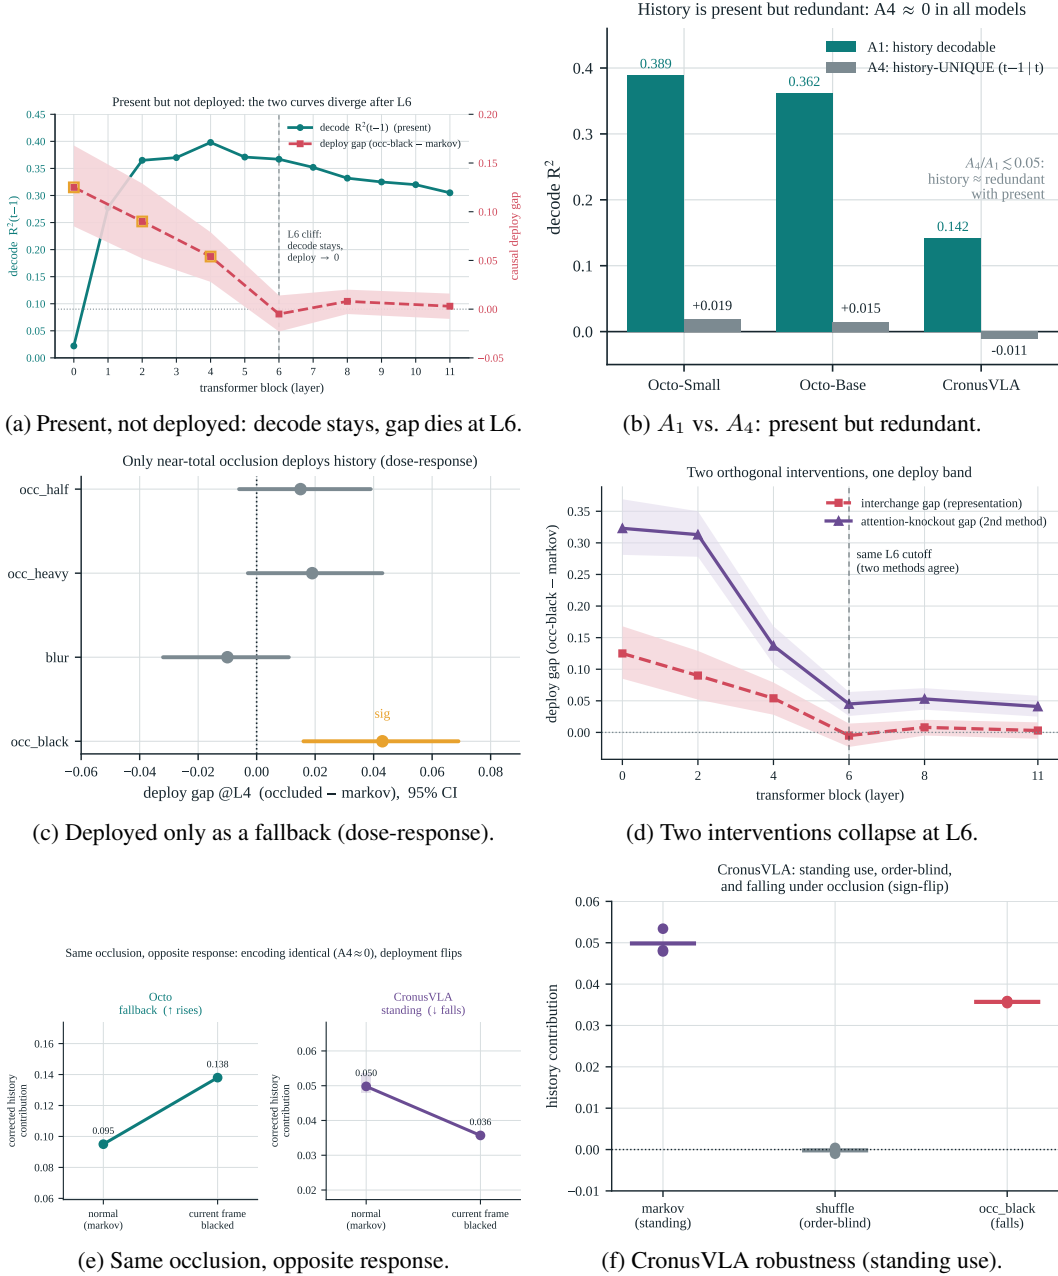
过去帧内容可从 Octo-Small 线性解码，在 L4 处达到峰值  $R^2 = 0.398$ ，从输入边缘（L0）的  $\approx 0$  上升，并在最终块之前保持在 0.30 以上（图 1a 和图 3a，青色）。仅凭当前标准，模型在每个深度（除第一层外）都明确记录了历史；解码峰值（L4）与锚定因果部署间隙的层（第 4.2 节）重合，因此历史在某一层最可解码且最被部署，之后解码持续但部署被切断。与仅当前帧基线的差距很小（每层 +0.014 至 +0.025），这已经暗示了我们接下来量化的冗余性。

**但冗余：历史几乎不携带独特信息。** 可解码的历史绝大多数是当前帧的副本。历史独特量  $A_4$  在 Octo-Small 的所有 81 个探针配置中最高仅为 +0.019，这不是一个脆弱的单一数字，而是一个上限，比原始解码（ $A_4/A_1 = 0.019/0.389 \approx 0.05$ ）低一个数量级：可解码的历史几乎完全与当前帧冗余。<sup>1</sup> 同样的结论适用于不同模型和架构： $A_4 = +0.019$ （Octo-Small）、+0.015（Octo-Base）和 -0.011（CronusVLA），分别对应  $A_1 = 0.389/0.362/0.142$ （图 1b，表 3）；对于 CronusVLA，其历史存在于不同的表征位置（逐帧认知特征）， $A_1$  需谨慎解读， $A_4$  是可比较的量（附录 E）。打乱标签的对照实验返回  $\approx 0$ ，确认探针是健康的而非过拟合。这预先排除了一个自然的反对意见，即 0.39 的解码仅仅反映了  $t-1 \approx t$ ：是的，我们精确测量了有多少（几乎全部）。

**冗余声明的范围。** 由于  $A_4$ （公式 2）对原始  $t-1$  帧进行残差化，这是唯一具有可控真实值的历史量，我们无法排除策略存储了一些抽象历史（任务进度、意图），而这些历史不是前一帧的线性读取。有两件事限制了这一点。首先， $A_4 \approx 0$  是在 81 个旨在最大化它的探针配置上的上限，因此在线性帧假设下，冗余不是不幸探针的工件。其次，核心的“存在但未部署”结论完全不依赖于解码目标：部署分支直接测量对动作的因果效应，与激活编码的内容无关，而该效应也在 L6.  $A_4$  处消失，这解释了原因（几乎没有独特的帧内容）；部署分支独立地确立了这一点。

---

本文将  $A_4/A_1$  解读为两个  $R^2$  点估计的启发式冗余比，而非正式方差分解；定性结论（ $A_4 \approx 0$  而  $A_1$  较大）不依赖于该比值。



**图 1：时序部署审计概览（除注明外均为 Octo-Small [25],  $n=200$ ）。各行分组展示：编码与核心分离 (a,b)、回退部署 (c,d)、跨架构 (e,f)。** (a) 解码  $R^2(t-1)$  (青色) 在所有深度均高于 0.30，而因果部署差距 (玫瑰色, occ 黑色 - 马尔可夫, 95% 置信带) 仅在 L4 层之前显著，并在 L6 层消失。(b) 历史可解码 ( $A_1$ )，但其独有信息 ( $A_4$ , 灰色) 在每个模型和两个家族中均为  $\approx 0$ ：当前状态的冗余副本。(c) 在退化阶梯上，仅近乎完全遮挡 (occ 黑色) 会部署历史；较轻的退化均不显著。(d) 互换 (玫瑰色) 与注意力剔除 (梅色) 均在 L6 层消失，排除了方法伪影。(e) 在相同遮挡下，Octo 对历史的依赖上升 (回退)，而 CronusVLA 下降 (常驻)，编码相同 (两者均为  $A_4 \approx 0$ )。(f) CronusVLA 的贡献在干净条件下为正，在时序打乱 (顺序盲) 下为  $\approx 0$ ，在遮挡下下降，基于三个种子。

## 4.2 未被记忆：仅作为回退部署

从因果角度看，历史仅在当前状态失效时才被读入动作。在退化阶梯上，仅完全遮挡 (occ 黑色) 在 L4 层产生显著部署差距 (+0.043, 95% CI [0.016, 0.069])；部分遮挡、重度遮挡和模糊均不显著 (图 1c)。

**表 2：**历史的分层因果部署 (Octo-Small [25],  $n=200$ )，在马尔可夫和 occ 黑色条件下的修正互换贡献，及其配对差距与自助法 95% 置信区间。差距仅在 L4 层之前显著，并在 L6 层消失，而解码在所有深度均保持较高 (图 1a)：历史存在但未被部署。

| layer | $C_{\text{markov}}$ | $C_{\text{occ.black}}$ | gap    | 95% CI          | sig. |
|-------|---------------------|------------------------|--------|-----------------|------|
| 0     | 0.356               | 0.481                  | +0.125 | [0.085, 0.168]  | yes  |
| 2     | 0.271               | 0.361                  | +0.090 | [0.052, 0.129]  | yes  |
| 4     | 0.087               | 0.141                  | +0.054 | [0.028, 0.079]  | yes  |
| 6     | 0.045               | 0.040                  | -0.005 | [-0.023, 0.014] | no   |
| 8     | 0.019               | 0.027                  | +0.008 | [-0.005, 0.020] | no   |
| 11    | 0.000               | 0.000                  | +0.003 | [-0.010, 0.016] | no   |

**表 3：跨架构总结：相同编码，相反部署，相反可操控性 (Octo [25], CronusVLA [19])。**历史可线性解码 ( $A_1$ )，但在每个模型和两个架构家族中几乎不携带过去独有信息 ( $A_4 \approx 0$ )；架构差异在于历史何时被读入动作 (回退与常驻) 以及注入的历史是否操控动作 (操控：配对供体 - 随机方向操控，附录 G)。Octo 的读出在三个战场上是内容盲的 (G3/G3b/G4; 惰性)；CronusVLA 的常驻通道可操控 (S3)。Octo-Base 操控未单独测试。

| model                 | $A_1$ (decodable) | $A_4$ (unique) | deployment            | steer  |
|-----------------------|-------------------|----------------|-----------------------|--------|
| Octo-Small (27M) [25] | 0.389             | +0.019         | fallback              | inert  |
| Octo-Base (93M) [25]  | 0.362             | +0.015         | fallback (replicates) | -      |
| CronusVLA-0.5B [19]   | 0.142             | -0.011         | standing              | +0.167 |

统一的  $n = 200$  来源也驱动了图 1a，差距在 L4 之前显著 (+0.054 在 L4, CI [0.028, 0.079] 处)，并在 L6 处崩溃 (表 2)：读出层在网络的中间位置就切断了其对历史的依赖，尽管解码在那里仍然很高。<sup>2</sup> 该差距经多种子复现和置换检验 (在 L4 处  $p = 0.0004$ ，在 5/5 个种子中显著) 得以保留，并且一个正交的注意力敲除干预恢复了相同的 L6 截止点，仅在 L6 之后留下很小的残差。从生态学角度看，会迫使使用历史的非马尔可夫步骤 (第 3.1 节) 很少见：对冻结集的无模型扫描发现，在 250 个案例中只有 3 个自然遮挡对，因此该回退机制在分布内很少被触发 (第 4.4 节)。接下来，我们用第二种正交干预 (第 4.2 节) 确认 L6 截止点，对其进行统计强化 (第 4.2 节)，并刻画其缩放特性 (第 4.3 节)。两种条件下的逐层贡献 (图 3b) 使这种闭合可见：条件差距 (琥珀色带) 早期较宽，并在 L6 处收窄闭合。

**第二种正交方法确认了 L6 截止点。**交换干预替换历史的内容；注意力敲除则移除读出层对历史的访问。这两种干预在机制上截然不同，但它们在部署区间上达成一致 (图 1d, 表 4)：敲除差距在早期层 ( $L_0/L_2 \approx +0.32$ ) 较大，在 L4 处较大 (+0.137)，并在 L6 处下降约七倍 (+0.045)，这与交换干预发现的截止点相同。敲除在 L6 之后留下一个小但显著的残差 (交换干预降至统计零)，这是预期且可解释的：在完全遮挡下，只要移除任何历史键，读出层仍会产生扰动。关键在于两种方法下的分界层都是 L6 (表 4 中的逐层差距)。

**部署差距经过统计强化。**早期区间的差距在三种强化检验下均得以保留 (表 9, 图 3c)。在五个种子中， $L_0$  和  $L_4$  的差距在 5/5 个种子中为正；置换检验给出  $p = 0.0000$  ( $L_0$ ) 和  $p = 0.0004$  ( $L_4$ )。在  $L_6$  和  $L_8$  处，差距与零在置换检验下不可区分 ( $p = 0.49, 0.34$ )：读出区间非部署是统计零，而不仅仅是一个小数值。 $L_4$  是干净的机制锚点 ( $L_0$  位于输入边缘，可能部分反映未混合的输入)。三种独立的显著性途径——自助法置信区间、多种子符号一致性和置换检验——结果一致。

### 4.3 缩放与跨架构

**逆向缩放。**Octo-Base (93M) 完整复现了该模式 (仅在完全遮挡下部署历史， $L_0$  层差距显著， $L_6$  层被切断)，但速率明显更低。在将每个模型按其自身模型内全交换分母进行归一化后 (以控制较大模型相对扰动较小的影响)，Octo-Base 部署历史的速率仅为 Octo-Small 的  $\approx 31\%$ ，且比率相同。<sup>2</sup> 遮挡黑色间隙@L4 在不同子研究中略有变化 (不同的  $n$  和供体池)：+0.054 ( $n=200$  主实验, 表 2)，+0.043 ( $n=160$  阶梯实验, 表 8)，+0.051 (门控 0, 表 7)；所有置信区间均排除零，且一致认为 L6 层崩溃。



**表 4: 按层划分的注意力剔除间隙 (Octo-Small [25], 读出  $\rightarrow$  历史, 所有头; 间隙 = 遮挡黑色 - 马尔可夫  $\Delta$ )。**一种正交干预恢复了与交换相同的 L6 截止点, 且在 L6 之后存在小幅显著残差 (在完全遮挡下, 当任何历史键被移除时, 读出仍会产生扰动)。

| layer  | L0        | L2        | L4        | L6        | L8        | L11       |
|--------|-----------|-----------|-----------|-----------|-----------|-----------|
| gap    | +0.323    | +0.313    | +0.137    | +0.045    | +0.053    | +0.041    |
| 95% CI | [.28,.37] | [.28,.35] | [.11,.17] | [.03,.06] | [.04,.07] | [.03,.06] |

在两种独立归一化方法下 (图 3d, 表 10)。因此,  $\sim 11\times$  的绝对下降仅部分源于稀释: 较大策略对历史的依赖比例更低。这反而在规模上强化了该诊断。

**跨架构: 编码相同, 部署相反。**最显著的结果是单一干预呈现相反符号。两种架构均编码  $\approx 0$  独特历史 ( $A_4$  如上), 然而在相同的当前帧遮挡下, 它们对历史的依赖方向相反 (图 1e)。Octo 的历史贡献在遮挡下上升, 历史是仅在当前失效时调用的紧急备份 (回退)。CronusVLA 的贡献在正常条件下较高 (+0.0498, CI [0.0479, 0.0534], 3/3 种子), 在遮挡下下降 (+0.0357, CI [0.0354, 0.0359]; 区间不重叠), 历史是常规的、常设的输入, 不会因危机而升级 (常设使用)。帧顺序打乱使两种架构的贡献均降至  $\approx 0$ , 因此顺序盲性是共享的不变量。因此, 架构差异纯粹在于何时读取历史, 而非存储了多少独特历史, 这是一种仅靠编码永远无法揭示的分离。

由于两种架构在不同的贡献尺度上运行 (克洛诺斯视觉语言动作模型 (CronusVLA) 的单点认知特征产生的绝对偏移小于章鱼模型 (Octo) 的令牌带), 我们读取每种架构内部的符号翻转, 即马尔可夫  $\rightarrow$  遮挡变化相对于该模型自身基线的方向, 而不是跨家族比较绝对幅度。因此, 该主张对尺度不匹配具有鲁棒性: 章鱼模型的比率为  $>1$  (上升), 克洛诺斯视觉语言动作模型的比率为  $<1$  (下降), 且各自均基于其自身的种子和自助置信区间 (附录 H, 表 17) 确立。

#### 4.4 群体: 回退机制究竟多久触发一次?

回退机制仅在触发条件出现时才有意义。对冻结集进行无模型扫描, 寻找自然遮挡对 (帧间差异大且伴随目标丢失或变暗), 在最宽松阈值下仅发现 250 个候选中的 3 个, 在更严格阈值下则无; 第 90 百分位的丢失分数仅为 0.055 (图 4b)。因此, 真正非马尔可夫的情况, 即第 3.1 节中  $\alpha_t$  不足的意义, 在分布中很少见, 这与一种策略一致: 该策略可以将历史视为最后手段的备份, 并且与添加记忆主要有助于长期基准 (如自由基准 (LIBERO) [22]) 所构建的精心设计的、依赖历史的任务这一观察一致。在行为上, 确实存在的小幅历史依赖性并不局限于单一输出通道: 交换  $t-1$  会扰动所有连续姿态维度, 而夹爪仅占综合效应的  $\approx 9\%$  (图 4a)。

## 4.5 综合与启示

这三个层面相互交织成一个陈述: 对于冻结的视觉语言动作模型, 历史并非独立编码的工作记忆, 而是当前帧的冗余残差, 仅当前帧失效时才作为回退机制部署到动作中。这重新定义了视觉语言动作模型无记忆的普遍说法。它们并非无法记忆; 它们存储了一份标记为过去的当前副本, 并且仅在压力下读取它。这就是为什么此类策略在真正非马尔可夫任务上失败的原因: 不是因为历史无法存储, 而是因为所存储的内容重复了已经丢失的那一帧。

设计启示是直接的: 由于原生基底已经将当前编码为历史, 添加更多历史 (更长的窗口、更丰富的叠加) 主要增加冗余; 收益在于注入过去独有信息的机制, 并使读出在原生依赖性被切断的中网络截止点之前关注这些信息。

**因果验证, 以及一种架构条件性的可操控性翻转。**  $A_4 \approx 0$  结果预测, 在回退机制中, 存储的历史 (即当前状态的副本) 在因果上是惰性的: 重新提供它无法添加从未被编码的内容。审计的注入性门控在 Octo 上证实了这一点 (附录 G): 在预截断层进行注入是局部化的且具有供体特异性, 然而在三个独立的战场上, 它均处于亚行为水平, 既不能修复遮挡, 也不能消除状态混叠,



**表 5：两种架构下的注入性门控（冻结、开环、免训练；在预截断层进行注入，Octo 为 L4）。在回退机制（Octo）中，注入是局部化的且具有供体特异性，但在三个独立战场（G3/G3b/G4）上对内容不敏感，从因果上证实了  $A_4 \approx 0$ ；在常驻机制（CronusVLA）中，相同的注入能够操控动作（S3）。可操控性与部署机制相关。Octo：完整 250 对集合，三个种子；S3：在留出刺激子集上使用三个种子和三个供体。**

| check | model (regime)       | question                | statistic                     | verdict     |
|-------|----------------------|-------------------------|-------------------------------|-------------|
| G0a   | Octo (fallback)      | injectable pre-cutoff?  | L4 contrib. $7-9 \times L8$   | localized   |
| G0b   | Octo                 | donor-specific info?    | sep-null +11.0 [9.6, 12.5]    | specific    |
| G2    | Octo                 | steers to donor action? | pre-null +0.069 [.043, .094]  | yes, modest |
| G3    | Octo                 | repairs occlusion?      | recovered -0.010 [-.42, +.41] | no          |
| G3b   | Octo                 | disambiguates aliasing? | paired +0.004 [-.12, +.11]    | no          |
| G4    | Octo                 | flips identity gate?    | paired -0.040 [-.071, -.009]  | no          |
| S3    | CronusVLA (standing) | steers to donor action? | paired +0.167 [.106, .227]    | yes         |

也无法通过（可完美解码的，探针准确率 1.0）时间身份方向打开回退门。Octo 的通路对内容不敏感：它只记录到有东西被注入，而非注入了什么。这并非普遍现象。在常驻使用架构上，其历史通道持续馈入动作，而非在截断点被切断，相同的注入确实能将动作导向供体（配对操控 - 随机 +0.167, CI [0.106, 0.227]；一个可靠的方向性效应）。因此，内容可操控性与部署机制相关，这是同一轴上的第三个架构条件性分离（编码相同，部署符号翻转，可操控性符号翻转），且其解读是因果性的：注入恰好在读出切断历史之处失效，而在未切断之处有效。这一教训更加清晰：回退模型的固有窗口无法通过注入解锁，因此外部记忆必须通过工程化通路添加当前状态不可约的信息，而常驻使用通道则可直接写入。

**一个综合的机制图景。**结合格兰特等人（Grant et al.）[12] 的融合轴结果，本文的发现完成了对视觉-语言-动作（VLA）作用机制的双轴描述。在模式轴上，该机制跨架构共享（视觉占主导，与架构无关）；在时间轴上，编码内容共享（两种家族中均为历史独有信息  $\approx 0$ ），但部署时机不同（回退式与常驻式）。两项研究并非相互竞争的增量，而是正交坐标：一项定位单个时间步内的空间，另一项定位跨时间步的信息。接受格兰特诊断的读者应视本文为必要的另一半，并应对相同编码/相反部署的分离现象感到惊讶，而融合轴无法揭示这一现象。

**为何底层表征是冗余的。**这种冗余并非特定于某个检查点；它在跨越两个家族的 27M、93M 和 0.5 B 模型上反复出现，并随规模增大而加深（第 4.3 节）。一个被训练来模仿近马尔可夫演示的策略，从未被要求存储任何在  $t$  中不可读的  $t-1$  信息，因此两帧窗口的历史几乎成为当前帧的副本，读出层仅在当前信息不足时才查询历史。这预测了在相同数据上训练的记忆模块会继承这种冗余，除非其目标函数明确奖励当前不可约信息，这是本文诊断交给记忆研究方向的一个可检验假设。

**该结果未主张的内容。**本文并未主张视觉-语言-动作模型无法记忆，也未主张记忆模块无用。该主张更为精确，并能经受其自身最强有力的反驳：历史以冗余形式存在并作为回退机制部署，解码与部署之间的差距以及  $A_1$  与  $A_4$  之间的差距精确量化了其程度。精确性正是要点所在，过于宽泛的“无记忆”口号既错误又不可证伪，而三层表述是可证伪的，并且其子假设之一（常驻使用编码更多历史）已被本文自身的数据明确证伪。

**未来工作。**三个扩展方向直接由此得出：（一）通过字典学习 [6] 进行特征级  $A_4$  分析，将冗余结果从群体统计转化为可放大的逐特征目标；（二）闭环研究，测量在读出频段注入当前不可约信息是否能提高非马尔可夫任务的成功率；（三）纳入更多架构成员（附录 D），将回退式与常驻式的分离现象发展为分类体系。

## 5 结论

视觉语言动作模型并非遗忘过去，而是其构建之初便未将过去视为与现在分离之物。历史存在于表征之中，但很大程度上只是当前帧的冗余副本，并且它

仅在当前失效时作为后备被部署到动作中，部署机制（而非编码方式）取决于架构。记忆增强文献所预设的诊断最终指向一个具体的修正方案：添加独特之物，而非更多之物。

**局限性。**两项设计选择是刻意为之，而非妥协。对  $\sim 250$  受控配对进行开环评估，正是使分层因果定位成为可能的原因：每个模块的交换与注意力剔除都需要一个固定、可重复的输入，而闭环推理无法提供这一点；纯行为研究可以注入激活，但无法读取我们所定位的逐层切断；闭环真实机器人扩展是互补的未来工作，不影响定位结论。两个架构家族足以确立后备与常备的分离，这仅需两个机制端点；对第三种冻结、开放、多帧、消费级图形处理器可运行家族的系统性搜索未获结果（附录 D），更多成员只会填充该轴而非证明它。最后，单个消费级图形处理器限制了模型规模，尽管反向缩放趋势（第 4.3 节）表明更大策略对历史的依赖更少，从而强化了诊断。

### 可复现性声明

所有实验均使用冻结的、公开可用的检查点（Octo-Small/Base [25]、CronusVLA-0.5B [19]），零训练，在单个消费级图形处理器上开环运行。刺激集是一个内容哈希、冻结的 250 个匹配对集合（哈希值 bb4992ac8bbc6803，213 条唯一指令），取自 BridgeData V2 [37]；构建脚本及哈希值代替原始语料发布。每个主要数字均绑定到特定运行，并报告其样本量和配对自助法置信区间（附录 A）；探针、互换和注意力剔除程序、自交换噪声校准以及固定的软件环境（两个 conda 规范、精确的检查点标识符）记录在附录 B–C 中。逐项复现映射（表 16）列出了每个模块及其预期的主要数值，测试框架通过骨干一致性检查（附录 J）进行认证。仅在自助法置信区间、五种子符号一致性和置换检验一致时（第 4.2 节）才做出统计声明。

### 伦理声明

本研究是对现有、已公开发布的机器人学习检查点和数据集的机制分析；不引入新的人体受试者数据，也不发布新模型。刺激是来自 BridgeData V2（一个成熟的学术操作数据集）的帧，根据其条款使用，仅以内容哈希和构建脚本的形式分发。由于我们的发现刻画了策略何时依赖或不依赖视觉历史，它们具有双重用途考量：指导更安全记忆设计的同一诊断，也可能帮助对手构建遮挡条件，使部署的策略在遮挡下悄然回退到过时历史。我们认为相对于透明度收益，该风险较低，因为该失效模式（近乎完全的当前帧丢失）对任何操作者都可见，且分析在冻结权重上开环运行。我们不使用专有数据，如实报告负面和零结果，并将开环范围标记为局限性，而非夸大真实机器人安全影响。

### 参考文献

- [1] Guillaume Alain and Yoshua Bengio. Understanding intermediate layers using linear classifier probes. *International Conference on Learning Representations (Workshop)*; *arXiv:1610.01644*, 2017.
- [2] Yonatan Belinkov. Probing classifiers: Promises, shortcomings, and advances. *Computational Linguistics*, 48(1), 2022.
- [3] Nora Belrose, Zach Furman, Logan Smith, Danny Halawi, Igor Ostrovsky, Lev McKinney, Stella Biderman, and Jacob Steinhardt. Eliciting latent predictions from transformers with the tuned lens. *arXiv preprint arXiv:2303.08112*, 2023.

- [4] Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, et al. GR00T N1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*, 2025.
- [5] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al.  $\pi_0$ : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- [6] Trenton Bricken, Adly Templeton, Joshua Batson, Brian Chen, Adam Jermy, Tom Conerly, et al. Towards monosemanticity: Decomposing language models with dictionary learning. *Transformer Circuits Thread*, 2023.
- [7] Anthony Brohan, Noah Brown, Justice Carbajal, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning (CoRL)*, 2023. arXiv:2307.15818.
- [8] Huub Buurmeijer, Carmen Amo Alonso, Aaron Swann, and Marco Pavone. Observing and controlling features in vision-language-action models. *arXiv preprint arXiv:2603.05487*, 2026.
- [9] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Robotics: Science and Systems (RSS)*, 2023.
- [10] Hoagy Cunningham, Aidan Ewart, Logan Riggs, Robert Huben, and Lee Sharkey. Sparse autoencoders find highly interpretable features in language models. In *International Conference on Learning Representations (ICLR)*, 2024. arXiv:2309.08600.
- [11] Atticus Geiger, Hanson Lu, Thomas Icard, and Christopher Potts. Causal abstractions of neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- [12] Bryce Grant, Xijia Zhao, and Peng Wang. Not all features are created equal: A mechanistic study of vision-language-action models. *arXiv preprint arXiv:2603.19233*, 2026.
- [13] Bear Häon, Kaylene Stocking, Ian Chuang, and Claire Tomlin. Mechanistic interpretability for steering vision-language-action models. In *Conference on Robot Learning (CoRL)*, 2025. arXiv:2509.00328.
- [14] Chi He, Xin Liu, Gemma M.S. Camps, John Bruno, Guillaume A. Sartoretti, and Mac Schwager. Demystifying robot diffusion policies: Action memorization and a simple lookup table alternative. In *International Conference on Learning Representations (ICLR)*, 2026.
- [15] Huiwon Jang, Sihyun Yu, Heeseung Kwon, Hoin Jeon, Younggyo Seo, and Jinwoo Shin. ContextVLA: Vision-language-action model with amortized multi-frame context. *arXiv preprint arXiv:2510.04246*, 2025.
- [16] Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, et al. DROID: A large-scale in-the-wild robot manipulation dataset. *arXiv preprint arXiv:2403.12945*, 2024.
- [17] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. OpenVLA: An open-source vision-language-action model. In *Conference on Robot Learning (CoRL)*, 2024. arXiv:2406.09246.
- [18] Moo Jin Kim, Chelsea Finn, and Percy Liang. Fine-tuning vision-language-action models: Optimizing speed and success. *arXiv preprint arXiv:2502.19645*, 2025.
- [19] Hao Li, Shiyu Yang, Yang Chen, Yonghao Tian, Xuanyu Yang, Xifeng Chen, Hanqing Wang, Tai Wang, Feng Zhao, and Dahua Lin. CronusVLA: Towards efficient and robust manipulation via multi-frame vision-language-action modeling. In *AAAI Conference on Artificial Intelligence*, 2026. arXiv:2506.19816.

- [20] Qixiu Li, Yaobo Liang, Zeyu Wang, Lin Luo, Xi Chen, Mozheng Liao, Fangyun Wei, Yu Deng, Sicheng Xu, Yizhong Zhang, et al. CogACT: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation. *arXiv preprint arXiv:2411.19650*, 2024.
- [21] Xuanlin Li, Kyle Hsu, Jiayuan Gu, Oier Mees, Karl Pertsch, Homer Walke, et al. Evaluating real-world robot manipulation policies in simulation. *arXiv preprint arXiv:2405.05941*, 2024.
- [22] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. LIBERO: Benchmarking knowledge transfer for lifelong robot learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [23] Kevin Meng, David Bau, Alex Andonian, and Yonatan Belinkov. Locating and editing factual associations in GPT. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [24] Marco Molinari, Leonardo Nevali, Saharsha Navani, and Omar G. Younis. Emergent world representations in OpenVLA. *arXiv preprint arXiv:2509.24559*, 2025.
- [25] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An open-source generalist robot policy. In *Robotics: Science and Systems (RSS)*, 2024.
- [26] Open X-Embodiment Collaboration. Open x-embodiment: Robotic learning datasets and RT-X models. *arXiv preprint arXiv:2310.08864*, 2023.
- [27] Kiho Park, Yo Joong Choe, and Victor Veitch. The linear representation hypothesis and the geometry of large language models. In *International Conference on Machine Learning (ICML)*, 2024.
- [28] Karl Pertsch, Kyle Stachowicz, Brian Ichter, Danny Driess, Suraj Nair, Quan Vuong, Oier Mees, Chelsea Finn, and Sergey Levine. FAST: Efficient action tokenization for vision-language-action models. *arXiv preprint arXiv:2501.09747*, 2025.
- [29] Physical Intelligence, Kevin Black, Noah Brown, Danny Driess, et al.  $\pi_{0.5}$ : A vision-language-action model with open-world generalization. In *Conference on Robot Learning (CoRL)*, 2025. *arXiv:2504.16054*.
- [30] Hao Shi, Bin Xie, Yingfei Liu, Lin Sun, Fengrong Liu, Tiancai Wang, Erjin Zhou, Haoqiang Fan, Xiangyu Zhang, and Gao Huang. MemoryVLA: Perceptual-cognitive memory in vision-language-action models for robotic manipulation. *arXiv preprint arXiv:2508.19236*, 2025.
- [31] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, Adil Zoutine, Michel Aractingi, Caroline Pascal, Martino Russi, Andres Marafioti, et al. SmolVLA: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.
- [32] Ajay Sridhar, Jennifer Pan, Satvik Sharma, and Chelsea Finn. MemER: Scaling up memory for robot control via experience retrieval. *arXiv preprint*, 2025.
- [33] Adly Templeton, Tom Conerly, Jonathan Marcus, Jack Lindsey, Trenton Bricken, Brian Chen, et al. Scaling monosemanticity: Extracting interpretable features from Claude 3 Sonnet. *Transformer Circuits Thread*, 2024.
- [34] Marcel Torne, Andy Tang, Yuejiang Liu, and Chelsea Finn. Learning long-context diffusion policies via past-token prediction. *arXiv preprint arXiv:2505.09561*, 2025.
- [35] Alexander Matt Turner, Lisa Thiergart, Gavin Leech, David Udell, Juan J. Vazquez, Ulisse Mini, and Monte MacDiarmid. Activation addition: Steering language models without optimization. *arXiv preprint arXiv:2308.10248*, 2023.
- [36] Jesse Vig, Sebastian Gehrmann, Yonatan Belinkov, Sharon Qian, Daniel Nevo, Yaron Singer, and Stuart Shieber. Investigating gender bias in language models using causal mediation analysis. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

- [37] Homer Walke, Kevin Black, Abraham Lee, Moo Jin Kim, Max Du, Chongyi Zheng, Tony Zhao, Philippe Hansen-Estruch, Quan Vuong, Andre He, et al. BridgeData V2: A dataset for robot learning at scale. In *Conference on Robot Learning (CoRL)*, 2023.
- [38] Kevin Wang, Alexandre Variengien, Arthur Conmy, Buck Shlegeris, and Jacob Steinhardt. Interpretability in the wild: A circuit for indirect object identification in GPT-2 small. In *International Conference on Learning Representations (ICLR)*, 2023.
- [39] Jiahui Zhang, Yurui Chen, Yueming Xu, Ze Huang, Yanpeng Zhou, Yu-Jie Yuan, Xinyue Cai, Guowei Huang, Xingyue Quan, Hang Xu, et al. 4D-VLA: Spatiotemporal vision-language-action pretraining with cross-scene calibration. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025.
- [40] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Robotics: Science and Systems (RSS)*, 2023.
- [41] Haoyu Zhen, Xiaowen Qiu, Peihao Chen, Jianzhe Yang, Xin Yan, Yilun Du, Yining Hong, and Chuang Gan. 3D-VLA: A 3d vision-language-action generative world model. In *International Conference on Machine Learning (ICML)*, 2024. arXiv:2403.09631.
- [42] Jinliang Zheng et al. X-VLA: Soft-prompted transformer as scalable cross-embodiment vision-language-action model. *arXiv preprint arXiv:2510.10274*, 2025.
- [43] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. TraceVLA: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. *arXiv preprint arXiv:2412.10345*, 2024.

## A 已验证数字

所有主要数值均取自单一已验证结果日志。按层 (L0 - L11) 解码  $R^2(t-1)$  : 0.022, 0.278, 0.365, 0.370, **0.398**, 0.371, 0.367, 0.352, 0.332, 0.325, 0.320, 0.305 ; 逐层部署差距及配对自助法 95% 置信区间见表 2。其余已验证表格, 包括门控 0 解码/部署分支、完整剂量反应、统计强化、注意力剔除、归一化跨尺度以及行为逐自由度分解, 汇总如下。

表 6: 门控 0 解码臂 (Octo-Small [25], 脊探针,  $n=200$ , 5 折交叉验证)。过去帧内容可从 L2 解码, 且相比仅使用当前帧的基线有较小优势。

| layer | $R^2(t-1)$ | $R^2(t)$ | baseline | margin |
|-------|------------|----------|----------|--------|
| 0     | 0.022      | 0.027    |          | -0.005 |
| 2     | 0.362      | 0.347    |          | +0.015 |
| 4     | 0.388      | 0.374    |          | +0.014 |
| 6     | 0.338      | 0.342    |          | -0.004 |

表 7: 门控 0 部署臂 (Octo-Small [25], 校正后的互换贡献,  $n=200$ )。在 L4 层, 对于遮挡黑色条件, 与马尔可夫模型的差距显著; 但对于遮挡部分条件则不显著。

| cell                | L0                                                                | L2    | L4    | L6    | L8    | L11   |
|---------------------|-------------------------------------------------------------------|-------|-------|-------|-------|-------|
| markov              | 0.344                                                             | 0.254 | 0.088 | 0.051 | 0.015 | 0.002 |
| occ_partial         | 0.385                                                             | 0.279 | 0.099 | 0.043 | 0.012 | 0.004 |
| occ_black           | 0.472                                                             | 0.367 | 0.139 | 0.049 | 0.015 | 0.000 |
| gap@L4: occ_partial | +0.010 [-0.008, 0.028] n.s.; occ_black +0.051 [0.026, 0.074] sig. |       |       |       |       |       |

**自然遮挡扫描 (群体分支)**。在冻结集上 ( $n=250$ , 无模型): 候选者在最宽松阈值 = 3/250, 在更严格阈值 = 0; 帧差百分位数 (50/90/95) = 5.08/9.99/12.52; 丢失分数百分位数 = 0.020/0.055/0.070。

**互换噪声校准**。原始供体交换与自交换零假设 (层 0/4/6/8/11): 原始马尔可夫 0.666/0.299/0.221/0.177/0.162, 零假设马尔可夫 0.151/0.150/0.166/0.161/0.158; 零假设下限 ( $\approx 0.15$ ) 被减去以获得校正后的贡献。刺激哈希 bb4992ac8bbc6803。

表 8: 刺激强度剂量反应 (Octo-Small [25], 门控 0b,  $n=160$ )。L2/L4 层的校正贡献以及 L4 层与马尔可夫模型的差距。仅遮挡黑色条件显著; 乱序 (时间顺序破坏) 作为顺序盲对照被报告。

| cell      | $c@L2$ | $c@L4$ | gap@L4 | 95% CI             | sig.        |
|-----------|--------|--------|--------|--------------------|-------------|
| markov    | 0.257  | 0.095  | ,      | (baseline)         | ,           |
| occ_half  | 0.334  | 0.110  | +0.015 | $[-0.006, 0.039]$  | no          |
| occ_heavy | 0.324  | 0.114  | +0.019 | $[-0.003, 0.043]$  | no          |
| blur      | 0.310  | 0.085  | -0.010 | $[-0.032, 0.011]$  | no          |
| occ_black | 0.376  | 0.138  | +0.043 | $[0.016, 0.069]$   | yes         |
| shuffle   | 0.000  | 0.000  | -0.098 | $[-0.116, -0.080]$ | order-blind |

表 9: 统计强化 (Octo-Small [25], 5 个种子  $\times$  60 对; 置换检验, 在  $n=300$  合并的逐对差距上进行 5000 次重采样)。部署差距在所有 5 个种子中符号一致, 且在 L0/L4 层具有置换显著性; 在 L6/L8 层与零无置换可区分。

| layer | per-seed gap (s0-s4)        | mean   | std   | +seeds | perm $p$ |
|-------|-----------------------------|--------|-------|--------|----------|
| 0     | .142/.119/.040/.096/.141    | +0.108 | 0.038 | 5/5    | 0.0000   |
| 4     | .037/.009/.023/.047/.054    | +0.034 | 0.016 | 5/5    | 0.0004   |
| 6     | -.001/.005/.013/-.008/-.008 | +0.000 | 0.008 | 2/5    | 0.4882   |
| 8     | .018/.000/.024/-.012/-.016  | +0.003 | 0.016 | 3/5    | 0.3376   |

## B 探针与干预细节

**解码探针。**对历史标记激活进行岭回归 (均值 + 最大池化, RGB16 帧目标), 逐层扫描, 5 折交叉验证; 在投影出当前帧 ( $t$ ) 探针后,  $A_4$  残差解码  $t-1$ 。  $A_4$  上限通过 81 种配置扫描 {层}  $\times$  {池化}  $\times$  {目标}  $\times$  {正则化} 确定; 最佳  $A_4$  为 +0.019 (Octo-Small), +0.015 (Octo-Base), 在标准化 CronusVLA 臂内 -0.011。打乱标签对照返回  $A_2 \approx 0$ , 排除了过拟合。互换。编码器块上的前向预钩子。  $\ell$  用供体的第  $\ell$  层表示覆盖 256 个历史标记位置 (一个  $16 \times 16$  补丁网格, 经验定位且在各对间稳定); 当前帧和读出保持不变。标记布局。[任务语言 ||  $t_0$ : 主 (256), 腕部, 读出 ||  $t_1$ : 主, 腕部, 读出], 总计 690 个标记, 宽度 384 (Octo-Small)。




图 2: 互换噪声校准 (Octo-Small [25])。原始供体交换偏移 (青色) 减去自交换零底 (石板色,  $\approx 0.15$ , 其真实贡献为零) 得到校正贡献 (阴影区域)。每个部署腿数值均为该校正值。

## C 环境与可复现性

实验使用两个固定的 conda 环境。Octo 路径固定 torch 2.6.0 +cu124、transformers 4.34.1 (支持 Flax)、仅用于权重加载的 CPU JAX 0.4.20、tensorflow-cpu 2.15.0 和 numpy 1.26.4; 解释使用 PyTorch 移植版 (JAX 仅用于权重加载)。CronusVLA 路径固定 torch 2.2.0 +cu121、transformers 4.40.1 (关键依赖)、numpy 1.26.4、tokenizers 0.19.1、timm 0.9.10 和 draccus; scikit-learn 被固定以免升级 numpy。模型从公共检查点冻结加载 (Octo-Small/Base 1.5; CronusVLA- 0.5B Bridge/RT-1 后训练检查点 step-042500-epoch-07-loss=0.0587.pt)。测试框架通过骨干一致性检查 (读出均值  $|\Delta| = 2.4 \times 10^{-4}$ ) 和确定性验证。



表 10: 归一化跨尺度 (Octo [25], 逆缩放; 模型内全交换分母)。归一化后, Octo-Base 仍以 Octo-Small 速率的  $\approx 31\%$  部署历史。

| model                 | contrib (markov L0) | norm/hist   | norm/cur    | abs. ratio |
|-----------------------|---------------------|-------------|-------------|------------|
| Octo-Small [25] (27M) | 0.339               | 0.637       | 0.555       | ,          |
| Octo-Base [25] (93M)  | 0.029               | 0.199       | 0.172       | ,          |
| <b>base/small</b>     | <b>0.09</b>         | <b>0.31</b> | <b>0.31</b> | ,          |

表 11: 逐自由度行为  $|\Delta|$  (Octo-Small [25], 马尔可夫单元,  $n=48 \times 32$  样本)。历史影响整个 7 自由度动作向量, 而不仅仅是离散夹爪 (夹爪 = 9.3% 占求和掩码  $\Delta$ )。标量行为敏感性较弱 (occ black/markov 比率  $1.22\times$ ), 这促使我们进行机制性研究而非行为研究。

| condition  | wx    | wy    | wz    | rx    | ry    | rz    | grip  |
|------------|-------|-------|-------|-------|-------|-------|-------|
| mask $t-1$ | 0.463 | 0.294 | 0.429 | 0.348 | 0.365 | 0.376 | 0.233 |
| swap $t-1$ | 0.720 | 0.477 | 0.538 | 0.409 | 0.392 | 0.553 | 0.260 |

读出奇偶性收紧。所有内容均在单个 24GB 消费级 GPU 上运行, 无量化且无训练; 387GB 的 Bridge 语料库被下采样至哈希的 250 对集合, 以构建脚本加哈希而非原始数据的形式分发。

## D 第三架构排除调查

一个冻结的公开检查点, 既开放、具备历史感知能力 (推理时多帧), 又能在消费级 GPU 上运行, 实属罕见。我们调查了候选池, 并出于原则性原因排除了每个成员: 多视图 (而非多帧) 微调策略 (例如 OpenVLA-OFT [18]); 默认单帧的流匹配策略 ( $\pi_0/\pi_{0.5}$  [5, 29], X-VLA [42], 基于 CVAE 的 ACT [40]); 一个联合嵌入预测模型, 其无泄漏学生在推理时退化为单帧 (其环境已构建并加载权重,  $\sim 6$  GB, 随后被排除); 以及一个时空 RGB-D 模型, 其强制深度输入在我们的刺激集中缺失 (3D-/4D-VLA [39, 41])。我们研究的两个家族, Octo 类和 Qwen-DiT (CronusVLA), 是满足全部四个约束的罕见成员, 这就是架构轴只有两个点而非更多的原因。我们将此界定为范围而非遗漏: 回退与站立解离是在约束所允许的两个成员上建立的。

## E 跨架构解码: 标准化修正

CronusVLA 的历史是逐帧认知特征 (896 维, VLM 最后一层最后一个标记)。首次解码尝试产生  $R^2 \ll 0$ , 其中打乱标签控制比真实标签更负 ( $-0.463$  vs.  $-0.004$ ), 这是岭回归对未归一化、大规模、高维特征过拟合导致的数值崩溃 ( $p \gg n$ )。修正后的探针对特征进行 z 分数标准化, 扩大正则化扫描范围 ( $10^2 - 10^5$ ), 并添加 PCA-50 变体; 打乱控制随后回到  $\approx 0$  ( $-0.032$ ), 结果变得可信:  $A_1 = 0.142$ ,  $A_4 = -0.011$ , 在完整和 PCA-50 参数化下均稳定。我们谨慎地报告 CronusVLA 的  $A_1$  (认知特征与 Octo 中间变换器标记的表示位置不同); 可比较的量为  $A_4$ , 两种架构均位于  $\approx 0$ 。

## F 支持层分辨率和鲁棒性面板

图 3 汇总了主图所概括的四个面板: (a) 历史解码  $A_1$  跨越全部 12 层, 在每一深度均可解码, 并在第 4 层达到峰值; (b) 在马尔可夫与遮挡黑两种条件下逐层修正的互换贡献, 两者沿同一下降曲线, 条件差距在第 6 层闭合; (c) 五个种子上的部署差距, 采用置换  $p$ , 在第 0 层/第 4 层显著, 在第 6 层/第 8 层统计上为零; (d) 八面体基础模型在两种归一化器下以  $\approx 31\%$  于八面体小型模型的速率部署历史。互换在规范层集  $\{0, 2, 4, 6, 8, 11\}$  上评估以控制成本; 12 层解码曲线显示, 表示在部署差距已消失的同一范围内仍保持可解码。

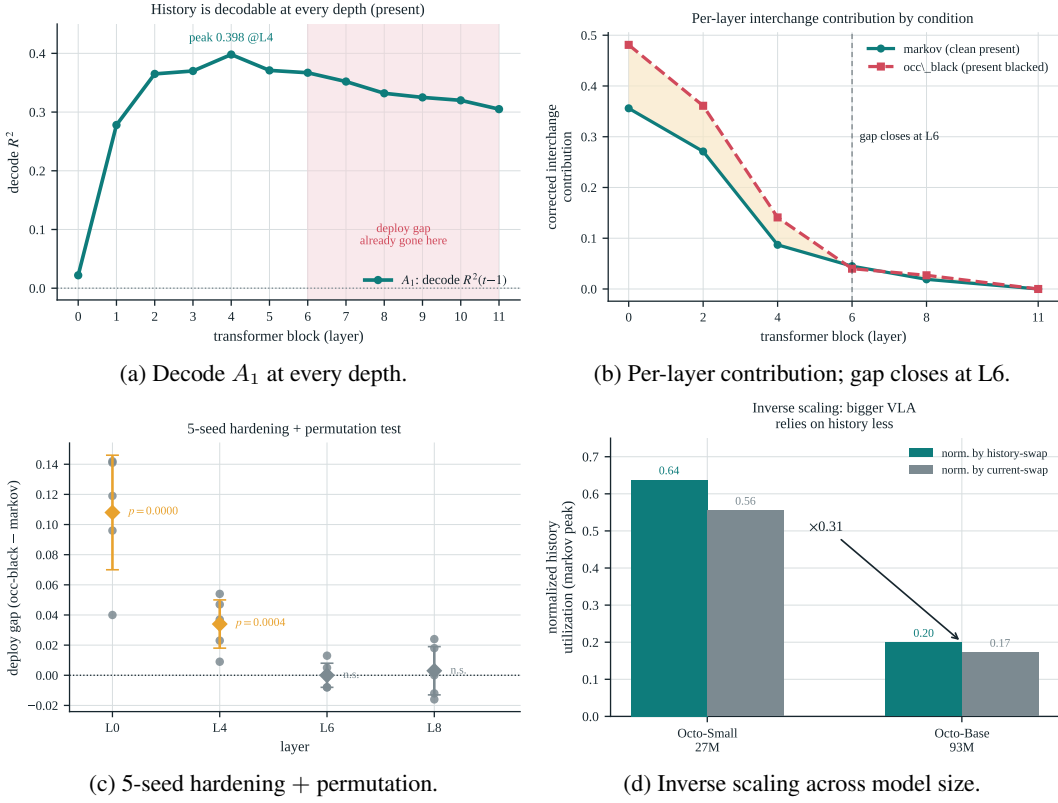


图 3：支持面板（除非注明 [25]，均为八面体小型模型）：(a) 按深度解码，(b) 逐层互换贡献，(c) 五种子部署差距强化与置换检验，(d) 跨模型规模的逆缩放。这些面板扩展了图 1 的汇总面板。




图 4：群体与行为证据（八面体小型模型 [25]）。(a) 在掩蔽与交换  $t-1$  下每个自由度  $|\Delta|$  的历史影响连续的姿态维度，而不仅仅是夹爪。(b) 冻结集上每对帧的丢失比例；该分布远低于触发部署的近全遮挡带，因此仅 3/250 对自然被遮挡，分布内回退机制很少被触发。

### G 注入性门控：截止前通路能否携带历史内容？

审计的最后一步（算法 1，以及第 4.5 节的因果验证）检验读取历史的通路能否被驱动以使用注入的历史内容。跨两种架构的六项检查复用噪声校正互换引擎（公式 3），无需训练，开环运行；八面体检查使用冻结的 250 对集合并采用三个种子；克洛诺斯视觉语言动作检查（S3）在留出刺激子集上使用三个供体。该链条设计使得阴性结果与阳性结果同样具有信息量：

回退机制的阴性结果是  $A_4 \approx 0$  的因果对应物，而常备机制的阳性结果表明内容盲性是架构条件性的，而非普遍性的。

**读取。** G0a/G0b/G2 确立：在 Octo 的预截断层注入干净供体的历史是局部的（L4 比 L8 更能移动动作  $7 - 9\times$ ），写入供体特异性信息（相对于自交换零假设的分离排除了零），并施加适度的方向偏差。三项决定性的 Octo 检查均为阴性。**G3** 在遮挡黑色条件下注入刺激自身的预遮挡历史：向未遮挡动作的恢复是干净的零，而不匹配的注入则有害（自身 - 随机  $+4.9$ , CI  $[3.1, 6.9]$ ），因此该钩子因果活跃，但模型自身的冗余历史无法填补任何内容。**G3b** 转向状态混叠（当前帧清晰但模糊）：在通过配对对比去除共同漂移后，混叠伙伴的历史未能切换分支，且无关历史对动作的移动程度相同。**G4** 沿时间身份方向推动当前标记，线性探针以准确率 1.0 解码该方向；它打开回退门的程度不超过范数匹配的随机推动，因此身份与内容一样，可解码但不可部署。三个战场一致表明：Octo 的通路是内容盲的，并在 L6 处被切断。**S3** 随后打破了普遍性：在 CronusVLA 上，其认知特征历史通道持续馈入动作的交叉注意力（常驻使用，无截断），注入供体的历史会将动作引向该供体（配对  $+0.167$ ；仍存在较大的非特异性漂移）。对比是干净的，注入在读出切断历史之处完全无效，而在未切断之处有效，因此我们报告一条因果定律：可操纵性追踪部署机制，而非一种控制方法——回退模型的本地窗口无法通过注入解锁，而常驻使用通道可直接写入。

## H 符号、设计扫描与复现

表 12 固定符号。表 13–14 给出了在两个尺度上建立  $A_4$  上限的解码设计扫描；表 15 给出了行为历史敏感性，为机制测度提供动机；表 16 将每条路径映射到其模块和预期的主要数字；表 17 报告了 CronusVLA 的加固（常驻使用在种子间稳健、顺序盲，且在遮挡下下降而非上升；图 1f）。图 4a 显示历史扰动整个 7 自由度动作向量，而不仅仅是离散夹爪，因此部署信号不是单一输出维度的工件。

表 12：符号。

| symbol    | meaning                                                                             |
|-----------|-------------------------------------------------------------------------------------|
| $t, t-1$  | current / previous timestep (observation)                                           |
| $\ell$    | transformer block index (L0–L11 for Octo-Small)                                     |
| $A_1$     | decode $R^2$ of $t-1$ from history-token activations ( <i>is history present?</i> ) |
| $A_4$     | decode of $t-1$ residualized against $t$ ( <i>history-unique info</i> )             |
| $A_2$     | shuffled-label decode control ( $\approx 0$ when the probe is healthy)              |
| $c@l$     | noise-corrected interchange contribution at layer $\ell$                            |
| gap       | $c_{\text{occ\_black}} - c_{\text{markov}}$ (conditional deployment signal)         |
| markov    | clean current frame (history nominally unnecessary)                                 |
| occ_black | current frame fully blacked (forces reliance on $t-1$ )                             |
| shuffle   | temporal order destroyed (order-blindness control)                                  |

表 13：解码设计扫描，Octo-Small [25]（在 81 个配置中按  $A_4$  排序的前 8 名）。历史唯一上限为  $A_4 = +0.019$ ；最佳原始解码为  $A_1 = 0.389$ （均值最大值、RGB16、L2、 $\alpha=10$ ，不在这个按  $A_4$  排序的视图中）。

| layer | pool    | target | $\alpha$ | $A_1$ | $A_4$  |
|-------|---------|--------|----------|-------|--------|
| L2    | meanmax | rgb16  | 100      | 0.248 | +0.019 |
| L4    | meanmax | rgb16  | 100      | 0.250 | +0.017 |
| L6    | meanmax | rgb16  | 100      | 0.223 | +0.014 |
| L2    | max     | rgb16  | 100      | 0.179 | +0.012 |
| L4    | max     | rgb16  | 100      | 0.178 | +0.012 |
| L4    | mean    | rgb16  | 100      | 0.174 | +0.009 |
| L2    | mean    | rgb16  | 100      | 0.165 | +0.009 |
| L6    | max     | rgb16  | 100      | 0.155 | +0.008 |

表 14: 解码设计扫描, Octo-Base [25] (按  $A_4$  排序的前 8 名)。上限  $A_4 = +0.015$ ; 最佳原始  $A_1 = 0.362$ 。  $A_4 \approx 0$  上限在第二个尺度上复现了 Octo-Small 的结果。

| layer | pool    | target | $\alpha$ | $A_1$ | $A_4$  |
|-------|---------|--------|----------|-------|--------|
| L4    | meanmax | rgb16  | 100      | 0.285 | +0.015 |
| L4    | max     | rgb16  | 100      | 0.243 | +0.014 |
| L6    | meanmax | rgb16  | 100      | 0.272 | +0.011 |
| L4    | mean    | rgb16  | 100      | 0.202 | +0.008 |
| L6    | max     | rgb16  | 100      | 0.233 | +0.007 |
| L6    | mean    | rgb16  | 100      | 0.189 | +0.004 |
| L2    | mean    | rgb16  | 100      | 0.200 | +0.003 |
| L2    | max     | rgb16  | 100      | 0.254 | +0.003 |

表 15: 行为历史敏感性 (Octo-Small [25], M0b; 在冻结集上的平均每自由度  $|\Delta|$ )。掩蔽或交换  $t-1$  会扰动动作, 但标量效应较弱 (occ black / markov ratio  $1.22\times$ ) , 这正是行为测度低估部署、需要机制性、分层解析测度的原因。

| condition  | mean $ \Delta $ | std  |
|------------|-----------------|------|
| mask $t-1$ | 0.425           | 0.20 |
| swap $t-1$ | 0.527           | 0.27 |

## 我扩展了相关工作

**策略的机制可解释性。**在 Grant 等人 [12] 关于融合轴的工作之外, Hoon 等人 [13] 展示了在真实机器人策略上的层局部 FFN 值向量操控, Molinari 等人 [24] 报告了 VLA 表示内部可解码的前向世界模型。两者都涉及当前步骤可用或从当前步骤投影的内容; 两者都没有测量过去帧的因果部署, 也没有将保留的历史与当前帧冗余分开, 这正是本文的贡献。我们的  $A_1/A_4$  划分是区分可解码与已使用 [1] 的探测工作在时间上的类比, 我们的交换分支遵循因果抽象和激活修补传统 [11, 23], 应用于动作输出而非词元对数几率。

**更广泛地, 序列模型中的记忆。**我们测量的冗余呼应了自回归模型中一个熟悉的观察: 相邻帧/词元高度相互可预测, 但其对动作策略的后果是具体的: 因为策略是在近马尔可夫演示上训练的, 读出层没有动机去查询它能够重建的过去, 我们表明它确实没有 (过去 L6)。字典学习分析 [6] 为  $A_4$  (a 历史唯一特征的特性级版本提供了一条途径, 我们将其留待未来工作。

**基准与增强, 扩展。**行为基准 [21, 22] 与记忆增强方法 [15, 30, 32, 34, 43] 构成一个先测量后修复的循环, 而本文的诊断位于该循环的上游: 它预测, 在相同近马尔可夫数据上训练的增强会继承冗余, 除非其目标明确奖励当前不可约信息; 并且它识别出在何处 (越过网络中部读出截止点之后) 必须让记忆信号发挥作用。

## J 测试装置认证

机制性论断的可靠性取决于测量装置。本文在一条简短的谱系中认证了 Octo 测试装置: 一个 NHWC  $\rightarrow$  NCHW 图像管线修复和一个骨干隔离钩子映射 (读出奇偶均值  $|\Delta| = 2.4 \times 10^{-4}$  相对于参考前向传播); 一次确定性读出奇偶收紧; 一个真实 Bridge 历史条件测试 (完整/掩码/交换), 确立历史仅在部分情况下起作用; 以及一个噪声校正的交换引擎 (自交换零值减法), 该引擎在所有下游环节中保持不变地复用。CronusVLA 测试装置以类似方式认证, 并额外包含附录 C 中描述的版本固定和附录 E 中的认知特征布线自检。被取代的脚手架 (冻结前的数据管道、钩子调试试点、未进行噪声校正的交换 v1) 保留用于溯源, 但不包含在发布的工件中。

表 16: 各环节复现映射（预期主要数值）。所有环节读取相同的冻结、哈希刺激集；运行在单个消费级 GPU 上，使用冻结的公开检查点。

| leg         | module               | expected headline                                                       |
|-------------|----------------------|-------------------------------------------------------------------------|
| stimuli     | build_stimuli        | hash bb4992ac8bbc6803, 250 pairs                                        |
| decode      | decode               | $A_1 = 0.389$ , $A_4 = 0.019$ (ceiling)                                 |
| deploy      | deploy_gate          | occ_black gap@L4 +0.054 [0.028, 0.079]                                  |
| dose        | deploy_gate          | only occ_black sig.; +0.043 (gate0b)                                    |
| 2nd method  | knockout             | same L6 cutoff; residual past L6                                        |
| hardening   | stats                | perm $p = 0.0004$ @L4 (5/5)                                             |
| cross-scale | cross_scale_octobase | $A_4 = 0.015$ ; norm. rate 0.31                                         |
| cross-arch  | cronus_decode/deploy | $A_1 = 0.142$ , $A_4 = -0.011$ ; markov 0.0498, occ_black_deploy 0.0357 |
| population  | natural_occlusion    | 3/250 candidates                                                        |

表 17: CronusVLA [19] 加固 (3 个种子  $\times$  80 对)。干净条件下的历史贡献稳健为正（常规使用）；时间顺序打乱将其驱动至  $\approx 0$ （顺序盲，类似 Octo）；在遮挡条件下它下降而非上升（与 Octo 的符号翻转）。马尔可夫和遮挡黑盒部署置信区间不重叠。

| seed          | markov               | shuffle              | occ_black_deploy     |
|---------------|----------------------|----------------------|----------------------|
| 0             | +0.0479              | -0.0000              | +0.0354              |
| 1             | +0.0482              | +0.0004              | +0.0358              |
| 2             | +0.0534              | -0.0010              | +0.0359              |
| mean $\pm$ sd | +0.0498 $\pm$ 0.0025 | -0.0002 $\pm$ 0.0006 | +0.0357 $\pm$ 0.0002 |
| 95% CI        | [0.0479, 0.0534]     | ,                    | [0.0354, 0.0359]     |
| verdict       | standing             | order-blind          | falls (standing)     |

## K 有效性威胁

是  $A_4 \approx 0$  探针功率伪影？否：81 配置扫描旨在最大化  $A_4$ ，其上限仍为  $\leq 0.02$ ；同一探针恢复  $A_1$  up to 0.39，因此并非功率不足。部署差距是随机读出伪影吗？否：自交换零假设已被减去，效应在五个种子上符号一致，置换检验在声称显著处显著，在声称零处为零。L6 截止是否依赖于方法？否：互换与注意力敲除这两种机制上截然不同的干预手段，在该截止点上结论一致。开环是否歪曲了闭环策略？它限定的是范围，而非定位：该论断涉及历史信息是否以及何处进入动作分布，开环直接读取的正是这一量；闭环行为恰是该量的下游结果。两种架构是否足以支撑架构依赖性论断？该论断是存在性的，部署机制并非架构不变，且一对符号相反的实例（编码相同）足以确立该论断；附录 D 说明了为何无法获得更多冻结、开放、多帧成员。