

RMBench: 面向策略设计洞见的记忆依赖型机器人操作基准

Tianxing Chen^{*1} Yuran Wang^{*2,3} Mingleyang Li^{*2} Yan Qin^{*4} Hao Shi⁵ Zixuan Li⁶
 Yifan Hu² Yingsheng Zhang⁵ Kaixuan Wang¹ Yue Chen² Hongcheng Wang² Tianhang Yang⁵
 Junjie Wang⁵ Tianhang Yang² Renjing Xu⁴ Ruihai Wu²
 Yao Mu⁷ Yaodong Yang^{2,3} Hao Dong^{†2} Ping Luo^{†1}

* Equal contribution, † Corresponding authors

Website: <https://RMBench.github.io> Code: <https://github.com/robotwin-Platform/rmbench>

摘要

机器人操作策略近年来取得了快速进展，然而现有方法大多对记忆能力的考虑有限。因此，它们难以解决需要基于历史观测进行推理并随时间保持任务相关信息任务，而这些要求在实操场景中普遍存在。尽管已提出若干具备记忆意识的策略，但对记忆依赖型操作的系统性评估仍探索不足，且架构设计选择与记忆性能之间的关系尚未得到充分理解。为填补这一空白，本文提出 **RMBench**，一个包含 9 项操作任务的仿真基准，这些任务跨越多个记忆复杂度层级，能够对策略的记忆能力进行系统性评估。本文进一步提出 **Mem-0**，一种模块化操作策略，其显式记忆组件旨在支持受控消融研究。通过大量仿真与真实世界实验，本文识别出现有策略中与记忆相关的局限性，并就架构设计选择如何影响记忆性能提供了实证洞见。

RDT2 (Team, 2025) 在柔性物体操作和精细技能方面取得了令人印象深刻的性能，包括制作咖啡等复杂活动。然而，现有机器人策略大多主要针对短时域任务和精细操作而设计。这些方法通常依赖固定长度的近期观测窗口，隐含假设底层决策过程近似马尔可夫。

相比之下，依赖记忆的任务在现实世界的机器人应用中无处不在。这类任务本质上具有非马尔可夫性，因为过去的观测和动作可能在较长的时间范围内影响未来的决策。例如，记住之前放置物体的位置，或在忘记密码后基于多次尝试进行推理。这些任务既具有挑战性又具有重要的实际意义，因为它们要求机器人能够保留、检索并利用超出短期感官输入的信息。

受这一挑战的推动，近期一些工作开始探索具有记忆意识的机器人策略。诸如记忆视觉语言动作模型 (MemoryVLA) (Shi 等人, 2025)、记忆高效机器人 (MemER) (Sridhar 等人, 2025)、克洛诺斯视觉语言动作模型 (CronusVLA) (Li 等人, 2025) 和基于分割任意模型的智能体 (SAM2Act) (Fang 等人, 2025) 等方法引入了显式记忆机制，以解决长时程和依赖记忆的决策问题。尽管做出了这些努力，该领域目前仍缺乏一个系统设计的实验平台，用于在长期记忆需求下评估和分析机器人策略。特别是，对于使记忆策略在机器人操作中有效的底层机制，理解仍然有限。

现有的基准仅部分弥补了这一差距。记忆基准 (MemoryBench) (Fang 等人, 2025) 包含七个涉及记忆的单臂操作任务，但其中只有三个可以在仿真中可靠复现，并且该基准在原则性任务设计方面提供的指导有限。米卡萨 (MIKASA) (Cherepanov 等人, 2025) 引入了 32 个与记忆相关的操作任务，但其形式主要针对强化学习而非通用模仿学习。

1. 引言

机器人操作领域的最新进展已在广泛任务中展现出强大能力。诸如 Pi0.6 (Intelligence 等, 2025a) 和 1MMLab@HKU 2PKU 3PsiBot 4HKUST (广州) 5THU 6SZU 7SJTU 等现代策略。通讯作者: 陈天行 <chentianxing@connect.hku.hk>, 罗平 <pluo@hku.hk>, 董豪 <hao.dong@pku.edu.cn>。

Preprint. Mar 1, 2026.

自由基准长时程版 (LIBERO-Long) (Liu 等人, 2023) 提供了十个长时程任务, 但这些任务并未明确要求记忆, 因为所有与任务相关的信息在整个执行过程中都保持可观测。

为解决这些局限性, 本文首先引入任务记忆复杂度 (Task Memory Complexity), 一种用于刻画机器人操作任务中记忆需求的原则性度量。该度量提供了一种系统化方法, 用于对依赖记忆的任务进行分类, 并为任务设计提供指导。基于此形式化定义, 本文提出 **RMBench**, 一个构建于 RoboTwin 2.0 平台之上的机器人操作基准。**RMBench** 包含 9 个双臂操作任务, 涵盖不同层级的任务记忆复杂度, 从而支持对机器人操作中记忆保持与利用的大规模、受控研究。

此外, 本文提出 **Mem-0**, 一种面向记忆的新型机器人操作策略, 其模块化组件设计便于替换或重新配置。**Mem-0** 采用双系统架构, 并配备任务阶段分类器, 显式区分任务的不同阶段, 从而在长时程中实现结构化的记忆使用。通过对 **Mem-0** 的系统性消融研究, 本文分析了哪些设计组件对机器人操作中的有效记忆至关重要, 并为未来策略设计提炼洞见。

本文的主要贡献总结如下:

- 本文引入任务记忆复杂度, 一种用于对依赖记忆的机器人操作任务进行分类的原则性度量, 并基于该度量提出 **RMBench**, 一个包含 9 个以记忆为核心任务的仿真基准。
- 本文提出 **Mem-0**, 一种面向记忆的机器人操作策略, 其特点是采用双系统架构并配备任务阶段分类器, 以实现灵活的记忆使用。
- 本文在 **RMBench** 上对具有代表性的最先进策略进行了全面评估, 并对 **Mem-0** 进行了详细的消融研究, 揭示了哪些策略设计机制对机器人操作中的记忆最为有益。

2. 相关工作

2.1. 机器人操作基准

基于物理的仿真器是现代机器人操作研究的基石, 近年来已提出众多仿真基准。RoboTwin (Mu 等, 2025; Chen 等, 2025a)、RoboCasa (Nasiriany 等, 2024)、ManiSkill3 (Tao 等, 2025)、AutoBio (Lan 等, 2025)、Uni-VTAC (Chen 等, 2026)、DexGarmentLab (Wang 等, 2025)、BEHAVIOR-1K (Li 等, 2024a) 和 SIMPLER (Li 等, 2024c) 提供了多样化的操作任务, 但大多数场景强调短时程交互, 或者可以在不依赖历史观测的情况下解决。

一些基准已开始考虑与记忆相关的操作任务。MemoryBench (Fang 等, 2025) 包含数量有限的记忆依赖任务, 但可复现性差, 且缺乏清晰的任务设计原则。MIKASA (Cherepanov 等, 2025) 引入了更大规模的记忆相关任务集合, 但其设计主要针对强化学习。LIBERO-Long (Liu 等, 2023) 和 RoboCerebra (Han 等, 2025) 具有长时程任务, 但任务相关信息在整个执行过程中保持可观测, 因此并不明确要求记忆。相比之下, **RMBench** 明确对操作任务中的记忆需求进行分层, 从而能够系统分析基于记忆的策略在不同任务难度级别下的表现。

2.2. 机器人操作策略

生成模型和模仿学习的最新进展催生了大量机器人操作策略, 这些策略在单个任务上取得了优异的性能 (Zhao 等, 2023; Chi 等, 2025; Ze 等, 2024; Chen 等, 2025b; Lu 等, 2024; Su 等, 2025)。受大型视觉基础模型的启发, 许多方法采用视觉-语言-动作 (Vision-Language-Action, VLA) 范式 (Wen 等, 2025a; Lin 等, 2025; Liang 等, 2025; Shen 等, 2025; Wen 等, 2025b), 策略在大规模机器人数据集上进行预训练, 并展现出更好的泛化能力。代表性示例包括 Pi0.5 和 Pi0.6 (Intelligence 等, 2025b; a)、RDT2 (Team, 2025) 和 X-VLA (Zheng 等, 2025), 以及结合未来观测预测的方法, 如 Motus (Bi 等, 2025)、CogACT (Li 等, 2024b) 和 CronusVLA (Li 等, 2025)。

尽管取得了这些进展, 大多数现有策略依赖于固定长度的观测历史, 这限制了它们在长时间跨度上有选择地保留任务相关信息的能力。这一局限性推动了近期记忆感知方法的发展, 包括记忆视觉语言动作模型 (MemoryVLA) (Shi 等人, 2025)、记忆高效机器人 (MemER) (Sridhar 等人, 2025) 和 SAM2Act (Fang 等人, 2025), 这些方法明确引入了记忆机制以支持依赖记忆的操作。基于这一研究方向, 本文提出 **Mem-0**, 一种模块化的记忆增强策略, 旨在促进对记忆组件和架构选择的系统性消融与分析。

3. RMBench

本节引入任务记忆复杂度 (Task Memory Complexity), 一种用于刻画机器人操作任务中记忆需求并指导基准设计的原则性准则。基于此, 本文提出 **RMBench**, 一个包含九个具有不同记忆需求的操作任务的仿真基准, 旨在支持在不同任务记忆复杂度水平下进行受控评估。




图 1. RMBench 任务。本文展示了 RMBench 中九个依赖记忆的任务及其关键执行步骤。任务的详细描述见附录 A。

3.1. 任务记忆复杂度 (TMC)

机器人操作通常在部分可观测条件下进行，仅凭当前观测可能不足以确定任务进展或正确的下一步动作，除非能够获取过去的信息。这种部分可观测性可能源于遮挡、延迟效应或状态混叠。重要的是，所需的过去信息并不一定对应于最近观测的连续序列，而是对应于在任意时间步出现的一小组与任务相关的观测。现有基准通常通过特定策略架构来评估记忆，但缺乏一种以任务为中心的准则来刻画随时间推移必须保留多少任务相关信息。为弥补这一不足，本文引入任务记忆

复杂度 (任务记忆复杂度 (TMC))，该指标衡量最优决策所需的最少过去信息量。

设定。我们将操作任务建模为具有潜在状态 $s_t \in \mathcal{S}$ 、观测 $o_t \in \mathcal{O}$ 和动作 $a_t \in \mathcal{A}$ 的部分可观测马尔可夫决策过程 (POMDP)。设截至时间 t 的完整交互历史为

$$h_t = (o_{1:t}, a_{1:t-1}). \quad (1)$$

本文不假设可获取完整历史，而是考虑一种记忆状态，该状态总结了过去观测中与任务相关的信息。设 $\mathcal{M}_t$ 表示由 h_t 构建的记忆表示，设 $\mathcal{M}_t^{(k)}$ 表示一种记忆状态，该状态编码了至多 k 个与任务相关的过去观测的信息。

定义。 **任务记忆复杂度** 被定义为满足以下条件的最小整数 $m \geq 0$ ：存在一个最优多-

策略 π^* 其在时间 t 的动作仅依赖于记忆 state $\mathcal{M}_t^{(m)}$ 。Formally,

$$\exists \pi^* \text{ s.t. } \pi^*(a_t | h_t) = \pi^*(a_t | \mathcal{M}_t^{(m)}), \quad \forall t. \quad (2)$$

任务标注。 任务根据其任务记忆复杂度 (Task Memory Complexity) 进行标注，使用符号 $M(0)$, $M(1)$, 或更一般地 $M(n)$ ，其中索引表示为了最优解决任务而必须保留的任务相关历史观测的数量。

解释。 $M(0)$ 表示无记忆任务，对于这类任务，当前观测足以唯一确定任务进度和最优动作。 $M(1)$ 表示需要保留单个与任务相关的过去观测以消除当前状态歧义的任务。更一般地， $M(n)$ 表示其最优决策依赖于保留 n 个与任务相关的过去观测的任务，这类任务捕捉了非局部和多步时间依赖关系。

3.2. RMBench 系统设计

RMBench 是在 RoboTwin 2.0 (Chen 等人, 2025a) 系统框架内开发的。它构建于 SAPIEN (Xiang 等人, 2020) 仿真引擎之上，并在统一流程中支持自动化数据合成与集成策略评估。该设计实现了可扩展的数据生成，以及机器人操作策略的一致且可复现的基准测试。

此外，我们提供了细粒度的语言标注，与每个动作-观测对齐。这些标注为低级交互和状态转换赋予了明确的语言描述，为下游高层推理或记忆模块的训练提供了结构化且

密集的监督信号。

3.3. RMBench 基准任务

基于所提出的任务记忆复杂度（第 3.1 节），我们设计了总共九个依赖记忆的操作任务。这些任务分为两类：五个 $M(1)$ 任务和四个 $M(n)$ 任务。每个任务的代表性关键帧如图 1 所示，详细的任务规格在附录 A 中提供。

$M(1)$ 类任务包括观察与拾取、重排积木、放回积木、交换积木和交换 T。这些任务要求策略保留单个过去观测或固定且有限数量的历史帧。成功执行依赖于在不同任务阶段动态关注与任务相关的信息。

$M(n)$ 类任务包括积木排序尝试、按压按钮、覆盖积木和电池尝试。这些任务需要反复主动探索、试错交互，或按任务特定次数重复执行，通常由外部反馈引导。因此，它们要求强大的长期记忆保持和有效的检索机制，以在较长的时间跨度内积累和利用历史信息。

4. Mem-0 策略

本节提出 **Mem-0**，一种面向记忆机制的模块化机器人策略，用于系统分析记忆机制。如图 2 所示，**Mem-0** 由规划模块和执行模块组成：规划模块基于关键记忆进行子任务级推理，执行模块利用滑动窗口和锚点记忆执行子任务。两个模块通过子任务结束分类器连接，实现闭环规划与执行。这种模块化设计支持对记忆依赖型机器人操作中不同记忆组件的作用进行细粒度分析。

4.1. 规划模块

在长时程操作任务中，端到端视觉-语言-动作模型在推理过程中容易产生误差累积和轨迹漂移。先前工作（Sridhar 等, 2025; Wen 等, 2024）通过子任务分解缓解这些问题。然而，在记忆依赖场景下，例如 RM-Bench 中的 $M(n)$ 类任务，此类方法变得不足，因为准确的子任务推理需要基于多个先前完成的子任务进行推理，例如跟踪按钮按压次数。为解决这一局限性，我们在规划模块中引入关键记忆窗口模块，该模块聚合已完成的子任务并支持记忆感知的子任务推理。

规划模块利用视觉语言模型，以视觉观测和结构化记忆为条件进行子任务级推理。在规划步骤 t ，模型接收初始观测 o_0 、任务目标 g ，和记忆状态 $\mathcal{M}_{t-1}$ 作为输入，并预测下一个子任务为

$$s_t = \mathcal{V}_{\text{plan}}(o_0, g, \mathcal{M}_{t-1}). \quad (3)$$

此处， $o_0 \in \mathbb{R}^{H \times W \times 3}$ 表示回合开始时的初始 RGB 观测， $g \in \mathcal{T}$ 表示全局任务指令。已完成任务记忆 $\mathcal{M}_{t-1}$ ，也称为关键记忆窗口，聚合了所有先前已完成的子任务，其定义为

$$\mathcal{M}_{t-1} = \{(s_i, o_i^{\text{end}})\}_{i=1}^{t-1}, \quad (4)$$

其中 $s_i \in \mathcal{T}$ 是第 i 个子任务的文本描述， $o_i^{\text{end}} \in \mathbb{R}^{H \times W \times 3}$ 是该子任务终止时的 RGB 观测。

以 $\mathcal{M}_{t-1}$ 为条件，使视觉-语言模型能够显式地推理先前已执行的子任务及其对应的视觉结果，从而支持超越基于单帧观测规划的依赖记忆的子任务推理。

与现有方法在每个观测帧推断新子任务、因此在 T 个时间步长的范围内需要 $O(T)$ 次规划调用不同，规划模块仅在子任务终止时进行子任务推理，该终止由子任务结束分类器（第 4.3 节）识别。对于由 N 个子任务组成的长程任务，其中 $N \ll T$ ，此设计将规划调用次数减少到 $O(N)$ 。因此，执行模块可以在每个子任务内以高控制频率运行，而不受规划延迟的限制，从而大幅降低计算开销并加速任务执行。

4.2. 执行模块

尽管子任务级规划对许多依赖记忆的任务有效，但某些任务并不适合显式的子任务分解。例如，在 $M(1)$ 类任务（如 Swap T）中，对象 T 的目标放置方向无法通过语言可靠地指定。此外，过于细粒度的子任务分解会增加标注工作量和规划延迟，从而降低整体执行效率。为解决这些局限性，我们在执行模块中引入了锚点记忆模块和滑动记忆窗口模块。该设计使执行模块能够通过维护持久的锚点记忆以及短期瞬态记忆，无需额外的子任务分解即可处理 $M(1)$ 类任务。

执行模块使用基于扩散的策略执行当前子任务，该策略以多模态每




图 2. Mem-0 流程。Mem-0 包含一个规划模块和一个执行模块，二者通过子任务结束分类器连接。规划模块根据任务指令、观测和关键帧记忆生成高层子任务，而执行模块利用当前观测、子任务以及融合的锚定记忆和滑动记忆，在基于扩散的策略中生成低层动作。子任务完成后，存储一个关键帧，以实现迭代规划与执行，直至任务完成。

感知与记忆。视觉-语言模型 (VLM)，记为 $\mathcal{V}_{\text{exec}}(\cdot)$ ，将当前 RGB 观测 $o_t \in \mathbb{R}^{H \times W \times 3}$ 和子任务指令 $s_t \in \mathcal{T}$ 编码为图像和文本标记嵌入：

$$(\mathbf{z}_t^{\text{img}}, \mathbf{z}_t^{\text{text}}) = \mathcal{V}_{\text{exec}}(o_t, s_t). \quad (5)$$

然后应用平均池化以获得紧凑的潜在表示 representations $\mathbf{z}_t^{\text{img}} = \text{MeanPool}(\mathbf{Z}_t^{\text{img}})$ and $\mathbf{z}_t^{\text{text}} = \text{MeanPool}(\mathbf{Z}_t^{\text{text}})$.

为了融入记忆，图像潜在表示关注两个记忆缓冲区：锚定记忆 $\mathcal{A}$ 和滑动记忆窗口 $\mathcal{S}_t$ 。记忆条件表示通过交叉注意力计算：

$$\tilde{\mathbf{z}}_t^l = \text{CrossAttn}(\mathbf{z}_t^{\text{img}}, \mathcal{M}_t^m) + \mathbf{z}_t^{\text{img}}, \quad (6)$$

where $l \in \{\text{anchor}, \text{slide}\}$, $\mathcal{M}_t^{\text{anchor}} = \mathcal{A}$ and $\mathcal{M}_t^{\text{slide}} = \mathcal{S}_t$. The fused token are concatenated with the text token to form the conditioning vector $\mathbf{c}_t = [\tilde{\mathbf{z}}_t^{\text{anchor}}; \tilde{\mathbf{z}}_t^{\text{slide}}; \mathbf{z}_t^{\text{text}}]$.

在时间步 t 的注意力之后，图像潜在表示被迫加到滑动记忆窗口：

$$\mathcal{S}_{t+1} = \text{Trunc}_K(\mathcal{S}_t \cup \{\mathbf{z}_t^{\text{img}}\}) \quad (7)$$

其中 $\text{Trunc}_K(\cdot)$ 保留最近的 K 个元素。在子任务开始时 ($t = 0$)，图像潜在表示 $\mathbf{z}_0^{\text{img}}$ 被

存储为锚定记忆 $\mathcal{A} = \{\mathbf{z}_0^{\text{img}}\}$ ，该记忆在整个子任务期间保持不变。子任务终止时，两个记忆缓冲区均被重置： $\mathcal{A} \leftarrow \emptyset, \mathcal{S}_t \leftarrow \emptyset$ 。

对于动作生成，我们采用具有固定动作视野 $H = 30$ 的扩散 Transformer (DiT)。设 $\mathbf{a}_{t:t+H-1}^{\epsilon} \in \mathbb{R}^{H \times d_a}$ 表示通过向真实动作序列添加高斯噪声而获得的含噪动作序列，并设 $\hat{\mathbf{a}}_{t:t+H-1} \in \mathbb{R}^{H \times d_a}$ 表示模型生成的相应去噪预测。在时间步 t ，DiT 预测去噪动作序列

$$\hat{\mathbf{a}}_{t:t+H-1} = \text{DiT}(\mathbf{a}_{t:t+H-1}^{\epsilon}, \mathbf{x}_t, \mathbf{c}_t). \quad (8)$$

预测序列的前缀，记为 $\hat{\mathbf{a}}_{t:t+\Delta-1}$ ，其中 $1 \leq \Delta \leq H$ ，在下一步重新规划之前作为控制命令执行。

4.3. 子任务结束分类器

为了实现规划模块与执行模块之间的闭环交互，本文引入子任务结束分类器来检测子任务完成情况。该分类器实现为一个轻量级多层感知机 (MLP)，作用于条件向量 $\mathbf{c}_t$ 并输出二值信号 $\mathcal{C}_{\text{end}}(\mathbf{c}_t) \in \{0, 1\}$ ，指示当前子任务在时间步 t 是正在进行还是已经终止。

为了提高鲁棒性并避免因瞬态噪声导致的过早终止

本文强制执行时序一致性准则。仅当分类器连续 $L = 8$ 个时间步预测终止时，才认为子任务完成：

$$\sum_{i=t-L+1}^t C_{\text{end}}(\mathbf{c}_i) = L. \quad (9)$$

一旦满足该条件，子任务即被终止，最终观测 o_t^{end} 连同相应的子任务描述 s_t 被传递给规划模块，以触发下一轮子任务级推理。该机制在高层规划与低层执行之间建立了闭环，实现了协调且迭代的子任务推理与执行。

5. 实验

本文设计了一组实验来验证三个关键目标：（1）评估现有操作策略和 Mem-0 在 RMBench 上的性能，从而刻画它们在不同难度级别下处理记忆依赖任务的能力；（2）对 Mem-0 架构进行系统性消融研究，以分析不同模块设计如何影响记忆密集型操作任务的性能；（3）开展真实世界机器人实验，以评估 Mem-0 在仿真之外的有效性和泛化能力。

除 SAPIEN 平台外，RMBench 还在 NVIDIA Isaac Lab - Arena 1 上实现。

5.1. 在 RMBench 上对策略的评估

我们在 RMBench 上对多种策略进行了基准测试，包括非预训练方法、预训练方法以及以记忆为中心的 Mem-0 策略。具体而言，DP 和 ACT 作为非预训练基线，Pi0.5 和 X-VLA 代表预训练方法。在 $M(1)$ 和 $M(n)$ 两种设置下的每个任务中，所有模型均使用 50 条专家演示进行训练，并在 100 个 rollout 回合上进行评估。

对于 $M(1)$ 类任务，Mem-0 在不进行子任务分解的情况下运行，报告的结果主要反映执行模块的能力。相比之下，对于 $M(n)$ 类任务，在关键决策点进行子任务分解，结果体现了规划模块和执行模块的联合性能。所有基线方法均在不进行子任务分解的情况下训练。我们在表 1 中报告了所有方法的成功率。

实验结果表明，非预训练和预训练基线在依赖记忆的任务上均持续表现不佳。这一现象可归因于大多数现有模型是在马尔可夫 1 <https://github.com/isaac-sim/IsaacLab-Arena>

假设下设计的，即下一个动作仅由当前观测决定。当应用于 RMBench 中的非马尔可夫任务时，这些模型无法在缺乏任务相关历史信息的情况下推断出正确动作，导致性能大幅下降。基线方法的代表性失败案例如图 3 所示。

相比之下，Mem-0 在大多数任务上表现出显著的性能提升，表明显式引入记忆机制的有效性。平均而言，Mem-0 在 $M(1)$ 任务上相对于基线将成功率提高了 38.4%，在 $M(n)$ 任务上提高了 21.2%，凸显了记忆模块在解决 RMBench 中依赖记忆的操作任务方面的关键作用。

尽管取得了这些进展，记忆零号（Mem-0）在需要强语义理解的任务上仍表现出局限性，例如观察与拾取任务，其中预训练模型因大规模预训练而保持优势。在精细操作任务（如交换 T）中，记忆零号的放置精度有限，仅带来边际性能提升。在按压按钮任务中，单次按压动作幅度小，进一步增加了可靠终止检测的难度：子任务结束分类器可能无法一致地识别任务完成，导致重复按压或漏接触，最终成功率为零。

这些结果凸显了当前记忆零号设计中存在的若干开放挑战。更多可视化与分析见附录 C 及补充材料。尽管如此，整体性能趋势清楚地表明，显式记忆建模在记忆基准（RMBench）的大多数依赖记忆的任务上带来了显著改进。

5.2. 记忆相关模块分析

本节分析记忆零号中各个组件的贡献，为有效的记忆模块设计提供洞见。为此，我们进行了四项消融研究：

(1) 无锚点：移除执行模块中的锚点记忆模块，图像令牌不再与锚点记忆令牌融合。

(2) 无滑动：移除执行模块中的滑动记忆模块，图像令牌不再与历史滑动记忆令牌融合。

(3) 无关键记忆：规划模块中的关键记忆窗口被移除，子任务推理仅依赖单帧观测。

(4) 真实分类器：子任务结束分类器被移除，子任务终止由模拟器提供的真实信号决定。

表 1. RMBench 基准测试结果。RMBench 包含九个操作任务，跨越任务记忆复杂度的 $M(1)$ 和 $M(n)$ 级别。我们报告了五种策略的成功率，每种策略使用 50 个合成演示训练，并在 100 次运行中评估。（粗体：最佳；下划线：次佳；绿色：相对于次佳的相对提升）。

Tasks	TMC	DP	ACT	Pi0.5	X-VLA	Mem-0 (ours)
Observe and Pick Up	$M(1)$	1%	1%	9%	9%	4%
Rearrange Blocks	$M(1)$	0%	<u>29%</u>	13%	13%	89%
Put Back Block	$M(1)$	0%	0%	11%	<u>18%</u>	90%
Swap Blocks	$M(1)$	11%	2%	24%	16%	67%
Swap T	$M(1)$	20%	2%	<u>15%</u>	3%	14%
Average	$M(1)$	6.4%	6.8%	<u>14.4%</u>	11.8%	52.8% (+38.4%)
Battery Try	$M(n)$	10%	19%	16%	26%	28%
Blocks Ranking Try	$M(n)$	<u>10%</u>	0%	6%	1%	18%
Cover Blocks	$M(n)$	0%	0%	0%	<u>2%</u>	68%
Press Button	$M(n)$	0%	0%	0%	0%	0%
Average	$M(n)$	5%	4.8%	5.5%	<u>7.3%</u>	28.5% (+21.2%)
Total Average	/	5.8%	5.9%	<u>10.4%</u>	9.8%	42.0% (+31.6%)

表 2. 消融实验。（粗体：最佳结果；下划线：次佳结果）。

$M(1)$ Tasks	Observe and Pick Up	Rearrange Blocks	Put Back Block	Swap Blocks	Swap T	Average
Vanilla (ours)	4%	89%	90%	67%	<u>14%</u>	52.8%
w/o Anchor	4%	<u>73%</u>	35%	15%	7%	26.8%
w/o Sliding	<u>3%</u>	62%	<u>78%</u>	<u>39%</u>	20%	<u>40.4%</u>
$M(n)$ Tasks	Battery Try	Blocks Ranking Try	Cover Blocks	Press Button	Average	
Vanilla (ours)	28%	<u>18%</u>	68%	0%	<u>28.5%</u>	
w/o Key	13%	1%	5%	0%	4.8%	
w/o Anchor	14%	0%	92%	<u>1%</u>	26.8%	
w/o Sliding	17%	0%	<u>84%</u>	0%	25.3%	
GT Classifier	30%	45%	92%	14%	45.3%	

由于 Mem-0 不对 $M(1)$ 型任务进行子任务分解， $M(1)$ 的消融实验仅包括无锚点和无滑动设置。所有消融结果见表 2。

锚点记忆性能分析。与原始设置相比，移除锚点记忆（w/o Anchor）导致大多数任务的成功率显著下降。对评估视频的定性检查表明，尽管滑动记忆窗口仍然活跃，但随着相关记忆随时间被逐出，Mem-0 逐渐失去对任务关键信息的访问。因此，策略无法关注正确决策所需的基本线索，并表现出与图 3 中观察到的类似的错误行为。这些发现表明，对于依赖记忆的操作任务，策略必须在整个执行过程中明确识别并保留任务关键信息，以实现可靠的任务完成。

滑动记忆性能分析。滑动记忆窗口主要捕获短期历史运动趋势。实验表明，即使有锚点信息的支持，移除该模块仍会降低大多数任务的性能，成功率

低于原始模型。定性结果进一步表明，在没有滑动记忆的情况下，Mem-0 表现出不稳定和振荡行为；例如，在按钮按压任务中，策略无法从单次观察推断按钮是否已被按下，导致过早终止或冗余动作并最终失败。

有趣的是，在 Swap T 任务上，无滑动设置的表现优于原始模型。这种改进可能源于训练数据中固定的运动模式以及该任务对 T 形物体初始方向的高度敏感性。移除滑动记忆使策略的依赖转向锚点信息，并减少来自瞬态运动线索的干扰，从而获得更好的性能。这一观察表明，滑动记忆既可以作为促进因素，也可以作为干扰源，凸显了协调滑动记忆和锚点记忆的重要性。

关键记忆性能分析。在关键设置下，子任务推断仅 w/o 基于单帧观察，成功率相对于原始配置显著下降。定性分析表明，对于需要长期记忆的 $M(n)$ 型任务



图 3. 基线典型错误可视化。由于基线仅根据当前观察预测下一个动作，因此在需要持续记忆的非马尔可夫任务上难以可靠执行。

为后续运动决策提供信息，当仅依赖当前观测时，规划模块无法可靠地推断正确的下一子任务，导致任务失败。这些结果表明，在依赖记忆的操作任务中，保留关键记忆对于准确可靠的子任务推断至关重要。

Analysis on the Classifier between the Planning and Execution Module. Mem-0 中的子任务结束分类器具有两个主要功能。首先，它通过仅在必要时触发高层推理来连接规划模块与执行模块，从而降低推理成本和延迟。其次，它通过子任务分解实现任务简化。与在每个时间步执行高层子任务推理的 MemER (Sridhar 等人, 2025) 相比，Mem-0 以约 5–10 赫兹的规划频率运行，而 MemER 以 1–2 赫兹运行。

此外，使用真值分类器所取得的优异性能凸显了子任务分解相对于完全端到端方法的有效性。然而，Mem-0 中当前的分类器设计相对简单，在检测子任务转换方面缺乏精确性。不准确的转换时机可能对规划模块中的子任务推断产生负面影响。这些结果表明，需要更精细的分类器设计，以通过更准确的子任务终止信号实现规划模块与执行模块之间更紧密的协调。

5.3. 真实世界实验

表 3. 真实世界实验结果。

Tasks	ACT	Pi0.5	Mem-0 (ours)
Put Back Block	0.0%	10.0%	17.5%
Rearrange Blocks	0.0%	7.5%	37.5%
Cover Blocks	0.0%	0.0%	12.5%
Average	0.00%	5.83%	22.50%




图 4. 真实世界实验任务。上方展示了真实世界实验设置。

为评估 Mem-0 在真实世界中的性能，我们在三个与 RMBench 对齐的物理操作任务上对其进行评估：放回积木、重排积木和覆盖积木。我们将 Mem-0 与 ACT 和 Pi0.5 进行比较，所有数据收集和评估均在 X-One 双臂机器人平台上进行。对于每个任务，我们收集 100 个真实世界演示，并在 40 次展开试验中评估训练后的策略，以成功率作为主要度量。评估结果汇总于表 3。

结果表明, Mem-0 在真实世界实验中优于两种基线策略。进一步观察发现, Mem-0 的大多数失败源于不精确的块操作, 而非高层任务规划。该行为可能归因于两个因素。首先, 真实世界数据采集涉及多样化的人类行为, 这引入了额外的变异性, 并增加了学习一致的低层操作技能的难度。其次, Mem-0 的训练未经过专门的机器人操作预训练, 这可能限制了其泛化细粒度运动行为的能力。通过改进低层预训练和更结构化的真实世界数据采集来解决这些局限性, 构成了未来工作的重要方向。

6. 结论

本文提出 RMBench (基准) 和 Mem-0 (策略), 以系统评估机器人操作中的记忆能力, 揭示现有策略的记忆局限性, 以及不同架构选择 (如锚定记忆、滑动记忆和键记忆) 如何影响记忆性能, 从而为有效依赖记忆的机器人操作中记忆机制的原则性集成提供初步洞见。

关于未来工作, 有前景的方向包括改进记忆表示与融合、更稳健的子任务终止准则, 以及集成预训练以增强语义理解和泛化。我们希望 RMBench 能促进可扩展的、记忆感知的机器人操作的原则性进展。

致谢

我们感谢 Xspark AI 支持我们的真实世界实验, 感谢 D-Robotics 提供计算资源。同时感谢 NVIDIA Isaac Lab - Arena 团队的技术支持。

影响声明

本文介绍的工作旨在推动机器学习领域的发展。我们的工作可能产生许多潜在的社会影响, 但我们认为无需在此特别强调任何一项。

参考文献

Bi, H., Tan, H., Xie, S., Wang, Z., Huang, S., Liu, H., Zhao, R., Feng, Y., Xiang, C., Rong, Y., et al. Motus: A unified latent action world model. *arXiv preprint arXiv:2512.13030*, 2025.

Chen, B., Wan, W., Chen, T., Guo, X., Xu, C., Qi, Y., Zhang,

H., Wu, L., Xu, T., Li, Z., et al. Univtac: A unified simulation platform for visuo-tactile manipulation data generation, learning, and benchmarking. *arXiv preprint arXiv:2602.10093*, 2026.

Chen, T., Chen, Z., Chen, B., Cai, Z., Liu, Y., Li, Z., Liang, Q., Lin, X., Ge, Y., Gu, Z., et al. Robotwin 2.0: A scalable data generator and benchmark with strong domain randomization for robust bimanual robotic manipulation. *arXiv preprint arXiv:2506.18088*, 2025a.

Chen, T., Mu, Y., Liang, Z., Chen, Z., Peng, S., Chen, Q., Xu, M., Hu, R., Zhang, H., Li, X., et al. G3flow: Generative 3d semantic flow for pose-aware and generalizable object manipulation. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pp. 1735–1744, 2025b.

Cherepanov, E., Kachaev, N., Kovalev, A. K., and Panov, A. I. Memory, benchmark & robots: A benchmark for solving complex tasks with reinforcement learning. *arXiv preprint arXiv:2502.10550*, 2025.

Chi, C., Xu, Z., Feng, S., Cousineau, E., Du, Y., Burchfiel, B., Tedrake, R., and Song, S. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, 44(10-11): 1684–1704, 2025.

Fang, H., Grotz, M., Pumacay, W., Wang, Y. R., Fox, D., Krishna, R., and Duan, J. Sam2act: Integrating visual foundation model with a memory architecture for robotic manipulation. *arXiv preprint arXiv:2501.18564*, 2025.

Han, S., Qiu, B., Liao, Y., Huang, S., Gao, C., Yan, S., and Liu, S. Robocerebra: A large-scale benchmark for long-horizon robotic manipulation evaluation. *arXiv preprint arXiv:2506.06677*, 2025.

Intelligence, P., Amin, A., Aniceto, R., Balakrishna, A., Black, K., Conley, K., Connors, G., Darpinian, J., Dhabalia, K., DiCarlo, J., Driess, D., Equi, M., Esmail, A., Fang, Y., Finn, C., Glossop, C., Godden, T., Goryachev, I., Groom, L., Hancock, H., Hausman, K., Hussein, G., Ichter, B., Jakubczak, S., Jen, R., Jones, T., Katz, B., Ke, L., Kuchi, C., Lamb, M., LeBlanc, D., Levine, S., Li-Bell, A., Lu, Y., Mano, V., Mothukuri, M., Nair, S., Pertsch, K., Ren, A. Z., Sharma, C., Shi, L. X., Smith, L., Springenberg, J. T., Stachowicz, K., Stoeckle, W., Sverdlow, A., Tanner, J., Torne, M., Vuong, Q., Walling, A., Wang, H., Williams, B., Yoo, S., Yu, L., Zhilinsky, U., and Zhou, Z. $\pi_{0.6}^*$: a vla that learns from experience, 2025a. URL <https://arxiv.org/abs/2511.14759>.

Intelligence, P., Black, K., Brown, N., Darpinian, J., Dhabalia, K., Driess, D., Esmail, A., Equi, M., Finn, C.,

- Fusai, N., Galliker, M. Y., Ghosh, D., Groom, L., Hausman, K., Ichter, B., Jakubczak, S., Jones, T., Ke, L., LeBlanc, D., Levine, S., Li-Bell, A., Mothukuri, M., Nair, S., Pertsch, K., Ren, A. Z., Shi, L. X., Smith, L., Springenberg, J. T., Stachowicz, K., Tanner, J., Vuong, Q., Walke, H., Walling, A., Wang, H., Yu, L., and Zhilinsky, U. $\pi_{0.5}$: a vision-language-action model with open-world generalization, 2025b. URL <https://arxiv.org/abs/2504.16054>.
- Kwon, W., Li, Z., Zhuang, S., Sheng, Y., Zheng, L., Yu, C. H., Gonzalez, J. E., Zhang, H., and Stoica, I. Efficient memory management for large language model serving with pagedattention. In *Proceedings of the ACM SIGOPS 29th Symposium on Operating Systems Principles*, 2023.
- Lan, Z., Jiang, Y., Wang, R., Xie, X., Zhang, R., Zhu, Y., Li, P., Yang, T., Chen, T., Gao, H., et al. Autobio: A simulation and benchmark for robotic automation in digital biology laboratory. *arXiv preprint arXiv:2505.14030*, 2025.
- Li, C., Zhang, R., Wong, J., Gokmen, C., Srivastava, S., Martín-Martín, R., Wang, C., Levine, G., Ai, W., Martinez, B., Yin, H., Lingelbach, M., Hwang, M., Hiranaka, A., Garlanka, S., Aydin, A., Lee, S., Sun, J., Anvari, M., Sharma, M., Bansal, D., Hunter, S., Kim, K.-Y., Lou, A., Matthews, C. R., Villa-Renteria, I., Tang, J. H., Tang, C., Xia, F., Li, Y., Savarese, S., Gweon, H., Liu, C. K., Wu, J., and Fei-Fei, L. Behavior-1k: A human-centered, embodied ai benchmark with 1,000 everyday activities and realistic simulation. *arXiv preprint arXiv:2403.09227*, 2024a.
- Li, H., Yang, S., Chen, Y., Tian, Y., Yang, X., Chen, X., Wang, H., Wang, T., Zhao, F., Lin, D., et al. Cronusvla: Transferring latent motion across time for multi-frame prediction in manipulation. *arXiv preprint arXiv:2506.19816*, 2025.
- Li, Q., Liang, Y., Wang, Z., Luo, L., Chen, X., Liao, M., Wei, F., Deng, Y., Xu, S., Zhang, Y., et al. Cogact: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation. *arXiv preprint arXiv:2411.19650*, 2024b.
- Li, X., Hsu, K., Gu, J., Pertsch, K., Mees, O., Walke, H. R., Fu, C., Lunawat, I., Sieh, I., Kirmani, S., Levine, S., Wu, J., Finn, C., Su, H., Vuong, Q., and Xiao, T. Evaluating real-world robot manipulation policies in simulation, 2024c. URL <https://arxiv.org/abs/2405.05941>.
- Liang, Z., Li, Y., Yang, T., Wu, C., Mao, S., Nian, T., Pei, L., Zhou, S., Yang, X., Pang, J., et al. Discrete diffusion vla: Bringing discrete diffusion to action decoding in vision-language-action policies. *arXiv preprint arXiv:2508.20072*, 2025.
- Lin, M., Ding, P., Wang, S., Zhuang, Z., Liu, Y., Tong, X., Song, W., Lyu, S., Huang, S., and Wang, D. Hif-vla: Hindsight, insight and foresight through motion representation for vision-language-action models. *arXiv preprint arXiv:2512.09928*, 2025.
- Liu, B., Zhu, Y., Gao, C., Feng, Y., Liu, Q., Zhu, Y., and Stone, P. Libero: Benchmarking knowledge transfer for lifelong robot learning, 2023. URL <https://arxiv.org/abs/2306.03310>.
- Lu, G., Gao, Z., Chen, T., Dai, W., Wang, Z., Ding, W., and Tang, Y. Manicm: Real-time 3d diffusion policy via consistency model for robotic manipulation. *arXiv preprint arXiv:2406.01586*, 2024.
- Mu, Y., Chen, T., Chen, Z., Peng, S., Lan, Z., Gao, Z., Liang, Z., Yu, Q., Zou, Y., Xu, M., et al. Robotwin: Dual-arm robot benchmark with generative digital twins. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pp. 27649–27660, 2025.
- Nasiriany, S., Maddukuri, A., Zhang, L., Parikh, A., Lo, A., Joshi, A., Mandlekar, A., and Zhu, Y. Robocasa: Large-scale simulation of everyday tasks for generalist robots. *arXiv preprint arXiv:2406.02523*, 2024.
- Shen, W., Liu, Y., Wu, Y., Liang, Z., Gu, S., Wang, D., Nian, T., Xu, L., Qin, Y., Pang, J., et al. Expertise need not monopolize: Action-specialized mixture of experts for vision-language-action learning. *arXiv preprint arXiv:2510.14300*, 2025.
- Shi, H., Xie, B., Liu, Y., Sun, L., Liu, F., Wang, T., Zhou, E., Fan, H., Zhang, X., and Huang, G. Memoryvla: Perceptual-cognitive memory in vision-language-action models for robotic manipulation. *arXiv preprint arXiv:2508.19236*, 2025.
- Sridhar, A., Pan, J., Sharma, S., and Finn, C. Memer: Scaling up memory for robot control via experience retrieval. *arXiv preprint arXiv:2510.20328*, 2025.
- Su, Y., Zhan, X., Fang, H., Xue, H., Fang, H.-S., Li, Y.-L., Lu, C., and Yang, L. Dense policy: Bidirectional autoregressive learning of actions. *arXiv preprint arXiv:2503.13217*, 2025.
- Tao, S., Xiang, F., Shukla, A., Qin, Y., Hinrichsen, X., Yuan, X., Bao, C., Lin, X., Liu, Y., kai Chan, T., Gao, Y., Li, X., Mu, T., Xiao, N., Gurha, A., Rajesh, V. N., Choi, Y. W., Chen, Y.-R., Huang, Z., Calandra, R., Chen, R., Luo, S., and Su, H. Maniskill3: Gpu parallelized robotics simulation and rendering for generalizable embodied ai, 2025. URL <https://arxiv.org/abs/2410.00425>.

- Team, R. Rdt2: Enabling zero-shot cross-embodiment generalization by scaling up umi data, September 2025. URL <https://github.com/thu-ml/RDT2>.
- Wang, Y., Wu, R., Chen, Y., Wang, J., Liang, J., Zhu, Z., Geng, H., Malik, J., Abbeel, P., and Dong, H. Dexgarmentlab: Dexterous garment manipulation environment with generalizable policy, 2025. URL <https://arxiv.org/abs/2505.11032>.
- Wen, J., Zhu, Y., Zhu, M., Tang, Z., Li, J., Zhou, Z., Liu, X., Shen, C., Peng, Y., and Feng, F. Diffusionvla: Scaling robot foundation models via unified diffusion and autoregression. In *Forty-second International Conference on Machine Learning*.
- Wen, J., Zhu, M., Zhu, Y., Tang, Z., Li, J., Zhou, Z., Li, C., Liu, X., Peng, Y., Shen, C., and Feng, F. Diffusionvla: Scaling robot foundation models via unified diffusion and autoregression. *arXiv preprint arXiv:None*, 2024.
- Wen, J., Zhu, Y., Li, J., Tang, Z., Shen, C., and Feng, F. Dexvla: Vision-language model with plug-in diffusion expert for general robot control. *arXiv preprint arXiv:2502.05855*, 2025a.
- Wen, J., Zhu, Y., Li, J., Zhu, M., Tang, Z., Wu, K., Xu, Z., Liu, N., Cheng, R., Shen, C., et al. Tinyvla: Towards fast, data-efficient vision-language-action models for robotic manipulation. *IEEE Robotics and Automation Letters*, 2025b.
- Xiang, F., Qin, Y., Mo, K., Xia, Y., Zhu, H., Liu, F., Liu, M., Jiang, H., Yuan, Y., Wang, H., et al. Sapien: A simulated part-based interactive environment. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 11097–11107, 2020.
- Ze, Y., Zhang, G., Zhang, K., Hu, C., Wang, M., and Xu, H. 3d diffusion policy: Generalizable visuomotor policy learning via simple 3d representations. *arXiv preprint arXiv:2403.03954*, 2024.
- Zhao, T. Z., Kumar, V., Levine, S., and Finn, C. Learning fine-grained bimanual manipulation with low-cost hardware, 2023. URL <https://arxiv.org/abs/2304.13705>.
- Zheng, J., Li, J., Wang, Z., Liu, D., Kang, X., Feng, Y., Zheng, Y., Zou, J., Chen, Y., Zeng, J., Zhang, Y.-Q., Pang, J., Liu, J., Wang, T., and Zhan, X. X-vla: Soft-prompted transformer as scalable cross-embodiment vision-language-action model, 2025. URL <https://arxiv.org/abs/2510.10274>.
- Zheng, Y., Zhang, R., Zhang, J., Ye, Y., Luo, Z., Feng, Z., and Ma, Y. Llamafactory: Unified efficient fine-tuning of 100+ language models. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations)*, Bangkok, Thailand, 2024. Association for Computational Linguistics. URL <http://arxiv.org/abs/2403.13372>.

A. 人民币基准任务描述

表 4. 人民币基准的任务描述。

<i>Task</i>	Description
<i>Observe and Pick Up</i>	A reference object is placed on a shelf, and multiple objects are placed on the table. The robot first observes the reference object while remaining stationary. After the reference object is hidden, the robot must pick up the matching object from the table.
<i>Rearrange Blocks</i>	Two pads and a button are placed on the table. One block is positioned between the two pads, and another block is placed on one of the pads. The robot moves the middle block onto a pad, presses the button, and then moves the other block to the middle position.
<i>Put Back Block</i>	Four pads are arranged around a central position, with one block placed on one of the pads. The robot moves the block to the center, presses the button, and then returns the block to its original pad.
<i>Swap Block</i>	Three pads and a button are placed on the table, with two blocks placed on different pads. The robot uses the empty pad to swap the positions of the two blocks and then presses the button.
<i>Swap T</i>	Two T-shaped blocks with different colors are placed on the table. The robot picks up both blocks and swaps their positions and orientations.
<i>Battery Try</i>	Two batteries with random orientations and a dual-slot battery holder are placed on the table. The robot repeatedly attempts different insertion orders, placing both batteries into the holder with the correct orientations until the insertion succeeds.
<i>Blocks Ranking Try</i>	Three blocks of different colors are randomly arranged on the table, along with a button. The robot repeatedly attempts different block arrangements and presses the button to confirm until the correct ordering is achieved.
<i>Cover Blocks</i>	Three colored blocks (red, green, and blue) and three covers are placed on the table. The robot covers the blocks from left to right, then uncovers them in red–green–blue order and returns the covers to their original positions.
<i>Press Button</i>	Three buttons (left, middle, and right) and two single-digit number tiles are placed on the table. The robot presses the left button the number of times indicated by the left digit, presses the middle button the number of times indicated by the right digit, and then presses the right button to confirm.

B. 训练细节

B.1. 规划模块

在规划模块中，我们通过 LLaMA-Factory (Zheng 等人, 2024) 使用 LoRA 对视觉-语言模型 (Qwen3-VL-8B-Instruct) 进行微调，以实现对关键记忆的推理。微调后，我们使用 vLLM (Kwon 等人, 2023) 部署模型，以实现高效加载和推理。用于视觉-语言模型微调的关键超参数总结在表 5 中。训练在 8 块 NVIDIA A800 GPU 上进行，单个任务的训练时长约为半小时。

表 5. 微调 Mem-O 规划模块的超参数。

Configuration	Finetuning Type	LoRA Rank	Batch Size	Learning Rate	Epochs	LR Scheduler	Warmup Ratio	Dtype
Value	LoRA	8	16	1.0×10^{-4}	25	Cosine	0.1	bf16

B.2. 执行模块

在本节中，我们详细介绍了 Mem-0 中执行模块（Execution Module）所采用的训练基础设施、训练组织策略以及超参数配置。

B.2.1. 训练基础设施与时间预算

Mem-0 的执行模块采用单任务训练策略，即针对每个特定任务从头开始训练模型。训练在 8 块 NVIDIA A800 GPU 上进行，全局批大小为 448，共迭代 30K 次。单个任务的训练时长约为 18 小时。

B.2.2. 训练组织策略

前向传播策略 鉴于 Mem-0 以记忆为中心的架构，我们采用了一种专门的训练方法论。在每个批次内，视觉语言模型（VLM）令牌生成与基于 DiT 的动作块生成过程并行执行。相反，滑动记忆（Sliding Memory）与锚定记忆（Anchor Memory）的融合要求数据具有时间完整性；因此，该阶段串行处理，确保一个回合内的所有帧保持顺序对齐。

这种方法保证了 VLM 令牌的有效利用。此外，我们在训练期间维护一个全局数据结构来存储每个回合的记忆信息，从而促进跨批次的令牌无缝利用。

数据加载器实现 因此，数据加载器经过定制设计以适配该架构。回合尽可能均匀地分配到所有图形处理器上。每个图形处理器使用特定数量的工作进程处理其分配的回合，并独立管理数据加载器的重置。由于分配的随机性，随着训练迭代的推进，全局批次内的帧在时间上逐渐失去同步。这使得模型能够同时从跨越不同时间步的数据中学习。

B.2.3. 超参数配置

表 6 总结了关键训练超参数。为平衡不同模块的学习率需求，我们采用了分组学习率策略，并配合带线性预热的余弦学习率调度。在数值精度方面，视觉语言模型和记忆库组件以 bfloat16 运行，而所有其他模块使用 float32。此外，对于视觉输入，图像被调整为 224×224 ，并通过帧独立的颜色抖动进行轻度数据增强，旨在提升模型的泛化能力。

表 6. 训练记忆 0 执行模块的超参数。

Configuration	Value	Configuration	Value
Batch Size	448	LR (Base)	1.0×10^{-5}
Iterations	30,000	LR (VLM)	1.0×10^{-5}
Max Grad. Norm	2.5	LR (Action Head)	1.0×10^{-4}
LR Scheduler	Cosine	LR (Classifier)	1.0×10^{-4}
Warmup Ratio	0.05	Min LR (Base)	1.0×10^{-6}
Optimizer	AdamW	Min LR (VLM)	1.0×10^{-6}
Momentum	$\beta_1, \beta_2 = 0.9, 0.999$	Min LR (Action Head)	5.0×10^{-6}
Weight Decay	0.005	Min LR (Classifier)	5.0×10^{-6}
Image Resize	224×224	Workers per GPU	2
Image Aug.	ColorJitter [†]		

[†] 抖动: (0.1, 0.1, 0.1, 0)

C. 记忆 0 中失败案例的额外可视化与分析

尽管记忆 0 相较于基线方法展现出显著改进，其架构设计仍留有广阔的探索空间。本节中，我们呈现记忆 0 表现欠佳的典型实例，旨在为未来研究提供有价值的洞见。




图 5. 观察与拾取的失败示例。（上）被颜色和形状相似的物体混淆。（中）被相同物体形态混淆。（下）普遍无法识别目标，导致机器人抓取平均位置或非预期位置。




图 6. 交换积木任务的失败示例。（上）完成单个子任务后过早终止。（中）完成两个子任务后过早终止。（下）未能按时终止，导致启动冗余子任务。




图 7. 重新排列积木任务的失败示例。Mem-0 冗余按下按钮，导致任务失败。

C.1. Failures Analysis for $M(1)$ Tasks

对于 $M(1)$ 任务，除了图 3 中展示的失败外，我们在下文总结了 Mem-0 遇到的代表性错误。

观察与拾取及交换积木 图 5 展示了观察与拾取任务中的典型失败模式，其中 Mem-0 未能准确识别目标物体。类似地，图 6 展示了交换积木任务中关于交换序列终止的误判示例，导致确认按钮在不适当的时机被按下。

这些实例表明，锚定记忆实际上在整个任务过程中持续施加影响。因此，模型必须持续关注锚定记忆，并智能地调节其对动作预测的贡献程度。

尽管如此，我们的消融研究已经证明了锚定记忆在 Mem-0 架构中带来的显著性能提升，其影响在重新排列积木和放回积木等任务中尤为突出。

重新排列积木 另一方面，图 7 展示了“重新排列积木”任务中的失败案例，其中 Mem-0 执行了过多的按钮按压，我们将此行为归因于滑动记忆模块的局限性。消融研究的定量结果显示，当省略滑动记忆时，该任务的性能显著下降。通过分析视频回放，我们发现没有滑动记忆时，冗余按钮按压事件的频率显著增加，这被确定为主要失败模式。这些发现表明，尽管当前的滑动记忆提供了显著的性能提升，但仍有进一步改进的潜力。

总结。 针对这些观察结果，我们认为一个潜在的改进方向是探索更丰富的表示融合机制，以提高锚点记忆和滑动记忆的利用率。这些进步将进一步提升模型在更复杂多变场景中的性能和稳定性。此外，增强现有视觉语言模型架构的视觉处理能力，有望在“观察并拾取”等任务中取得更好的结果。

C.2. Failures Analysis for $M(n)$ Tasks

对于 $M(n)$ 任务，尽管 Mem-0 相比基线有显著改进，但仍有很大的提升空间。我们认为需要解决的主要挑战在于分类器的性能和鲁棒性。




图 8. 覆盖积木的失败示例。分类器未能准确检测到“揭开 xxx”子任务的完成，从而阻止了子任务转换。由于指令保持不变，模型被迫在错误的任务上下文中运行，导致非预期且不稳定的行为。

覆盖积木 当前分类器（Classifier）的设计偶尔无法准确感知正在进行的任务进度，导致无法判别特定状态是表示子任务的开始还是结束。这一现象在图 8 中执行盖块（Cover Blocks）任务时得到了例证。

积木排序尝试（Blocks Ranking Try） 另一个主要挑战涉及按钮按压操作的执行。我们观察到，加入按钮按压动作往往会对并非仅专注于按压的混合任务引入干扰。例如，在积木排序尝试中，按钮按压与积木交换之间的过渡偶尔会受到流畅性干扰，这一现象如图 9 所示。

在积木排序尝试任务中，即使单次执行错误也必然导致整体任务失败。这种敏感性是该任务失败的主要驱动因素，这一点已被我们消融研究的定量结果明确证实。



图 9. 积木排序尝试的失败示例。按下按钮后，系统预期会过渡到下一个子任务以执行指定积木的交换。然而，分类器未能及时触发这一过渡，导致任务停滞在按压按钮状态。这导致双臂之间的协调冲突：右手试图开始操作，而左手仍受限於按钮按压指令。




图 10. 按压按钮的失败示例。（上）按压不足：即使按钮按压未成功，分类器也会发出假阳性终止信号。（下）按压过度：分类器未能识别子任务成功完成，导致重复执行同一子任务。




图 11. 电池尝试 (Battery Try) 的失败示例。(上) 对于水平放置的圆柱形电池，次优的抓取姿态阻碍了成功提起并导致显著位移，使模型进入未预见的观察状态。(下) 模型在电池调整过程中未能坚持特定的操作策略，导致平均动作使电池在槽中放置不当。

按下按钮 具体而言，按键任务作为一个专门的按钮按压场景，凸显了该操作的内在难度。在当前记忆-0 的设计中，按钮的状态（按下与未按下）仅通过极其细微的视觉线索反映在视觉输入中。因此，由视觉语言模型骨干生成的视觉标记缺乏封装此类细粒度信息的粒度，为下游分类器造成了根本性的瓶颈。

图 10 展示了按压按钮任务中分类器 (Classifier) 的典型失败案例。

电池试用 此外，对于电池尝试任务，一个典型的失败模式是操作精度欠佳。这包括将电池放入槽中的插入错误，以及由于槽的视觉线索极其细微而难以确定合适的抓取策略，如图 11 所示。

总结。 针对上述观察，本文认为引入本体感觉或触觉反馈可为分类器提供关键的非视觉信息。此外，由于分类器是记忆零号 (Mem-0) 中最下游的模块，优化上游视觉语言模型 (VLM) 的令牌提取以及锚定记忆与滑动记忆的融合机制仍是一条有前景的途径。此类改进将使分类器能够在分布条件更佳、信息显著性更强的输入令牌上运行。本文还预期，更具可解释性的令牌能够增强不同子任务之间的协同作用，从而进一步提升在诸如积木排序尝试等复杂场景中的性能。

然而，当前设计的有效性已在多种 $M(n)$ 任务中得到验证，尤其在覆盖块 (Cover Blocks) 任务中相较于基线取得了显著的性能提升。我们希望上述分析能为未来工作进一步提升性能提供有价值的洞见。