

权重中的技能，代码中的记忆：面向记忆依赖型机器人操作的混合学习

Yunhao Zhao^{1*}, Zhenyang Ni^{1*}, Haoyang Chen²

Ruohan Zhang^{1,3}, Qi Zhu¹

¹Northwestern University ²University of Minnesota ³Stanford University

yunhaozhao2028@u.northwestern.edu zhenyangni2030@u.northwestern.edu chen9861@umn.edu
zharu@stanford.edu qzhu@northwestern.edu

* 同等贡献

摘要

现代视觉-语言-动作（VLA）策略已习得广泛的操控技能，但通常仅基于当前观测或短固定长度历史生成每个动作块。然而，现实世界的操控往往是非马尔可夫的，要求机器人从长时程交互历史中保留并推理与任务相关的信息以确定下一步动作。为应对这一挑战，本文提出 **HyMeS**，一种混合学习框架，利用编码智能体的推理与记忆管理能力来引导马尔可夫 VLA 完成记忆依赖型操控。具体而言，**HyMeS** 通过基于梯度的模仿学习习得底层运动技能，而编码智能体则通过启发式学习获取高层记忆管理策略，即根据回放反馈迭代更新可执行启发式系统。此外，本文通过多模态阶段完成验证闭环引导与执行之间的回路，利用本体感觉信号和多帧 VLM 判断更新记忆。与端到端记忆增强 VLA 相比，**HyMeS** 仅需针对可复用运动技能的演示，而非针对每个历史依赖任务配置，从而实现数据高效的组合泛化。在 **RoboMemArena** 上，**HyMeS** 将平均累积成功率从 52.5% 提升至 66.2%，平均任务成功率从 41.3% 提升至 60.1%，优于 $\pi_{0.5}$ ，同时在累积成功率上超出 **PrediMem** 4.5 个百分点，在任务成功率上超出 14.5 个百分点。

引言

视觉-语言-动作（VLA）模型在通用机器人控制方面取得了快速进展。近期模型如 $\pi_{0.5}$ 能够泛化至多样化的物体、场景和语言指令（Physical Intelligence 等，2025b），而 $\pi_{0.6}$ 进一步将这些能力扩展至精细和灵巧操控（Physical Intelligence 等，2025a）。单一策略现已能够习得广泛的运动技能库，并在众多操控任务中取得高成功率。这些进展表明，底层运动能力正日益得到现代 VLA 的良好支持。尽管取得上述进展，大多数 VLA 在设计上仍为马尔可夫式：它们仅基于当前观测或短固定长度上下文生成每个动作块，而现实世界的机器人操控往往是非马尔可夫的，且

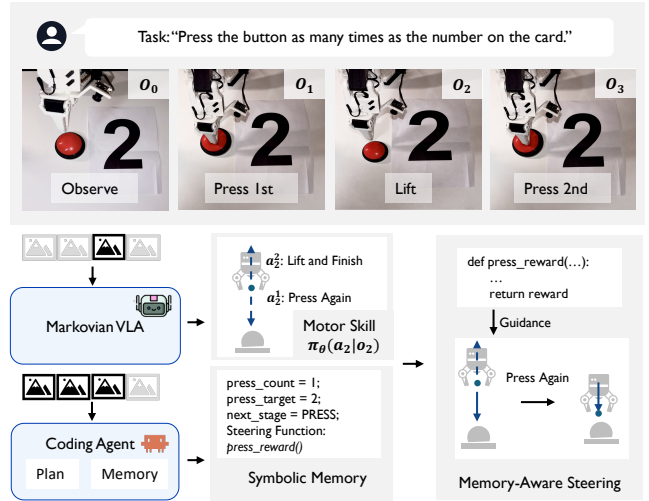


图 1：记忆即代码解决了依赖历史的动作歧义。顶部：所需按压次数由回合开始时观察到的一张卡片指定。底部：在 O_2 处第一次按压已完成且机械臂已抬起，因此仅凭当前观测支持两种互斥的动作模式：再次按压（ a_2^1 ）或抬起并停止（ a_2^2 ）。马尔可夫视觉语言动作模型仅以 O_2 为条件，无法在两者之间做出选择。HyMeS 则将交互历史传递给一个编码智能体，该智能体以可执行形式维护符号记忆，并选择相应的转向函数。该函数的梯度引导动作生成趋向再次按压，使用相同的策略权重且无需更新权重。

需要对长程交互历史中与任务相关的信息进行推理。例如，尽管按压按钮是一项简单的运动技能，但当按压次数必须从早期观测中回忆时，马尔可夫视觉语言动作模型无法可靠地按所需次数按压多个按钮。现有的记忆增强视觉语言动作模型通过扩展观测上下文或添加可学习的记忆模块来解决这一局限性，然后从机器人演示中端到端地训练以历史为条件的策略（Shi 等人，2025；Yang 等人，2026a,b）。然而，这将记忆获取与运动学习纠缠在一起，迫使进行昂贵的机器人演示

以覆盖组合记忆配置，即使不涉及新的物理技能。为克服这一局限性，本文提出 **HyMeS**，一种混合学习框架，利用编码智能体的推理与记忆管理能力来引导马尔可夫视觉语言动作模型（VLA）。核心思想是将运动技能学习与记忆策略学习分离。VLA 通过基于梯度的模仿学习在权重空间中习得低级运动技能，而编码智能体通过启发式学习在代码空间中习得高级记忆管理策略（Weng 2026）。编码智能体根据 rollout 反馈迭代更新可执行启发式系统。执行期间，该系统维护符号化任务记忆，并将其转化为记忆条件化约束，以引导 VLA 的流匹配动作生成。本文进一步引入多模态阶段完成验证机制，通过本体感觉信号和多帧视觉语言模型（VLM）判断更新记忆，从而闭合引导与执行之间的回路。与端到端记忆增强 VLA 相比，**HyMeS** 仅需针对可复用运动技能的演示，而非针对每种历史依赖任务配置的演示，从而实现数据高效的组合泛化。本文在 **RoboMemArena** 的四个记忆依赖任务类别上评估 **HyMeS**，与同权重 $\pi_{0.5}$ 策略及记忆增强 **PrediMem** 进行对比。**HyMeS** 将累积成功率（CSR）从 52.5% 提升至 66.2%，任务成功率（TSR）从 41.3% 提升至 60.1%，相较于 $\pi_{0.5}$ ，同时超出 **PrediMem** 4.5 个 CSR 点和 14.5 个 TSR 点。在 **SO-101** 机器人上，TSR 从 25.7% 提升至 57.1%。消融实验表明，rollout 经验使 CSR 和 TSR 分别提升 8.5 和 18.4 个点，而结合本体感觉与视觉信号比任一单独信号能实现更可靠的阶段转换。本文的贡献包括：• 将记忆依赖操作形式化为混合学习问题，分离运动技能学习与记忆策略学习。运动技能通过专家演示在权重空间中学习，而记忆管理策略通过启发式学习在代码空间中从 rollout 反馈中获取。• 提出 **HyMeS**，利用可执行符号记忆通过记忆条件化去噪约束引导马尔可夫 VLA。进一步通过多模态阶段完成验证闭合引导与执行之间的回路，该验证根据本体感觉信号和多帧 VLM 判断更新记忆。• 在 **RoboMemArena** 上，**HyMeS** 将 CSR 从 52.5% 提升至 66.2%，TSR 从 41.3% 提升至 60.1%，相较于 $\pi_{0.5}$ ，同时分别超出 **PrediMem** 4.5 和 14.5 个点。


相关工作

记忆增强的视觉语言动作模型。现代视觉语言动作模型将当前观测——或一个短的、固定长度的窗口——映射为动作（Brohan 等，2022，2023；Kim 等，2024；Chi 等，2023；Black 等，2024；Physical Intelligence 等，2025b），

因此在构造上具有马尔可夫性。针对记忆依赖任务的主流解决方案是将缺失的记忆融入动作模型并进行端到端学习：通过预训练历史表示（Zhou 等，2026a）、检索感知-认知记忆（Shi 等，2025，2026）、在记忆令牌上循环（Cherepanov 等，2026）、重新编码自适应工作记忆（Tan、Li 和 Jing，2026；Hu 等，2026），或存储事件触发、分层和完整历史状态（Yang 等，2026a，b；Wang 等，2026a；Sun 等，2026；Zhou 等，2026b）。由于记忆逻辑是组合且离散的，在权重空间中学习它需要覆盖组合空间的演示，容易遗忘，并产生难以检查或编辑的潜在缓冲区。相比之下，**HyMeS** 仅针对运动技能训练动作模型，保持其马尔可夫性，并在代码空间中获取记忆逻辑——无需覆盖记忆组合的演示，也无需任何记忆感知的权重更新。

在推理时引导视觉语言动作模型。另一条互补的研究路线保持预训练生成策略冻结，并在测试时偏置其动作采样，注入来自人类交互（Wang 等，2024）、学习价值函数（Nakamoto 等，2024）、目标条件动力学模型（Du 和 Song，2025）、成功预测器（Wang 等，2026b）、触觉可行性（Zhang 等，2026b）或视觉语言模型合成的阶段奖励（Liu 等，2026a）的引导。这些方法将基础策略保留为技能先验，但其引导是反应式的——根据当前观测或外部信号计算——因此无法维持记忆依赖任务所需的回合级记忆。此外，信息仅单向流动，没有从策略中读回任何内容。**HyMeS** 采用视觉语言引导的引导接口，但将注入的约束条件建立在显式符号记忆之上，并读回执行反馈（本体感觉和视觉）用于事件检测，使耦合成为双向的。

面向机器人技术的编码智能体。编写可执行代码的大语言模型长期以来一直作为机器人领域的策略与奖励设计者：代码即策略（Code as Policies）和体素姿态器（VoxPoser）从语言中组合控制应用程序编程接口与价值图（梁等人，2022；黄等人，2023），尤里卡（Eureka）则为技能学习演化奖励代码（马等人，2023）。近期的智能体系统通过环境反馈闭合回路，根据回放结果迭代重写控制器或策略库（徐、方和胡，2026；加博阿尔迪·多斯桑托斯等人，2026；库马尔，2026；埃尔马鲁菲等人，2026），而编排框架则允许视觉语言模型智能体将底层策略作为工具进行规划、调用和监控（陈等人，2026；刘等人，2026b）。最密切相关的是，哈内斯视觉语言动作（Harness VLA）利用任务特定的迹和全局失败规则，将冻结的视觉语言动作编排为可重试的接触丰富原语（张等人，2026a）。其记忆在原语粒度上运作，而混合记忆执行系统（**HyMeS**）则将可执行记忆直接耦合到视觉语言动作的去噪过程中，以引导单个动作。然而，在所有这些系统中，智能体的代码要么取代底层策略，要么在子任务粒度上指挥它，动作生成本身未被触及。在混合记忆执行系统中，编码智能体则将记忆维护为可执行任务状态，并在代码空间中学习其更新规则。



一个编码智能体。在视觉-语言-动作模型（VLA）微调完成后，其参数在整个启发式开发与评估过程中保持固定。学习到的程序 $\mathcal{P} = (\mathcal{C}, \mathcal{V}, \mathcal{U})$ 包含约束选择规则 $\mathcal{C}$ 、事件验证规则 $\mathcal{V}$ 和记忆更新规则 $\mathcal{U}$ 。令 π_{θ^*} 表示经过任务特定运动技能微调后的预训练 VLA，令 s_t 为 $\mathcal{P}$ 在第 t 个控制步维护的符号记忆状态——即公式 1 中潜在任务状态 z_t 的可执行估计。在评估时， $\mathcal{P}$ 被冻结：评估运行不再修改其启发式经验或约束生成策略。编码智能体仍应用 $\mathcal{P}$ 来实例化上下文相关的阶段规则和初始记忆 $s_1 = \text{Init } \mathcal{P}(\ell, o_1)$ ，根据指令和初始观测构建阶段计划（图 2），然后通过以下闭环过程与马尔可夫 VLA 交互：

$$R_t = \mathcal{C}(s_t, o_t, \ell), \quad (2)$$

$$\mathbf{a}_t = \text{Steer}(\pi_{\theta^*}, R_t, o_t, \ell), \quad (3)$$

$$e_t = \mathcal{V}(o_{\mathcal{W}_t}, \mathbf{a}_{\mathcal{W}_t}; s_t), \quad (4)$$

$$s_{t+1} = \mathcal{U}(s_t, e_t, o_t), \quad (5)$$

其中 R_t 是为当前阶段选择的可微约束（公式 11）， $\text{Steer}(\cdot)$ 表示约束引导的动作生成（公式 12）， $e_t \in \{0, 1\}$ 是由 $\mathcal{V}$ 从滑动验证窗口 $\mathcal{W}_t$ 内的观测和执行动作块中验证的阶段进展事件，通过公式 15 的多模态投票实例化。一旦事件被接受， $\mathcal{U}$ 推进阶段并根据当前观测更新记忆内容。这种双向交互使 VLA 保持马尔可夫性，而外部程序承载长时程任务状态。

权重空间中的运动技能学习 运动组件是一个马尔可夫流匹配策略 $\pi_{\theta}(\mathbf{a}_t | o_t, \ell)$ ，从预训练的 VLA 初始化，例如 $\pi_{0.5}$ （Physical Intelligence et al. 2025b）。令 $\epsilon \sim \mathcal{N}(0, I)$ 表示高斯噪声， τ 表示从 $[0, 1]$ 均匀采样的流时间步。遵循原始流匹配目标，我们在噪声与专家动作块之间进行插值，即

$$\mathbf{a}^{\tau} = (1 - \tau)\epsilon + \tau\mathbf{a}, \quad (6)$$

并通过以下方式微调速度场

$$\theta^* = \arg \min_{\theta} \mathbb{E}_{(o, \mathbf{a}, \ell) \sim \mathcal{D}, \tau, \epsilon} \left[\|v_{\theta}(\mathbf{a}^{\tau}, \tau | o, \ell) - (\mathbf{a} - \epsilon)\|_2^2 \right]. \quad (7)$$

该阶段学习 $\mathcal{D}$ 中演示的接触丰富运动行为。微调完成后， θ^* 被固定。因此，记忆获取不会修改策略权重，也不需要额外的专家动作。

代码空间中的记忆策略学习 记忆组件维护一个显式的符号状态

$$s_t = (\text{plan}, \rho_t, \mathcal{B}_t, \mathcal{N}_t, \mathcal{F}_t), \quad (8)$$

其中 ρ_t 表示活动计划阶段。其余变量记录任务绑定、重复事件计数和持久交互状态，共同实现估计

式 1 中的任务状态 z_t 。与学习得到的历史嵌入不同， s_t 通过可执行规则更新，并直接暴露用于选择下一行为的任务信息。程序 $\mathcal{P}$ 由编码智能体迭代开发。给定候选程序 $\mathcal{P}^{(n)}$ ，展开 n 生成符号执行迹

$$\xi_n = ((s_t, e_t, R_t))_{t=1}^{T_n}, \quad (9)$$

连同基准提供的分阶段判定 $\mathbf{b}_n$ 。编码智能体将 PACE 记录的各阶段转换与完成证据同 $\mathbf{b}_n$ 进行比对，以定位失败阶段。随后，其诊断主动约束奖励是否被错误设定，或相应验证规则是否过于严格或宽松，并修订可执行程序：

$$\mathcal{P}^{(n+1)} = \text{Edit}(\mathcal{P}^{(n)}, \xi_n, \mathbf{b}_n). \quad (10)$$

修订可以修改阶段约束奖励或调整事件验证与转换规则。在开发回滚中表现最佳的程序被保留为 $\mathcal{P}^*$ 。这一学习过程更新软件而非神经网络参数。它既不使用梯度也不使用专家动作标签，使编码智能体能够根据执行反馈优化记忆逻辑。在评估期间，编码智能体应用冻结的程序 $\mathcal{P}^*$ 来更新回合内记忆并实例化阶段特定的规则和奖励，而不进行回滚级别的诊断或程序修订。

记忆条件化动作引导 在控制步骤 t ，活动阶段 ρ_t 与符号记忆 s_t 选择一个可微约束 $R_{\rho_t}(\mathbf{a}, o_t; s_t)$ 。例如，一个到达阶段可以实例化

$$R_{\text{reach}} = -\|\text{ee}(\mathbf{a}) - \Gamma(\text{target}(s_t), o_t)\|_2^2, \quad (11)$$

其中 $\text{ee}(\mathbf{a})$ 表示块 $\mathbf{a}$ 的末端执行器位置， $\Gamma(\cdot)$ 利用开放词表检测、掩码细化及深度反投影（如 VLS 所述，Liu 等人，2026a）将符号目标锚定到场景关键点。所选约束被注入到流匹配速度场中：

$$\hat{v} = v_{\theta^*}(\mathbf{a}^{\tau}, \tau | o_t, \ell) + \lambda_t \nabla_{\mathbf{a}^{\tau}} R_{\rho_t}(\mathbf{a}^{\tau}, o_t; s_t), \quad (12)$$

其中约束在 VLS 之后的中间块上进行评估（Liu 等人，2026a），其梯度与干净动作梯度一致，如 $\tau \rightarrow 1$ 所示。对 $\hat{v}$ 进行积分，将去噪过程引导至与当前记忆状态一致的动作模式。符号程序决定应执行何种行为，而 VLA 则负责实现相应的运动技能。

随着策略接近交互区域，我们进一步衰减引导，其调度为

$$\lambda_t = \frac{\lambda_0}{1 + \exp(\beta(p_t - p_{\text{mid}}))}, \quad (13)$$

其中 λ_0 为基础尺 $p_t = \text{clip}(1 - c_t/c_{\rho}, 0, 1)$ 度，为自阶段进入以来约束残差的归一化减少量 $c_t =$

$-R_{\rho_t}(\mathbf{a}_t, o_t; s_t)$ ，在步 $t_{\rho, p_{\text{mid}}}$ 处为尺度减半的中点， β 控制衰减速率。该调度使记忆引导全局行为选择，同时允许学习到的运动策略主导接触丰富的执行。

多模态进展验证与记忆更新 可靠的记忆更新需要判断当前阶段是否真正完成。我们将这一机制称为本体感知与完成驱动的阶段切换（本体感知与补全驱动的阶段切换，PACE）。PACE 从机器人执行期间可用的两个互补证据流中推断完成情况。本体感知证据检测动作依赖的运动模式，并通过符号锁存器保持持久事件。视觉证据由 Qwen3-VL-8B 提供，它根据活动阶段和最多五帧最近的 RGB 图像判断完成情况。多帧上下文有助于区分正在进行的动作和已完成的动作。PACE 定期发出完成查询；令 $r(t)$ 索引步骤 t 之前的最近一次查询。在查询 r 处，两个证据流产生二元判断 $e_{\text{prop}}^{(r)}$ 和组合为

$$d_r = e_{\text{prop}}^{(r)} \vee e_{\text{vlm}}^{(r)}, \quad (14)$$

为抑制孤立错误，阶段进展事件仅在完成得到最近 w 次查询中至少 k 次支持时触发：

$$e_t = \mathbb{I} \left[\sum_{i=r(t)-w+1}^{r(t)} d_i \geq k \right], \quad (15)$$

该过程在由这些 w 查询覆盖的窗口 $\mathcal{W}_t$ 上实例化式 (4) 的验证规则 $\mathcal{V}$ ；投票在阶段推进时重置。所有实验中均采用 $w = 5$ 和 $k = 3$ 。一旦事件被接受， $\mathcal{U}$ 会更新相应的绑定、计数器和持久状态，然后激活下一阶段的约束。这就在记忆条件引导与物理执行之间形成了闭环，无需特权环境状态或单独训练的特定任务完成模型。

实验

实验设置

任务与度量。 我们在来自 RoboMemArena (Lei 等, 2026) 的修正 12 任务协议上评估 HyMeS，该协议包含 160 个回合，涵盖转移、计数、顺序执行和遮挡。我们修正了可能产生假阳性的成功判定，并保留那些 $\pi_{0.5}$ 具备所需运动技能但仍因缺失历史而失败的任务。可通过观察捷径解决或主要由运动技能失败主导的任务被排除。该选择仅使用协议检查和 $\pi_{0.5}$ 行为，不涉及 HyMeS 结果。所有方法均在相同的修正任务和回合上进行评估。每个转移和计数任务使用 10 个回合，每个遮挡任务使用 15 个回合，每个顺序任务使用 20 个回合。我们还在 SO-101 机器人上额外评估了三个依赖记忆的任务。我们

报告任务成功率 (TSR) 和累积成功率 (CSR)，分别衡量完整任务成功和阶段级进展。评估期间冻结探索经验。

基线。 我们将反应式 $\pi_{0.5}$ 策略与 PrediMem (Lei 等, 2026) 进行比较，后者是随 RoboMemArena 引入的记忆增强基线。PrediMem 结合了高层视觉语言模型规划器与近期帧和关键帧记忆，而 HyMeS 利用以可执行代码学习的记忆策略来引导马尔可夫视觉语言动作模型。PrediMem 在我们的 12 任务协议上重新评估，而非使用其已发表的 26 任务结果。在真实机器人上， $\pi_{0.5}$ 和 HyMeS 共享相同的演示和微调策略权重，从而隔离可执行记忆的影响。

实现 细节。 仿真使用通过 OpenPI 的 RoboMemArena 训练 $\pi_{0.5}$ 检查点，而真实机器人策略则通过 LeRobot 在 SO-101 演示上微调。在启发式开发和评估期间，策略权重保持固定。编码智能体使用 Opus 4.8 模型，在开发期间从 PACE 迹和基准阶段判定中更新经验。在评估期间，它应用冻结的程序 $\mathcal{P}^*$ 来实例化上下文相关约束；回滚总结、经验修订以及对 $\mathcal{P}^*$ 的更新被禁用。Qwen3-VL-8B 仅用于多帧阶段完成验证。

定量结果

仿真实验。 表 1 展示了 $\pi_{0.5}$ 、PrediMem 和 HyMeS 在 12 个 RoboMemArena 任务上的任务级、类别平均及总体 CSR 和 TSR。所有方法均在 160 个评估回合中，针对相同任务和场景配置进行评估。结果得出四个主要发现。i) 在相同策略权重下，HyMeS 相较于 $\pi_{0.5}$ 将 CSR 从 52.5% 提升至 66.2%，TSR 从 41.3% 提升至 60.1%，表明可执行记忆与转向机制弥补了马尔可夫 VLA 中缺乏内置记忆的不足。ii) HyMeS 的 TSR 超出 PrediMem 14.5 个百分点，尽管 CSR 仅高出 4.5 个百分点。这一结果表明 HyMeS 能更有效地将中间进展转化为完整任务成功，支持了我们结合权重空间运动学习与代码空间记忆策略学习的混合设计。iii) 相较于 $\pi_{0.5}$ ，TSR 提升最大的任务类别为计数（30.0 个百分点）、转移（26.6 个百分点）和序列任务（22.5 个百分点），这与显式计数器、物体-位置关联及阶段状态的优势一致。在计数任务上，HyMeS 的 TSR 高于 PrediMem（50.0% 对 36.7%），尽管 CSR 较低（60.3% 对 72.2%）。在我们的实验中，发现这些失败集中在早期执行阶段，可能源于冻结 VLA 的局限性或偶尔的引导干扰。一旦这些阶段成功，显式计数和已验证的转换使完整任务完成更加可靠。iv) 遮挡是记忆注入最困难的类别：PrediMem 的 CSR 低于反应式 $\pi_{0.5}$ （38.3% 对 50.4%），表明当目标被遮挡时，不可靠的记忆可能主动误导执行。HyMeS 在 CSR 上与 $\pi_{0.5}$ 持平（50.6%），同时提升了 TSR

Scenario	CSR			TSR		
	$\pi_{0.5}$	PrediMem	HyMeS	$\pi_{0.5}$	PrediMem	HyMeS
Transferring						
Pudding + butter $\rightarrow$ cabinet 2	90.0	100.0	100.0	80.0	100.0	100.0
Butter + cheese $\rightarrow$ plate 2	50.0	80.0	80.0	50.0	70.0	80.0
Pudding + cheese $\rightarrow$ plate 2	70.0	80.0	100.0	70.0	60.0	100.0
Category average	70.0	86.7	93.3	66.7	76.7	93.3
Counting						
Tomato sauce $\times 2$ on cookies $\rightarrow$ drainer	50.0	86.7	63.0	60.0	60.0	60.0
Pudding + pour $\times 2 \rightarrow$ drainer	35.0	57.5	50.0	0.0	20.0	40.0
Butter + pour $\times 2 \rightarrow$ drainer	32.5	72.5	68.0	0.0	30.0	50.0
Category average	39.2	72.2	60.3	20.0	36.7	50.0
Sequence						
Butter + popcorn $\rightarrow$ basket	60.0	72.5	80.0	40.0	50.0	65.0
Cream + pudding $\rightarrow$ basket	45.0	67.5	67.5	40.0	50.0	60.0
Category average	52.5	70.0	73.8	40.0	50.0	62.5
Occlusion						
Cookies + chocolate $\rightarrow$ microwave	55.0	38.3	42.0	46.7	26.7	28.0
Butter + chocolate $\rightarrow$ microwave	58.3	36.7	63.3	46.7	40.0	80.0
Cream + popcorn $\rightarrow$ microwave	50.0	50.0	57.0	46.7	46.7	60.0
Cookies + popcorn $\rightarrow$ microwave	38.3	28.3	40.0	20.0	13.3	20.0
Category average	50.4	38.3	50.6	40.0	31.7	47.0
Overall	52.5	61.7	66.2	41.3	45.6	60.1

表 1: 微调 $\pi_{0.5}$ 策略、PrediMem 与 HyMeS 在 RoboMemArena 上的比较。行按记忆能力对任务分组，列报告累积成功率（CSR），衡量平均子目标完成情况，以及任务成功率（TSR），衡量完整任务完成情况。类别平均行总结每个任务类别，最后一行报告所有 160 个评估回合的整体性能。HyMeS 执行探索期间选择的最佳启发式，并在整个评估过程中冻结，代码编辑和反思被禁用。粗体表示最佳结果。

Task	$\pi_{0.5}$	HyMeS
Observe-and-pick-up	2/10	7/10
Number-Guided Button Pressing	7/15	11/15
Put-Back Block	0/10	2/10

表 2: SO-101 上的真实世界任务成功率。列比较微调 $\pi_{0.5}$ 策略与 HyMeS。HyMeS 执行探索期间选择的启发式，并在整个评估过程中保持固定。

提高了 7.0 个百分点，表明经过验证的阶段转换限制了错误绑定的损害，尽管视觉完成证据在遮挡下仍然最不可靠。

真实世界实验。表 2 报告了 $\pi_{0.5}$ 和 HyMeS 在使用 SO-101 机器人的三个依赖记忆的任务上的任务成功率，每种方法共 35 次试验。两种方法共享相同的演示、观察和微调策略权重；只有 HyMeS 维护符号记忆并应用记忆条件引导。得出三个发现。i) 总体 TSR 从 25.7% 上升到 57.1%，验证了硬件上的可执行记忆和引导。ii) 每个任务分别提高 50.0、26.7 和 20.0 个百分点，表明一个符号状态支持线索保留、计数，

以及源-位置关联。iii) 前两个任务的提升支持历史条件选择和经过验证的转换；Put-Back 仍然具有挑战性，因为环境光照的变化降低了底层视觉运动策略的鲁棒性。

演示成本与可检查性。激励我们设计的两个特性在这些实验中也可见。首先，上述所有结果均通过每个平台单一微调检查点获得：获取记忆从不更新策略权重，新的记忆配置——不同的目标颜色或不同的所需计数——通过编辑代码空间程序来实现，而非收集覆盖该配置的演示。因此，演示预算随可重用运动技能的数量扩展，而非随历史依赖任务配置的数量扩展。其次，符号状态在每个控制步骤均可读，因此每个失败回合可定位到记忆更新、运动执行或事件验证。我们在下文利用这一特性分析剩余失败。

定性结果 记忆引导执行的可视化。图 3 展示了混合记忆与符号执行（HyMeS）如何利用可执行记忆解决历史依赖的动作歧义。顶行显示瞬时任务提示及提示移除后的当前观测；仅凭当前观测无法提供任何关于哪个方块是目标的证据。底部




图 3: SO-101（观察并拾取）任务上的记忆引导执行。顶部：目标颜色写在一张卡片上，该卡片仅在回合开始时可见（初始提示），随后从工作区移除（提示消失），因此当前观测不再能识别应拾取哪个方块。底部：无引导时，反应式 $\pi_{0.5}$ 策略无法再访问提示，对任一候选方块均无差别地伸手（目标歧义）。HyMeS 将提示保留在可执行记忆中，并实例化相应约束，将相同策略权重引导至蓝色方块（记忆引导）。

行对比了相同观测下的两种策略。尽管反应式 $\pi_{0.5}$ 策略能够执行所需运动技能，但由于其输入中缺少相关历史，它不会选择与历史一致的目标。HyMeS 则将提示保留为符号状态，将其转化为记忆条件约束，并在激活下一约束前利用本体感觉和多帧视觉证据验证阶段完成。我们看到，HyMeS 将早期观测中的信息转化为显式控制决策，使相同的马尔可夫视觉-语言-动作模型能够产生与历史一致的动作。

失败模式的可视化。图 4 展示了具有代表性的失败案例，其中符号状态与激活约束初始正确，但运动执行或阶段完成验证失败。顶行展示抓取失败：记忆目标与转向方向正确，但预抓取姿态处的瞄准偏差导致预训练视觉语言动作模型在方块旁闭合夹爪。底行展示按钮任务上的两次计数失败，其中执行抖动产生一次多余的按压，而浅按压未被 PACE 识别为完成。这些失败源于运动执行与事件验证，而非长时程记忆损坏。




图 4: SO-101 上的可解释失败模式。在这些示例中，符号记忆与激活约束在执行前均正确。失败源于运动执行或阶段完成验证。顶部：预抓取姿态处的横向偏差（瞄准偏差）使夹爪在记忆目标旁闭合（抓取失败）。底部：在按钮任务上，接触点附近的垂直抖动导致意外的第二次按压（多余按压），而按压深度不足（按压深度不足）未被 PACE 识别为完成。

消融研究 表 3 在涵盖全部四个任务类别（每类一至两个任务）的六任务子集上评估了基于轨迹的启发式学习与多模态阶段完成验证。所有变体使用相同的微调 $\pi_{0.5}$ 策略、观测与评估回合。消融得出两点发现。i) 用轨迹精化程序 $\mathcal{P}^*$ 替换一次性程序 $\mathcal{P}^{(0)}$ ，将 CSR 与 TSR 分别提升 8.5 与 18.4 个百分点，验证了轨迹经验作为学习记忆管理启发式有效反馈的价值。ii) 仅依赖任一完成信号均会降低性能：仅视觉验证使 CSR 与 TSR 分别下降 16.0 与 21.7 个百分点，而仅本体感觉验证使其分别下降 8.8 与 8.4 个百分点。任一信号单独使用都可能误判阶段转换；二者的互补证据使这些转换更加可靠。

结论

本文提出混合记忆与技能框架（HyMeS），一种面向记忆依赖型机器人操作的混合学习框架。其核心思想是通过基于梯度的模仿学习在权重空间中学习运动技能，同时通过启发式学习在代码空间中获取记忆管理策略。由此生成的可执行记忆选择阶段特定约束以引导马尔可夫视觉语言动作模型（VLA），而多模态进度验证则

Variant	Learn	PACE evidence	CSR	TSR
One-shot $\mathcal{P}^{(0)}$	–	Vis.+Prop.	63.3	53.3
Vision-only PACE	✓	Vis.	55.8	50.0
Proprio.-only PACE	✓	Prop.	63.0	63.3
Full HyMeS	✓	Vis.+Prop.	71.8	71.7

表 3: 在共享策略权重和评估配置下, 对六任务子集的消融实验。我们消融了启发式细化以及进度感知约束估计器 (PACE) 所使用的视觉和本体感觉证据。约束满足率 (CSR) 和任务成功率 (TSR) 为百分比; 破折号表示不使用基于执行的启发式学习的变体。

通过物理执行更新记忆。在机器人记忆竞技场 (RoboMemArena) 和真实世界操作任务上的实验表明, 混合记忆与技能框架显著提高了阶段完成率和任务成功率, 且无需专家演示覆盖所有历史依赖的任务配置。

局限性与未来工作。当前工作聚焦于相关历史可由紧凑符号状态表示的任务。仍存在两个进一步的局限性。任务成功仍受限于运动能力和阶段完成验证。如失败分析所示, 正确的记忆状态和适当的约束并不能保证接触丰富执行的成功。此外, 周期性的视觉语言模型查询和编码代理调用增加了每回合的推理延迟和成本。在未来工作中, 我们计划将相同的混合学习原理扩展到分层和多模态记忆表示, 以实现更开放的指令和更长时程的操作。

参考文献

Black, K.; Brown, N.; Driess, D.; Esmail, A.; Equi, M.; Finn, C.; Fusai, N.; Groom, L.; Hausman, K.; Ichter, B.; et al. 2024. π_0 : A Vision-Language-Action Flow Model for General Robot Control. arXiv:2410.24164.

Brohan, A.; Brown, N.; Carbajal, J.; Chebotar, Y.; Chen, X.; Choromanski, K.; Ding, T.; Driess, D.; Dubey, A.; Finn, C.; et al. 2023. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control. arXiv:2307.15818.

Brohan, A.; Brown, N.; Carbajal, J.; Chebotar, Y.; Dabis, J.; Finn, C.; Gopalakrishnan, K.; Hausman, K.; Herzog, A.; Hsu, J.; et al. 2022. RT-1: Robotics Transformer for Real-World Control at Scale. arXiv:2212.06817.

Chen, S.; Hadfield, H.; Zook, A.; Uy, M. A.; Song, C. H.; Coumans, E.; Yang, X.; Ladhak, F.; Qu, Q.; Birchfield, S.; Tremblay, J.; and Blukis, V. 2026. VoLo: A Physical Orchestrator for Open-Vocabulary Long-Horizon Manipulation. arXiv:2606.07723.

Cherepanov, E.; Kachaev, N.; Zelezetsky, D.; Bulatov, A.; Pshenitsyn, A.; Kuratov, Y.; Skrynnik, A.; Panov, A. I.; and Kovalev, A. K. 2026. μ VLA: On Recurrent Memory for Partially Observable Manipulation in VLA Models. arXiv:2606.12497.

Chi, C.; Xu, Z.; Feng, S.; Cousineau, E.; Du, Y.; Burchfiel, B.; Tedrake, R.; and Song, S. 2023. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. arXiv:2303.04137.

Du, M.; and Song, S. 2025. DynaGuide: Steering Diffusion Policies with Active Dynamic Guidance. arXiv:2506.13922.

Elmaaroufi, K.; Svegliato, J.; Kalade, S.; Schelle, G.; Seshia, S. A.; and Zaharia, M. 2026. RHO: Your Coding Agent is Secretly a Robotcist. arXiv:2606.16458.

Gaboardi dos Santos, V.; Khadraoui, I.; Farhat, I.; Yous, H.; Teffahi, S.; and Hacid, H. 2026. ALRM: Agentic LLM for Robotic Manipulation. arXiv:2601.19510.

Hu, Q.; Qiu, Z.; Xu, Z.; Zhang, K.; Bu, X.; Sun, Z.; Zhang, B.; Zhao, J.; Gan, Z.; and Ding, W. 2026. Resolving State Ambiguity in Robot Manipulation via Adaptive Working Memory Recoding. *IEEE Robotics and Automation Letters*, 11(7): 8439–8446.

Huang, W.; Wang, C.; Zhang, R.; Li, Y.; Wu, J.; and Fei-Fei, L. 2023. VoxPoser: Composable 3D Value Maps for Robotic Manipulation with Language Models. arXiv:2307.05973.

Kim, M. J.; Pertsch, K.; Karamcheti, S.; Xiao, T.; Balakrishna, A.; Nair, S.; Rafailov, R.; Foster, E.; Lam, G.; Sankei, P.; Vuong, Q.; Kollar, T.; Burchfiel, B.; Tedrake, R.; Sadigh, D.; Levine, S.; Liang, P.; and Finn, C. 2024. OpenVLA: An Open-Source Vision-Language-Action Model. arXiv:2406.09246.

Kumar, V. 2026. Act-Observe-Rewrite: Multimodal Coding Agents as In-Context Policy Learners for Robot Manipulation. arXiv:2603.04466.

Lei, H.; Song, W.; Zhang, H.; Pei, J.; Chen, J.; Yan, H.; Zhao, H.; Ding, P.; Zhang, Z.; Huang, L.; Wang, D.; Wang, Y.; and Li, H. 2026. RoboMemArena: A Comprehensive and Challenging Robotic Memory Benchmark. arXiv:2605.10921.

Liang, J.; Huang, W.; Xia, F.; Xu, P.; Hausman, K.; Ichter, B.; Florence, P.; and Zeng, A. 2022. Code as Policies: Language Model Programs for Embodied Control. arXiv:2209.07753.

Liu, S.; Singh, I. S.; Xu, Y.; Duan, J.; and Krishna, R. 2026a. VLS: Steering Pretrained Robot Policies via Vision-Language Models. arXiv:2602.03973.

Liu, Z.; Ning, X.; Hu, Z.; Xie, X.; Li, W.; Tang, Z.; Wang, C.; Yang, Z.; Wang, H.; Liu, Y.; and Pu, Z. 2026b. Goal2Skill: Long-Horizon Manipulation with Adaptive Planning and Reflection. arXiv:2604.13942.

Ma, Y. J.; Liang, W.; Wang, G.; Huang, D.-A.; Bastani, O.; Jayaraman, D.; Zhu, Y.; Fan, L.; and Anandkumar, A. 2023. Eureka: Human-Level Reward Design via Coding Large Language Models. arXiv:2310.12931.

Nakamoto, M.; Mees, O.; Kumar, A.; and Levine, S. 2024. Steering Your Generalists: Improving Robotic Foundation Models via Value Guidance. arXiv:2410.13816.

Physical Intelligence; Amin, A.; Aniceto, R.; Balakrishna, A.; Black, K.; et al. 2025a. $\pi_{0.6}^*$: a VLA That Learns From Experience. arXiv:2511.14759.

Physical Intelligence; Black, K.; Brown, N.; Darpanian, J.; Dhabalia, K.; Driess, D.; Esmail, A.; Equi, M.; Finn, C.; Fusai, N.; et al. 2025b. $\pi_{0.5}$: A Vision-Language-Action Model with Open-World Generalization. arXiv:2504.16054.

Shi, H.; Li, W.; Xie, B.; Wang, Y.; Zhou, R.; Wang, T.; Zhang, X.; Luo, P.; and Huang, G. 2026. MemoryVLA++: Temporal

Modeling via Memory and Imagination in Vision-Language-Action Models. arXiv:2606.09827.

Shi, H.; Xie, B.; Liu, Y.; Sun, L.; Liu, F.; Wang, T.; Zhou, E.; Fan, H.; Zhang, X.; and Huang, G. 2025. MemoryVLA: Perceptual-Cognitive Memory in Vision-Language-Action Models for Robotic Manipulation. arXiv:2508.19236.

Sun, X.; Zhang, R.; Cao, C.; Sun, Y.; Chen, J.; Xu, Z.; Chen, B.; Chen, H.; Yang, Z.; Zhu, J.; Hong, Y.; Xu, J.; Pang, J.; Yuan, M.; and Chen, J. 2026. HiMem-WAM: Hierarchical Memory-Gated World Action Models for Robotic Manipulation. arXiv:2606.10363.

Tan, L.; Li, J.; and Jing, G. 2026. MemoAct: Atkinson-Shiffrin-Inspired Memory-Augmented Visuomotor Policy for Robotic Manipulation. arXiv:2603.18494.

Tsui, B. Y.; Fang, A. Y.; and Hwu, T. J. 2026. Demonstration-Free Robotic Control via LLM Agents. arXiv:2601.20334.

Wang, K.; Gu, Z.; Chen, Y.; Xu, Y.; Ma, Q.; Su, P.; Li, Z.; Huang, Y.; and Wang, L. 2026a. DIM-WAM: World-Action Modeling with Diverse Historical Event Memory. arXiv:2606.27677.

Wang, Y.; Wang, L.; Du, Y.; Sundaralingam, B.; Yang, X.; Chao, Y.-W.; Perez-D’Arpino, C.; Fox, D.; and Shah, J. 2024. Inference-Time Policy Steering through Human Interactions. arXiv:2411.16627.

Wang, Z.; Jha, D. K.; Qureshi, A. H.; and Romeres, D. 2026b. PPGuide: Steering Diffusion Policies with Performance Predictive Guidance. arXiv:2603.10980.

Weng, J. 2026. Learning Beyond Gradients. <https://trinkle23897.github.io/learning-beyond-gradients/>. Blog post.

Yang, G.; Tu, Z.; Yang, Y.; Mao, S.; Dong, J.; Chen, T.; Peng, J.; Xiong, J.; Cao, J.; Dai, J.; Zhou, W.; Mu, Y.; and Wang, T. 2026a. EventVLA: Event-Driven Visual Evidence Memory for Long-Horizon Vision-Language-Action Policies. arXiv:2606.20092.

Yang, S.; Mu, J.; Wei, T.; Lu, C.; Li, X.; Xu, L.; Xue, Z.; Yuan, Z.; Lin, D.; Pang, J.; and Xu, H. 2026b. MemoryWAM: Efficient World Action Modeling with Persistent Memory. arXiv:2606.20562.

Zhang, Y.; Zhang, H.; Gao, F.; Li, X.; Liu, Z.; Zhu, C.; Qiu, J.; Yan, Y.; Liu, J.; Tang, W.; Fang, Z.; Nie, Y.; Wei, C.; Wang, Y.; Ding, W.; and Yu, C. 2026a. Harness VLA: Steering Frozen VLAs into Reliable Manipulation Primitives via Memory-Guided Agents. arXiv:2607.08448.

Zhang, Z.; Ma, J.; Yang, X.; Wen, X.; Zhang, Y.; Li, B.; Qin, Y.; Liu, J.; Zhao, C.; Kang, L.; Hong, H.; Yin, Z.; Torr, P.; Su, H.; Zhang, R.; and Ma, D. 2026b. TouchGuide: Inference-Time Steering of Visuomotor Policies via Touch Guidance. arXiv:2601.20239.

Zhou, Y.; Liang, Q.; Zhuang, S.; Li, J.; Wang, X.; Cai, B.; Mo, Y.; and Xu, R. 2026a. Action-Effect Memory Pretraining for Robot Manipulation. arXiv:2606.12499.

Zhou, Y.; Wang, Y.; Wang, N.; Xing, S.; Tu, S.; Li, X.; Zhang, J.; Jiang, N.; Lin, Y.; Yang, H.; Zeng, X.; and Yin, Z. 2026b. Chronos: A Physics-Informed Full-History Framework for Non-Markovian Long-Horizon Manipulation. arXiv:2606.30318.