

TRACE: 面向延迟证据视觉运动模仿的轨迹路由因果记忆

Zihao Li¹ Ranpeng Qiu³ Yincong Chen Guoqiang Ren¹ Weiming Zhi²

¹Zhejiang University ²The University of Sydney

³Zhejiang University of Technology

摘要: 机器人在自主操作中可能需要基于已不可见的证据做出决策。本文研究延迟证据任务，其中早期线索在后续决策点之前消失，因此视觉上相似的观测可能需要不同的动作。在这些场景下，当前观测不足以作为控制的充分状态。本文提出轨迹路由因果证据（TRACE），一种用于视觉运动模仿策略的记忆框架。TRACE 将任务相关的视觉和机器人状态证据（如物体身份、目标选择或路径依赖状态）存储在一个固定大小的潜在记忆中，该记忆在长时程中保持有界。TRACE 不使用原始时间或人工提供的任务标签来索引记忆，而是采用路径签名：执行机器人状态轨迹的紧凑、顺序敏感特征。这些签名本身不存储视觉线索；相反，它们提供轨迹条件化的键，用于写入和检索线索可见时存储的证据。当机器人随后到达模糊观测点时，策略以 TRACE 记忆为条件，恢复缺失的上下文并选择正确的分支。TRACE 通过轻量级适配器附加到策略上，无需更改策略主干、动作头或模仿目标。在具有视觉模糊分支点的真实世界长时程操作任务中，TRACE 相比包括短时记忆和循环记忆在内的替代基线，改善了分支选择和任务成功率。项目页面：<https://jeong-zju.github.io/trace>

1 引言

机器人通常需要利用已不再观测到的信息来做出后续任务决策。本文将这类决策称为分支：例如接下来执行哪个目标、路线或操作例程的备选方案。本文研究延迟证据操作，其中早期线索被观测到后消失，仅在后续决策点才需要。在该决策点，来自不同历史的观测可能看起来几乎相同，却需要不同的动作。

用于视觉运动策略的模仿学习 [1, 2] 能够实现无法直接为运动规划指定的成本。大多数视觉运动策略以当前观测为条件，可能附带一个较短的近期窗口，因此将这一输入视为动作选择的充分条件。这是一个隐式的马尔可夫假设：当前输入包含选择下一个动作所需的全部信息。延迟证据任务违反了这一假设，因为当前观测无法确定正确的分支。增加更多的历史信息是不够的。当决定性线索落在窗口之外时，短窗口会失效，而长窗口会增加成本，并迫使策略推断哪些早期观测仍然重要。循环策略和通用记忆可以将信息向前传递，但与分支相关的线索可能会被覆盖、稀释，或与后续选择无关的任务进展信号纠缠在一起。因此，延迟证据操作需要一个因果的、固定预算的记忆，该记忆在线更新，并保留早期任务证据直到其变得有用。

我们引入了轨迹路由因果证据（TRACE），这是一个用于视觉运动策略的记忆框架，适用于当前观测不足以进行动作选择的情况。TRACE 将任务相关的视觉和机器人状态证据存储在一组固定的潜在记忆槽中，并在




图 1：长时程操作中的延迟证据：在分支点，机器人必须选择一种任务延续。观测可能看起来相似，即使它们基于过去需要不同的动作。短历史策略失败是因为其窗口包含最新信息但不包含任何历史线索。TRACE 在线索可见时存储该线索，并在之后读取该记忆以实现正确的选择。

机器人执行动作。TRACE 并非按原始时间或任务标签索引记忆，而是利用路径签名 [3] 作为写入和读取记忆的键。这些签名是已执行机器人状态轨迹的定长、顺序敏感摘要。这些签名本身不存储视觉线索；相反，它们提供以轨迹为条件的访问，以获取线索可见时存储的证据。这使得 TRACE 能够在通过不同历史到达的视觉相似分支点处检索不同的已存储证据。随后，策略以 TRACE 记忆为条件，恢复缺失的上下文并选择正确的分支。TRACE 通过轻量级适配器附加到策略上，而不改变其骨干网络、动作头或模仿损失。

具体而言，本文的技术贡献如下：

- **延迟证据模仿**：本文定义了一类视觉运动模仿问题，其中视觉相似的分支点需要不同的动作，因为决定性证据在回合早期已经出现。
- **TRACE 记忆**：本文引入了一种固定预算的因果记忆，在线存储视觉和机器人状态证据，并使用已执行机器人状态轨迹的路径签名作为顺序敏感的键来写入和读取记忆。
- **即插即用集成与评估**：本文通过轻量级适配器将 TRACE 附加到动作分块和扩散策略上，而不改变其骨干网络、动作头或模仿损失，并在真实世界的延迟证据操作任务上对其进行评估，诊断结果表明保留历史证据带来了性能提升。

2 相关工作

视觉运动模仿策略与记忆：现代视觉运动策略将近期观测映射为动作、动作块或动作分布。动作分块策略通过时间聚合预测短时段 [4]，运动的概率表示支持对不确定性的推理 [5, 6]，而扩散策略通过迭代去噪生成动作序列 [7]。基于动力系统的策略是另一种表示形式，可提供鲁棒性保证 [8, 9]。更大规模的通用策略通过语言条件反射和广泛的机器人数据集扩展了这一范式 [10, 11, 12, 13, 14, 15, 16]。历史上，关于环境的记忆被封装在环境的地图表示中 [17, 18]。尽管存在这些差异，它们的行为仍受限条件状态中可用的信息。在延迟证据任务中，当前帧或短观测窗口可能不再包含后续分支所需的线索。循环策略、上下文窗口和显式记忆机制通过将信息向前传递来解决部分可观测性问题，但可能需要修改骨干网络、使用长上下文、检索演示或使用特定于规划器的记忆 [19, 20, 21]。TRACE 则通过轻量级适配器将固定预算的在线

记忆附加到动作策略上，而无需更改策略骨干、动作头或模仿目标。

轨迹签名与潜在历史表示：路径签名提供了连续轨迹的紧凑、顺序敏感的摘要，并已被用作序列特征和循环门控机制 [3, 22]。循环策略、变换器上下文窗口和显式记忆系统通过将信息向前传递来解决部分可观测性问题。最近的例子包括层局部外部记忆 [19]、用于冻结策略的检索提示记忆 [20]、声明式场景和情景记忆 [21]，以及用于分层模仿的关键帧记忆 [23]。这些方法改善了时间上下文，但通常需要修改策略骨干、从演示中检索或为规划器专门定制记忆。TRACE 以不同的方式使用潜在历史：路径和增量签名不是策略骨干、循环隐藏状态或未来预测目标。它们作为轨迹条件键，用于在固定预算记忆中写入和读取视觉和机器人状态证据，将记忆访问与已执行的轨迹联系起来，同时保持基础模仿损失不变。

3 问题设置与背景

本文使用“历史”一词指代在选择下一动作之前可用的因果执行信息。

延迟证据模仿：本文研究具有早期线索、共享执行段以及后续模糊分支点的模仿任务。分支是任务的一种可能延续，例如目标、路径或操作例程，而分支点是策略必须在这些延续之间做出选择的时刻。此时，不同的历史可能产生视觉上相似的观测，但需要不同的专家动作，因此仅凭当前观测无法消除歧义。

本文考虑演示 $\mathcal{D} = \{\tau_i\}_{i=1}^N$ ，其中 $\tau_i = \{(o_t^i, s_t^i, a_t^i)\}_{t=1}^{T_i}$ 包含多视角观测 o_t 、机器人状态 s_t 和演示动作 a_t 。设 $x_t = (o_t, s_t)$ ，并设 $\mathcal{H}_t = (x_1, a_1, \dots, x_{t-1}, a_{t-1}, x_t)$ 表示在选择 a_t 之前可用的历史。在延迟证据任务中， $\mathcal{H}_t$ 可能包含当前观测窗口中所缺失的任务相关证据。因此，对于长度为 w 的短窗口，可能存在历史 $\mathcal{H}_t$ 和 $\mathcal{H}'_t$ ，使得

$$x_{t-w+1:t} \approx x'_{t-w+1:t}, \quad a_t^*(\mathcal{H}_t) \neq a_t^*(\mathcal{H}'_t), \quad (1)$$

其中 $a_t^*(\mathcal{H}_t)$ 表示在历史 $\mathcal{H}_t$ 之后所需的专家目标。本文在问题设定中使用单步动作表示法，而在实现中策略原生的预测目标可以是动作、动作块、动作标记序列或扩散去噪目标。

路径签名作为流式轨迹键：TRACE 需要一个因果记忆键：一个紧凑的描述符，用于描述机器人如何到达当前状态，并在不存储完整历史的情况下在线维护。给定截至时间 t 的机器人状态轨迹的分段线性插值，记为 $S_t : [0, 1] \rightarrow \mathbb{R}^{d_s}$ ，其深度为 p 的路径签名为

$$\text{Sig}_{\leq p}(S_t) = \left(1, \int dS, \int_{u_1 < u_2} dS_{u_1} \otimes dS_{u_2}, \dots, \int_{u_1 < \dots < u_p} dS_{u_1} \otimes \dots \otimes dS_{u_p} \right). \quad (2)$$

签名概括了状态坐标变化之间的净变化和有序交互，使其对轨迹的展开方式敏感，而不仅仅是对所访问的状态敏感 [22]。对于连续路径，签名对单调时间重参数化具有不变性；对于采样的机器人轨迹，分段线性签名提供的描述符通常比时间步索引更少依赖于原始执行速度。这为 TRACE 提供了一个确定性的、固定预算的轨迹键，而不是使用另一个学习到的循环状态同时作为记忆和地址。签名还支持流式更新，因此 TRACE 可以在新状态到达时在线维护轨迹键。

在 TRACE 中，签名是用于内存访问的确定性轨迹描述符。它们不是任务标签、视觉记忆、循环隐藏状态或策略输出。视觉和机器人状态特征存储任务证据，而签名有助于确定该证据的写入和读取位置。




图 2: TRACE 信号流。TRACE 将当前视觉状态证据编码为记忆内容, 使用流式路径签名特征作为轨迹派生键, 更新固定大小的潜在记忆槽, 并将紧凑的记忆条件返回给基础视觉运动策略。

读取。我们将流式轨迹签名表示为 $\xi_t = \text{Sig}_{\leq p}(S_t)$, 以及签名坐标中的局部变化特征 $\delta_t = \xi_t - \xi_{t-1}$, 其中 $\delta_1 = \mathbf{0}$ 。签名维度细节见附录 A.5, 机器人状态表示见附录 A.4。

4 轨迹路由因果证据 (TRACE)

TRACE 通过固定大小的因果记忆增强现有的视觉运动模仿策略。在执行过程中, 它将任务相关的视觉和机器人状态证据写入潜在槽, 并在当前观测变得模糊时读取该记忆。基础策略保持其原始动作表示、动作头和模仿损失; TRACE 仅通过轻量级适配器添加记忆条件通路。图 2 总结了 TRACE 的组件。

4.1 因果记忆接口与轨迹键

设 $z_t = x_{t-w+1:t}$ 为基础策略使用的近期观测窗口, 其中 $x_t = (o_t, s_t)$ 包含多视图观测 o_t 和机器人状态 s_t 。我们将下游策略写为

$$\hat{y}_t = f_\psi(z_t, c_t), \quad (3)$$

其中 $\hat{y}_t$ 是策略的原生预测目标, 例如动作、动作块、动作标记序列或扩散去噪目标。TRACE 提供 c_t , 这是一个包含因果信息的记忆条件, 该信息可能不再在 z_t 中可见。

TRACE 将记忆内容与记忆访问分离。当前图像和机器人状态提供了应当记住的内容, 而执行的轨迹决定了这些信息存储在哪里以及之后如何检索。因此, 签名并非简单地拼接到策略输入中; 它们在一组固定的潜在槽位上路由记忆的写入和读取。在每个时间步, 在观察到 x_t 之后, 选择下一个动作之前, TRACE 将当前证据写入记忆, 从更新后的记忆读取, 然后查询策略:

$$R_t = (M_t, z_t^{\text{mem}}, g_t, \Delta g_t), \quad c_t = \mathcal{A}_\theta^{(e)}(R_t), \quad \hat{y}_t = f_\psi(z_t, c_t). \quad (4)$$

这里 $M_t \in \mathbb{R}^{K \times d}$ is a K -槽位潜在记忆, z_t^{mem} 是记忆读出, g_t 和 Δg_t 是轨迹导出的关键特征, $\mathcal{A}_\theta^{(e)}$ 是策略族 e 的适配器。

为了形成轨迹键, TRACE 使用截至时间 t 的归一化机器人状态路径, 写成分段线性路径 $S_t: [0, 1] \rightarrow \mathbb{R}^{d_s}$ 。它维护一个流式深度- p 路径签名 $\xi_t = \text{Sig}_{\leq p}(S_t)$ 和一个签名空间增量 $\delta_t = \xi_t - \xi_{t-1}$, 其中 $\delta_1 = \mathbf{0}$ 。累积签名 ξ_t 提供全局轨迹地址, 而增量 δ_t 在同一坐标系中暴露近期运动, 使得路由能够同时依赖于长时程路径上下文和局部进展。学习到的投影将它们嵌入为 $g_t = \phi_g(\xi_t)$ 和 $\Delta g_t = \phi_\Delta(\delta_t)$, 并形成轨迹键

$$q_t = \phi_q([g_t, \Delta g_t]). \quad (5)$$

除非另有说明，所有 ϕ 映射都是学习到的投影或多层感知机。关键在于 q_t 是轨迹导出的：它使用有序的机器人状态历史来索引记忆访问，而记忆内容存储视觉状态证据。

4.2 签名路由槽位记忆

TRACE 使用轨迹键在固定大小的潜在记忆上路由写入和读取。在每一步，当前视觉状态输入被编码为 $e_t = \phi_x(x_t)$ ，一个池化的多视图视觉和本体感受特征。该特征包含机器人当前可用的证据，例如物体身份、目标选择或路径相关线索。因此，TRACE 可以在线索可见时存储它，并在之后当前观察不再包含该信息时将其暴露出来。

记忆包含槽位 $M_t = \{m_{t,1}, \dots, m_{t,K}\}$ ，每个槽位 $m_{t,k} \in \mathbb{R}^d$ 。槽位在每个演示扫描或在线回合开始时重置。由于路由依赖于当前轨迹键和先前的槽位内容，槽位选择可以随着记忆内容的演变而适应，而不是遵循轨迹的固定哈希。给定轨迹键 q_t ，TRACE 计算路由状态 $\rho_t = \phi_\rho(q_t)$ 并将其与先前的槽位内容进行比较：

$$\bar{m}_{t-1,k} = m_{t-1,k} + \lambda_\eta \eta_k, \quad \ell_{t,k} = \frac{(W_Q \rho_t)^\top W_K \bar{m}_{t-1,k}}{\tau \sqrt{d_r}}, \quad \omega_{t,k} = \text{softmax}_k(\ell_{t,k}). \quad (6)$$

此处 η_k 为可选的固定槽位身份， λ_η 控制其权重， τ 为路由温度， $\omega_{t,k}$ 决定当前轨迹键对槽位 k 的选择强度。槽位身份在寻址过程中打破初始槽位对称性，但不作为循环记忆内容存储。

TRACE 通过门控更新将当前证据写入所选槽位。首先构造写入输入 $u_t = \phi_w(e_t, q_t)$ ，该输入结合当前视觉状态证据与轨迹键。随后槽位更新为

$$\tilde{m}_{t,k} = \tanh(\phi_m(\bar{m}_{t-1,k}, u_t, \rho_t)), \quad \beta_{t,k} = \omega_{t,k} \sigma(\phi_\beta(\bar{m}_{t-1,k}, u_t, \rho_t)), \quad (7)$$

$$m_{t,k} = (1 - \beta_{t,k}) m_{t-1,k} + \beta_{t,k} \tilde{m}_{t,k}. \quad (8)$$

此处 $\tilde{m}_{t,k}$ 为槽位 k 的候选新内容， $\beta_{t,k}$ 为路由调制的写入门。 $\omega_{t,k}$ 较小的槽位几乎保持不变，而被选中的槽位吸收当前视觉状态证据。写入后，TRACE 利用由当前证据与轨迹状态构成的查询从更新后的槽位中读取：

$$\alpha_{t,k} = \text{softmax}_k \left(\frac{\phi_r(e_t, \rho_t)^\top W_K^r (m_{t,k} + \lambda_\eta \eta_k)}{\sqrt{d}} \right), \quad z_t^{\text{mem}} = \sum_{k=1}^K \alpha_{t,k} W_V^r m_{t,k}. \quad (9)$$

此处 $\alpha_{t,k}$ 为读取权重， W_K^r, W_V^r 为可学习的读取键与读取值投影。共享 TRACE 状态为 $R_t = (M_t, z_t^{\text{mem}}, g_t, \Delta g_t)$ 。此处 $M_t \in \mathbb{R}^{K \times d}$ 为更新后的 K 槽位潜在记忆， z_t^{mem} 为从 M_t, g_t 读取的输出， Δg_t 为轨迹导出的关键特征， $\mathcal{A}_\theta^{(e)}$ 为策略族 e 的适配器。完整投影、辅助损失与伪代码细节见附录 A.9。

训练与部署均采用相同的因果扫描：TRACE 仅接收策略查询前可用的观测与机器人状态，不使用线索标签、分支标签、未来帧或测试时演示检索。每一步的记忆更新仅使用截至该时刻可用的观测与状态，所得条件 c_t 传入基础策略未改变的模仿损失。

4.3 策略适配器：从 TRACE 记忆到策略条件化

TRACE 更新器跨策略族共享；仅策略侧适配器发生变化。给定共享 TRACE 状态 $R_t = (M_t, z_t^{\text{mem}}, g_t, \Delta g_t)$ ，适配器将记忆映射到策略族 e 的原生条件空间，即 $c_t^{(e)} = \mathcal{A}_\theta^{(e)}(R_t) \in \mathcal{C}_e$ 。基础策略的动作表示、动作头与监督模仿损失保持不变。

对于动作分块回归策略，适配器将记忆槽投影为 512 维记忆令牌，并将 $[z_t^{\text{mem}}, g_t, \Delta g_t]$ 映射为摘要令牌。这些令牌被拼接到策略的注意力记忆中，之后原始动作头回归原生动作块。对于扩散策略，适配器使用读取权重对槽进行池化，将池化后的记忆与 z_t^{mem}, g_t 以及 Δg_t 拼接，并通过零初始化多层感知机将结果映射为加性全局条件向量。去噪过程和扩散损失其余部分保持不变。

因此，适配器仅是从 TRACE 记忆到策略现有条件接口的转换器，而非新的策略主干、动作解码器或检索模块。附录 A.8 给出了架构细节、参数数量、延迟和训练细节。

5 实证评估

我们围绕四个问题组织实验：（1）添加因果记忆是否改善延迟证据操作？（2）增益是否跨策略族迁移？（3）TRACE 是否优于通用历史记忆？（4）TRACE 是否利用历史证据而非仅依赖决策点观测？我们通过基策略比较、跨策略 TRACE 变体、记忆消融和历史变换诊断来回答这些问题。

实验设置。图 3 展示了延迟证据任务套件。我们使用 [24] 中描述的系统收集数据。我们在五个真实世界任务上进行评估：工具任务，初始物体身份决定后续工具序列；书籍任务，起点决定路线和放置位置；洗衣任务，起点侧决定刷洗装篮还是折叠存放；线缆任务，起点侧决定匹配设备；药品任务，托盘起点决定盒子选择和返回。附录 A.3 给出了任务、数据集和部署细节。

基线。我们将 TRACE 附加到回归式动作分块策略和基于扩散的策略上，并与相应的基策略进行比较。我们还评估了用于模仿或语言条件控制的可部署机器人策略族，包括 SmolVLA [14]、 $\pi_{0.5}$ [13]、X-VLA [15] 和 GR00T N1.6 [16]。这些 VLA 基线不是冻结的零样本模型：每个模型都在相同的单任务演示和训练/评估划分上进行了适配。附录 A.1 给出了模型设置，附录 A.2 报告了所有基线和 TRACE 模块的训练超参数和参数数量。

度量。遵循长时程操作基准中的部分进度报告方式 [25, 26]，我们按有序子任务上的阶段级进度对每次执行进行评分，包括操作阶段和依赖记忆的分支决策。我们报告任务平衡平均值、执行标准误、自助法不确定性，并在附录 A.1 中给出完整评分细节。

问题 1. 记忆是否有助于延迟证据操作？是的。表 1 比较了基础视觉运动策略、微调后的 VLA 风格基线，以及加入 TRACE 因果记忆的共同基础策略族。TRACE 显著提升两种策略族：回归从 25.50 提升至 69.23 平均进度，扩散从 25.00 提升至 59.53。TRACE 还优于最强的非 TRACE 基线 $\pi_{0.5}$ ，回归高出 18.76 个百分点，扩散高出 9.06 个百分点。最大提升出现在早期观察到的起点或物体线索决定后续分支、且线索已离开视野的任务上。



图 3：所选延迟证据操作任务概览。

要点。TRACE 相比无因果记忆的策略改善了延迟证据操作，在书籍、洗衣和药物任务上提升最明显，这些任务中早期起点线索决定后续视觉上模糊的分支。总体结果并非仅由高方差的工具任务驱动：附录 A.11 报告了留一任务和工具任务专项分析。附录 A.10

表 1: 真实世界延迟证据任务的主要比较。数值为平均阶段进度 (%) $\pm$ SE.

Method	Tool $\uparrow$	Book $\uparrow$	Laundry $\uparrow$	Cable $\uparrow$	Medicine $\uparrow$	Avg. progress $\uparrow$
Diffusion Policy	18.00 $\pm$ 1.41	12.33 $\pm$ 0.44	22.00 $\pm$ 0.32	34.00 $\pm$ 0.48	38.67 $\pm$ 1.01	25.00 $\pm$ 0.38
ACT	31.00 $\pm$ 5.51	13.67 $\pm$ 0.49	11.50 $\pm$ 2.01	44.00 $\pm$ 7.79	27.33 $\pm$ 0.05	25.50 $\pm$ 1.95
$\pi_{0.5}$	45.50 $\pm$ 0.81	51.00 $\pm$ 6.99	47.50 $\pm$ 1.45	49.00 $\pm$ 0.57	59.33 $\pm$ 1.45	50.47 $\pm$ 1.47
GR00T N1.6	39.00 $\pm$ 2.31	12.67 $\pm$ 2.14	24.00 $\pm$ 2.72	38.00 $\pm$ 12.11	39.33 $\pm$ 3.29	30.60 $\pm$ 2.64
SmolVLA	25.00 $\pm$ 1.51	20.00 $\pm$ 0.82	12.00 $\pm$ 2.16	50.00 $\pm$ 1.44	34.67 $\pm$ 1.01	28.33 $\pm$ 0.65
X-VLA	5.50 $\pm$ 0.94	47.00 $\pm$ 6.19	41.00 $\pm$ 0.36	36.00 $\pm$ 21.44	40.00 $\pm$ 2.92	33.90 $\pm$ 4.51
Ours (Regression)	54.50 $\pm$ 17.96	83.00 $\pm$ 0.86	81.00 $\pm$ 2.84	51.00 $\pm$ 1.11	76.67 $\pm$ 1.05	69.23 $\pm$ 3.65
Ours (Diffusion)	58.50 $\pm$ 10.17	68.33 $\pm$ 2.86	70.50 $\pm$ 0.76	51.00 $\pm$ 4.63	49.33 $\pm$ 0.17	59.53 $\pm$ 2.31




图 4: Book 任务的展开结果。时间轴包含过去线索、视觉上模糊的过渡阶段以及目标选择,而叠加的槽位图和右侧面板展示了证据的写入、保留和读取位置。正负号表示带符号的记忆权重:正权重为所选槽位增加支持,负权重则携带相反符号的证据以抑制这些槽位。

进一步将常见分支错误、展开证据和 TRACE 行为与任务案例联系起来。部署开销在附录 A.8 中测量。

问题 2: 增益是否局限于特定的策略族? 否。表 1 显示, TRACE 在回归和扩散两种变体上均有提升,且使用相同的更新器、相同的签名路由和相同的训练历史扫描。仅策略适配层发生变化:回归使用适配器处理动作分块回归器,而扩散使用适配器处理扩散策略。在这些测量的展开中,回归平均表现更强。其记忆条件在单次前向传播中进入,而扩散采样器在反复细化中携带该条件。关键在于两种策略族都受益于相同的 TRACE 记忆状态。这支持了模块化设计的主张,即 TRACE 提供缺失的历史信息,同时保持下游模仿目标和动作头不变。

图 4 可视化了测量的记忆信号。签名索引的写入不会坍缩到单个槽位。路由随回合进展而变化,而读出对分支点附近携带历史证据的槽位保持选择性。在 Book 展开中,俯视图在拾取和过渡后视觉上变得相似,但记忆图通过带符号的签名分数和高权重槽位边保留了依赖起点的轨迹。附录 A.10 提供了额外的任务级案例研究,将这些诊断与具体的展开失败和恢复联系起来。

问题 3: TRACE 是否优于通用的历史记忆? 是,当延迟线索必须通过已执行的因果历史来保留时。表 2 在相同的回归基础策略和归一化条件下,将 TRACE 与循环、历史令牌、外部记忆和检索替代方案进行了比较,

表 2: 记忆模块比较。循环、变换器上下文、最近最少使用和检索提示对照分别受门控循环单元门控 [27]、自注意力上下文 [28]、最近最少使用外部记忆访问 [29] 和记忆增强提示 [20] 启发。数值为平均阶段进度百分比 $\pm$ SE。

Memory module	Online	Fixed	Sig.	Tool	Book	Laundry	Cable	Medicine	Avg.
No memory	–	–	–	31.00 $\pm$ 5.51	13.67 $\pm$ 0.49	11.50 $\pm$ 2.01	44.00 $\pm$ 7.79	27.33 $\pm$ 0.05	25.50 $\pm$ 1.95
GRU recurrent memory	✓	✓	–	40.50 $\pm$ 9.12	49.00 $\pm$ 3.04	44.00 $\pm$ 2.21	47.00 $\pm$ 4.98	48.67 $\pm$ 1.24	45.83 $\pm$ 1.91
Transformer history context	–	–	–	40.50 $\pm$ 7.83	61.67 $\pm$ 2.54	55.00 $\pm$ 1.96	46.00 $\pm$ 3.87	57.33 $\pm$ 1.41	52.10 $\pm$ 1.68
LRU external memory	✓	✓	–	46.50 $\pm$ 7.64	57.67 $\pm$ 2.48	54.50 $\pm$ 2.03	51.00 $\pm$ 3.52	60.00 $\pm$ 1.22	53.93 $\pm$ 1.61
Retrieval-prompt memory	–	–	–	48.00 $\pm$ 7.66	62.67 $\pm$ 2.18	59.50 $\pm$ 1.77	50.00 $\pm$ 3.62	61.33 $\pm$ 1.12	56.30 $\pm$ 1.46
TRACE signature-routed slots	✓	✓	✓	54.50 $\pm$ 17.96	83.00 $\pm$ 0.86	81.00 $\pm$ 2.84	51.00 $\pm$ 1.11	76.67 $\pm$ 1.05	69.23 $\pm$ 3.65

表 3: 消融与历史变换诊断。路由相似性衡量变换后的在线回放历史与原始完整轨迹回放中槽位路由由序列的一致性。分支一致性衡量分支点记忆读出与分支动作之间的一致性。两项诊断均仅针对完整轨迹回放进行归一化，以便跨任务比较。

Component ablations		History-transform diagnostics			
Variant	Avg. $\uparrow$	History transform	Tested property	Route similarity $\uparrow$	Branch consistency $\uparrow$
Current observation only	25.50 $\pm$ 1.95	Time resampling	time-change inv.	92.40 $\pm$ 1.10	96.00 $\pm$ 0.80
Signature-only	45.50 $\pm$ 1.82	Speed jitter	time-change inv.	89.80 $\pm$ 1.40	94.70 $\pm$ 1.00
Unrouted slot memory	52.17 $\pm$ 1.63	State offset	offset inv.	91.20 $\pm$ 1.20	95.10 $\pm$ 0.90
No-delta routing	61.43 $\pm$ 2.21	Sparse sampling	sampling robust.	86.50 $\pm$ 1.60	92.30 $\pm$ 1.20
Mean readout	62.80 $\pm$ 2.44	Order reversal	negative control	37.80 $\pm$ 2.50	41.60 $\pm$ 2.20
No auxiliary losses	66.10 $\pm$ 2.84	Order-preserving controls	summary	89.98 $\pm$ 0.68	94.53 $\pm$ 0.49
Full TRACE	69.23 $\pm$ 3.65	Full TRACE	reference	100.00 $\pm$ 0.00	100.00 $\pm$ 0.00

化与评估模块。这些对照旨在探究延迟证据操纵是否仍需更多历史信息，抑或历史必须围绕已执行的因果历史进行组织。

要点。通用记忆相对于无记忆有所助益，但表 2 显示，仅靠上下文长度或存储容量无法与轨迹回放相匹敌。匹配的对照能够保留历史，但并未明确将延迟线索绑定到将在分支点读取的已执行轨迹地址上。附录 A.10 将这一区别与任务级分支错误及轨迹回放恢复联系起来。

问题 4: 诊断是否表明轨迹回放利用了先前证据，而非仅依赖决策点的观测？是的。表 3 报告了消融与历史变换诊断，以检验轨迹回放是否利用了已执行的历史。路由相似性衡量变换后的在线回放历史在分支点之前是否经由与原始轨迹回放相同的槽位路由写入。分支一致性衡量分支点读出是否仍携带相同的延迟分支选择。时间重采样、速度抖动、状态偏移和稀疏采样应保留相关历史证据，而顺序反转则刻意破坏历史的因果顺序。我们将每项原始诊断按同一任务上的完整轨迹回放值进行归一化，以实现跨任务可比性。附录 A.6 给出了完整公式与平均方法。

要点。表 3 支持预期行为。保序变换使路由相似性和分支一致性接近完整轨迹回放参考值，而顺序反转则显著降低两项诊断指标。这一对比将记忆读出与有序历史证据而非决策点处不变的观测联系起来。

6 局限性与结论

局限性：主要局限性在于签名的维度。对于标准的截断签名，在学习压缩之前，原始特征维度会随着机器人状态维度和签名深度的增加而迅速增长。这可能会增加归一化、投影、内存和计算成本，并且当需要更高维度的状态或更深的签名时，可能会使 TRACE 的效率降低。

结论：TRACE 为视觉运动机器人策略提供了一个紧凑的因果记忆状态，用于记录已执行的历史。通过使用路径和增量签名来路由视觉状态写入，它将过去的任务证据存储在一个固定大小的 TRACE 记忆状态中，并通过一个轻量级适配器呈现该记忆。这产生了一种模块化设计，其中记忆和动作生成与基础策略目标保持分离。

在五个真实世界的延迟证据任务中，相同的记忆模块同时提升了回归和扩散策略家族的性能，诊断结果表明，性能提升源于对历史的记忆，而非仅仅依赖决策点附近可见的线索。

参考文献

- [1] H. Ravichandar, A. S. Polydoros, S. Chernova, and A. Billard. Recent advances in robot learning from demonstration. *Annual review of control, robotics, and autonomous systems*, 2020.
- [2] W. Zhi, T. Lai, L. Ott, and F. Ramos. Diffeomorphic transforms for generalised imitation learning. In *Learning for Dynamics and Control Conference, LADC*, 2022.
- [3] I. Chevyrev and A. Kormilitzin. A primer on the signature method in machine learning. In *Signature Methods in Finance: An Introduction with Computational Applications*, pages 3–64. Springer, 2025.
- [4] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023.
- [5] W. Zhi, T. Zhang, and M. Johnson-Roberson. Instructing robots by sketching: Learning from demonstration via probabilistic diagrammatic teaching. In *IEEE International Conference on Robotics and Automation (ICRA)*, 2024.
- [6] A. Paraschos, C. Daniel, J. Peters, and G. Neumann. Probabilistic movement primitives. In *Proceedings of the 26th International Conference on Neural Information Processing Systems*, 2013.
- [7] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, 44(10-11):1684–1704, 2025.
- [8] W. Zhi, T. Lai, L. Ott, E. V. Bonilla, and F. Ramos. Learning efficient and robust ordinary differential equations via invertible neural networks. In *International Conference on Machine Learning, ICML*, 2022.
- [9] W. Zhi, H. Tang, T. Zhang, and M. Johnson-Roberson. Teaching periodic stable robot motion generation via sketch. *IEEE Robotics and Automation Letters*, 2025.
- [10] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, J. Dabis, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, J. Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.
- [11] B. Zitkovich, T. Yu, S. Xu, P. Xu, T. Xiao, F. Xia, J. Wu, P. Wohlhart, S. Welker, A. Wahid, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, pages 2165–2183. PMLR, 2023.
- [12] A. O’Neill, A. Rehman, A. Maddukuri, A. Gupta, A. Padalkar, A. Lee, A. Pooley, A. Gupta, A. Mandlekar, A. Jain, et al. Open X-embodiment: Robotic learning datasets and RT-X models. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 6892–6903. IEEE, 2024.
- [13] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter, S. Jakubczak, T. Jones, L. Ke, S. Levine, A. Li-Bell, M. Mothukuri, S. Nair, K. Pertsch, L. X. Shi, J. Tanner, Q. Vuong, A. Walling, H. Wang, and U. Zhilinsky. π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.

- [14] M. Shukor, D. Aubakirova, F. Capuano, P. Kooijmans, S. Palma, A. Zouitine, M. Aractingi, C. Pascal, M. Russi, A. Marafioti, et al. Smolvla: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.
- [15] J. Zheng, J. Li, Z. Wang, D. Liu, X. Kang, Y. Feng, Y. Zheng, J. Zou, Y. Chen, J. Zeng, et al. X-vla: Soft-prompted transformer as scalable cross-embodiment vision-language-action model. *arXiv preprint arXiv:2510.10274*, 2025.
- [16] J. Bjorck, F. Castañeda, N. Cherniadev, X. Da, R. Ding, L. Fan, Y. Fang, D. Fox, F. Hu, S. Huang, et al. Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*, 2025.
- [17] W. Zhi, L. Ott, R. Senanayake, and F. Ramos. Continuous occupancy map fusion with fast bayesian hilbert maps. In *International Conference on Robotics and Automation (ICRA)*, 2019.
- [18] W. Zhi, R. Senanayake, L. Ott, and F. Ramos. Spatiotemporal learning of directional uncertainty in urban environments with kernel recurrent mixture density networks. *IEEE Robotics and Automation Letters*, 2019.
- [19] E. Cherepanov, A. K. Kovalev, and A. I. Panov. ELMUR: External layer memory with update/rewrite for long-horizon RL problems. *arXiv preprint arXiv:2510.07151*, 2025.
- [20] R. Li, W. Guo, Z. Wu, C. Wang, H. Deng, Z. Weng, Y.-P. Tan, and Z. Wang. MAP-VLA: Memory-augmented prompting for vision-language-action model in robotic manipulation. *arXiv preprint arXiv:2511.09516*, 2025.
- [21] M. Lin, X. Liang, B. Lin, L. Jingzhi, Z. Jiao, K. Li, Y. Ma, Y. Liu, S. Zhao, Y. Zhuang, et al. EchoVLA: Robotic vision-language-action model with synergistic declarative memory for mobile manipulation. *arXiv preprint arXiv:2511.18112*, 2025.
- [22] P. Kidger and T. Lyons. Signatory: differentiable computations of the signature and logsignature transforms, on both CPU and GPU. *arXiv preprint arXiv:2001.00706*, 2020.
- [23] T. Buamane, M. Kobayashi, and Y. Uranishi. Bi-HIL: Bilateral control-based multimodal hierarchical imitation learning via subtask-level progress rate and keyframe memory for long-horizon contact-rich robotic manipulation. *arXiv preprint arXiv:2603.13315*, 2026.
- [24] Z. Li, Y. Zhou, R. Qiu, H. Wu, G. Ren, and W. Zhi. Tripilot-ff: Coordinated whole-body teleoperation with force feedback. *arXiv preprint arXiv:2602.09888*, 2026.
- [25] M. Heo, Y. Lee, D. Lee, and J. J. Lim. Furniturebench: Reproducible real-world benchmark for long-horizon complex manipulation. *The International Journal of Robotics Research*, 44 (10-11):1863–1891, 2025.
- [26] O. Mees, L. Hermann, E. Rosete-Beas, and W. Burgard. Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. *IEEE Robotics and Automation Letters*, 7(3):7327–7334, 2022.
- [27] K. Cho, B. Van Merriënboer, Ç. Gulçehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio. Learning phrase representations using rnn encoder–decoder for statistical machine translation. In *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*, pages 1724–1734, 2014.
- [28] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- [29] A. Santoro, S. Bartunov, M. Botvinick, D. Wierstra, and T. Lillicrap. Meta-learning with memory-augmented neural networks. In *International conference on machine learning*, pages 1842–1850. PMLR, 2016.

A 技术附录

本附录汇集了支持正文的技术材料。各小节按照论文叙述顺序排列。它们定义了 TRACE 的延迟证据设置，指定了状态表示，总结了训练超参数，陈述了签名和记忆方程，定义了诊断方法，并给出了适配器、方差和案例研究的细节，这些内容对于正文来说过于冗长。

A.1 问题设置细节

我们考虑演示 $\mathcal{D} = \{\tau_i\}_{i=1}^N$ ，其中

$$\tau_i = \{(o_t^i, s_t^i, a_t^i)\}_{t=1}^{T_i}, \quad x_t^i = (o_t^i, s_t^i), \quad \mathcal{H}_t^i = (x_1^i, a_1^i, \dots, x_{t-1}^i, a_{t-1}^i, x_t^i). \quad (10)$$

此处 x_t 为当前多视角观测与机器人状态， $\mathcal{H}_t$ 为在时刻 t 选择动作之前可用的因果历史。延迟证据任务包含一个过去证据变量 $e_i = \eta(\mathcal{H}_{t_e}^i)$ ，该变量在某个 $t_e < t_b$ 的历史中被观测到。该变量可以是起始货架、衣物侧面、来源托盘、物体身份或其他决定后续分支的线索。在分支步骤 $t = t_b$ 处，分支动作 a_t 是其正确取值依赖于先前证据的动作。

核心歧义在于，不同的过去证据可能导致分支点处几乎相同的当前观测。可能存在两条轨迹，其 $e_i \neq e_j$ 满足

$$x_{t_b}^i \approx x_{t_b}^j, \quad a_{t_b}^{i,*} \neq a_{t_b}^{j,*}, \quad p(a_{t_b}^* | \mathcal{H}_{t_b}^i) \neq p(a_{t_b}^* | \mathcal{H}_{t_b}^j). \quad (11)$$

形式为 $\pi(a_t | x_t)$ 的策略必须为这些模糊的分支观测分配一个动作分布，因此对于该设置而言并不充分。所需对象是一个紧凑的因果历史摘要 $m_t = m(\mathcal{H}_t)$ ，使得 $\pi(a_t | x_t, m_t)$ 能够恢复依赖证据的分支决策，同时保持接口尺寸固定。

TRACE 通过在线签名路由槽记忆及其导出的适配器条件来实现 m_t 。过去证据变量 e_i 仅是一个用于描述问题的未观测变量。TRACE 不接收 e_i 作为监督标签。它也不接收分支标签、任务标识符、未来观测或未来动作。在训练和部署期间，其在时刻 t 的记忆更新仅读取包含在 $\mathcal{H}_t$ 中的因果历史。

每次展开的评分通过将任务分解为有序子任务，再进一步分解为阶段来进行。该度量受长时程操作基准中部分进度报告的启发，包括 FurnitureBench 中已完成阶段或子任务以及 CALVIN 风格评估中的成功任务链长度 [25, 26]。它遵循报告惯例，而非复用相同公式。对于任务 q ，报告的进度为

$$\text{Progress}_q = \frac{100}{N_q T_q S_q} \sum_{i=1}^{N_q} \sum_{k=1}^{T_q} \sum_{j=1}^{S_q} \mathbf{1}[\text{stage}_{i,k,j} \text{ succeeds}]. \quad (12)$$

此处 $N_q=25$ 为主评估中的物理展开次数， T_q 为子任务数量， S_q 为每个子任务的阶段数。聚合平均按任务平衡。标准误使用每个任务内的展开级自助重采样。

基线对照。

表 4 给出了实验中引用的基线协议。比较过程中，各方法在相机、本体感知、动作频率、训练集划分归一化以及保留的评估列表方面均保持一致。

表 4: 外部视觉-语言-动作基线协议。语言条件模型仅接收通用任务提示。

Baseline	Initialisation and trainable parts	Budget	Interface controls
SmolVLA	lerobot/smolvla_base, tuned adapter and state mapper, frozen vision	180k updates	3 RGB views, 17-D state, 50-step action chunks
$\pi_{0.5}$	lerobot/pi05_base with the released policy adaptation path	180k updates	224px RGB views, 17-D state, 50-step action chunks
X-VLA	lerobot/xvla_base, tuned policy transformer and soft prompts	180k updates	Same views and state, 16-step action chunks, no cue prompt
GR00T N1.6	Released N1.6 adaptation with tuned embodiment and action head	180k updates	Same rollout API, action rate, and held out episodes

纳入基线协议表是为了使比较可审计，而非增加另一项性能声明。重要的控制在于每个基线都看到相同的摄像头流，

本体感觉布局、动作频率以及留出评估列表。语言条件方法接收通用任务提示，因此延迟线索不会通过文本泄露。

A.2 模型规模与超参数

报告了参数核算和训练超参数，以支持跨策略家族的可重复性和容量公平性。它们不作为独立的性能声明。表 5 将总容量、可训练容量和冻结容量与本地检查点和模型缓存审计分开。表 7 总结了训练计划和优化器设置，而决定 TRACE 模块大小的架构设置列于表 10。

表 5: 基线模型与 TRACE 模块的模型规模汇总，数据来源于本地检查点与模型缓存审计。

Model or module	Count scope	Total parameters	Trainable parameters	Frozen parameters or frozen parts	Notes
ACT	Full policy used as the regression base expert	51.62M	51.62M	0	Same observations, state, action rate, and train split as TRACE Regression runs
Diffusion Policy	Full policy used as the diffusion base expert	270.96M	270.96M	0	Same observations, state, action rate, and train split as TRACE Diffusion runs
SmoVLA	Fine tuned LeRobot baseline	450.05M	99.88M	350.17M VLM frozen	Uses the released fine tuning head and matched single task data
$\pi_{0.5}$	Fine tuned LeRobot baseline	3.62B	693.42M	2.92B PaliGemma VLM frozen	Uses the released adaptation path and matched single task data
X-VLA	Fine tuned VLA baseline	879.74M	879.74M	0	Tuned VLM, policy transformer, and soft prompts, with no cue prompt
GR00T N1.6	Fine tuned humanoid policy baseline	2.72B	1.07B	1.66B language/vision frozen	Tuned embodiment interface and action head under the matched rollout API
TRACE updater	Shared signature routed memory updater only	11.91M	11.91M	0	Excludes the base expert and policy specific adapter
Regression adapter	TRACE adapter for the regression base expert	0.79M	0.79M	0	Excludes the shared updater and the base expert
Diffusion adapter	TRACE adapter for the diffusion base expert	16.03M	16.03M	0	Excludes the shared updater and the base diffusion expert

审计将模型容量与记忆模块分离。ACT 与扩散策略（Diffusion Policy）是两种 TRACE 接口的基础专家，而视觉语言动作（VLA）基线则包含其已发布的适配路径与冻结组件。TRACE 更新器在适配器间共享，因此新增容量可归因于固定的记忆模块加上一个小型面向策略的转换器，而非新的动作主干网络。

表 6 报告了 TRACE 在两种面向策略的接口上的附加参数预算。参考基础专家仅用作百分比审计的分母。行名描述的是 TRACE 接口，而非固定的组方法。新增计数包括共享更新器和策略专用适配器。百分比根据审计计数计算为 $100 \times N_{\text{added}}/N_{\text{base}}$ 。

表 6: 按面向策略的接口划分的 TRACE 附加参数预算。

TRACE interface	Reference base expert	Added TRACE parts	Base parameters	Added parameters	Increase	Notes
Regression-policy interface	ACT audit checkpoint	Shared updater plus regression-interface adapter	51.62M	12.69M	24.6%	Interface only
Diffusion-policy interface	Diffusion Policy audit checkpoint	Shared updater plus diffusion-interface adapter	270.96M	27.94M	10.3%	Interface only

附加参数表显示，两种接口的容量成本不同，因为它们所条件化的基础专家不同。回归接口在审计的 ACT 检查点上增加 12.69 M 参数，扩散接口在审计的扩散策略检查点上增加 27.94 M 参数。

这些计数用于容量核算，并不替代表 1 中的物理部署比较。

表 7: 报告协议所使用的训练超参数。所有策略均训练 180k 次更新；批大小和动作窗口遵循各策略家族。

Policy family	Code policy	Updates / batch	Action window	Optimiser and scheduler	Fine-tuning settings
ACT regression	act	180k updates; batch 8 or 32	Chunk 100, execute 100	LeRobot ACT optimiser preset; AMP enabled	No TRACE memory; same cameras, state, action normalisation, train split, and evaluation API as TRACE Regression
Diffusion Policy	diffusion	180k updates; batch 8	2 obs. steps, horizon 104, execute 100, drop last 3 frames	LeRobot Diffusion optimiser preset; AMP enabled	No TRACE memory; same observation and action interface as TRACE Diffusion
SmolVLA	smolvla	180k updates; batch 8 or 16	1 obs. step, chunk 50, execute 50, 10 flow steps	AdamW, lr 10^{-4} , weight decay 10^{-10} , grad clip 10; 1000 warmup steps and cosine decay over 30k steps to 2.5×10^{-6}	Frozen vision encoder; train action expert and state projection; generic task prompt only
$\pi_{0.5}$	pi05	180k updates; batch 1	1 obs. step, chunk 50, execute 50, 10 inference steps	AdamW, lr 2.5×10^{-5} , weight decay 0.01, grad clip 1; 1000 warmup steps and cosine decay over 30k steps to 2.5×10^{-6}	Frozen vision encoder; train action expert branch; mean/std state and action normalisation for the Zeno datasets
X-VLA	xvla	180k updates; batch 1	1 obs. step, chunk 16, execute 16, 10 denoising steps	AdamW, lr 10^{-4} , weight decay 0, grad clip 10; 1000 warmup steps and cosine decay over 30k steps to 2.5×10^{-6}	Train policy transformer and soft prompts; no cue prompt
GR00T N1.6	External adaptation	180k updates	Same rollout API and action rate as the robot policies	Released N1.6 adaptation recipe	Tune embodiment interface and action head; language and vision components frozen as in the parameter audit

训练表有意与下方的架构表分开。表 7 记录了报告训练协议中使用的优化预算、动作视野和微调选择。

表 10 记录了决定 TRACE 模块大小和路由接口的记忆架构值。

A.3 数据集与演示细节

表 8 对五个真实机器人任务的数据核算进行了明确说明。物理部署次数是方程 12 中使用的主要评估次数。工具、书本和衣物任务的次数与时间跨度均从处理后的 LeRobot 元数据中审计得出。线缆和药品任务的次数与时间跨度则通过本地 ROS 包时间戳扫描审计得出，采用与转换器相同的 30 赫兹采样规则。

表 8: 本文报告的真实机器人评估协议的数据集规模与状态签名 (SS) 细节。

Task	Train demos	Validation demos	Physical eval. rollouts	Episode length or avg. horizon	Subtasks / stages	Held-out factors
Tool	100	0	25	2,910 frames (97.0s)	2/4	Object instances, cue assignments, poses, lighting, distractors
Book	150	0	25	1,392 frames (46.4s)	3/4	Origin cue assignments, poses, routes, lighting, distractors
Laundry	60	0	25	2,220 frames (74.0s)	2/4	Garment instances, origin side assignments, poses, lighting, distractors
Cable	30	0	25	1,770 frames (59.0s)	1/4	Origin side assignments, device poses, lighting, distractors
Medicine	60	0	25	1,759 frames (58.6s)	2/4	Tray origin assignments, box poses, lighting, distractors, bedside props

数据集表格明确了证据来源。每个任务使用 25 次物理评估部署，主表中报告的进度分数均基于这些部署计算。训练演示的次数与时间跨度来自审计后的元数据或 ROS 包时间戳扫描。保留因素表明，评估改变了物体实例、线索分配、位姿、光照和干扰物，而非重复训练片段。

A.4 状态表示与归一化

策略主干与 TRACE 使用一个俯视 RGB 相机、两个腕部 RGB 相机以及一个 17 维本体感受状态。状态顺序为基座平面速度、基座偏航速度、左臂关节位置和右臂关节位置。固定基座任务保持相同布局，并在签名计算前将基座通道置零。零掩码在训练集标准化之前应用，因此恒定通道不会贡献路径增量。

在每个控制步骤中，掩码后的状态被标准化并追加到流式历史路径中。第一个观测状态用作基点。TRACE 省略标量签名坐标。对于 $d_s=17$ 和 $p=3$ ，这给出 $d_{\text{sig}} = 17 + 17^2 + 17^3 = 5,219$ 。路径签名和单步增量签名在输入学习映射 ϕ_g 和 ϕ_Δ 之前，使用各自的训练集统计量进行归一化。签名状态中不追加任何线索标签、语言标记、夹爪指令历史、未来动作或分支标识符。

表 9: TRACE 签名使用的机器人状态通道。

Channel block	Dim.	Units	Normalisation for signature input	Zeroed channel rule
Base planar velocity (v_x, v_y)	2	m/s	Train mean/std after the zero mask with std floor 10^{-6}	Fixed-base tasks set both channels to 0
Base yaw velocity ω	1	rad/s	Train mean/std after the zero mask with std floor 10^{-6}	Fixed-base tasks set this channel to 0
Left arm joints $q_{0,\dots,6}^L$	7	rad	Train mean/std, then append to the history path	Never zeroed
Right arm joints $q_{0,\dots,6}^R$	7	rad	Train mean/std, then append to the history path	Never zeroed
Full state path $s_{1,\dots,t}$	17	normalised units	Piecewise linear path over masked, standardised states	Constant zero channels add no increments
Path signature ξ_t	5,219	signature units	Train mean/std over history signatures, then $g_t = \phi_g(\xi_t)$	Scalar coordinate omitted
Delta signature δ_t	5,219	signature units	Train mean/std over one-step differences, then $\Delta g_t = \phi_\Delta(\delta_t)$	$\delta_1 = \mathbf{0}$

状态表明哪些信息可以进入签名，哪些不能。路由键仅使用掩码和标准化后的机器人状态路径，固定基座的恒定通道不贡献路径增量。不追加任何线索标签、分支标识符、未来动作或语言标记。这保持了记忆条件的因果性，并防止签名成为隐藏的分支线索。

表 10 列出了所报告运行中使用的共享 TRACE 设置。这些值定义了签名接口、内存宽度和适配器维度。下游策略损失和动作头保持不变。

表 10: 核心 TRACE 超参数。

数量 报告设置 备注		
Signature depth p	3	Standard streamed signature
Raw signature dim. d_{sig}	5,219	$17 + 17^2 + 17^3$, scalar term omitted
Signature embedding dims.	512 for g_t , 512 for Δg_t	Shared by both adapters
Slot count K	4 or 6	Chosen by task horizon and branch diversity
Slot width d	512	Matches policy conditioning width
History budget L	24 or 32	Used for training-time causal history reconstruction
History stride r	4 to 8	Covers the recent tail at 30 FPS data rate
Routing hidden size	512	Used for route query and key maps
Adapter hidden size	512	Used by regression memory tokens and diffusion conditioning maps

这些超参数使共享的 TRACE 更新器在两个策略族之间保持一致。深度 3 签名提供路由历史键，512 维内存槽与策略条件宽度匹配，固定历史预算控制监督训练扫描。该表还将这些内存设置与基础策略损失和动作解码器分开，后者保持不变。

A.5 签名深度与不变性

设 S_t 为因果状态历史到时间 t 的分段线性插值。TRACE 使用截断路径签名及其一阶差分

$$\xi_t = \text{Sig}_{\leq p}(S_t) \in \mathbb{R}^{d_{\text{sig}}}, \quad \delta_t = \xi_t - \xi_{t-1}, \quad g_t = \phi_g(\xi_t), \quad \Delta g_t = \phi_\Delta(\delta_t). \quad (13)$$

初始增量为 $\delta_1 = \mathbf{0}$ 。学习到的映射将确定性签名向量转换为路由特征。

对于递增的时间变化 α 和恒定状态偏移 b ，路由键使用

$$\text{Sig}_{\leq p}(S \circ \alpha) = \text{Sig}_{\leq p}(S), \quad \text{Sig}_{\leq p}^{S_0+b}(S+b) = \text{Sig}_{\leq p}^{S_0}(S). \quad (14)$$

第二个恒等式使用基点签名。因此，地址取决于已执行的历史几何结构，而非采样率、执行速度或恒定坐标偏移。地址保持顺序敏感性，因此反转因果顺序会改变键。

对于维度为 d_s 的状态路径，以及省略标量坐标的标准截断签名，

$$d_{\text{sig}}(p) = \sum_{k=1}^p d_s^k. \quad (15)$$

维度随深度呈指数增长。在我们实验中使用的 17 维状态路径下，从 $p=3$ 到 $p=4$ 的跳跃将原始签名从 5,219 个坐标增加到 88,740 个坐标，之后再进行学习压缩。

表 11: $d_s=17$ 的签名深度扩展。

Depth p	Standard d_{sig}	Log signature dim.	Used in reported runs	Practical interpretation
1	17	17	No	Captures net displacement only
2	306	153	No	Adds pairwise order terms at low cost
3	5,219	1,785	Yes	Captures route and phase interactions while remaining practical for learned compression
4	88,740	22,593	No	Requires aggressive compression before routing

我们使用 $p=3$ 作为实用的平衡。深度 1 接近位移描述符，丢失了区分延迟分支的大部分顺序信息。深度 2 成本较低，但可能不足以表示多阶段历史，例如提示、传输和分支设置。深度 4 显著增加了特征存储和学习压缩成本，使压缩成为 TRACE 项中的主导部分。

对数签名具有吸引力，因为它们消除了代数冗余并降低了特征维度，如表 11 所示。作为学习映射的输入，它们的冗余度也较低。权衡在于工程和数值复杂度。流式在线更新、增量特征、归一化统计量和 GPU 支持必须与部署路径匹配。因此，我们在所有报告的实验中使用标准流式签名。对数签名是一种侧重于效率的替代方案，不在这些结果的范围内。

A.6 诊断度量定义

对于来自任务 q 和历史变换 T 的每个留出在线评估回放 e ，我们沿变换后的历史运行因果诊断过程，并将其与同一在线回放上的恒等过程进行比较。令 I 表示恒等变换， $t_b(e)$ 表示第一个模糊分支点， $\mathcal{P}_e = \{t : t < t_b(e)\}$ 表示分支点之前的历史索引。诊断输入包括槽路由分布 $\omega_t^{T,e} \in \Delta^{K-1}$ （对于 $t \in \mathcal{P}_e$ ）、分支点读出 $z_{t_b(e)}^{T,e} \in \mathbb{R}^d$ ，以及由动作头诱导的分支动作标签 $\hat{b}^{T,e}$ 。变换仅应用于产生 TRACE 签名的机器人状态路径。回放身份、分支帧、分支标签以及策略使用的视觉观测均来自在线执行且保持不变，因此该比较隔离了变换后历史路径的影响，同时保留了在线回放数据源。

路由相似度衡量的是，在分支决策之前，变换后的历史是否通过与身份在线展开过程相同的内存槽进行写入。对于任务 q ，其保留的展开过程为 $\mathcal{E}_q$ ，原始路由得分为

$$r(e, T) = |\mathcal{P}_e|^{-1} \sum_{t \in \mathcal{P}_e} \frac{\langle \omega_t^{T,e}, \omega_t^{I,e} \rangle}{\|\omega_t^{T,e}\|_2 \|\omega_t^{I,e}\|_2}, \quad (16)$$

$$R_q(T) = |\mathcal{E}_q|^{-1} \sum_{e \in \mathcal{E}_q} r(e, T). \quad (17)$$

路由向量是非负概率分布，因此余弦相似度位于 $[0, 1]$ 区间内。高路由相似度意味着变换后的历史遵循与完整 TRACE 展开过程相同的软槽地址序列。报告值已针对同一任务上的完整 TRACE 身份在线展开过程进行归一化，

$$\text{RouteSim}_q(T) = 100 \frac{R_q(T)}{R_q(I)}. \quad (18)$$

对于完整 TRACE 参考， $R_q(I) = 1$ 由构造决定。我们保留显式分母，因为所有任务级得分均相对于该参考报告，然后再跨任务取平均。

分支一致性衡量的是从内存中读取的分支点证据是否得以保留，以及该证据是否支持相同的延迟分支动作。我们计算一个连续读出项和一个离散动作一致项，

$$C_q^{\text{read}}(T) = |\mathcal{E}_q|^{-1} \sum_{e \in \mathcal{E}_q} \frac{1 + \frac{\langle z_{t_b(e)}^{T,e}, z_{t_b(e)}^{I,e} \rangle}{\|z_{t_b(e)}^{T,e}\|_2 \|z_{t_b(e)}^{I,e}\|_2}}{2}, \quad (19)$$

$$C_q^{\text{act}}(T) = |\mathcal{E}_q|^{-1} \sum_{e \in \mathcal{E}_q} \mathbf{1}[\hat{b}^{T,e} = \hat{b}^{I,e}], \quad (20)$$

$$B_q(T) = \frac{1}{2} (C_q^{\text{read}}(T) + C_q^{\text{act}}(T)), \quad (21)$$

$$\text{BranchCons}_q(T) = 100 \frac{B_q(T)}{B_q(I)}. \quad (22)$$

读出余弦值从 $[-1, 1]$ 映射到 $[0, 1]$ 区间，动作项是与原始完整 TRACE 分支动作的一致率。高分支一致性意味着变换后的历史在第一个模糊决策点暴露出相似的内存读出，并引导动作头选择相同的分支。最终表格值为任务平衡平均值， $|\mathcal{Q}|^{-1} \sum_q$ 度量 $q(T)$ 。标准误通过对每个任务内的保留展开过程进行自助重采样，并重新计算任务平衡平均值来获得。

顺序反转被用作阴性对照，因为它保留了保留的回合、分支帧以及许多边际状态值，但破坏了历史的因果顺序。这正是路径签名和槽路由键所要编码的信息。保序变换（如时间重采样或速度抖动）使两个诊断指标都保持较高，而当 TRACE 使用有序历史证据而非仅在决策点附近可见的线索或无序的相同状态时，反转会降低这些指标。完整 TRACE 是身份在线展开参考，因此对于 I ，两个归一化诊断指标按构造均报告为 100。这些量仅在训练后计算。它们不是损失，不用于模型选择，也不对其求梯度。

A.7 长时程记忆稳定性

上述不变性诊断检验分支决策是否依赖于有序历史证据。我们还进行了长历史稳定性检验，以检查固定槽位记忆在保留的在线轨迹提供更长因果历史后，在分支读出前是否仍然可用。该检验是对报告时长的诊断，而非对任意回合长度的理论保证。

该协议有两种形式。在报告时长的在线历史检验中，每条保留的物理轨迹提供因果历史。训练后的更新器沿该执行历史应用，并在第一个模糊分支点记录记忆状态。在扩展历史诊断中，我们继续使用来自记录的在线轨迹和部署的诊断检验中的测量因果片段进行相同的在线历史累积。扩展使用重复的干扰片段、速度抖动、稀疏重采样以及额外的共享路径在线片段（当这些片段在记录的诊断源中可用时）。分支帧、分支标签、视觉观察

以及策略权重保持固定，因此诊断分数的变化反映了记忆路径和存储历史证据的变化。这些诊断行不是外推的轨迹成功率。

对于长历史稳定性，我们记录槽位变化、写入熵、槽位占用率、分支读出一致性和分支决策一致性。对于具有写入分布 $\omega_1, \dots, \omega_T$ 的回合，这些指标为

$$\text{Churn} = (T - 1)^{-1} \sum_{t=2}^T \mathbf{1} \left[\arg \max_j \omega_t^{(j)} \neq \arg \max_j \omega_{t-1}^{(j)} \right], \quad (23)$$

$$\text{WriteEnt} = (T \log K)^{-1} \sum_{t=1}^T \left(- \sum_{j=1}^K \omega_t^{(j)} \log \omega_t^{(j)} \right), \quad (24)$$

$$\text{Occupancy} = K^{-1} \sum_{j=1}^K \mathbf{1} \left[\exists t \leq T, j = \arg \max_{j'} \omega_t^{(j')} \right]. \quad (25)$$

分支读出一致性是扩展历史的分支读出与匹配的报告时长在线历史检验的读出之间的余弦相似度。分支决策一致性是相应的动作一致率。

表 12: 固定槽位 TRACE 记忆的长时程记忆稳定性诊断。数值为保留轨迹上的任务平衡均值。读出和决策一致性将每个扩展与匹配的报告时长分支读出进行比较。

Diagnostic pass	History extension	Slot churn↓	Write entropy↓	Slot occupancy↑	Readout cons.↑	Decision cons.↑
Reported-horizon online history	1.0×	0.010	0.356	0.646	1.000	1.000
Extended history	1.25×	0.017	0.374	0.690	0.982	0.968
Extended history	1.5×	0.025	0.397	0.710	0.962	0.936
Extended history	2.0×	0.041	0.431	0.744	0.928	0.904
Repeated distractor extension	1.5×	0.052	0.462	0.758	0.907	0.872
Shared-route online extension	2.0×	0.035	0.412	0.737	0.943	0.916

稳定性读数是所评估扩展上的一种测量诊断，而非对任意时段的证明。在所评估的扩展中，槽位变动保持在 0.05 或更低，占用保持广泛但未坍塌，分支决策一致性即使在重复干扰片段下也至少为 0.872。干扰扩展下更大的熵来自新增片段对模糊共享路径观测的复用，而分支读数仍接近报告时段的参考值。变动或熵上升同时分支一致性下降是覆盖或扩散写入失败的标志。因此，该诊断仅在所评估时段和历史扩展上支持记忆声明。它并未表明固定槽位能在任意长的展开中避免覆盖旧信息。

A.8 适配器架构

两种 TRACE 变体使用相同的签名索引记忆更新器。正文按基础目标将两种变体命名为回归和扩散。在本架构小节中，同一变体被描述为回归适配器和扩散适配器，因为图和表引用的是将记忆读数呈现给各基础策略的策略面向模块。对于由 e 索引的策略族，

$$H_t = (M_t, z_t^{\text{mem}}, g_t, \Delta g_t), \quad \mathcal{A}_\theta^{(e)} : \mathcal{H}_{\text{TRACE}} \rightarrow \mathcal{C}_e, \quad c_t^{(e)} = \mathcal{A}_\theta^{(e)}(H_t). \quad (26)$$

此处 $\mathcal{C}_e$ 是下游策略族的原生条件空间。适配器改变策略输入条件，但保持动作参数化和模仿目标不变。

表 13: 回归和扩散骨干的适配器接口。

适配器 TRACE 输入 适配器计算 产生的专家条件 专家损失				
Regression adapter	Slot memory $M_t \in \mathbb{R}^{K \times 512}$, readout z_t^{mem} , signature embeddings $g_t, \Delta g_t$	Map each slot with W_M . Map $[z_t^{\text{mem}}, g_t, \Delta g_t]$ into one summary token. Optionally use the summary for feature modulation	512-D memory tokens concatenated to the regression policy attention memory. The action head regresses the native action chunk	Unchanged chunk L1 loss plus the standard optional KL term
Diffusion adapter	Same $M_t, z_t^{\text{mem}}, g_t, \Delta g_t$ from the shared updater	Pool slots with readout attention weights. Concatenate $\text{pool}(M_t), z_t^{\text{mem}}, g_t$, and Δg_t . Pass the result through a zero-initialised MLP	512-D additive global conditioning vector appended to time-step and action conditioning. Diffusion denoising iterations are unchanged	Unchanged diffusion denoising loss over the action trajectory
Shared updater	Masked state path, pooled multi-view visual feature v_t , proprioceptive embedding p_t , and previous slots M_{t-1}	Compute $g_t, \Delta g_t$. Route a write distribution ω_t . Update gated slot candidates and read slots with the current visual-state query	Policy-agnostic TRACE memory state H_t consumed by either adapter	Auxiliary balance, entropy, and consistency losses only during training

适配器比较显示了两种 TRACE 变体的差异之处。两者消耗相同的路由记忆状态，但回归适配器将其暴露为注意力记忆令牌，而扩散适配器将其暴露为全局条件向量。这就是为什么主实验可以将共享增益归因于因果记忆，同时仍允许每个策略族保留自己的动作损失。

表 14 将未改变的基础策略前向传播与 TRACE 的逐步计算分开。条目为平均/第 95 百分位延迟。回归行是在 NVIDIA GeForce RTX 5090 上使用 CUDA 12.8 和 PyTorch 2.9.1，从流式回归策略配置的 1,900 个预热后控制步骤中测量的。扩散行结合了测量的共享 TRACE 路径与部署的 TRACE 条件策略中记录的扩散和适配器时序。

表 14: 每步部署延迟分解（毫秒）。

Policy path	Base forward	Signature	Slot update	Readout	Adapter	TRACE overhead	Total loop	Overhead
Regression adapter	5.90 / 7.21	0.52 / 0.69	0.90 / 1.26	0.58 / 0.74	0.10 / 0.15	2.11 / 2.66	8.32 / 10.02	35.8%
Diffusion adapter [†]	118.00 / 142.00	0.52 / 0.69	0.90 / 1.26	0.58 / 0.74	0.14 / 0.21	2.15 / 2.72	120.46 / 144.87	1.8%

[†] 扩散计时使用共享的实测 TRACE 路径。基础前向是 100 步扩散去噪调用。

延迟表显示，TRACE 在未改变的基础策略调用之前增加了少量固定计算。对于回归适配器，由于基础策略本身已经很快，因此开销可见。对于扩散适配器，相同的记忆路径与 100 步扩散去噪调用相比很小。因此，该表支持了 TRACE 是一种在线条件化模块，而非第二次策略传递或离线检索过程的说法。

A.9 记忆更新、训练与在线推理

在每一步中，相机特征被池化为 $v_t = C^{-1} \sum$ ，且本体感 $c \rho(f_{\text{vis}}(o_t^{(c)}))$

觉嵌入为 $p_t = \phi_s(\tilde{s}_t)$ 。这些特征构成视觉状态内容 **tate conten**

$e_t = [v_t, p_t]$ 。地址特征 q_t 由投影路径签名和增量签名构建。当启用首帧锚定时， q_t 还包含因果首帧锚。利用该地址向量，路由查询和写入分布为

$$\rho_t = \phi_\rho(q_t), \quad \tilde{m}_{t-1,k} = m_{t-1,k} + \lambda_\eta \eta_k, \quad (27)$$

$$\ell_{t,k} = \frac{(W_q \rho_t)^\top W_k \tilde{m}_{t-1,k}}{\tau \sqrt{d_r}}, \quad \omega_{t,k} = \frac{\exp(\ell_{t,k})}{\sum_{j=1}^K \exp(\ell_{t,j})}. \quad (28)$$

其中 η_k 在启用时为固定正弦槽身份；设置 $\lambda_\eta = 0$ 可得到不使用槽身份的适配器。内容提议、写入强度和槽更新为

$$u_t = \phi_w(e_t, q_t), \quad (29)$$

$$\tilde{m}_{t,k} = \tanh(\phi_m(\tilde{m}_{t-1,k}, u_t, \rho_t)), \quad (30)$$

$$\beta_{t,k} = \omega_{t,k} \sigma(\phi_\beta(\tilde{m}_{t-1,k}, u_t, \rho_t)), \quad (31)$$

$$m_{t,k} = (1 - \beta_{t,k}) m_{t-1,k} + \beta_{t,k} \tilde{m}_{t,k}. \quad (32)$$




图 5: 训练与推理一致性。训练扫描在线可用的掩码固定预算历史，部署则在每个执行步骤应用相同的更新器一次。

记忆读出使用独立的注意力分布：

$$u_t^r = \phi_r(e_t, \rho_t), \quad (33)$$

$$\bar{m}_{t,k} = m_{t,k} + \lambda_\eta \eta_k, \quad (34)$$

$$a_{t,k} = \frac{(u_t^r)^\top W_k^r \bar{m}_{t,k}}{\sqrt{d}}, \quad (35)$$

$$\alpha_{t,k} = \frac{\exp(a_{t,k})}{\sum_{j=1}^K \exp(a_{t,j})}, \quad (36)$$

$$z_t^{\text{mem}} = \sum_{k=1}^K \alpha_{t,k} W_v^r m_{t,k}. \quad (37)$$

在训练过程中，每个目标时间 t 使用带有效掩码 b_l 的填充固定预算因果历史索引序列 $I_{L,r}(t) = (i_1, \dots, i_L) \subseteq \{1, \dots, t\}$ 。所选有效条目包含第一个可用帧、当前帧以及近期步长采样的尾部。从 $M^{(0)} = \mathbf{0}$ ，开始扫描

$$M^{(l)} = \mathcal{U}_\theta(M^{(l-1)}, o_{i_l}, s_{i_l}, q_{i_l}, b_l), \quad l = 1, \dots, L. \quad (38)$$

该扫描应用与部署相同的更新器，在每个在线步骤使用缓存的记忆状态执行一次。最终扫描得到的记忆构成 H_t ，专家族 e 的原生策略损失为

$$\mathcal{L}_{\text{policy}}^{(e)} = \mathbb{E}_{(\tau,t) \sim \mathcal{D}} \left[\ell_e \left(\mathcal{E}_\psi^{(e)}(x_t, \mathcal{A}_\theta^{(e)}(H_t)), y_t^* \right) \right]. \quad (39)$$

有限槽更新器在训练期间存在三种常见失效模式。槽坍塌将大部分证据写入少数几个槽。弥散写入将一次观测分散到多个槽，导致后续寻址能力减弱。读写不匹配以读出器在后续更新后无法恢复的形式存储信息。TRACE 针对每种情况使用一个轻量级稳定器，并保持下游模仿目标不变。

$$\mathcal{L} = \mathcal{L}_{\text{policy}}^{(e)} + \lambda_{\text{bal}} \mathcal{L}_{\text{bal}} + \lambda_{\text{ent}} \mathcal{L}_{\text{ent}} + \lambda_{\text{cons}} \mathcal{L}_{\text{cons}}. \quad (40)$$

对于目标 t 的第 l 个所选历史元素，令 $\omega_{t,l}$ 为槽路由分布， $u_{t,l}$ 为写入提议， $z_{t,l}^{\text{mem}}$ 为记忆读出。其中 $N_v = \sum_{l,b_{t,l}} b_{t,l}$ 及 $\bar{\omega}^{(j)} = N_v^{-1} \sum_{t,l} b_{t,l} \omega_{t,l}^{(j)}$, the

辅助项为

$$\mathcal{L}_{\text{bal}} = K^{-1} \sum_{j=1}^K \left(\bar{\omega}^{(j)} - K^{-1} \right)^2, \quad (41)$$

$$\mathcal{L}_{\text{ent}} = (N_v \log K)^{-1} \sum_{t,l} b_{t,l} \left(- \sum_{j=1}^K \omega_{t,l}^{(j)} \log \omega_{t,l}^{(j)} \right), \quad (42)$$

$$\mathcal{L}_{\text{cons}} = N_v^{-1} \sum_{t,l} b_{t,l} d^{-1} \left\| \tanh z_{t,l}^{\text{mem}} - \tanh u_{t,l} \right\|_2^2. \quad (43)$$

$\mathcal{L}_{\text{bal}}$ 惩罚不均匀的平均路由，从而抑制槽位坍塌。 $\mathcal{L}_{\text{ent}}$ 惩罚每个有效写入步骤的高熵路由，从而抑制弥散式写入。 $\mathcal{L}_{\text{cons}}$ 将有界记忆读出与当前写入提议对齐，从而减少读写不匹配。

这些项是有限容量的稳定器，而非理论保证。它们使训练偏向于均衡、可寻址且可读的写入，但不能证明每一份因果信息都保持可恢复。由于记忆具有固定数量的槽位和有界的槽位宽度，足够长的视野或信息量超过记忆可表示范围的轨迹仍可能迫使多个事实共享容量。在此类情形下，后续更新可能覆盖或模糊早期内容，尤其是当证据被反复路由到邻近槽位，或视觉上相似的观测需要不同解释时。

辅助项仅作用于记忆。下游策略损失对于回归任务仍为分块 L1 加上标准可选 KL 项，对于扩散任务则为原生扩散去噪损失。

Algorithm 1 Causal TRACE memory update and adapter conditioning.

Require: Observation o_t , robot state s_t , previous memory M_{t-1} , previous signature ξ_{t-1} , optional first-frame anchor a^0 , state mask Z_q , train-split normalisation statistics, policy family $e \in \{\text{regression}, \text{diffusion}\}$.

Ensure: Updated memory M_t , signature ξ_t , adapter conditioning c_t , and policy prediction $\hat{y}_t$.

1: Apply the task mask and state normalisation.

$$\bar{s}_t = Z_q(s_t), \quad \tilde{s}_t = (\bar{s}_t - \mu_s) / (\sigma_s + \epsilon).$$

2: Append $\tilde{s}_t$ to the piecewise linear history path S_t .

3: Compute $\xi_t = \text{Sig}_{\leq p}(S_t)$ and $\delta_t = \xi_t - \xi_{t-1}$.

4: Remove the scalar signature coordinate, standardise ξ_t and δ_t , then map them to $g_t = \phi_g(\xi_t)$ and $\Delta g_t = \phi_\Delta(\delta_t)$.

5: Encode the current observation as $v_t = C^{-1} \sum_c \rho(f_{\text{vis}}(o_t^{(c)}))$ and $p_t = \phi_s(\tilde{s}_t)$.

6: Compute address features $q_t = [g_t, \Delta g_t]$, appending a^0 only when first-frame anchor routing is enabled, and set $\rho_t = \phi_\rho(q_t)$.

7: Route the write with Equation 28.

8: Form gated write candidates from visual-state content and address state, then update slots with Equation 32.

9: Read memory with Equation 37.

10: Construct $H_t = (M_t, z_t^{\text{mem}}, g_t, \Delta g_t)$ and $c_t^{(e)} = \mathcal{A}_\theta^{(e)}(H_t)$.

11: Predict $\hat{y}_t = f_\psi(z_t, c_t^{(e)})$ with the unchanged base policy.

A.10 补充案例研究

表 15 总结了五个任务背后的具体延迟证据结构。这些案例研究将主文中的诊断量与 rollout 层面的行为联系起来，并给出主文中讨论的基线失败模式的证据来源。

表 15: 连接基线失败、证据与 TRACE 行为的补充任务级案例研究。

Task	History evidence	Ambiguous branch	Baseline failure	Failure evidence	TRACE behaviour
Tool	Initial object identity determines the later tool sequence	Object and tool are no longer jointly visible when the sequence must branch	Wrong tool order at the branch, or correct branch followed by contact loss	Table 1 shows high Tool variance, and Table 18 separates delayed-memory errors from contact losses	Stores the object-dependent history and improves branch selection, while contact-rich stages still create variance
Book	Origin shelf determines route and placement	After pickup and transit, the overhead view is similar across origins	Places on a visually plausible target that is inconsistent with the origin route	Figure 4 shows similar views after transit, and Table 2 shows the matched memory gap	Reads the origin-dependent slot near placement and preserves route-specific evidence
Laundry	Origin side determines brush-and-basket versus fold-and-store	Garment pose becomes visually similar after the shared carry segment	Executes the visually dominant routine regardless of origin side	Tables 1 and 2 show the largest gains on this origin-side branch task	Routes the side cue during pickup and reuses it at the later branch
Cable	Origin side determines the matched device	Traversal and local device pose provide evidence still visible near the device choice	Reaches the workspace but can choose the wrong device when local geometry is ambiguous	Tables 1 and 2 show closer scores, consistent with partial evidence from current geometry	Memory helps at the device choice, but local manipulation still contributes many credited stages
Medicine	Tray origin determines box selection and return	Boxes enter a shared bedside area before the return decision	Selects or returns the wrong box after a correct past pickup	Tables 1 and 2 show gains on the tray-origin branch, and Table 3 supports history-sensitive readout	Keeps the tray-origin cue available through the shared staging segment

这些案例研究解释了为何同一记忆模块在不同任务层面产生不同效果。书籍、洗衣和医药任务将后期得分的大部分置于对起始线索的记忆上，因此 TRACE 改变了主导分支的错误模式。电缆任务在设备选择附近仍包含有用的局部几何信息，从而缩小了差距；而工具任务将延迟分支与接触密集的执行相结合，因此需要附录 A.11 中单独的方差分析。

A.11 方差与失败分析

工具任务在表 1 中具有最高的标准误。其进度得分将离散的延迟记忆决策与决策后的多个接触密集操作阶段相结合。一次执行可能记住了正确的物体和工具分支，但由于抓取滑动、工具接触不足或恢复超时而丢失许多计入的阶段。错误的延迟分支也可能一次性移除多个下游阶段。这解释了为什么工具任务比书籍、洗衣和药物任务噪声更大，在这些任务中，起始线索更直接地决定了分支得分。

表 16 报告了对主要平均值的一个简单鲁棒性检验。剔除工具列移除了标准误最大的任务，并从剩余四个任务均值重新计算任务平衡均值。TRACE 回归在 72.92 处仍是最强方法，TRACE 扩散在 59.79 处仍高于最强非 TRACE 基线，而后者为 51.71。仅使用报告的任务标准误，得到剔除工具后的 95% 区间为：TRACE 回归 [71.28, 74.55]，TRACE 扩散 [57.10, 62.48]，最强非 TRACE 基线 [48.13, 55.29]。该检验未使用任何工具任务的执行数据，因此平均增益并非由高方差任务所主导。该表直接由表 1 计算得出。

表 16: 主要比较的留一任务任务平衡平均值。数值由表 1 中的任务均值重新计算。

Method	All tasks	Drop Tool	Drop Book	Drop Laundry	Drop Cable	Drop Medicine
Diffusion Policy	25.00	26.75	28.17	25.75	22.75	21.58
ACT	25.50	24.12	28.46	29.00	20.88	25.04
$\pi_{0.5}$	50.47	51.71	50.33	51.21	50.83	48.25
GR00T N1.6	30.60	28.50	35.08	32.25	28.75	28.42
SmolVLA	28.33	29.17	30.42	32.42	22.92	26.75
X-VLA	33.90	41.00	30.62	32.12	33.38	32.38
Ours (Regression)	69.23	72.92	65.79	66.29	73.79	67.38
Ours (Diffusion)	59.53	59.79	57.33	56.79	61.66	62.08

表 17 将噪声较大的工具得分与总体结论分开。工具任务对两种 TRACE 变体都有较宽的区间，因为离散延迟分支之后跟随多个接触密集阶段。同一表还报告了剔除工具后的平均值及其与最强非 TRACE 基线的差距，使用表 1 中报告的任务标准误。回归保持 21.21 点的剔除工具优势，高于 $\pi_{0.5}$ ；扩散保持 8.08 点的优势。

表 17: TRACE 变体的工具任务不确定性与剔除工具鲁棒性。工具区间使用报告的均值 ± 1.96 标准误。剔除工具区间由表 1 中报告的任务标准误计算。

Method	Tool mean $\pm$ SE	Tool 95% interval	Drop-Tool avg.	Drop-Tool gap vs. $\pi_{0.5}$
Ours (Regression)	54.50 $\pm$ 17.96	[19.30, 89.70]	72.92 [71.28, 74.55]	+21.21 [17.27, 25.15]
Ours (Diffusion)	58.50 $\pm$ 10.17	[38.57, 78.43]	59.79 [57.10, 62.48]	+8.08 [3.60, 12.56]

表 18 给出了用于解释工具任务高方差的失败类别。这些类别区分了 TRACE 是否以正确的物体条件决策到达延迟分支，与后续接触密集损失。这一区分很重要，因为工具任务可能因不同原因产生中等或较低的进度。一些执行保留了延迟线索但通过接触丢失下游阶段，而另一些则在依赖记忆的分支本身失败。

表 18: 用于解释高方差展开的工具故障分类法。该分类将延迟记忆故障与分支后的接触故障和恢复故障区分开来。

Failure class	Operational definition	Score pattern	Interpretation
Correct branch with contact loss	The object-dependent tool order is selected correctly, then progress drops from grasp slip, weak contact, or incomplete tool engagement	Shared setup and branch stages receive credit, but later manipulation stages are missing	Memory succeeds, while execution noise lowers total progress
Wrong branch or tool order	The shared setup reaches the delayed decision, but the selected tool sequence does not match the initial object identity	past stages receive credit, followed by a sharp loss at the branch and its downstream stages	Direct delayed-evidence error. This is the failure mode TRACE is designed to reduce
Recovery timeout	Manipulation stalls during recovery after a partial success and exceeds the timeout	Progress plateaus after partial later-stage credit	Separates memory retention from long-horizon recovery and contact robustness
Pre-branch setup failure	The rollout fails before the delayed decision can be evaluated	Low progress before the branch point	Does not test delayed memory, but still contributes to rollout-level Tool variance
Other or unclassified	The score trace or video evidence does not cleanly match the categories above	Mixed or inconsistent stage evidence	Reserved for audit before making branch-level rate claims