

awesome_memory_vla · 2026-09

证据消失之后，策略靠什么行动

记忆 VLA 全景调研：EventVLA × TRACE × SAI

Memory for vision-language-action policies — three June-2026 papers and a 103-paper landscape

3

核心论文全文深读
架构 / 模块 / 数据三个层面

17

篇有英文 PDF + DeepSeek 中译
其中 14 篇邻居也有全文笔记

103

项工作 · 十个家族 · 26 个子类
每篇一句话定位

10 / 6 / 14

洞见 / 可证伪预测 / 研究机会
另附 28 条数字口径账本

十条结论：记忆的问题不是"要不要"，而是"记什么、何时写、写到哪、存多少"

1. 标准 VLA 是马尔可夫的，而操作任务不是：掀盖看一眼、读一张数字卡、看别人点一遍顺序——证据出现后就消失。
2. 前沿从"存多少"转到了"何时写"：EventVLA / KEMO / UniMem / WeaveLA / MemoryWAM 在 2026 年 6–8 月从不同架构同时转向事件驱动的稀疏写入。
3. 历史大多是当前帧的冗余副本（Present but Not Remembered 的探针审计）；记忆增强应注入只属于过去的信息。
4. 原图还是 latent 取决于要恢复多少比特：EventVLA 的 24.9 vs 75.2 与 TRACE 的 69.23 并不矛盾。
5. 寻址被低估：TRACE 用轨迹签名让写入时刻与读取时刻有稳定对应，倒放历史路由相似度掉到 37.8。
6. 可靠性来自有纪律的状态更新，不是容量：AGM 验证后推进、EventVLA NMS + 冷却、TRACE 门控写入是同一原则。
7. 计数与过程记忆上双系统仍领先：RoboMME / RoboMemArena 榜首都是高层管状态的方案。
8. 记忆的成本趋近于零：NativeMEM 每帧 1 token、TempoFit 免训练、StreamPI 零参数；EventVLA 的 3× 延迟是短板。
9. 多机器人是同一问题的另一张脸：搭档相位是从历史推断的隐变量（SAI），但还没有人给它显式记忆。
10. 评测在分裂、诊断在成熟：一年 12 套基准；并排任何两个数字之前先查口径账本。

32 页怎么读：先看两张总览图，再沿"主角 → 证据链 → 纵深专题 → 判断"走一遍

p4—5 · 总览

时间线（十个泳道，2026-06 汇合月）与分类树（十个家族、26 个子类）。

p6—12 · 三个主角

旧范式为什么失效 → EventVLA（架构）、TRACE（模块）、SAI（数据）各两页：机制、数字、代价、留意点。

p13—17 · 路线与证据链

同一目标五条路线；17 篇六问对照矩阵；RMBench / RoboMME / RoboMemArena / 真机四条证据链。

p18—23 · 六个纵深专题

何时写 · 原图还是 latent · 寻址 · 双系统 vs 端到端 · 成本归零 · 多机器人。


p24—29 · 判断

趋势、十个洞见、六条可证伪预测、十四个研究机会、口径账本。

p30—32 · 方法论与交付物

三篇论文教的三件事；仓库里有什么、怎么复现。

时间线：2025 年 24 篇、2026 年 1–5 月 23 篇，6 月一个月 20 篇



RMbench (3-01)、RoboMME (3-04)、RoboMemArena (5-11) 三个基准春天落地，夏天的方法论文是对这些靶子的第一轮回应；三篇核心论文全部落在 6 月 12–18 日。

分类体系：十个家族、26 个子类——按"记忆放在哪、以什么形式存在"划分

图 2 · 记忆 VLA 的设计空间：十个家族、二十六个子类——与 README 第 1—10 节一一对应

Figure 2 · The design space of memory for VLA policies: ten families, twenty-six sub-classes, matching README sections 1—10



旧范式： $a_t = \pi(o_t, l)$ 默认一切可见；加长窗口是默认答案，但历史没有被"记住"

三类既有路线，各有一个具体的失败方式

路线	代表	失败方式
双系统	MemER, Mem-0, MEM	延迟高、误差沿层级传播
循环 / 隐状态	AVA-VLA, RMT	信息瓶颈，细粒度视觉细节丢失
帧缓冲	MemoryVLA, CronusVLA, ContextVLA	无选择堆帧，冗余淹没稀疏证据

EventVLA §1-2 的诊断

为什么帧堆叠收益不稳定：历史 $\approx$ 当前帧的副本

Liao & Cao 对 Octo-Small / Octo-Base / CronusVLA-0.5B 做逐层线性探针 + 因果交换干预：过去帧内容全网络可解码 (A_1 0.39 / 0.36 / 0.14)，但只属于历史的信息几乎为零 (A_4 +0.019 / +0.015 / -0.011)；历史只在当前帧被全黑遮挡时才被因果使用，且能否用注入的历史驾驭动作因架构而异 (Octo 不能，CronusVLA +0.167)。

设计准则：注入过去独有的信息，而不是更多的历史——这正是稀疏事件帧、签名增量、动作历史压缩在做的事。

三篇论文，一个问题，三个层面：架构 · 模块 · 数据

2606.20092

EventVLA · 架构

USTC / 上海 AI Lab。KEM 头从 VLA 隐状态预测未来 50 步的关键帧概率，存原图，5 帧 FIFO；RoboTwin-MeM 18.0 → 75.2。

2606.14551

TRACE · 模块

浙大 / 悉尼大学。外挂 K 槽 latent 记忆，用机器人轨迹的路径签名做读写地址；ACT 25.5 → 69.2，顺序反转 37.8。

2606.16490

SAI · 数据

浙大 / 悉尼大学。单遥操作者三阶段非对称课程学双机器人耦合策略；历史 token 把提前松手 64.5% → 16.1%。

	EventVLA	TRACE	SAI
看不见的是什么	消失的视觉证据	早期分支线索	搭档内部相位
记忆内容	原始图像帧	512 维 latent 槽	GRU 隐状态
何时写	学习的关键帧概率 + NMS + 冷却	每步，门控	每步
寻址	时间拼接 + 注意力	轨迹路径签名	无
代价	吞吐 2.91 → 0.94 Hz	+2.1 ms / 步	干预数据 ≈ 30%

EventVLA：把"何时该记住"变成一个可学习的预测问题

记忆 $M_t = A_t \cup E_t$

- 锚帧 $A_t = \{o_0\} \cup \{o_{t-30}, o_{t-15}\}$: 全局布局 + 运动线索 (规则)
- 事件帧 E_t : KEM 写入, $N_{\max} = 5$, FIFO
- $\text{concat}([A_t, E_{t-1}, o_t])$ 直接进 VLM 视觉编码器——"读"就是多帧注意力

$\hat{p}_t = \sigma(\text{MLP}(h_t)) \in [0, 1]^H$, $H = 50$; $\hat{p}_t^i \geq 0.55 \Rightarrow$ 存 o_{t+i}


1-D NMS ($w = 8$) + 冷却 ($C = 10$) 防止同一事件灌满缓冲区

训练与"为什么按整块预测"

- 标签: Qwen3-VL-235B 离线看演示输出关键帧步 (仿真误差 < 10 步, 真机 < 50 步)
- 软标签: 升余弦核 $y = \frac{1}{2}(1 + \cos \pi|t+i-t^*|/R)$; $L = L_{\text{action}} + 0.1 \cdot L_{\text{kem}}$
- 师生课程: 真值缓冲 $\rightarrow$ 自身预测, $\alpha: 1 \rightarrow 0$

事件常在一个动作块中途出现又消失, 逐步分类器来不及; 共享 h_t 让 KEM 知道策略接下来要做什么, 能**预约**一次写入。

同一个骨干、同一份数据，只多了 5 帧：18.0 → 75.2；原图 vs latent 75.2 vs 24.9



三个值得记住的数字

- 24.9 vs 75.2：只换记忆表征，原图胜 latent——至少在要同时记 3—5 个视觉细节时
- 13.6：动作块 50 → 15，KEM 的前瞻随之崩塌，低于不用 KEM 的 18.0
- 0.94 Hz：多帧输入把吞吐压到基座 (2.91 Hz) 的三分之一
真机 ARX ACONE 4 任务 × 20：90 / 60 / 90 / 75， π_{MEM} 50 / — / 30 / 40。留意：两套基准同出 RoboTwin 系；5 帧 FIFO 对 > 10 分钟任务会饱和。

TRACE: 内容与地址分离——当前画面决定"记什么", 走过的路决定"存到哪、从哪取"

延迟证据 → 轨迹签名做钥匙

- 短窗口下 $x_{t-w+1:t} \approx x'_{t-w+1:t}$ 但 $a_t^*(H_t) \neq a_t^*(H'_t)$: 单帧策略注定至少错一半
- 内容 $e_t = \phi_x(x_t)$: 多视角视觉 + 本体感受
- 地址: 17 维状态路径的深度-3 路径签名, $17 + 17^2 + 17^3 = 5219$ 维, 加增量 δ_t
- 对时间重参数化、常数偏移不变, 对**顺序**敏感; 流式 0.52 ms

$$\omega_{t,k} = \text{softmax}_k(\langle W_Q \rho_t, W_K \tilde{m}_{t-1,k} \rangle / \tau \sqrt{d}) ; \quad m_{t,k} = (1-\beta) m_{t-1,k} + \beta \tilde{m}_{t,k}$$

适配器只做翻译, 骨干、动作头、损失都不改

- ACT: 槽 → 512 维记忆 token 拼进注意力 memory (+0.79 M)
- Diffusion: 池化 → 零初始化 MLP → 加性全局条件 (+16.03 M)
- 共享更新器 11.91 M; $K = 4 / 6$ 槽 × 512 维
- 三个稳定器只作用于记忆: L_{bal} 防槽塌缩 · L_{ent} 防弥散写入 · L_{cons} 防读写失配 (去掉: 69.23 → 66.10)

训练与部署走同一条因果扫描: 不用线索标签、分支标签、未来帧, 也不做测试时演示检索。

任何记忆都比没有好 (+20 到 +30)，但 TRACE 再往上 13 个点；倒放历史，读出就变了

方法 (5 真机任务, 阶段进度 %, 25 次/任务)	平均
ACT / Diffusion Policy	25.50 / 25.00
$\pi_{0.5}$ (同数据微调, 无记忆模块)	50.47
GRU 循环记忆	45.83
Transformer 历史上下文	52.10
LRU 外部记忆	53.93
检索提示记忆 (MAP-VLA 式)	56.30
TRACE (回归 / 扩散)	69.23 / 59.53
只有签名 / 无路由槽 / 去增量	45.50 / 52.17 / 61.43

历史变换诊断 (归一化到完整 TRACE = 100)		
变换	路由相似度	分支一致性
时间重采样	92.4	96.0
速度抖动	89.8	94.7
状态偏移	91.2	95.1
稀疏采样	86.5	92.3
顺序反转 (负对照)	37.8	41.6
同样的分岔点画面、同样的权重，只把历史倒放——"记忆在用有序历史"从假设变成测量。每步开销 +2.11 ms。		

SAI：搭档看不全，历史和课程都要替它补——协调是搭档分布的函数，不是架构的函数

单遥操作者三阶段

- 1. A 与顺从的人类搭档学任务；搭档区域随机化（噪声 / 模糊 / SD 修补）防止学人类外观捷径
 - 2. 冻结 A，人遥操 B；给 A 加速度 / 噪声 / 时序扰动，B 学会等待、让步、恢复
 - 3. A+B 联合部署，只在协调快失败处对 A 做 DAgger 式稀疏干预（≈ 30% 数据，动作维掩码）
- 策略：ACT + 冻结 DINOv3，30 步历史（12 帧对数采样 → GRU 历史 token），级联底盘 → 手臂头；两台机器人无通信

任务	方法	成功	相位同步	让步
Bed-throw	独立 / SAI	23.3 / 53.3	30.8 / 62.5	26.7 / 68.3
Tablecloth	独立 / SAI	43.3 / 66.7	54.4 / 68.9	46.7 / 70.0
Laundry	独立 / SAI	50.0 / 70.0	51.7 / 73.3	31.7 / 71.7
Painting	独立 / SAI	33.3 / 56.7	42.7 / 74.7	34.4 / 68.9

- 阶段 2 抬相位同步，阶段 3 抬让步；成功率是两者之和（30 次 rollout / 任务-方法）
- 历史 token：提前松手 64.5% → 16.1%——单帧分不清"搬运中"与"该松手"
- 换 Diffusion 头同样有效（成功 23.5 → 52.9）

同一个目标，五条路线：记忆可以被触发、被压缩、被寻址、被符号化、被预测

1 · 事件 / 关键帧 (5)

只在"发生了什么"时写，存原图或 token。

EventVLA (学习触发)、KEMO (运动学 + 视觉规则)、UniMem (事件分类器)、WeaveLA (子目标完成)。

2 · 稠密压缩历史 (25)

每帧都进，靠压缩 / token 化 / KV 复用控制成本。

MemoryVLA、HAMLET、NativeMEM (1 token/帧)、TempoFit (免训练)、StreamPI (零参数)、DySta。

3 · latent / 循环 / 槽 (20)

历史压成固定向量或槽递归更新。TRACE (签名寻址)、 μ VLA (最小循环)、Chronos (SSM 状态)、TFP (进度信念)、GMP (何时回忆)。

4 · 双系统 / 符号 (19)

高层维护文本 / 图 / 进度指针，低层执行。MEM、MemER、AGM (验证后推进)、HyMeS (记忆在代码)、PonderPounce、BATON。

5 · 世界模型内的记忆 (3)

记忆服务于预测，预测服务于动作。MemoryWAM (近期 + 事件锚帧 + gist)、MemoryVAM、TriVLA。

第六个方向 · 多机器人搭档记忆 (9)


搭档相位是只能从历史推断的隐变量。SAI、HATS、Duet、Tri-Manual、AutoIntervene——几乎都在解数据采集，没有显式记忆模块。

17 篇一页对照：六个必答问题——存什么 · 何时写 · 寻址 · 容量 · 接在哪 · 监督

方法	存什么	何时写	寻址	容量	接在哪	监督
EventVLA	原图	学习触发 + NMS	时间拼接	5 + 锚帧	视觉编码器输入	235B 标注 + 软标签
TRACE	512-D latent	每步，门控	轨迹签名	K = 4/6	动作头前适配器	三项稳定器
SAI	GRU 隐状态	每步	无	30 步	解码器输入	数据课程 + DAgger
KEMO	关键帧 token	运动学 + 视觉规则	时序 token	K 逐任务设	门控残差融合	事件附近加权
UniMem	关键帧密集记忆	事件分类器	注意力	关键帧缓存	单骨干	分类器
MemoryVLA	感知 + 认知 token	每步，冗余合并	内容相似	记忆库	扩散专家条件	模仿损失
MemER / MEM	关键帧 + 文本 / 视频 + 文本	高层 VLM / 持续	VLM 推理	选中帧 / 文本无界	双系统	语言标注 / 演示
Chronos	每步一个状态 token	每步	选择性 SSM	全历史（压缩）	策略 latent 状态	IMLE + 薛定谔桥
μVLA	m 个记忆 token	每步自注意力	隐式	m	骨干内	TBPTT，无辅助损失
AGM / HyMeS	进度指针 / 代码结构	物理验证后 / 阶段验证后	指针 / 代码	子目标数 / 无界	冻结 VLA 外部	2.43M 验证头 / rollout 反馈
AutoIntervene	视觉-动作支持记忆	成功执行后	视觉相似 + 动作一致	成功轨迹集	策略 ↔ 操作者切换	分位数校准阈值

完整 40 方法矩阵见 [insights/DESIGN_SPACE_MATRIX.md](#)。两个极端在同一个月被占住：EventVLA 押“何时写”，TRACE 押“从哪读”；既学写入时机、又学寻址的中间地带还是空的。

RM Bench: "初始帧 + 近期帧"就到 67.8——它测的更多是布局记忆，不是事件记忆



成功率 %，每任务 100 次。Chronos 报 7 任务（其表中 Mem-0 为 50.8），EventVLA 报 9 任务——不可直接比。

逐任务看才知道基准测了什么

- EventVLA 仅锚帧：Rearrange 96、Put Back 95、Swap Blocks 96、Cover 97——持久布局类近乎解决
- 但 Observe and Pick Up 21%、Press Button 3%（所有方法 $\leq 3\%$ ）——计数与瞬态证据才是硬核
- RM Bench 自己的 Mem-0 消融：Cover Blocks 去锚帧 92、去滑窗 84，都高于完整版 68
- Chronos 的 73.6 靠全历史 SSM，也不是事件记忆；Press Button 2%

这正是 EventVLA 另建 RoboTwin-MeM（用 n 参数化"必须记住几个中间关键帧"）的理由。

RoboMME 与 RoboMemArena：计数与过程记忆的榜首都是双系统；记忆表征的效果高度依赖任务

RoboMME (16 任务, $\pi_{0.5}$ 骨干, 成功率 %)

方法	Counting	Permanence	Reference	Imitation	平均
$\pi_{0.5}$	28.78	17.00	17.17	8.78	17.93
MemER	48.83	53.17	38.00	29.50	42.38
FrameSamp+Modul (感知最佳)	65.22	25.11	36.33	51.39	44.51
AGM (Counting 子集)	55.96	—	—	—	—
PonderPounce 9B	—	—	—	—	60.83
GroundSG+Oracle (上界)	83.86	93.31	95.17	63.98	84.08

每种记忆各有强项：FrameSamp 赢 Counting/Imitation，MemER 赢 Permanence；动作 token 对记忆 token 的注意力只有 0.7—4.8%

RoboMemArena (26 任务, > 1000 步, 68.9% 子任务依赖记忆)

方法	TSR	CSR
$\pi_{0.5}$ / MemoryVLA / MemER	21.5 / 15.0 / 27.3	38.7 / 35.3 / 49.1
PrediMem (Qwen3-VL-8B, 基准自带)	38.5	55.2
HyMeS (12 任务修正协议, 160 回合)	60.1 ($\pi_{0.5}$ 41.3)	66.2 (52.5)
Ground Truth (oracle)	46.1	64.8

HyMeS 的口号是全场最直接的立场：**技能在权重里，记忆在代码里**——低层技能模仿学，高层记忆管理由编码智能体从 rollout 反馈迭代。

HyMeS 与 PrediMem 的任务协议不同 (12 vs 26 任务)，表内数字不可跨行比较

真机上，瞬态视觉证据由端到端事件记忆拿走最高绝对成功率；延迟证据由轨迹寻址拿走

论文	平台 / 协议	无记忆基线	记忆方法	口径提醒
EventVLA	ARX ACONE 双臂，4 任务 × 20	$\pi_{0.5}$ 0—10%； π_{MEM} 50 / — / 30 / 40	90 / 60 / 90 / 75	π_{MEM} 为作者复现
KEMO	YAM 双臂，6 任务 × 12	$\pi_{0.5}$ 聚合 TSR 27.8；MemoryVLA 1.4	51.4 (SCR 42.3 → 76.4)	MemoryVLA 单相机、换骨干
UniMem	xArm6，4 任务 × 15	无记忆 5.0；MemER 43.5	80.0	四路相机 16 关键帧仅 +25 ms
Chronos	双 UR3 单 RGB，4 任务 × 50	$\pi_{0.5}$ 7% (记忆任务 0/150)	78% (记忆任务 108/150)	0.3B 参数
TRACE	双臂移动平台，5 任务 × 25	ACT 25.50 / DP 25.00 / $\pi_{0.5}$ 50.47	69.23 / 59.53	阶段进度，非成功率
MemER	Franka，3 任务 × 20	无历史错舀 61 次；32 帧长历史 12	错舀 1 次	计数错误数，越低越好
AGM	AgileX PiPER，每 N 10 次	$\pi_{0.5}$ PickXTimes 100/20/10/0/0 (N=1—5)	全部 100	冻结 $\pi_{0.5}$ + 2.43M 验证头
SAI	两台双臂移动机器人，4 任务 × 30	独立模仿 23—50%	53—70%	协作成功率；让步为事件级指标
AutoIntervene	双臂，7 任务 × 25	基线 30.9%；人判切换 68.6%	80.0%	两轮干预后；操作者时间 122.9 s vs 179.9 s

九个真机结果，九种口径：每行内可比，跨行不可比。

历史里绝大多数帧是冗余，值得写的只有状态转移的瞬间——五种触发器，一个结论

方法	触发器	证据
EventVLA	学习：KEM 头预测未来 50 步关键帧概率	RoboTwin-MeM 18.0 → 75.2
KEMO	规则：关节减速峰值 + DINOv2 去重 ($\epsilon = 0.05$) + 冷却	事件驱动选帧优于均匀采样与最近 K 帧
UniMem	事件分类器	93.4 vs 6 s 定间隔采样 68.2
WeaveLA	子目标完成事件	SwingXtimes N=3: 0 → 47.8, 单次任务不变
MemoryWAM	事件边界锚帧 + gist token	世界动作模型里的同构设计
TFP	液态时间常数信念，事件附近写入增益 $\approx 6\times$	机制分析而非显式触发

为什么这是 2026 年中的共识

2025 年的记忆 VLA 在比谁的窗口长、压缩得好 (CronusVLA、ContextVLA、MemoryVLA)。RoboMME 测得动作 token 对记忆 token 的平均注意力只有 0.7—4.8%，Present-but-Not-Remembered 测得历史独有信息 ≈ 0 。两条独立证据都说：堆帧堆进去的是重复。

仍未回答：哪种触发能跨任务迁移。EventVLA 靶 235B 标注、KEMO 逐任务手调窗口 (w 10—40、冷却 8—60)、UniMem 训分类器——没有对照实验 (研究机会 #2)。

原图还是 latent? 取决于下游要恢复多少比特: EventVLA 的 24.9 与 TRACE 的 69.23 不矛盾

高熵: 多个视觉细节

EventVLA 的任务要同时记 3—5 个物体的颜色、位置、顺序。把关键帧压成一个 latent 向量: **24.9**; 保留原图: **75.2**。UniMem 的密集空间记忆、NativeMEM 的逐帧 token 同属此类。

低熵: 一两个比特的分支变量

TRACE 的任务只需记"来自哪一侧""是哪本书"。512 维槽足够: **69.23**。TFP 的进度信念、RB-VLA 的紧凑信念 (32.5 → 77.5)、 μ VLA 的 m 个记忆 token (0.42 → 0.84) 都在这一档。

离散: 计数与过程

"按 3 次""跳过已完成子任务"目前符号状态最稳: AGM 的进度指针 (PickXTimes 100)、Notes-to-Self 的草稿板、HyMeS 的代码记忆; FM-VLA 用力历史记计数 (80%+) 是端到端的例外。

可操作的版本: 先估计下游决策要从过去恢复多少信息, 再选表征。RoboMME 的结论"记忆表征效果高度依赖任务"在这里有了机制解释。

寻址是被低估的一轴：写入时刻和读取时刻之间需要一个稳定的对应

寻址方式	代表	对应关系来自	失效条件
时间（拼接）	帧堆叠、EventVLA	顺序位置，注意力自找	历史长时虚假相关
内容相似	MemoryVLA、HALO	当前观测像什么	分岔点画面相同 ⇒ 检索不出分支
执行轨迹	TRACE	走过的路（签名，保序 ~90 / 倒序 37.8）	分支不对应运动差异
任务进度	Keyframe–Chaining、AGM	做到第几步	进度估计本身出错
LRU / 槽身份	ELMUR、MANN	最近使用 / 固定槽	容量与更新策略

TRACE 的边界

- 五个任务的来源都对应不同空间位置——舒适区；同轨迹、异线索（只差颜色）时签名地址重合（研究机会 #3）
- 签名维度随状态维度立方增长：17 维 → 5219，深度 4 → 88,740；高维人形需 log-signature（1785 维）或学习的低维键（#4）
- "只有签名"也能到 45.50：轨迹形状本身带一部分分支信息

分界线正在从"哪个更好"变成"哪类信息该放在哪一层"

双系统在计数与过程记忆上领先

- RoboMME: PonderPounce 60.83 (MLLM 原生上下文当记忆, p50 78 ms 刷新 / 25 ms 动作); AGM Counting 55.96、PickXTimes 100
- RoboMemArena: HyMeS 41.3 $\rightarrow$ 60.1; BATON 把子任务当探索单位, 成本 $T^K \rightarrow T \cdot K$
- MemER 的 Counting: 错舀 1 次 vs 32 帧长历史 12 次; 但加文本模态反而更差 (13)
- MEM: 视频短时 + 文本长时, 15 分钟级任务, 上下文自适应 +11 / +62 点

端到端的反驳与共同原则

- EventVLA: 双系统延迟高、误差沿层级传播; MemER 在 RoboTwin-MeM 10.5、Mem-0 0.0
- RoboMME 测得 MemER 计算量约 $\pi_{0.5}$ 的 5x; API 模型在线部署因 10–15 s 延迟全部失败 (MemER 附录)
- **共同原则**: 记忆写入应是带验证的事务——AGM 验证后推进 (核实写入 100 vs 按尝试写入 32)、BATON 验证器、EventVLA NMS + 冷却、TRACE 门控写入

开放问题: 符号状态的优势是表征性的还是只是验证机制带来的? 在 RoboMME Counting 上对照 AGM、EventVLA、FM-VLA、WeaveLA 可以回答 (研究机会 #12)。

记忆的成本正在趋近于零: "几乎免费"已是可达到的工程目标

方法	做法	开销
EventVLA	多帧原图进视觉编码器	2.91 → 0.94 Hz (仅锚帧已 1.07)
MemER	高层 VLM 在线推理	约 $\pi_{0.5}$ 的 5× (RoboMME 测)
TRACE	签名 + 槽更新 + 读出	+2.11 ms/步
UniMem	关键帧缓存	四路相机 16 帧仅 +25 ms
MemoryVLA	记忆库检索	+3.6% (0.187 → 0.194 s)
NativeMEM	VLA 自己的视觉编码器压每帧每视角为 1 token	近乎零
TempoFit	免训练, 复用中间层前缀 K/V	零新增 token / 参数
StreamPI / DySta	零参数流式注意力 / 静态 token KV 复用	DySta 2× 加速且涨点

含义

- EventVLA 的 3× 延迟会成为后继者首先优化的对象: 把事件帧经 NativeMEM 式 tokenizer 压成 1 token 是最直接的组合
- 免训练记忆没有在瞬态证据基准 (RoboTwin-MeM) 上测过; 若 n=1 持平、n=4 崩塌, 就给出"何时必须学习写入"的边界 (研究机会 #13)
- 成本表里没有 SAI: 它的成本在数据侧 (干预 $\approx 30\%$) 而非推理侧

多机器人是同一个问题的另一张脸：搭档相位是从历史推断的隐变量，却没有显式记忆

现有工作几乎都在解数据采集

工作	解什么	与记忆的关系
SAI	单遥操作者的三阶段课程	30 步 GRU 历史，提前松手 64.5 → 16.1
HATS	单人 + MLLM 智能体控四臂	—
Duet	人-人演示预训练 + 少量双机器人微调 (加速 5.4×)	—
Tri-Manual	三臂演示离线重排时序	—
AutoIntervene	何时把控制交还操作者	视觉-动作支持记忆；30.9 → 80.0%

与 TRACE 的同构，以及一个具体实验

把"早期线索"换成"对方刚才做了什么"，SAI 的设定就是 TRACE 的延迟证据设定。SAI 的历史只有约 1 秒，记不住 B 两分钟前做过什么。

MVE：在 Tablecloth 受控延迟实验上，把 A 的 GRU 换成签名槽记忆（键 = A 自己的轨迹，内容 = 对 B 的观测），把 B 的暂停从 2 秒拉到 30 秒，报告 Yield/Wait 随延迟时长的曲线（研究机会 #14）。

AutoIntervene 已经把 SAI 阶段三"何时干预"自动化（切换指标 1.00 vs LazyDagger 0.00 / RND-Dagger 0.90 误触发），下一步是同时纠正两台机器人。

六大趋势：触发、表征、寻址、路线、成本、评测

1 · 从"存多少"到"何时写"

2025 比窗口长度与压缩，2026 年中集体转向事件触发；写入触发成为一等设计变量。

2 · 表征按信息量分层

原图（多比特细节）、槽 / 信念（分支变量）、符号（计数与过程）三档并存，不再有"一种记忆通吃"。

3 · 寻址进入设计空间

时间、内容之外出现轨迹（TRACE）与进度（Keyframe-Chaining、AGM）寻址；诊断方法随之出现。

4 · 双系统与端到端分层共存

符号状态管计数与过程，端到端事件记忆管瞬态视觉证据；PonderPounce 在缩小双系统的延迟劣势。

5 · 成本归零

免训练（TempoFit）、零参数（StreamPI）、单 token（NativeMEM）三条路径合流。

6 · 评测分裂、诊断成熟

一年 12 套基准；顺序反转负对照、探针 + 因果干预、隐状态干预成为新的报告项。

洞见 1–5：触发、机理、比特、寻址、长上下文

1. 前沿从"存多少"转到"何时写"——EventVLA / KEMO / UniMem / WeaveLA / MemoryWAM / TFP 从不同架构同时转向事件驱动稀疏写入；TFP 测得事件附近写入增益 $\approx 6\times$ 。
2. 机理 (Present but Not Remembered) ——冻结 VLA 里的历史是当前帧的冗余副本 ($A_4 \approx 0$)，只在全黑遮挡下才被因果使用 $\Rightarrow$ 记忆增强应注入过去独有的信息。
3. 原图 vs latent 取决于要恢复多少比特——EventVLA 24.9 vs 75.2 (3–5 个视觉细节) 与 TRACE 69.23 (1–2 比特分支变量) 并不矛盾；计数用符号。
4. 寻址被低估——TRACE 让写入时刻与读取时刻有稳定对应 (保序 ~ 90 ，倒序 37.8)；分支若不对应运动差异则退化。
5. 长上下文没那么脆，但虚假相关是真的——Agarwal 等的系统扫描 vs PTP / GMP (+30.1) / HALO：能否用长窗口取决于监督是否把注意力引向任务相关历史。

洞见 6—10：纪律、分层、成本、多机器人、评测

6. 可靠性来自有纪律的状态更新，不是容量——AGM 核实后写入 100 vs 按尝试写入 32 (PickXTimes)；EventVLA NMS + 冷却、TRACE 门控写入、BATON 验证器是同一原则：记忆写入应是带验证的事务。
7. 双系统在计数与过程记忆上仍领先——RoboMME / RoboMemArena 榜首都是高层管状态的方案；分界线变成"哪类信息放哪一层"。
8. 记忆成本趋近于零——NativeMEM 每帧 1 token、TempoFit 免训练、StreamPI 零参数、DySta 2× 加速；EventVLA 的 3× 延迟会被后继者先优化。
9. 多机器人是同一问题的另一张脸——搭档相位 = 从历史推断的隐变量；SAI 只有 30 步 GRU，无人把显式记忆用于搭档状态估计。
10. 评测在分裂，诊断在成熟——一年 12 套基准，同一方法 (MemoryVLA) 在 RoboMME 附录 < 10%、RoboMemArena TSR 15.0、自报 SimplerEnv 71.9；并排任何数字前先查口径账本。

六条可证伪的预测：把判断写成可以被打脸的形式

#	预测	怎么证伪（截止 2027-09）
P1	至少一个主流开源 VLA 基座（ π 系 / GR00T / OpenVLA 后继）在默认配置里内置事件触发的稀疏记忆写入，而非固定间隔帧堆叠。	查发布配置与默认推理管线。
P2	RoboMME / RoboMemArena 的 Counting 与过程类子集上，端到端记忆方法追平双系统榜首（差距 < 5 点）。	若仍差 > 10 点，则符号状态优势是表征性的，而非验证机制带来的。
P3	EventVLA 类"存原图"方法的后继版本把推理开销压到基座 1.3 $\times$ 以内（与 NativeMEM / TempoFit 技术合流）。	查后继论文的吞吐表；仍 > 2 $\times$ 则原图记忆将被 token 化记忆取代。
P4	至少一篇工作把 TRACE 式诊断（顺序反转负对照）用于审计非自家的记忆方法。	若没有，诊断只是各论文的装饰。
P5	多机器人协作出现显式的搭档状态记忆模块，并报告 Yield/Wait 随受控延迟时长的曲线。	查 SAI / Duet / HATS 后继工作的实验设计。
P6	至少两套记忆基准采用统一报告模板（RoboMME 四类 $\times$ 中间事件数 $n \times$ 指标类型 $\times$ 试验数）。	查基准论文的结果表头。

预测的价值在于能被打脸；一年后回来逐条对账。

十四个没人占的位置，**每条配最小可行实验**——只做一件事就做第 1 条

A · 写入与寻址

- #1 前瞻写入 × 轨迹寻址：KEM 门控 TRACE 的写入，在 Book / Laundry 上测 2×/4× 历史一致性
- #2 写入触发的跨任务迁移：学习 / 规则 / 分类器同骨干对照，报告触发精确率与召回率
- #3 轨迹地址的可区分性边界：同轨迹、异线索任务
- #4 高维状态下的签名：log-signature vs 学习的低维键

B · 容量、纪律与安全

- #5 缓冲区饱和后的分层（n = 8、12 的按钮任务）
- #6 把"验证后才推进"搬进端到端记忆（回读撤销）
- #7 错误记忆的恢复：注入随机历史帧测容忍度
- #8 预测窗口与执行窗口解耦（50 / 10）

C · 评测与诊断

- #9 标准化记忆诊断：RoboMME 四类各配保序 / 破序变换
- #10 跨基准统一报告模板（账本雏形已在仓库）
- #11 RMBench 到底测了什么：只加初始帧 / 只加近 2 帧退化基线

D · 路线与成本

- #12 计数能否端到端：AGM vs EventVLA vs FM-VLA vs WeaveLA
- #13 免训练记忆的失效边界：TempoFit / StreamPI 上 RoboTwin-MeM

E · 多机器人

- #14 搭档相位的显式记忆：SAI × TRACE，延迟 2 → 30 秒曲线

并排任何两个数字之前先查这张表：67.8 与 73.6 不在同一个任务集上

数字	它其实是
EventVLA 67.8	RMBench 9 任务，仅锚帧，每任务 100 次
Chronos 73.6	RMBench 7 任务子集（其表中 Mem-0 为 50.8，非 42.0）
TRACE 69.23	阶段进度 %，非成功率；25 次/任务，Tool SE $\pm$ 17.96
MemER 1	Counting 任务的错舀次数（越低越好），20 trials
SAI 68.3 (Yield/Wait)	分母是事件数（60 个让步机会），不是独立试验
HyMeS 60.1	RoboMemArena 12 任务修正协议，160 回合；PrediMem 的 38.5 是 26 任务
MEM 主结果	只有柱状图，未给精确数值；EventVLA 里的 π _MEM 是复现

四个最常踩的坑

1. 任务集不同：RMBench 9 vs 7 任务；RoboMemArena 26 vs 12。
2. 指标类型不同：成功率 / 阶段进度 / 错误次数 / TSR 与 CSR。
3. 基线是谁跑的：MemoryVLA 在 EventVLA 表里 41.7（作者复现）、KEMO 表里 1.4%（单相机换骨干）、RoboMME 附录 < 10%、RoboMemArena 15.0（基准方实现）、自报 SimplerEnv 71.9——同一方法五个数字，五种口径。
4. 图内数字与文字数字：只在图里的数字标"图"，引用时不补数。

三篇论文教给我们的三件事：单变量对照、报告代价、用诊断代替猜测

把一个默认做法拆开单独测

EventVLA 只换记忆表征（原图 vs latent：75.2 vs 24.9）；TRACE 只换寻址（有无签名路由：69.23 vs 52.17）；SAI 只换数据课程（架构固定：独立 vs 搭档条件 vs SAI）。说服力来自单变量对照。

报告代价

EventVLA 报延迟（0.94 Hz），TRACE 报每步毫秒与参数增量（+24.6% / +10.3%），SAI 报干预数据占比（30%）。读者能判断收益是否值得。

用诊断替代猜测

TRACE 的顺序反转负对照把"记忆在用历史"从假设变成可测量；Liao & Cao 的探针 + 因果干预回答"历史是不是当前帧的副本"；AGM 的表 10（核实写入 100 vs 按尝试写入 32）把"纪律"量化。

三句话带走：记忆的四问比"要不要记忆"重要（记什么 / 何时写 / 写到哪 / 存多少）；表征跟信息量走；用诊断代替猜测。

本调研仓库：103 项工作 · 17 篇原文 + 中译 · 17 份全文深读 · 十个家族

想要	打开
15 分钟拿到全部结论	<code>report/survey_slides.html</code> · <code>.pdf</code> (本 PPT)
系统研读	<code>report/survey_full_report.pdf</code> (趋势 + 三篇深读 + 矩阵 + 103 篇解读按家族合订)
三篇主角的深读 (中/英)	<code>reports/01-03*_{cn,en}.md</code> + <code>reports/pdf/</code>
趋势与洞见 (中/英)	<code>reports/04_trends_insights_{cn,en}.md</code>
研究机会 / 口径账本 / 设计矩阵	<code>insights/OPEN_PROBLEMS.md</code> · <code>NUMBERS_LEDGER.md</code> · <code>DESIGN_SPACE_MATRIX</code>
原文与中译	<code>papers/pdf/</code> · <code>papers/zh/</code> (QA 见 <code>QA_REPORT.md</code>)
全部解读	<code>notes/</code> (14 篇全文手写 + 89 篇摘要笔记)

复现

`build_manifest.py` → `make_notes.py` → `make_bib.py` →
`make_readme.py` → `make_figures.py` → `build_pdfs.py`
翻译: `translate_core.sh` <KEY> (SuperTranslate + DeepSeek);
`launch_detached.py` 批量; `apply_zh_patches.py` 版式补丁;
`make_zh_qa.py` QA 汇总

工具致谢

`super_translate` (翻译) · `ppt-master` (PPT 叙事模式参考) · `anti-defensive-writing` / `shuorenhua` (写作约束) · `beamer-skill` (Beamer 讲稿版 `slides/`) · 列表规范参考 `awesome-ml4co`

Thank you

证据消失之后，策略靠什么行动

EventVLA (2606.20092) · TRACE (2606.14551) · SAI (2606.16490)

Present but Not Remembered (2607.03372) · RoboMME (2603.04639) · AGM (2608.29537) · Chronos (2606.30318) · KEMO (2606.23589)

所有数字只取自原文；不同论文的数字建立在各自的任务集与判定口径上，不可直接比大小。