

记忆 VLA 的趋势与洞见：读完三篇核心论文和 97 篇周边工作之后

本报告是 awesome_memory_vla 的综合判断部分。三篇核心论文的逐篇深读见 [EventVLA](#)、[TRACE](#)、[SAI](#)；全部 103 篇条目见 [README](#)。所有数字只取自原文或摘要，不同论文的数字建立在各自的任务集和判定口径上，不能直接比大小。

1. 这个领域正在发生什么

1.1 时间线：2026 年 6–8 月的爆发

按提交月份统计仓库里 97 篇非背景文献：2025 年全年 24 篇，2026 年 1–5 月 23 篇，**2026 年 6 月 20 篇、7 月 10 篇、8 月 17 篇**。三篇核心论文全部出自 6 月中旬（TRACE 6 月 12 日、SAI 6 月 15 日、EventVLA 6 月 18 日），和 KEMO（6 月 22 日）、 μ VLA（6 月 10 日）、MemoryWAM（6 月 18 日）、WeaveLA（6 月 16 日）、PRISM/ReMemBench（6 月 15 日）、长上下文扩散策略研究（6 月 15 日）挤在同一个月。这不是巧合：RMBench（3 月 1 日）、RoboMME（3 月 4 日）、RoboMemArena（5 月 11 日）三个记忆基准在春天相继落地，给了方法论文一个能对齐比较的靶子，夏天的论文就是对这些靶子的第一轮回应。

1.2 一个共同的出发点

几乎每篇论文的第一段都在说同一件事：VLA 是马尔可夫的（ $a_t = \pi(o_t, l)$ ），而操作任务不是。差别在于各家对“为什么不是”的诊断，这决定了他们的记忆设计：

诊断	典型表述	代表工作	记忆设计倾向
证据消失	掀盖看一眼就盖上；线索出现后离开视野	EventVLA、TRACE、KEMO、UniMem	稀疏、显式、可寻址
状态混叠	视觉相同的状态对应不同阶段（第 2 次和第 3 次按按钮）	KEMO、TFP、ChainVLA、WeaveLA、CAMP	任务进度信念、事件计数
空间遗忘	单腕部相机看不到离开视野的物体	AtlasVLA、AnchorVLA4D、SAM2Act+	持久空间状态、初始锚帧
搭档不可观	对方处于哪个阶段只能从历史推	SAI、Duet	历史 token + 训练分布覆盖
缺乏进度追踪	冻结 VLA 开环执行动作块，不知道自己做到哪了	AGM、HELM、BATON、HyMeS	外部符号状态 + 验证器

1.3 五个技术家族

把 97 篇按“记忆放在哪、以什么形式存在”分成五类（README 的第 3–7 节）：

- 事件 / 关键帧记忆（EventVLA、KEMO、Keyframe-Chaining、UniMem、WeaveLA、Bi-HIL、MemoryWAM 的锚帧层、MemER 的高层选帧）：只在“发生了什么”的时刻写，存的是原图或原图的

token。

- 2. 稠密压缩历史 (MemoryVLA / MemoryVLA++、ContextVLA、CronusVLA、HAMLET、NativeMEM、StreamPI、TempoFit、DySta、FibVLA、PRISM、HALO、LaMem-VLA、Remember Smarter)：每帧都进，靠压缩、token 化、KV 复用或采样控制成本。
- 3. latent 状态 / 循环 / 槽记忆 (TRACE、 μ VLA、VPWEM、VQ-Memory、MemoAct、RB-VLA、MTIL、DSSP、Chronos、TFP、CAMP、GMP、ELMUR、AEM、FM-VLA)：历史被压成固定大小的向量或槽，随时间递归更新。
- 4. 双系统 / 智能体 / 符号记忆 (MEM、MemER、MAP-VLA、Notes-to-Self、显式语言记忆、CodeGraphVLP、HyMeS、HELM、Harness VLA、AGM、PonderPounce、BATON、OnEvoMemory、ChainVLA)：高层用 VLM / LLM / 代码维护文本、图或进度指针，低层 VLA 执行。
- 5. 世界模型内的记忆 (MemoryWAM、MemoryVAM、TriVLA、MemoryVLA++ 的想象分支)：记忆服务于预测未来，再由预测服务于动作。

第六个方向——多机器人的搭档记忆 (SAI、HATS、Duet、Tri-Manual、AutoIntervene) ——目前只有零星工作，但它和前五类共享同一个数学问题。

2. 设计空间：六个必须回答的问题

任何记忆 VLA 都要回答下面六个问题。把三篇核心论文和代表性周边工作填进去，能看清各自站在哪里：

问题	EventVLA	TRACE	SAI	其他典型答案
存什么 (内容)	原始图像帧	视觉+状态的 512 维 latent	GRU 隐 状态	单 token/帧 (NativeMEM)、K/V (TempoFit)、文本 (MEM、Notes-to-Self)、语义图 (CodeGraphVLP)、力序列 (FM-VLA)、体素状态 (AtlasVLA)
何时写 (触发)	学到的未来关键帧概 率 + NMS + 冷却	每步写，门 控决定写多 少	每步	运动学+视觉规则 (KEMO)、事件分类器 (UniMem)、子 目标完成 (WeaveLA)、物理验证后才推进 (AGM)、价值 引导 (OnEvoMemory)
写到哪 / 从哪读 (寻址)	时间顺序拼接，注意 力自找	机器人轨迹 的路径签名	无 (单 向量)	内容相似度 (MemoryVLA、HALO)、进度感知查询 (Keyframe-Chaining)、轨迹相似度检索演示 (MAP- VLA)、LRU (ELMUR)
存多少 (容量)	5 帧 + 3-4 锚帧	K = 4/6 槽	30 步	固定 token 数 (VPWEM、 μ VLA 的 m 个记忆 token)、随 历史线性增长 (帧堆叠、StreamPI)、文本无界 (MEM)
接在哪 (集成点)	VLM 视觉编码器输入	动作头前的 适配器	解码器 输入	动作专家的条件 (TFP、WeaveLA、FM-VLA)、KV 缓存 (TempoFit)、提示 (MAP-VLA、PonderPounce)
靠什么学 (监督)	Qwen3-VL 自动关键 帧标签 + 软标签 + 师 生课程	无标签，三 项稳定器	数据课 程 + 干 预	时间对比 (HAMLET)、过去 token 预测 (PTP)、VQA 蒸 馏 (HALO)、TBPTT (μ VLA)、只靠模仿损失 (多数)

读表的方式：两个极端已经被同一个月的两篇论文占住——EventVLA 在”何时写”上下最重的注，TRACE 在”从哪读”上下最重的注。中间地带（既学写入时机、又学寻址）还是空的。

3. 跨基准的证据

三个 2026 年基准上目前公开的数字（各自口径，按论文自报）：

RM Bench（9 任务，RoboTwin 2.0）

方法	平均	备注
$\pi_{0.5}$ （无记忆）	10.4–11.2	EventVLA 与 Chronos 各自报告
MemoryVLA (QwenOFT)	41.7	EventVLA 复现
Mem-0（RM Bench 自带模块化策略）	42.0	
ChainVLA	62.8	1.2B，去掉 Motion Tail 掉到 11.2，去掉 Progress Context 掉到 3.0
EventVLA（仅锚帧）	67.8	未启用 KEM
Chronos	73.6	参数量比 $\pi_{0.5}$ 少 10 倍，比 Mem-0 少 30 倍

RoboMME（16 任务，时间 / 空间 / 物体 / 过程记忆， $\pi_{0.5}$ 骨干）

方法	数字
$\pi_{0.5}$ 当前观测	17.93
FrameSamp+Modul（RoboMME 自带最强变体）	44.51（9× 数据时 57.88）
PonderPounce 0.8B / 9B	50.04 / 60.83（9× 数据时 75.54）
WeaveLA	最难重复切片 SwingXtimes N=3 从 0% 到 47.8%，单次执行任务不变
AGM	Counting 子集上超过最强记忆基线（PickXTimes、BinFill）

RoboMemArena（26 任务，平均 >1000 步，68.9% 子任务依赖记忆）

方法	累计成功 / 任务成功
$\pi_{0.5}$	52.5 / 41.3
PrediMem（基准自带双系统）	比 HyMeS 低 4.5 / 14.5
HyMeS（技能在权重、记忆在代码）	66.2 / 60.1
BATON	相对 SoTA +14.9 / +11.6

MIKASA-Robo（32 任务，RL 出身）

方法	数字
MemoryVLA	41.2（比 CogACT/ π_0 +11.8）
VPWEM	比扩散策略与 VLA 高 20% 以上
μ VLA（最小循环记忆）	五个训练任务 0.42 → 0.84，留出任务 0.07 → 0.23
ELMUR	23 个任务里 21 个最好，聚合成功率比此前最好高约 70%

真机延迟证据 / 瞬态证据

论文	数字
EventVLA (ARX ACONE, 4 任务 × 20)	90 / 60 / 90 / 75 vs π_MEM 50 / - / 30 / 40
TRACE (5 任务 × 25)	ACT 25.50 → 69.23, DP 25.00 → 59.53, $\pi_{0.5}$ 50.47
KEMO (双臂, 830–2846 步)	任务成功 +23.6, 阶段完成 +34.1 (相对 $\pi_{0.5}$)
NativeMEM	仿真 32.4 → 84.0, 真机最高 98.7, 20% 数据即可竞争
UniMem	仿真 93.4 vs 固定间隔采样 68.2; 真机 80.0 vs 分层基线 43.5
Chronos (单 RGB 双臂)	4 任务 78%, 记忆依赖子集 72%, $\pi_{0.5}$ 为 7% / 0%

三个观察：第一，RMBench 上”只用初始帧 + 近期帧”已经能到 67.8%，说明这套基准的记忆需求偏浅，Chronos 的 73.6% 也是靠全历史 SSM 而非显式事件记忆拿到的；第二，RoboMME 和 RoboMemArena 上领先的都是双系统 / 智能体方案（PonderPounce、HyMeS、BATON），说明当任务需要计数和过程记忆时，符号化的进度状态目前比端到端 latent 更可靠；第三，真机瞬态证据任务上端到端事件记忆（EventVLA、KEMO、UniMem）的绝对成功率最高。没有一种记忆在所有基准上领先——RoboMME 论文的结论”记忆表征的效果高度依赖任务”被后续一整年的结果反复印证。

4. 十个洞见

洞见 1：前沿从”存多少”转到了”何时写”

2025 年的记忆 VLA 在比谁的窗口长、压缩得好（CronusVLA、ContextVLA、MemoryVLA）。2026 年中的论文几乎同时转向写入时机：EventVLA 学未来关键帧概率，KEMO 用运动学 + 视觉变化检测事件，UniMem 训练事件分类器，WeaveLA 在子目标完成时触发，MemoryWAM 用事件边界锚帧，TFP 的机制分析发现记忆写入增益在操作事件附近比非事件阶段大约 6 倍，OnEvoMemory 从 rollout 结果学该留什么。这些工作从不同架构出发，落到同一个结论：历史里绝大多数帧是当前帧的冗余，值得写的只有状态转移的瞬间。

洞见 2：”Present but Not Remembered”给出了机理解释

Liao & Cao 用逐层线性探针和因果交换干预审计三个冻结 VLA，发现：过去帧内容在全网络都可线性解码，但只属于历史、当前帧没有的信息几乎不存在——存下来的历史基本是现在的副本；历史只有在当前帧严重退化时才被因果地使用。这解释了为什么帧堆叠收益不稳定（ContextVLA 的出发点），也解释了为什么稀疏事件帧有效：事件帧携带的正是当前帧没有的信息。它给记忆增强定了一条设计准则：注入只属于过去的信息，而不是更多的历史。TRACE 的签名增量 δ_t 、CAMP 的动作历史压缩、PTP 的过去 token 预测都可以读成这条准则的实例。

洞见 3：原图还是 latent，取决于要恢复多少比特

EventVLA 的隐式记忆库消融（24.9% vs 75.2%）和 TRACE 的 512 维槽（69.23%）看起来矛盾，其实测的是两类信息。EventVLA 的任务要同时记 3–5 个物体的颜色、位置、顺序——高熵、需要空间细节；TRACE 的任务要记的是”来自哪一侧””是哪本书”——两个比特的分支变量。RoboMME 的结论（表征效果依任务而异）在这里有了可操作的版本：先估计下游决策需要从过去恢复多少信息，再选表征。需要细节的用原图或

密集 token (EventVLA、NativeMEM、UniMem 的密集空间记忆)，需要分支变量的用槽或信念 (TRACE、TFP、RB-VLA)，需要计数的用符号 (AGM 的进度指针、Notes-to-Self 的草稿板)。

洞见 4：寻址是被低估的一轴

多数工作默认“按时间拼接、让注意力自己找”。TRACE 是少数把寻址当一等问题的：轨迹签名做键，保序变换下路由相似度 ~90、倒序 37.8。Keyframe-Chaining 的进度感知查询、MAP-VLA 的轨迹相似度检索、ELMUR 的 LRU 槽是另外三种寻址。寻址的价值在于写入时刻和读取时刻之间有一个稳定的对应关系——TRACE 用的是“走过的路”，进度感知方法用的是“做到第几步”。当任务的分支结构和机器人运动不对应时（线索只是颜色差异、动作完全相同），轨迹寻址会退化，这是下一步要解决的边界。

洞见 5：长上下文没那么脆，但虚假相关是真的

Agarwal 等（长上下文扩散策略）系统扫了上下文长度，结论是“naive 加长没文献说的那么脆”，用 UNet + 交叉注意力在常规数据量下多数任务能拿高成功率。但另一条证据链同样扎实：PTP 指出扩散策略会忽略过去-未来动作依赖 (copycat 的反面)，GMP 发现直接加长历史会因分布偏移和过拟合显著掉点 (MemMimic 上门控记忆比长历史基线 +30.1)，HALO 需要 VLM 先验蒸馏和稀疏注意力来压虚假相关。两者的调和：长上下文能不能用，取决于监督是否把注意力引向任务相关的历史。EventVLA 的软标签 + 师生课程、TRACE 的平衡 / 熵 / 一致性损失、 μ VLA 的 TBPTT 都是在做这件事。

洞见 6：记忆的可靠性来自“有纪律的状态更新”，不是容量

AGM 的核心论断是：外部记忆如果把“尝试过”当成“完成了”，局部执行错误会变成持久的任务状态错误，所以进度指针只在物理证据验证子目标后才推进。同样的纪律出现在 EventVLA 的 NMS + 冷却（防止同一事件灌满缓冲区）、TRACE 的门控写入（未被路由到的槽几乎不动）、BATON 的验证器智能体（腕部相机确认场景就位才调用 VLA）、HELM 的状态验证器（执行前预测失败）。记忆写入应当是一个带验证的事务，这一原则在端到端和智能体两条路线上同时被独立发现。

洞见 7：双系统在计数与过程记忆上仍然领先

RoboMME 和 RoboMemArena 的榜首 (PonderPounce、HyMeS、BATON) 都是“高层管状态、低层 VLA 执行”。HyMeS 的表述最直接：“技能在权重里，记忆在代码里”——低层技能靠模仿学，高层记忆管理靠编码智能体从 rollout 反馈里迭代启发式。EventVLA 对双系统的批评（延迟高、误差传播）在瞬态视觉证据任务上成立，但在“按 3 次、跳过已完成的子任务”这类离散过程记忆上，符号状态目前更稳。PonderPounce 用 MLLM 的原生因果上下文当记忆、异步只传最新的认知 token (p50 78 ms 刷新、25 ms 动作)，是在缩小双系统的延迟劣势。端到端与双系统的分界线正在从“哪个更好”变成“哪类信息该放在哪一层”。

洞见 8：记忆的成本正在趋近于零

EventVLA 的多帧输入把吞吐从 2.91 Hz 压到 0.94 Hz，是这批论文里最贵的；同期的工作在往另一头走：TRACE 每步 +2.1 ms；NativeMEM 用 VLA 自己的视觉编码器把每帧每视角压成 1 个 token；TempoFit 完全不训练、不加 token，只复用中间层的前缀 K/V；StreamPI 不加任何参数，靠指令锚定的因果注意力和长度外

推做流式多帧；DySta 只保留一份静态 token 并复用其 KV 缓存，推理快 2 倍还涨点。“记忆几乎免费”已经成为可以达到的工程目标，EventVLA 的三倍延迟会在后续版本里成为首要优化对象。

洞见 9：多机器人是同一个问题的另一张脸

SAI 把“搭档看不全”处理成数据课程问题，但论文自己的消融显示历史 token 是执行可靠性的关键（提前松手 64.5% → 16.1%）。把搭档相位当成一个从历史推断的隐变量，SAI 与 TRACE 的延迟证据设定是同构的——只是“早期线索”换成了“对方刚才做了什么”。目前多机器人工作几乎都在解数据采集（HATS 单人 + 智能体控四臂，Duet 人-人演示预训练，Tri-Manual 离线重排时序），还没有人把显式记忆模块用在搭档状态估计上。这是一个明确的空白。

洞见 10：评测在分裂，诊断在成熟

一年之内出现了 RMBench、RoboMME、RoboMemArena、RoboTwin-MeM、ReMemBench、LIBERO-Mem、MemMimic、MemoryRTBench、RuleSafe、Memory-T-Bench、MemoryBench、LongBench 至少 12 套记忆相关基准，各自的任务集和口径不同，跨论文的数字无法比较（第 3 节的表只能按基准分块）。同时，**诊断方法**在成熟：TRACE 的路由相似度 / 分支一致性 + 顺序反转负对照，Present-but-Not-Remembered 的探针 + 因果干预，TFP 的隐状态干预，LongBench 把长时程失败拆成执行鲁棒性和上下文依赖两个机制。下一阶段的评测应当同时报告“成功率”和“记忆到底用了什么”。

5. 开放问题

1. **缓冲区饱和**：EventVLA 的 5 帧 FIFO 在 >10 分钟、事件密集的任务上会挤掉早期证据；TRACE 的固定槽在 2× 历史下一致性降到 0.928。分层（近期 / 事件 / gist，如 MemoryWAM）是目前的折中，还没有在同一基准上和平面记忆正面比过。
2. **寻址的可区分性**：轨迹签名要求分支对应不同的运动；签名维度随状态维度立方增长（17 维 → 5219，深度 4 → 88740）。高维人形 / 灵巧手需要 log-signature 或学习的低维轨迹键。
3. **写入触发的监督来源**：EventVLA 靠 235B 模型离线标注，KEMO 靠规则，UniMem 靠分类器，OnEvoMemory 靠 rollout 结果。哪一种能跨任务泛化，尚无对照。
4. **记忆与动作块长度的耦合**：EventVLA 的前瞻能力随动作块从 50 缩到 15 而崩塌（75.2 → 13.6）；WhyChunking 指出动作块的好处之一正是非马尔可夫表达力。记忆机制与块长度应当联合设计。
5. **错误记忆的安全性**：AGM 指出未经验证的记忆会把局部错误固化；EventVLA 若把错误帧写入缓冲区如何恢复，论文没有讨论。
6. **多机器人的显式记忆**：见洞见 9。
7. **基准统一**：RoboMME 的四类记忆（时间 / 空间 / 物体 / 过程）+ RoboTwin-MeM 的 n 参数化 + TRACE 的阶段进度指标，可以拼成一个共同的报告模板。

6. 三篇论文教给我们的方法论

- 把一个默认做法拆开单独测。EventVLA 只换记忆表征（原图 vs latent）；TRACE 只换寻址（有无签名路由、有无增量）；SAI 只换数据课程（架构固定）。三篇论文的说服力都来自这种单变量对照。

- **报告代价。**EventVLA 报延迟 (0.94 Hz), TRACE 报每步毫秒和参数增量, SAI 报干预数据量占比 (30%)。这让读者能判断收益是否值得。
- **用诊断替代猜测。**TRACE 的顺序反转负对照是最值得推广的一个设计: 它把”记忆在用历史”从假设变成可测量。

7. 我们的下一步 (研究方向建议)

1. **前瞻写入 × 轨迹寻址:** 把 EventVLA 的 KEM 头作为写入触发、TRACE 的签名作为槽地址, 检验能否在 RoboTwin-MeM (高熵视觉证据) 和 TRACE 任务 (低熵分支变量) 上同时保持性能。假设: 稀疏写入解决容量, 轨迹寻址解决读写对齐。
2. **搭档相位记忆:** 在 SAI 的两机器人设定上, 把 A 的 30 步 GRU 换成 TRACE 式签名槽记忆 (键 = A 自己的轨迹, 内容 = 对 B 的观测), 测 Yield/Wait 是否随 B 的延迟长度保持稳定。
3. **记忆诊断基准:** 给 RoboMME 四类任务各配一组保序 / 破序历史变换, 把路由相似度 / 分支一致性变成所有记忆 VLA 的标准报告项。
4. **写入触发的跨任务迁移:** 在同一骨干上对照 EventVLA (学习触发)、KEMO (规则触发)、UniMem (分类器触发) 三种写入策略在未见任务上的迁移, 回答”写入时机是任务特定的还是通用的”。